SEMANA 7 · CÓMPUTO EN LA NUBE: INSTANCIAS VIRTUALES, TIPOS, ESCALADO

La instancia virtual

Parte 1 de 3 · Unidad 2

Ing. Rodolfo Cañas Cervantes
Universidad de la Costa (CUC) · Ingeniería de Sistemas
Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

La instancia virtual: del hardware compartido al servidor por API

ENCUADRE

El tercer pilar de la arquitectura

Almacenamiento y red ya están construidos; hoy entra en escena el recurso que ejecuta la aplicación.

SEMANA 3 · DATOS



Almacenamiento

objetos · bloques · archivos

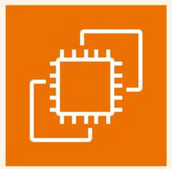
SEMANA 4 · TRANSPORTE



Red

subredes · rutas · firewall

SEMANA 7 · EJECUCIÓN



Cómputo

instancias · tallas · precio

los tres pilares se necesitan entre sí: el laboratorio de esta semana toca los tres

CASO: Corporación Industrial del Caribe (Barranquilla) — aplicación de pedidos de planta



Planta
operarios

RED · VPC 10.0.0.0/16

Subred pública 10.0.1.0/24



Instancia web
CÓMPUTO



Volumen EBS
DATOS



Bucket S3
reportes · DATOS



Internet Gateway

Un solo pedido
usa los tres pilares:
llega por la red,
corre en cómputo
y guarda en datos.

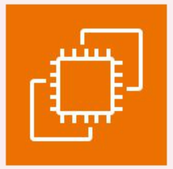
Adaptado de AWS — documentación de Amazon EC2 y Amazon VPC · íconos AWS Architecture Icons

RUTA DE LA SEMANA

Tres partes, cuatro preguntas de ingeniería

Cada parte responde una pregunta concreta; juntas forman el criterio para decidir cómputo en cualquier nube pública.

1 Parte 1



La instancia virtual

¿Qué es y cómo nace una máquina en la nube?

- Hipervisor y aislamiento
- Imagen (AMI)
- Discos, red e identidad

2 Parte 2



Ciclo de vida y tallas

¿Cómo se administra y de qué tamaño?

- Estados y transiciones
- Familias de instancia
- Créditos de ráfaga

3 Parte 3



Modelos de precio

¿Cuánto cuesta y cómo pagar menos?

- Bajo demanda · compromiso
- Spot e interrupciones
- Presupuestos y etiquetas

4 Parte 4



Escalado y laboratorio

¿Cómo crece el sistema con la demanda?

- Vertical y horizontal
- Sin estado + balanceador
- Laboratorio de cafetería

Hilo conductor: cada decisión de cómputo se evalúa con tres criterios

AISLAMIENTO
la frontera que protege tu carga
Parte 1

COSTO
pagar solo lo que se necesita
Partes 2 y 3

CAPACIDAD DE CRECER
seguir en pie cuando sube la demanda
Parte 4

Meta: Al final de la hora sabrás elegir, comprar y hacer crecer un servidor virtual sin adivinar.

DEFINICIÓN

Anatomía de una instancia virtual

Una máquina de software con los mismos componentes de un servidor: procesador, memoria, disco y red.



Imagen (AMI)
de aquí nace

INSTANCIA VIRTUAL (ejemplo t3.small): lo que ve el sistema operativo

2	2 GiB	8 GiB	10.0.1.25
vCPU	**Memoria RAM**	**Disco raíz**	**Red virtual**
tiempo de procesador asignado	dedicada a esta máquina	volumen de bloques EBS	IP privada + grupo de seguridad
CPU	RAM	EBS	vNIC

asigna y aísla

Hipervisor (en AWS: sistema Nitro)
reparte el hardware físico entre muchas instancias sin que se vean entre sí

Un mismo equipo físico aloja muchas instancias



Servidor físico del proveedor (host)
en un centro de datos; se comparte entre varios clientes

Idea: la instancia no es una caja: es una asignación de software sobre hardware compartido.

Adaptado de AWS — Amazon EC2 instance types y Nitro System (docs.aws.amazon.com)

CÓMO FUNCIONA

El hipervisor: la capa que multiplica el hardware

Software que particiona un servidor físico en muchas máquinas aisladas, cada una con su propio sistema operativo.

TIPO 1 — nativo (centros de datos)



aislamiento fuerte · rendimiento casi nativo

TIPO 2 — hospedado (escritorio)



cómodo para desarrollo · una capa más, menor aislamiento

¿QUÉ USA CADA NUBE?

- **AWS: Nitro** — hipervisor ligero basado en KVM
- **Azure: Hyper-V** — el hipervisor de Microsoft
- **Google Cloud: KVM** — kernel Linux como hipervisor
- **OpenStack: Nova** — orquesta KVM u otros

Todos son tipo 1: la capa que multiplica el hardware vive en el servidor del proveedor

El laboratorio del curso corre sobre ese hipervisor: tú pides la instancia, la frontera no la administras.

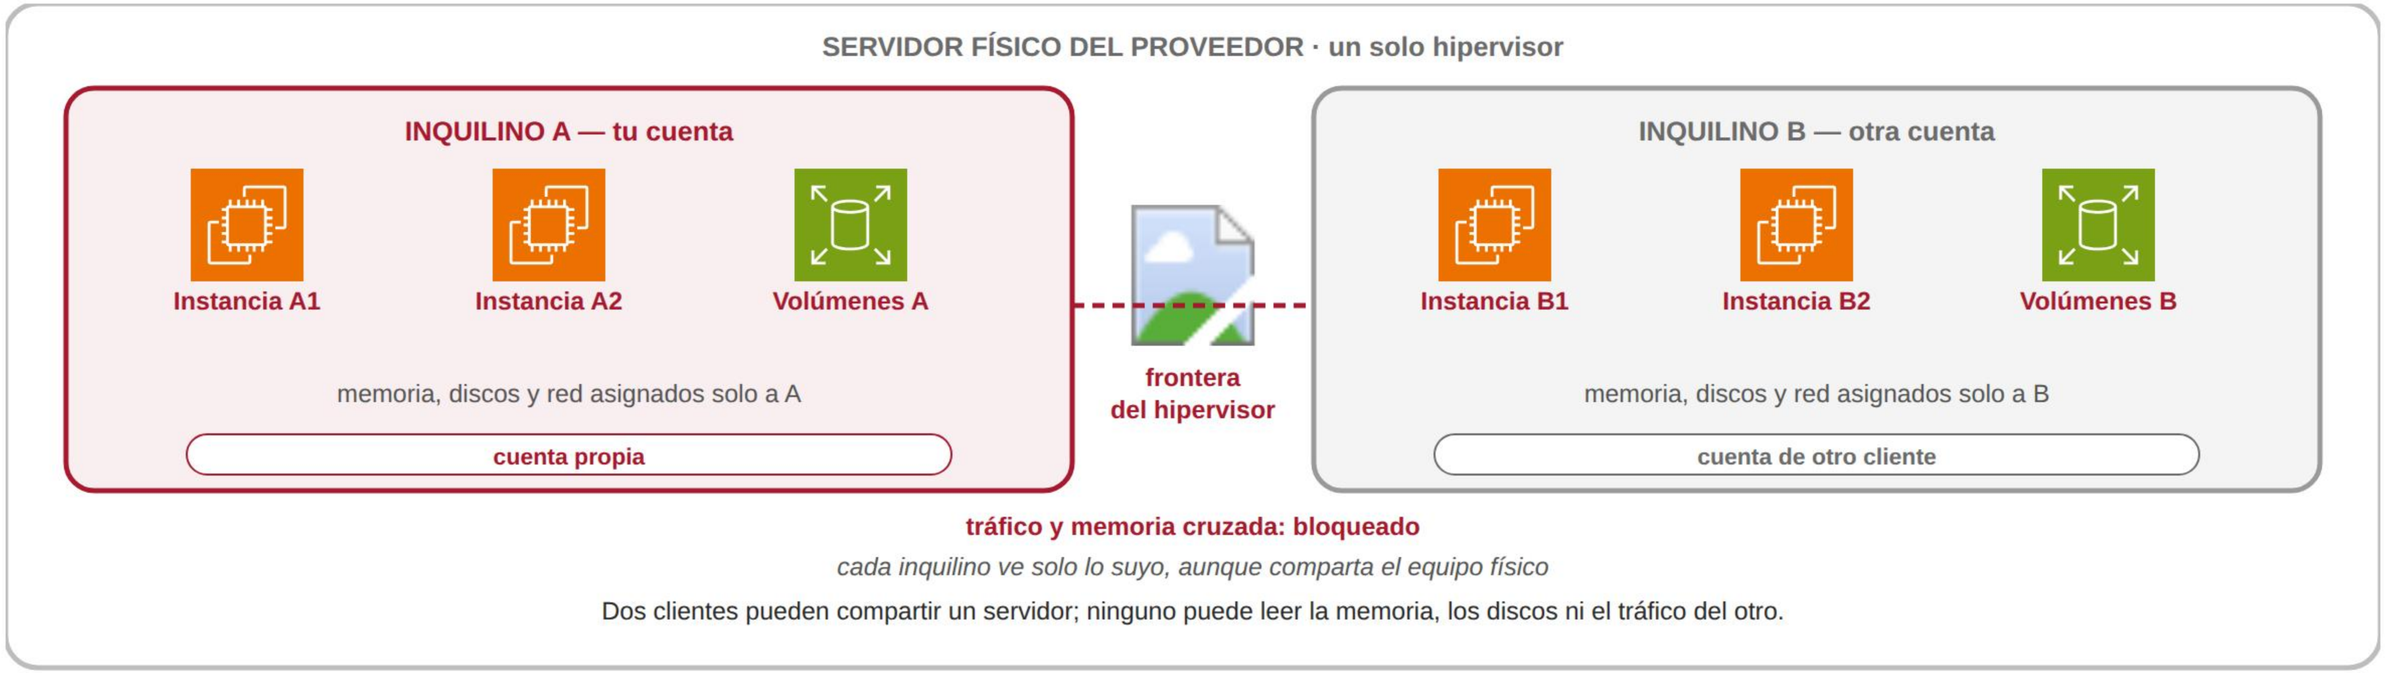
La nube pública usa tipo 1; el tipo 2 es para tu portátil (VirtualBox, VMware Workstation).

Multi-nube: misma idea en todas las nubes; solo cambia el nombre del hipervisor.

Adaptado de Microsoft Learn (virtualización) y AWS Nitro System · íconos de cada proveedor

Aislamiento: dos clientes, un mismo servidor

La frontera que impide que una instancia vea la memoria, los discos o el tráfico de otra.



FRONTERA ENTRE INQUILINOS — la garantiza el proveedor

hipervisor, memoria, discos y red virtual aislados.

Parte de la responsabilidad "de" la nube.

FRONTERAS DENTRO DE TU CUENTA — las diseñas tú

grupos de seguridad, subredes y roles de acceso.

Parte de la responsabilidad "en" la nube (semana 5).

Regla: el aislamiento entre clientes es del proveedor; el aislamiento entre tus propias cargas es tuyo.

COMPARACIÓN

Del servidor físico a la instancia

Lo que cambia no es la potencia: es el tiempo de provisión, el modelo de costo y la capacidad de crecer.

TIEMPO HASTA TENER EL PRIMER SERVIDOR ÚTIL (escala ilustrativa)



CAPITAL Y COSTO

Servidor físico
Inversión inicial y depreciación a varios años

Instancia virtual
Gasto operativo por uso: se paga por segundo

CAPACIDAD

Servidor físico
Fija hasta la siguiente compra; el repuesto queda ocioso

Instancia virtual
Cambia de talla en minutos; la redundancia es asequible

CORREGIR UN ERROR

Servidor físico
Se corrige con dinero y tiempo

Instancia virtual
Se corrige en minutos: se termina y se crea otra

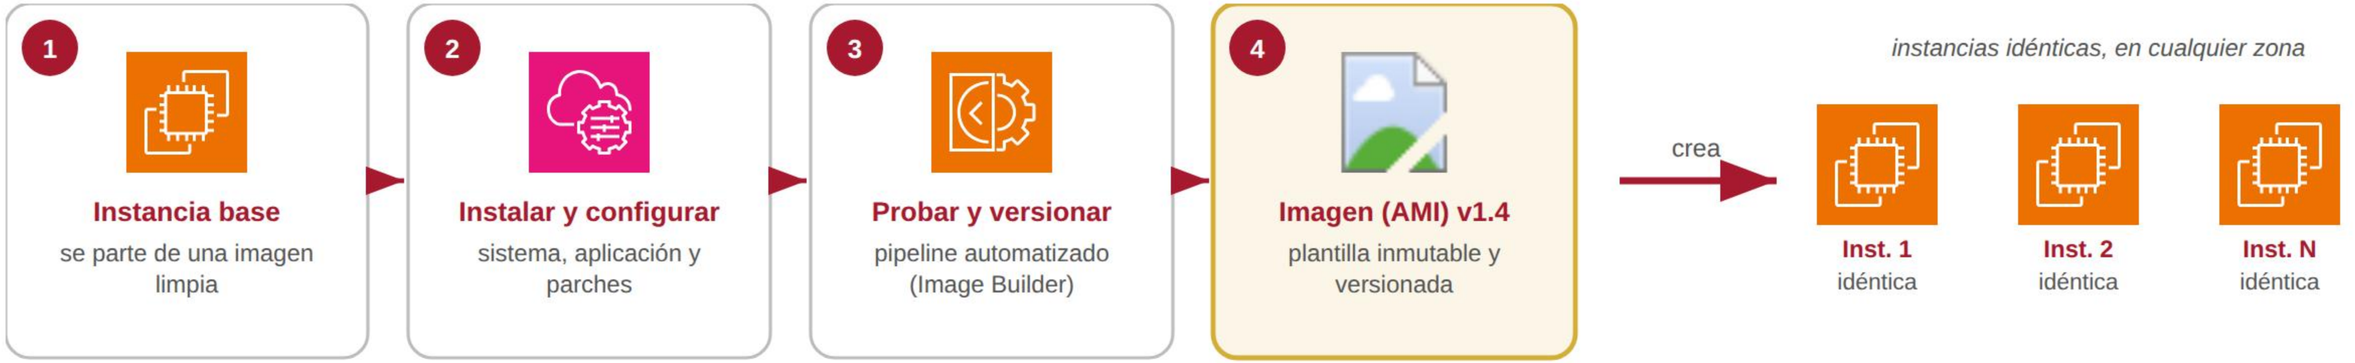
Consecuencia: el dimensionamiento deja de ser una apuesta a varios años y se vuelve una decisión reversible.

Adaptado de AWS Well-Architected (pilar de costos) y documentación de Amazon EC2 · tiempos ilustrativos

PLANTILLA

La imagen de máquina: la plantilla inmutable

Una plantilla versionada con sistema operativo, aplicaciones y configuración con la que se crean instancias idénticas.



user data: lo único que cambia en el primer arranque

```
#!/bin/bash
echo "Planta Barranquilla" > /var/www/html/index.html
systemctl start httpd
```

Imagen dorada: la plantilla que se cuida

construida una vez, probada y versionada (v1.4);
las instancias se reemplazan, no se parchan a mano;
los secretos nunca van dentro de la imagen.

Inmutable: para cambiar algo no se edita una instancia, se crea una imagen nueva y se reemplazan las instancias

Igual que Docker en contenedores y las imágenes de máquina de Azure y Google Cloud: la plantilla es la fuente de verdad.

Analogía: la imagen es la receta; la instancia, el plato servido. Cien instancias salen iguales.

SECUENCIA

Del clic al servicio: el arranque de una instancia

Cinco pasos que ocurren en minutos y que conviene saber leer cuando algo no funciona.

Consola, CLI o API
pedir la instancia

1 Plantilla y talla
se elige la imagen y se reserva capacidad

2 Volumen raíz
se crea desde la imagen; el sistema arranca

3 Red
IP privada, subred y grupo de seguridad

4 Identidad
rol y credenciales temporales

5 Arranque
user data y servicio en ejecución

estado pendiente (pending): se prepara y todavía no factura cómputo

en ejecución (running)

SI LA INSTANCIA NO RESPONDE, SE DIAGNOSTICA EN ORDEN INVERSO

4 Identidad
¿el rol tiene el permiso que usa la app?
Herramienta: registro de auditoría (CloudTrail).

3 Red
¿el grupo de seguridad abre el puerto? ¿hay IP pública y ruta a Internet?
Herramienta: Reachability Analyzer.

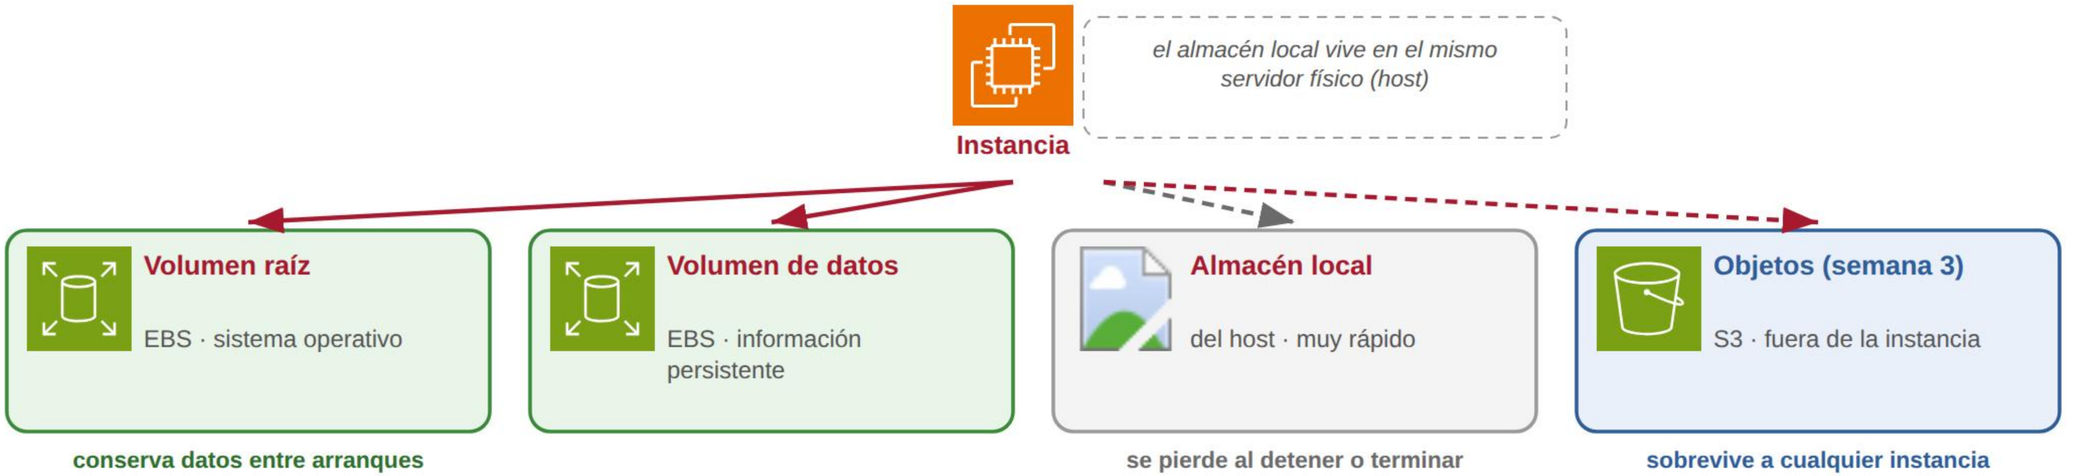
2 Volumen raíz
¿arrancó el sistema operativo?
Herramienta: registro y captura de pantalla de la consola.

1 Plantilla y talla
¿la imagen es compatible con la talla?
Herramienta: comprobaciones de estado (2 de 2).

Diagnóstico: revisa de afuera hacia adentro: lo último que se configuró es lo primero que falla.

Los discos de la instancia: raíz y datos

El volumen raíz define el arranque; los volúmenes de datos guardan lo que debe sobrevivir a la instancia.



¿QUÉ PASA CON LOS DATOS?

	Volumen raíz	Volumen de datos	Almacén local	Objetos (semana 3)
DETENER	se conserva	se conserva	se pierde	se conserva
TERMINAR	se elimina*	se conserva*	se pierde	se conserva

** por defecto: el volumen raíz se elimina al terminar y los de datos se conservan; ambos son configurables al crear la instancia.*

Regla: lo que debe persistir nunca vive solo en el almacén local del host.

La red de la instancia: direcciones y firewall

Dirección privada estable, dirección pública reasignable y reglas de seguridad que siguen a la instancia.



IP privada
10.0.1.25 · estable entre reinicios
solo dentro de la VPC

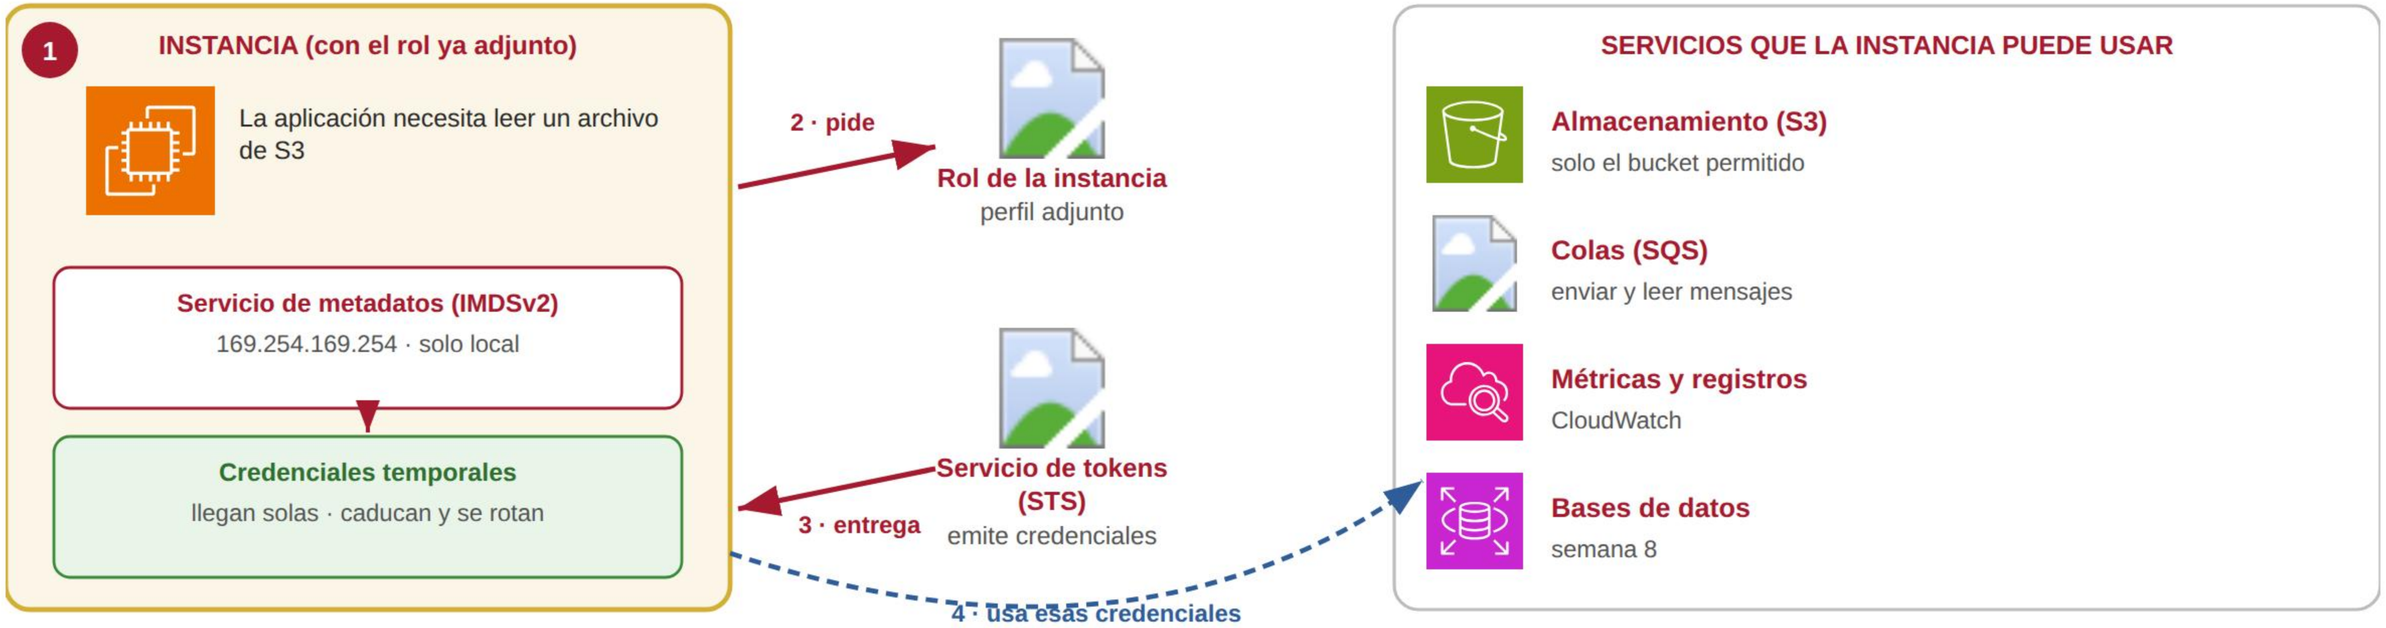
IP pública
54.x.x.x · cambia al detener y arrancar
la asigna el proveedor

IP elástica
reservada · se conserva y se reasigna
factura si no está en uso

Clave: el firewall sigue a la instancia; la dirección pública no, salvo que se reserve.

La identidad de la instancia: el rol, no las claves

La máquina obtiene credenciales temporales de un rol adjunto; nunca se guardan llaves dentro del servidor.



CORRECTO: el rol entrega credenciales temporales

permisos mínimos, rotación automática, un mismo rol para todas las instancias del grupo y cada operación queda auditada (CloudTrail).

INCORRECTO: claves guardadas en el servidor

una clave en el código, en el disco o en la imagen se copia, se filtra y no caduca: es la causa de muchos incidentes.

Regla: nunca se guardan claves de acceso dentro de la instancia: el rol entrega credenciales temporales.

PLANTILLA

Elegir la imagen correcta

No todas las plantillas sirven: sistema operativo, arquitectura, licencias y mantenimiento son criterios de selección.



Sistema y versión

Una versión sin soporte hereda vulnerabilidades en cada instancia creada de esa imagen.



Arquitectura

La imagen fija el procesador (x86 o ARM): no arranca en otra arquitectura.



Licenciamiento

Sistemas y software incluidos o facturados aparte: se ve en la factura.



Origen y mantenimiento

Imágenes propias versionadas y parchadas frente a imágenes de la comunidad sin control.

CICLO DE VIDA DE UNA IMAGEN DORADA PROPIA



Buena práctica: una imagen dorada propia, actualizada con un proceso definido: nada de imágenes anónimas.

SÍNTESIS

Lo que queda de la Parte 1

Cuatro ideas para llevarse antes de hablar de ciclo de vida y dimensionamiento.

4

recursos que se dimensionan

vCPU, RAM, disco y red

idea 1

1

plantilla versionada

la imagen crea instancias idénticas

idea 2

0

claves guardadas en el servidor

la identidad es un rol

idea 3

3

capas de red que la protegen

tabla de rutas, NACL y grupo de seguridad

idea 4

SIGUIENTE PREGUNTA

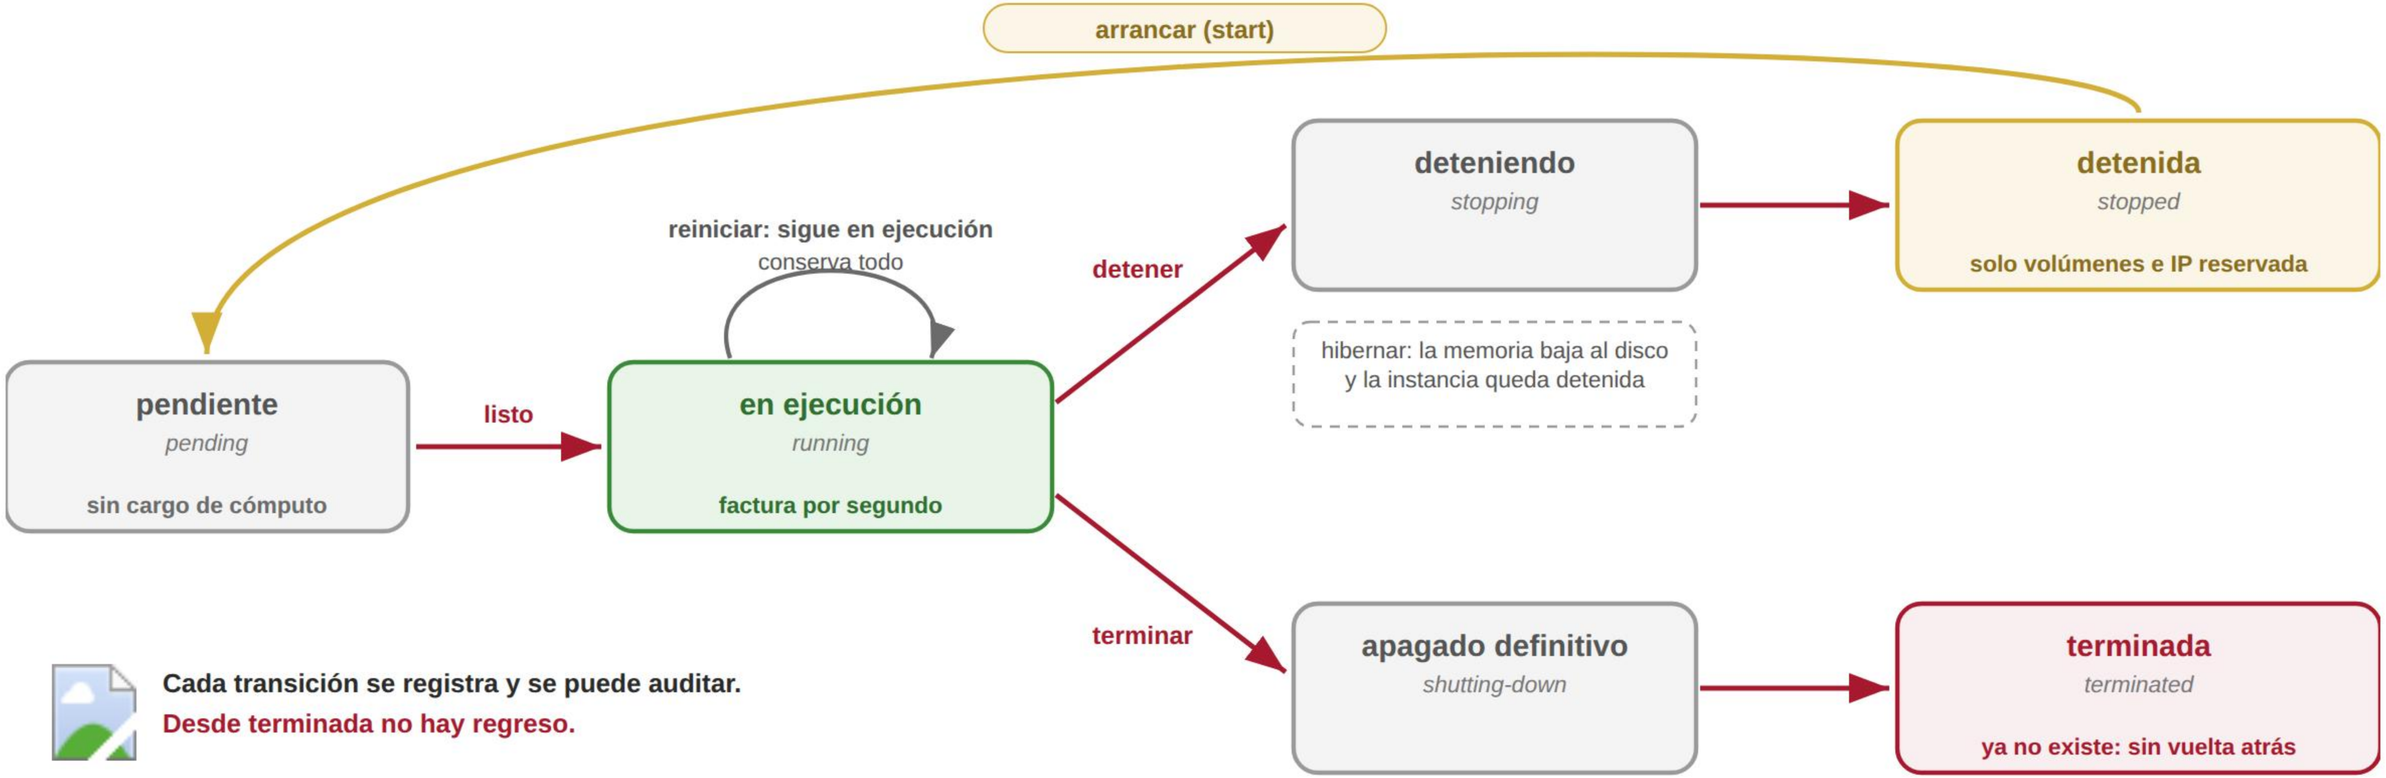
¿Cómo se administra la instancia en el tiempo, deteniendo, redimensionando o terminando, y cómo se elige su talla?



Sigue: Parte 2: ciclo de vida y tallas.

El ciclo de vida de una instancia

Seis estados y transiciones con nombre propio — saber leerlos evita el error de laboratorio más común.



Cada transición se registra y se puede auditar.
Desde terminada no hay regreso.

Idea: cuatro estados estables y dos de paso: aprender los nombres evita el error de laboratorio más común.

DECISIÓN CRÍTICA

Detener no es terminar

La confusión más costosa del laboratorio: una instancia detenida sigue existiendo y sigue generando cargos.

DETENER — la pausa

el cómputo deja de facturar

SE CONSERVA	disco raíz, volúmenes, IP privada e identidad
SE CONSERVA	se puede arrancar de nuevo en el mismo punto
SIGUE FACTURANDO	volúmenes e IP elástica reservada
SE PIERDE	el almacén local del host
SE PIERDE	la IP pública automática (cambia al arrancar)

Usa DETENER para pausar

TERMINAR — el borrado

la instancia deja de existir

SE DESTRUYE	la instancia: no hay vuelta atrás
SE DESTRUYE	el disco raíz, por defecto
SIGUE FACTURANDO	la IP elástica queda sin asociar: hay que liberarla
SE CONSERVA	los volúmenes de datos, por defecto
SE PIERDE	el almacén local del host

Usa TERMINAR para limpiar

Disciplina de laboratorio: detener lo que está en pausa y terminar lo que ya terminó. Activa la protección contra terminación en lo importante.

COSTO

La factura cambia con cada estado

El cómputo factura solo en ejecución; el almacenamiento y las direcciones reservadas facturan casi siempre.

	pendiente	en ejecución	detenida	terminada
Cómputo de la instancia	sin cargo	por segundo (mín. 1 min)	sin cargo	sin cargo
Volumen raíz (EBS)	factura	factura	factura	se elimina por defecto
Volúmenes de datos	factura	factura	factura	siguen: facturan
IPv4 pública o elástica	por hora	por hora	por hora (elástica)	elástica sin asociar: factura
Instantáneas (snapshots)	siempre	siempre	siempre	siempre

verde = no genera cargo en ese estado · rojo = sigue facturando

Los cargos que nadie recuerda haber creado son los recursos huérfanos: volúmenes sueltos, direcciones sin asociar e instantáneas viejas.

Recuerda: el cómputo factura solo en ejecución; almacenamiento y direcciones facturan casi siempre.

SEMANA 7 · CÓMPUTO EN LA NUBE: INSTANCIAS VIRTUALES, TIPOS, ESCALADO

Tallas, familias y costo de la instancia

Parte 2 de 3 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

Redimensionar, elegir talla y familia, leer el nombre del tipo, créditos de ráfaga y el costo del cómputo

VARIANTE

Hibernar: congelar la memoria en disco

Cuando detener y arrancar desde cero tarda demasiado: el estado de la memoria se guarda y se restaura.

EN EJECUCIÓN

Memoria RAM

- procesos en memoria
- aplicación inicializada
- cachés cargadas

hibernar

DETENIDA (hibernada)

Volumen raíz (EBS)
la memoria se guarda aquí

copia de la RAM (cifrada)

sin facturación de cómputo; el volumen raíz sí factura.

arrancar

CONTINÚA

Memoria RAM

- procesos en memoria
- aplicación inicializada
- cachés cargadas

COMPARACIÓN DE ARRANQUE (escala ilustrativa)

Arranque normal	sistema operativo + servicios + aplicación + carga de cachés
Desde hibernación	**restaura la memoria y sigue**



ideal para aplicaciones que tardan mucho en calentarse.

Requisitos: condiciones: familia compatible, hibernación habilitada al lanzar y espacio en el volumen raíz para la memoria.

AWS — EC2 instance lifecycle: hibernated instances (docs.aws.amazon.com)

Redimensionar: cómo crecer sin recrear la instancia

El tipo de instancia no es una decisión permanente: se cambia deteniendo, modificando y arrancando.

1 Detener

el cómputo deja de facturar; datos e identidad se conservan

2 Modificar el tipo

familia y talla compatibles con la arquitectura de la imagen

3 Arrancar

mismos datos e IP privada, nueva capacidad

m5.large
familia m, propósito general

vCPU	2
RAM	8 GiB

mismo disco, misma IP privada, misma identidad

misma máquina, más capacidad

m5.xlarge
familia m, propósito general

vCPU	4
RAM	16 GiB

mismo disco, misma IP privada, misma identidad

Lo que no arregla: una consulta ineficiente o una fuga de memoria. Subir de talla compra tiempo, no corrige el diseño.

Regla: el tipo de instancia no es una decisión permanente: se cambia deteniendo, modificando y arrancando.

DIMENSIONAMIENTO

Elegir talla: primero el recurso escaso

No se elige la instancia más grande: se identifica qué recurso limita la carga y se busca el perfil que lo maximiza.

SÍNTOMA EN LAS MÉTRICAS		PERFIL QUE LO MAXIMIZA
Ningún recurso domina equilibrio CPU y memoria		**Propósito general** familias M y T
CPU al límite conexiones cortas, cálculo		**Optimizada a cómputo** familia C
Memoria al límite cachés grandes, datos en RAM		**Optimizada a memoria** familias R y X
Disco al límite lectura y escritura intensiva		**Optimizada a almacenamiento** familias I, D y H
Acelerador al límite modelos y video		**Acelerada** GPU y chips de IA

Método: la talla final se ajusta con métricas reales, no con intuición, y es reversible.

AWS — Amazon EC2 instance types (docs.aws.amazon.com/ec2/latest/instancetypes)

FAMILIA 1

Propósito general: el punto de partida

Equilibrio entre procesador y memoria — el perfil correcto para la mayoría de cargas de negocio.

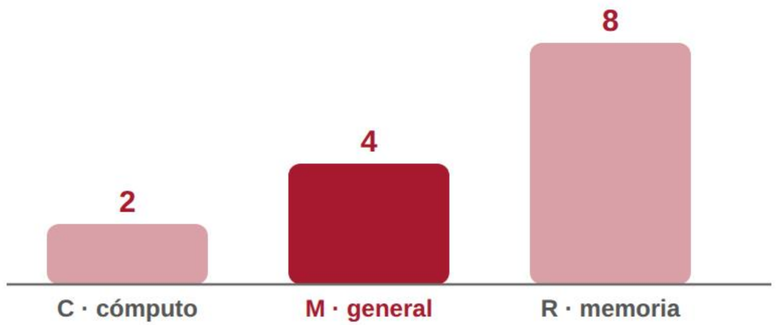
Propósito general

Referencia: M y T

Equilibrio entre procesador y memoria: 4 GiB por vCPU en la familia M (m5.large: 2 vCPU, 8 GiB). La familia T añade ráfaga para picos cortos.

Ejemplo: la aplicación de pedidos de la Corporación Industrial del Caribe.

GiB de memoria por vCPU (referencia)

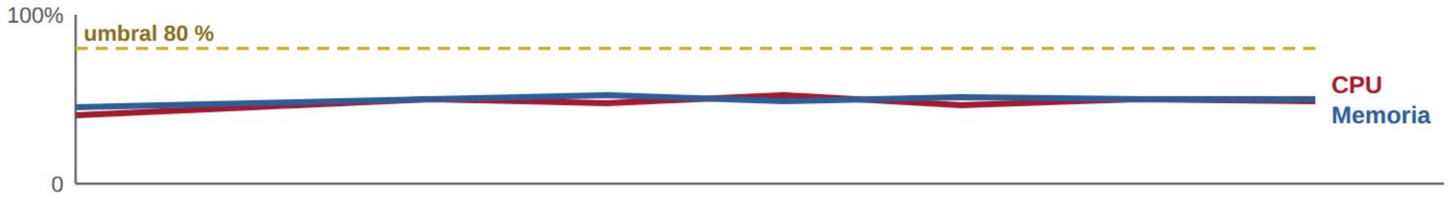


CUÁNDO USARLA

- Servidores web y de aplicaciones
- Desarrollo, pruebas y servicios internos
- Primera talla cuando aún no hay métricas
- Cuidado: una T con CPU alta constante agota créditos

SEÑAL EN LAS MÉTRICAS

Ninguno de los dos recursos domina: CPU y memoria se mueven en rangos medios y con holgura.



Criterio: si no hay una razón medida para otra familia, esta es la elección por defecto y se corrige con métricas.

FAMILIA 2

Optimizadas a cómputo: procesador de alta frecuencia

Cuando el cuello de botella es el cálculo: más CPU por cada gigabyte de memoria.

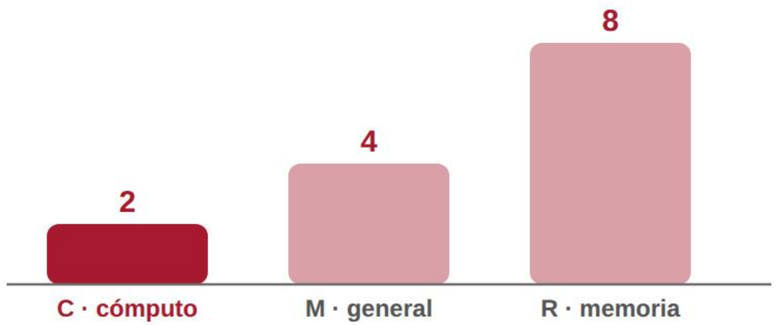
Optimizadas a cómputo

Referencia: C

Procesadores de alta frecuencia: 2 GiB por vCPU, la mitad de memoria que propósito general (c5.large: 2 vCPU, 4 GiB). Más cálculo por dólar.

Úsala cuando la métrica lo muestre, no cuando se suponga.

GiB de memoria por vCPU (referencia)

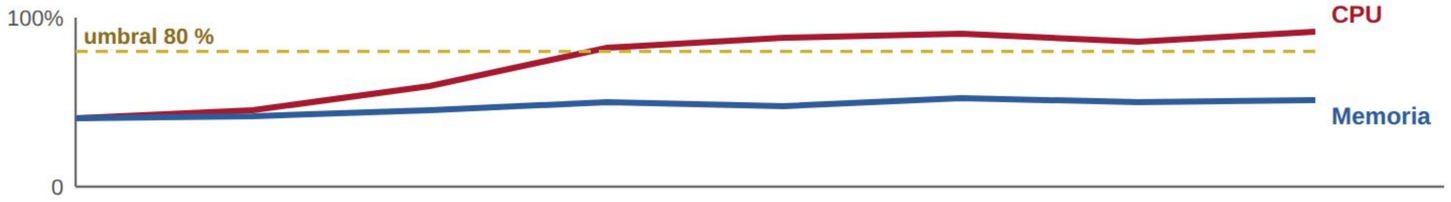


CUÁNDO USARLA

- Lotes y análisis paralelo
- Codificación y renderizado
- Simulación y cálculo científico
- Alta concurrencia por segundo

SEÑAL EN LAS MÉTRICAS

CPU sostenida sobre 80 % con memoria holgada: la carga pide cómputo, no más RAM.



Error simétrico: elegir cómputo para una carga con cachés grandes deja procesadores ociosos y presión de memoria.

AWS — Amazon EC2 instance types: Compute optimized (C) · valores de c5 como referencia

FAMILIA 3

Optimizadas a memoria: muchos gigabytes por vCPU

Bases de datos en memoria, cachés y analítica que mantienen grandes volúmenes de datos activos.

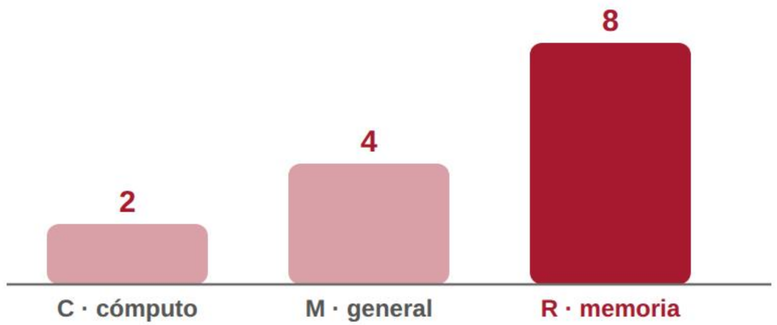
Optimizadas a memoria

Referencia: R y X

Muchos gigabytes por vCPU: 8 GiB por vCPU en la familia R (r5.large: 2 vCPU, 16 GiB). La familia X llega a proporciones aún mayores.

Una base o caché que no cabe en RAM se vuelve lenta.

GiB de memoria por vCPU (referencia)

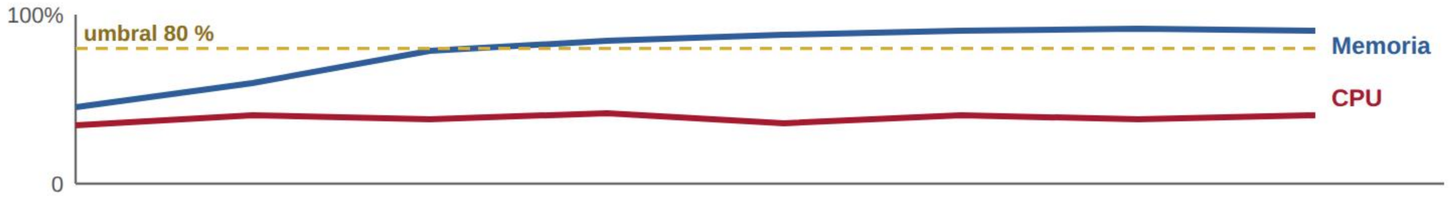


CUÁNDO USARLA

- Bases en memoria y cachés
- Índices de búsqueda
- Analítica con datos activos
- Bases relacionales grandes

SEÑAL EN LAS MÉTRICAS

Memoria sostenida sobre 80 % con CPU holgada y consultas que se degradan al no caber en RAM.



Puente: este perfil reaparece en la semana 8 (bases administradas) y en la semana 12 (caché).

FAMILIA 4

Almacenamiento y aceleradas: perfiles especializados

Rendimiento de disco sostenido o procesadores gráficos — dos nichos que no se cubren con tallas generales.

OPTIMIZADAS A ALMACENAMIENTO · I, D, H

Instancia

discos NVMe locales

en el mismo servidor

Discos locales de alto rendimiento y baja latencia.

- bases transaccionales de alto tráfico
- sistemas de archivos distribuidos
- búsqueda y almacenes de datos

Recuerda: el almacén local es efímero. Lo que debe persistir se replica o va a EBS y S3.

Señal: la carga espera al disco, no al procesador.

ACELERADAS · GPU Y CHIPS DE IA

GPU
entrenamiento e inferencia de modelos

Chips de IA
propios del proveedor

- renderizado profesional y simulación
- procesamiento gráfico intensivo
- video y visualización

Las más costosas por hora del catálogo: en el laboratorio consumen el presupuesto rápidamente.

COSTO RELATIVO POR HORA (ilustrativo)

General	Cómputo	Memoria	Almacenamiento	Acelerada
● ○ ○ ○	● ○ ○ ○	● ● ○ ○	● ● ○ ○	● ● ● ●

Para las cuatro familias: método único: identificar el recurso escaso, elegir el perfil y ajustar con métricas.

AWS — Amazon EC2 instance types: Storage optimized y Accelerated computing (docs.aws.amazon.com)

LECTURA DE NOMBRES

Cómo leer el nombre de una instancia

Familia, generación, procesador y talla: cuatro datos en una cadena de texto.

m6g.2xlarge

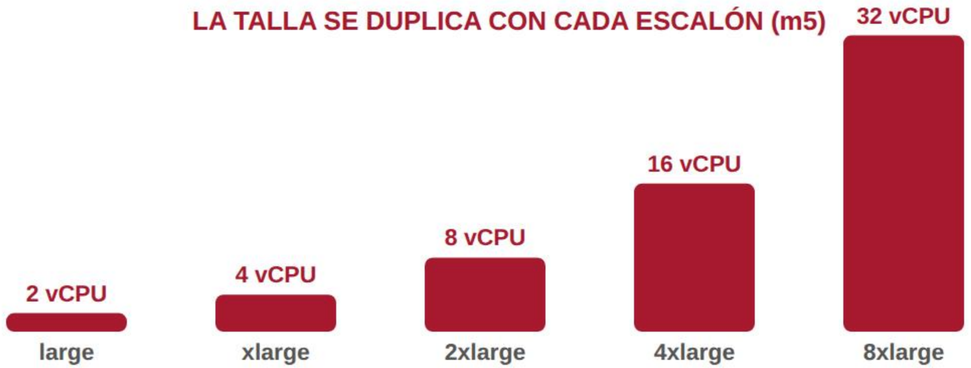
familia
m general · c cómputo · r memoria · t ráfaga

generación
más nueva, mejor precio y desempeño

procesador
g Graviton (ARM) · i Intel · a AMD · n red

talla
large · xlarge · 2xlarge · 4xlarge…

LA TALLA SE DUPLICA CON CADA ESCALÓN (m5)



MÁS EJEMPLOS

`c7i.xlarge`	cómputo · gen. 7 · Intel · 4 vCPU
`r6a.large`	memoria · gen. 6 · AMD · 2 vCPU
`t3.micro`	ráfaga · gen. 3 · 2 vCPU y 1 GiB
`i4i.large`	almacenamiento · gen. 4 · Intel

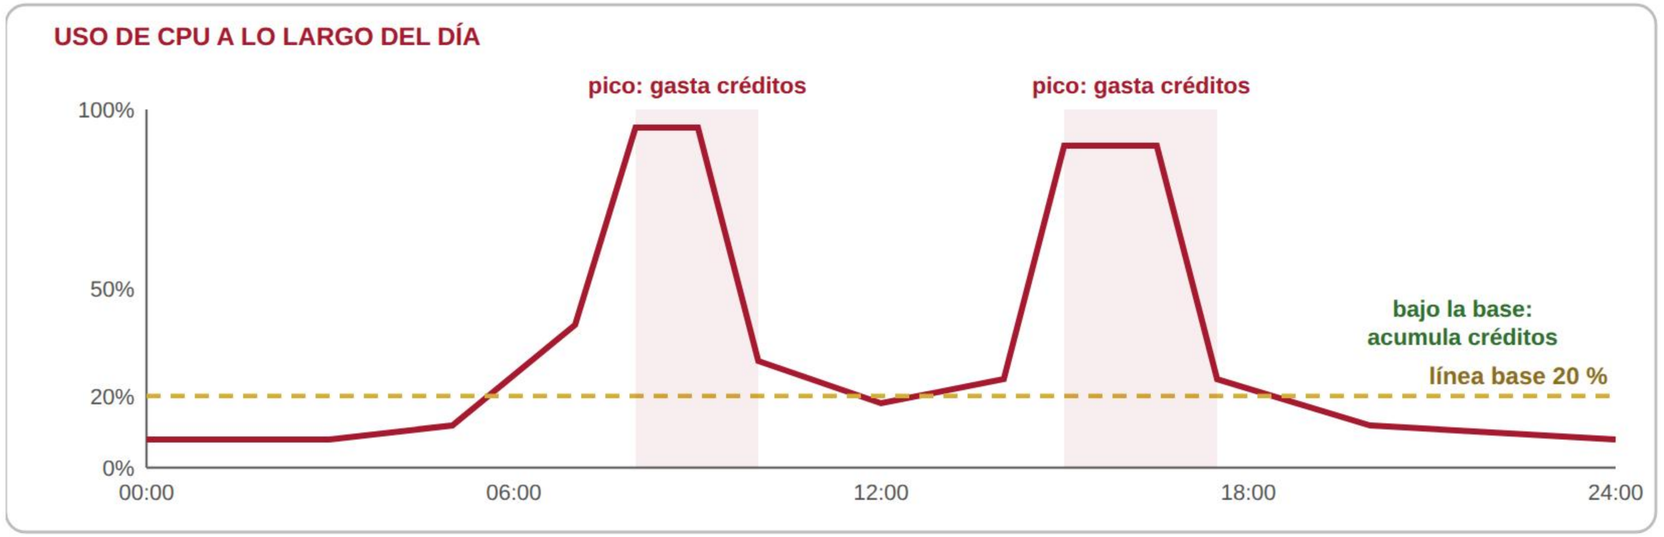
Ojo: no se memoriza el catálogo: se lee el patrón. La letra del procesador condiciona la compatibilidad de la imagen.

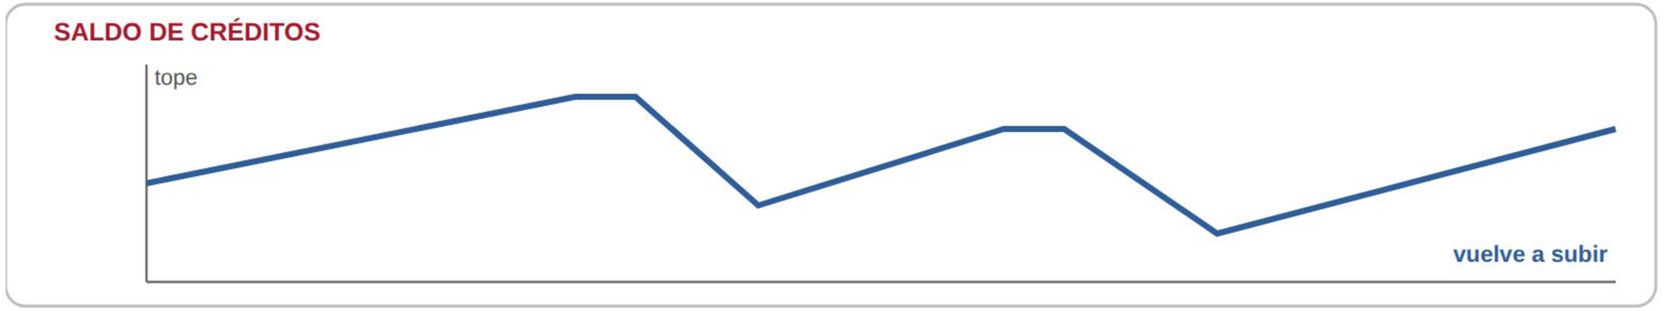
AWS — Amazon EC2 instance type naming conventions (docs.aws.amazon.com/ec2/latest/instancetypes)

DETALLE TÉCNICO

Créditos de ráfaga: cómo funcionan las familias T

La familia económica de propósito general no regala procesador: lo acumula y lo gasta en picos.





Familia T (ráfaga)

Gana créditos cuando la carga está bajo la base y los gasta en los picos.

MODO ESTÁNDAR

al agotar los créditos se limita a la línea base.

MODO ILIMITADO

sigue acelerando y paga un extra por el exceso de créditos.

Ojo: una T con CPU alta constante deja de ser barata: para eso existen las familias M y C.

SÍNTESIS

Lo que queda de la Parte 2

Ciclo de vida y dimensionamiento: dos decisiones reversibles si se administran con disciplina.



≠

detener ≠ terminar

pausar conserva y factura el almacenamiento; terminar destruye sin vuelta

idea 1



↕

la talla es reversible

se cambia deteniendo, modificando y arrancando

idea 2



1

recurso escaso

se identifica el límite antes de elegir la familia

idea 3



4

datos en el nombre

familia, generación, procesador y talla

idea 4

PUENTE CON LA PARTE 3: el mismo cómputo, tres precios

Bajo demanda		**100 %**
Con compromiso (hasta 72 % menos)		**≈ 28 %**
Spot (hasta 90 % menos)		**≈ 10 %**

valores de referencia publicados

Puente: el mismo cómputo puede costar el 100 % o una fracción según cómo se compre.

Síntesis de la Parte 2 · elaboración propia; descuentos publicados por AWS (consultados 2026-09)

CONTEXTO

Por qué el cómputo domina la factura

Se factura por segundo de uso, con mínimo de un minuto por arranque — y por eso las decisiones de arquitectura se ven en el costo.

COMPOSICIÓN TÍPICA DE UNA FACTURA DE CÓMPUTO (proporciones ilustrativas)



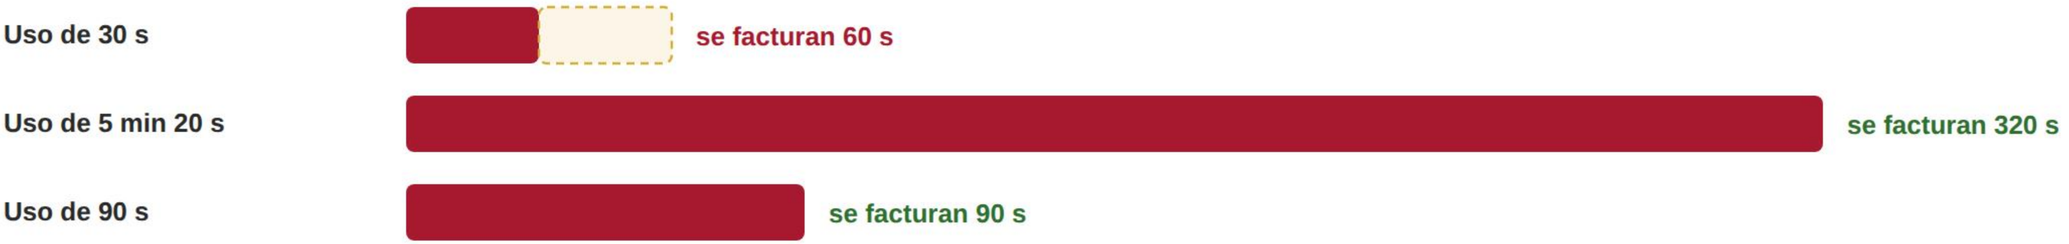
Instancia
por segundo, mínimo de 1 minuto

Volúmenes
por GB al mes, mientras existan

Red
transferencia de salida por GB

Objetos
almacenamiento y peticiones

FACTURACIÓN POR SEGUNDO (Linux, con mínimo de 1 minuto por arranque)



rayado dorado: segundos redondeados al mínimo

Primera regla: el cómputo se paga por tiempo encendido: apagar lo que no se usa es la primera optimización.

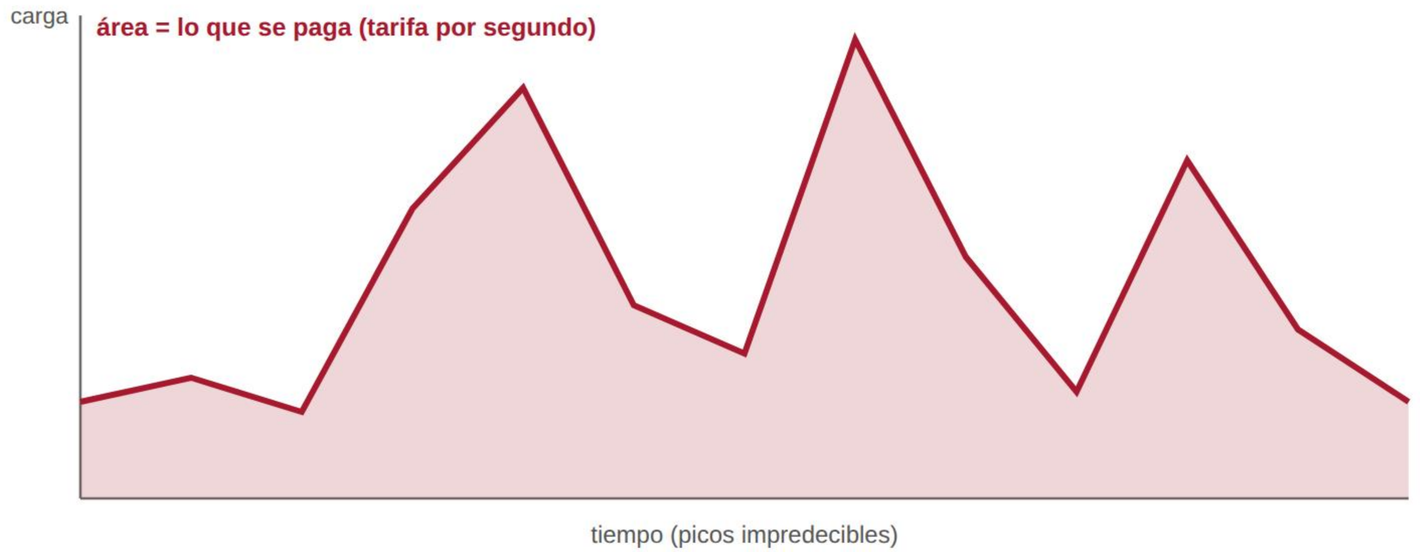
AWS — Amazon EC2 pricing y facturación por segundo (consultada 2026-09) · proporciones ilustrativas

MODELO 1

Bajo demanda: flexibilidad sin compromiso

Se paga la tarifa completa por segundo de uso, sin contrato ni anticipo — el modelo de la incertidumbre.

LO QUE SE PAGA SIGUE A LO QUE SE USA



Bajo demanda

Tarifa publicada por segundo, sin contrato ni anticipo: el precio de referencia contra el que se miden los demás.

- CUÁNDO · cargas nuevas sin historial
- CUÁNDO · picos impredecibles
- CUÁNDO · desarrollo por jornada
- CUÁNDO · laboratorio académico

Error 1: dejar todo bajo demanda por comodidad cuando la demanda base ya es conocida.

Error 2: comprometerse antes de conocer la demanda. Primero medir.

En el laboratorio: AWS Academy trabaja en este modelo: el objetivo es crear y destruir recursos, no optimizar contratos.

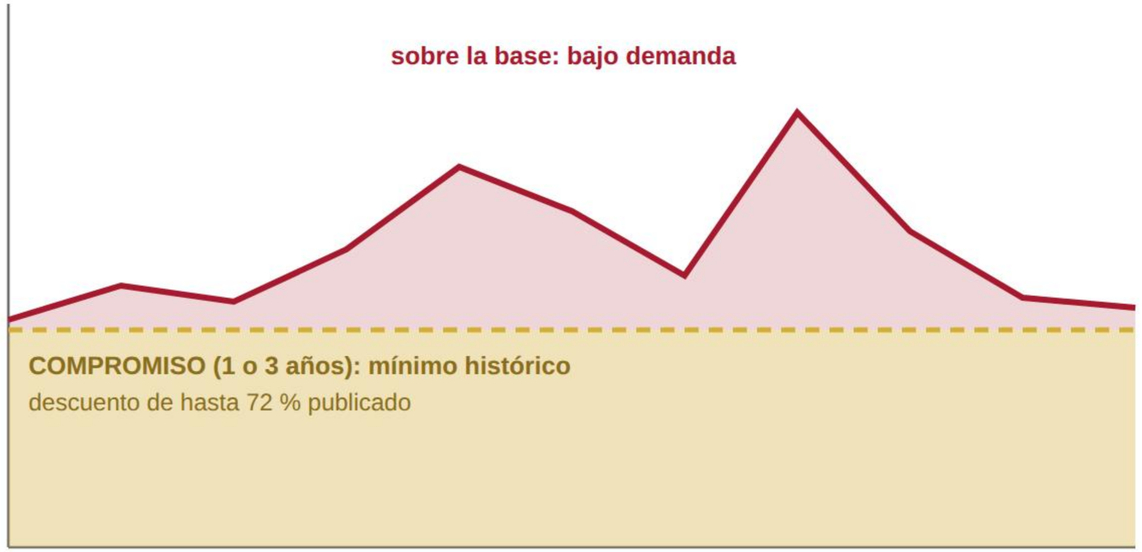
AWS — Amazon EC2 On-Demand Instances pricing (consultada 2026-09) · curva ilustrativa

MODELO 2

Compromiso: pagar menos por lo predecible

Reservas y planes de ahorro: a cambio de comprometer consumo por uno a tres años, el proveedor descuenta hasta 72 %.

SE COMPROMETE LA BASE; LO DEMÁS SE PAGA BAJO DEMANDA



consumo mensual a lo largo del tiempo

RESERVAS

compromiso atado a familia y región
mayor descuento, menor flexibilidad
pago: todo anticipado, parcial o sin anticipo
ideal para la carga base muy estable

PLANES DE AHORRO

compromiso de gasto por hora (USD/h)
aplica a familias, sistemas y regiones
más flexibles, descuento algo menor
hasta 72 % de ahorro publicado

Regla: se compromete el mínimo histórico, no el promedio: la demanda que no se usa también se paga.

AWS — Savings Plans: «Save up to 72%» (aws.amazon.com/savingsplans, consultada 2026-09)

MODELO 3

Spot: capacidad ociosa a precio de remate

El proveedor vende la capacidad que no está usando con descuentos publicados de hasta 90 % — a cambio, puede recuperarla.

LA CAPACIDAD DE UNA ZONA NO SIEMPRE SE USA COMPLETA

capacidad total de servidores en la zona



hasta 90 %
de descuento publicado
frente al precio bajo demanda

interrumpible
el proveedor puede reclamarla
el diseño debe tolerarlo

no acumulable
el consumo spot no está cubierto
por los planes de ahorro

Contrato implícito: "yo te cobro una fracción, tú aceptas que la máquina puede desaparecer"

Si la aplicación no puede cumplirlo, el ahorro es un riesgo.

Idea: spot es capacidad ociosa a precio de remate: el riesgo se paga con ingeniería.

AWS — Amazon EC2 Spot: «Save up to 90% on On-Demand Prices» (aws.amazon.com/ec2/spot, consultada 2026-09)

COMPORTAMIENTO

Cómo se interrumpe una instancia spot

Aviso de dos minutos, tres formas de terminar y una señal preventiva que permite reaccionar antes.



QUÉ HACE UN DISEÑO PREPARADO

Migrar la carga

pedir capacidad en otra reserva y vaciar la instancia

Guardar estado

punto de control, cola o almacenamiento externo

Retirar del balanceador

drenar conexiones antes de que desaparezca

Reintentar

otra instancia retoma la tarea pendiente

El aviso se puede leer desde el servicio de metadatos de la instancia y también llega como evento al bus de eventos, donde puede disparar una función o una alarma.

Reacción por diseño: escuchar el aviso, guardar el trabajo y reintentar en otra instancia: eso convierte spot en ingeniería, no en lotería.

AWS — Spot Instances: aviso de interrupción de dos minutos y rebalance recommendation (consultada 2026-09)

CRITERIO DE DISEÑO

Qué cargas pueden usar spot

Sin estado, con reintentos y con puntos de control: el patrón que convierte la interrupción en un evento trivial.

SÍ: tolerantes a interrupción

requisito: unidades independientes y reintentables

- trabajos por lotes y análisis de datos
- contenedores y pipelines de integración continua
- cómputo de alto rendimiento por unidades
- entornos de prueba y desarrollo

NO: sin tolerancia a interrupción

el trabajo no se puede repetir sin efectos

- bases de datos monolíticas con transacciones
- sesiones guardadas localmente
- controladores únicos del sistema
- procesos no repetibles con efectos secundarios

PRUEBA: ¿el sistema continúa solo si la máquina desaparece?

Puntos de control
guardar avance cada cierto tiempo

Colas de tareas
las unidades esperan en la cola

Arquitecturas sin estado
cualquier máquina atiende

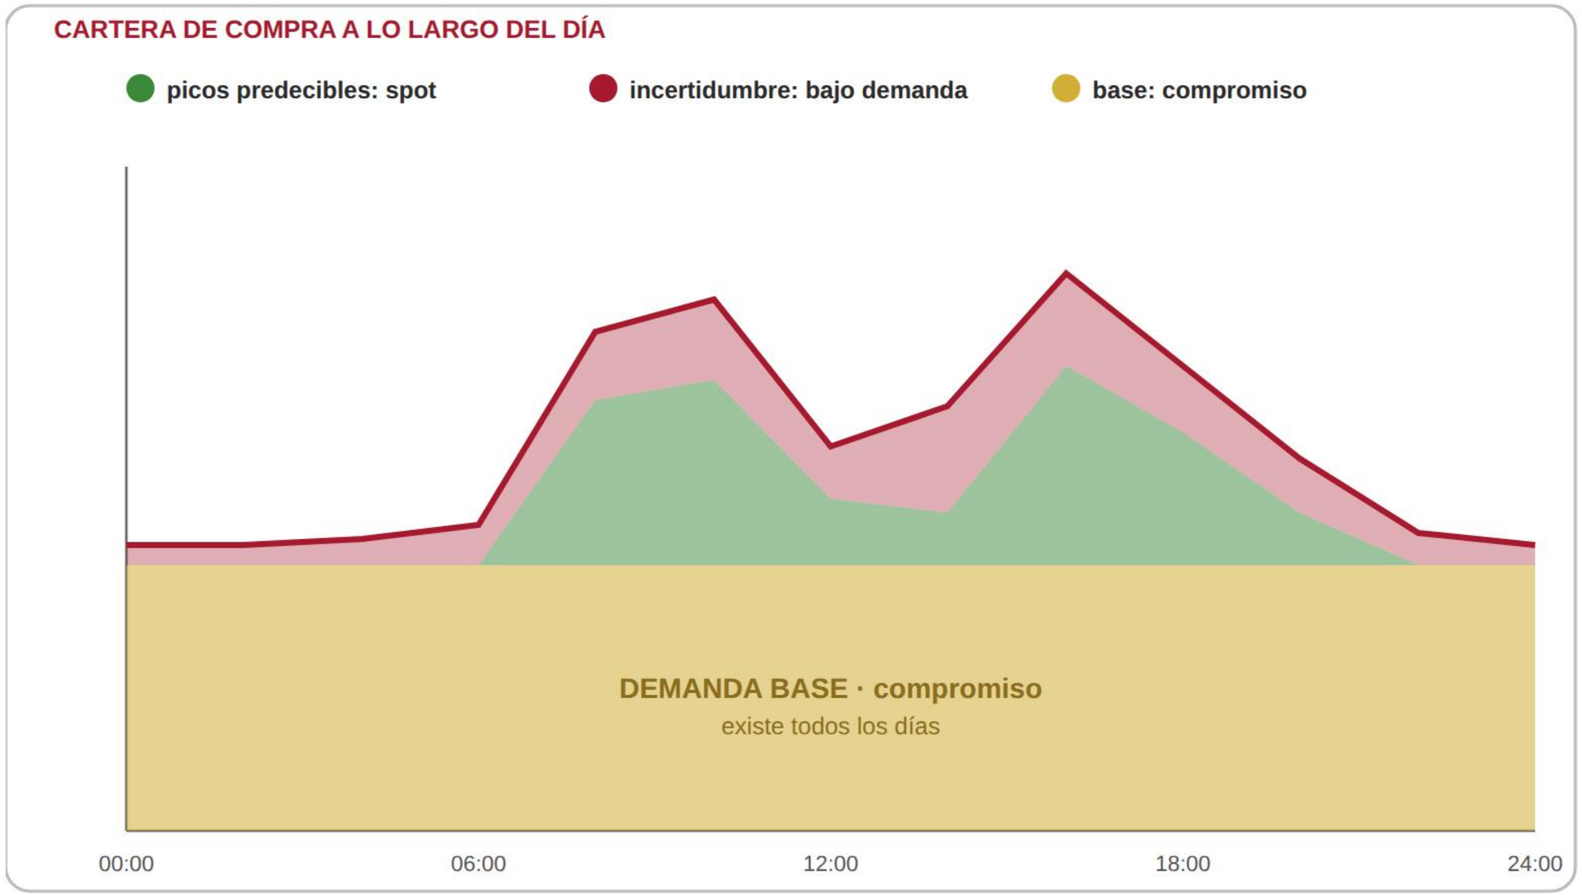
Patrón: tres técnicas convierten la interrupción en un evento trivial: puntos de control, colas y servicios sin estado.

AWS — Spot Instances: casos de uso recomendados (docs.aws.amazon.com, consultada 2026-09)

ESTRATEGIA

La mezcla: cada carga al modelo que le corresponde

Base comprometida, picos spot, incertidumbre bajo demanda — una cartera, no un único modelo.



Compromiso

el mínimo histórico, no el promedio

Spot

picos predecibles tolerantes a fallos

Bajo demanda

cargas nuevas, experimentos y picos impredecibles

Condición: la arquitectura habilita la cartera: sin cargas sin estado no hay spot posible.

COSTO TOTAL

Lo que no aparece en el precio por hora

Transferencia de salida, almacenamiento, instantáneas y licencias: el costo real de una arquitectura.



Lo que aparece en la cotización: instancia × horas

precio por hora (ilustrativo)

línea de flotación



Transferencia de salida

se cobra por GB al salir a Internet o entre regiones; la entrada normalmente no



Volúmenes

facturan mientras existan, incluso con la instancia detenida



Instantáneas

respaldos incrementales por almacenamiento; se acumulan si nadie los limpia



Licencias

sistemas y software comercial: incluidos o facturados aparte según la imagen

Cada flecha es una decisión de arquitectura: regiones, replicación, respaldos y tráfico.

Consecuencia: el costo se estima por arquitectura, no por una instancia aislada.

AWS — Amazon EC2 pricing: transferencia de datos, EBS, snapshots y licencias (consultada 2026-09)

EJEMPLO GUIADO

Comparar tres estrategias con números

Ejercicio con supuestos didácticos explícitos: la mecánica del cálculo, no una tarifa real.

SUPUESTOS DIDÁCTICOS *ilustrativo, no es una cotización*

10 instancias · mes de 720 horas · 0,10 USD por hora bajo demanda · 6 de base todo el mes · 4 variables, 360 h cada una

A · todo bajo demanda



≈ 576 USD

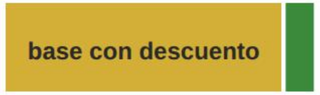
B · base comprometida (72 %) + variable bajo demanda



≈ 265 USD

ahorro frente a A: 54 %

C · base comprometida + variable en spot (90 %)



≈ 135 USD

ahorro frente a A: 77 %

A: (6 × 720 + 4 × 360) × 0,10 = 576 · B: 6 × 720 × 0,10 × 0,28 + 4 × 360 × 0,10 ≈ 265 · C: 121 + 4 × 360 × 0,10 × 0,10 ≈ 135

Supuestos didácticos: descuentos máximos publicados; en la práctica varían según plazo, familia y región. No usar como cotización.

SEMANA 7 · CÓMPUTO EN LA NUBE: INSTANCIAS VIRTUALES, TIPOS, ESCALADO

Ahorro, escalado y elasticidad

Parte 3 de 3 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

Reservas y planes de ahorro, escalado vertical y horizontal, aplicaciones sin estado y balanceador de carga

OPTIMIZACIÓN

Ahorrar por diseño antes que por contrato

Apagar, ajustar la talla y limpiar recursos huérfanos rinde más que cualquier descuento sobre una carga mal dimensionada.

1



Apagar lo que no se usa

desarrollo fuera de horario y pruebas olvidadas

2



Ajustar la talla

bajar de talla con métricas reales

3



Limpiar huérfanos

volúmenes, IP sin asociar, instantáneas viejas

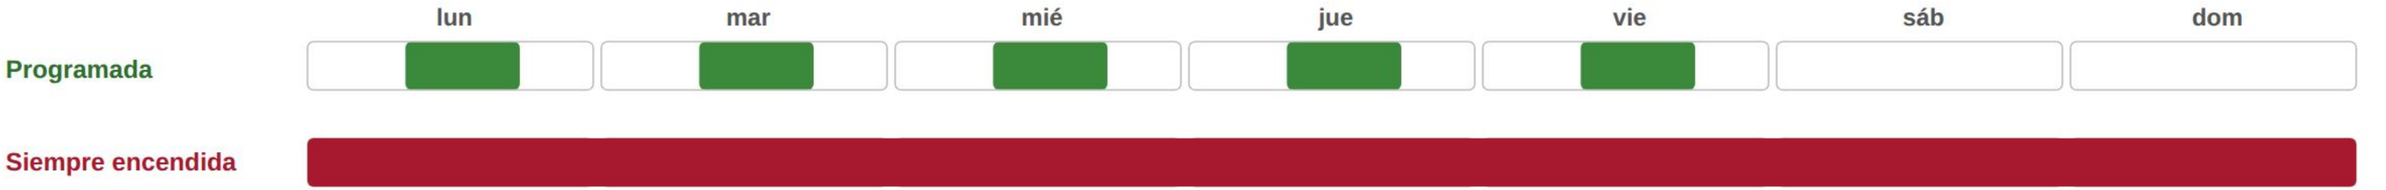
4



Elegir almacenamiento

no todo necesita el disco más rápido

EJEMPLO: UNA INSTANCIA DE DESARROLLO DURANTE UNA SEMANA



50 h frente a 168 h por semana: ≈ 70 % menos cómputo sin comprar ningún contrato

medir → **optimizar diseño** → **ajustar talla** → **evaluar compromiso**

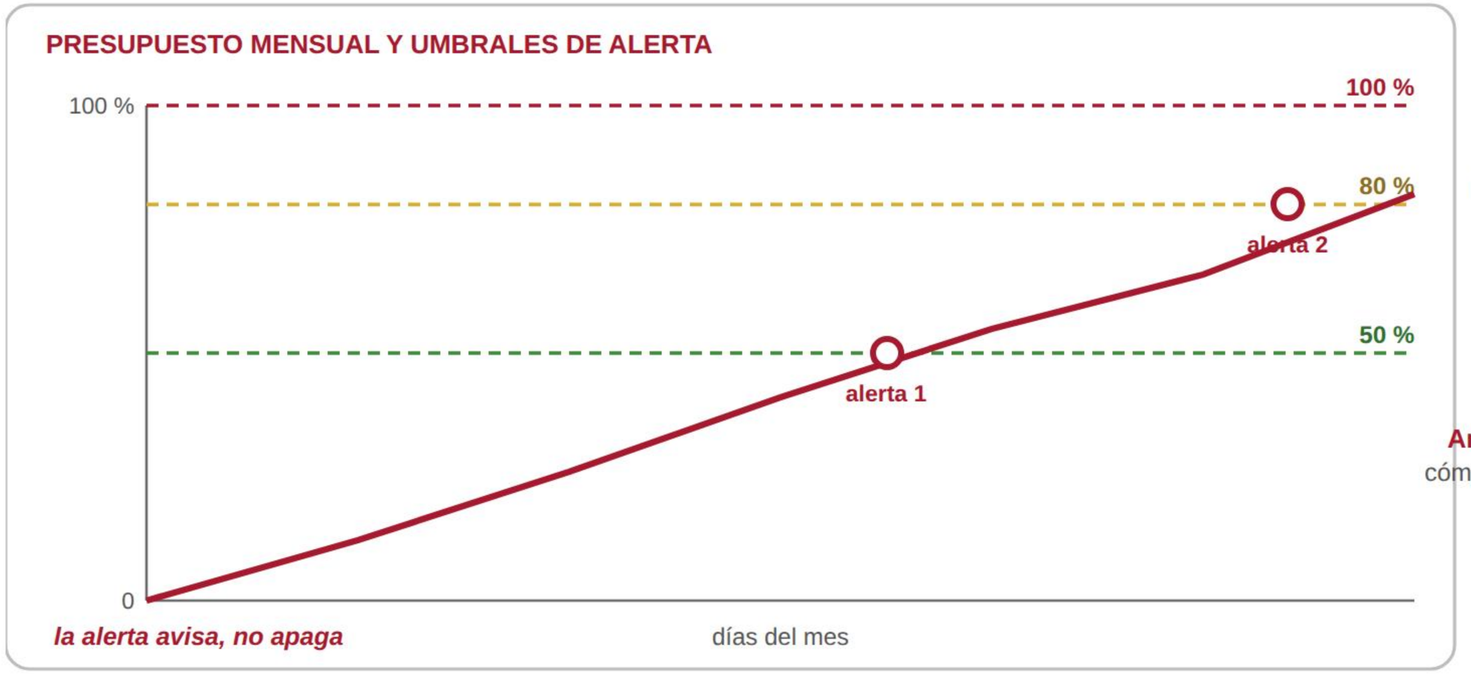
Orden: secuencia profesional: los tres primeros pasos son reversibles; el compromiso no lo es.

AWS Well-Architected — pilar de costos (right sizing, apagado programado) · ejemplo ilustrativo

CONTROL

Presupuesto y alertas: el freno antes de la sorpresa

En el laboratorio el presupuesto es limitado y visible; en producción se administra con alertas y etiquetas.



Presupuesto
monto y umbrales

Notificación
correo o mensaje

Análisis por servicio
cómputo, almacenamiento, red

Etiquetas
proyecto · dueño · ambiente

Etiqueta ejemplo: proyecto = pedidos-planta · dueño = barranquilla · ambiente = prueba

En el laboratorio, AWS Academy tiene un presupuesto acotado y visible; la disciplina de apagar y terminar es la misma que se aplica en producción.

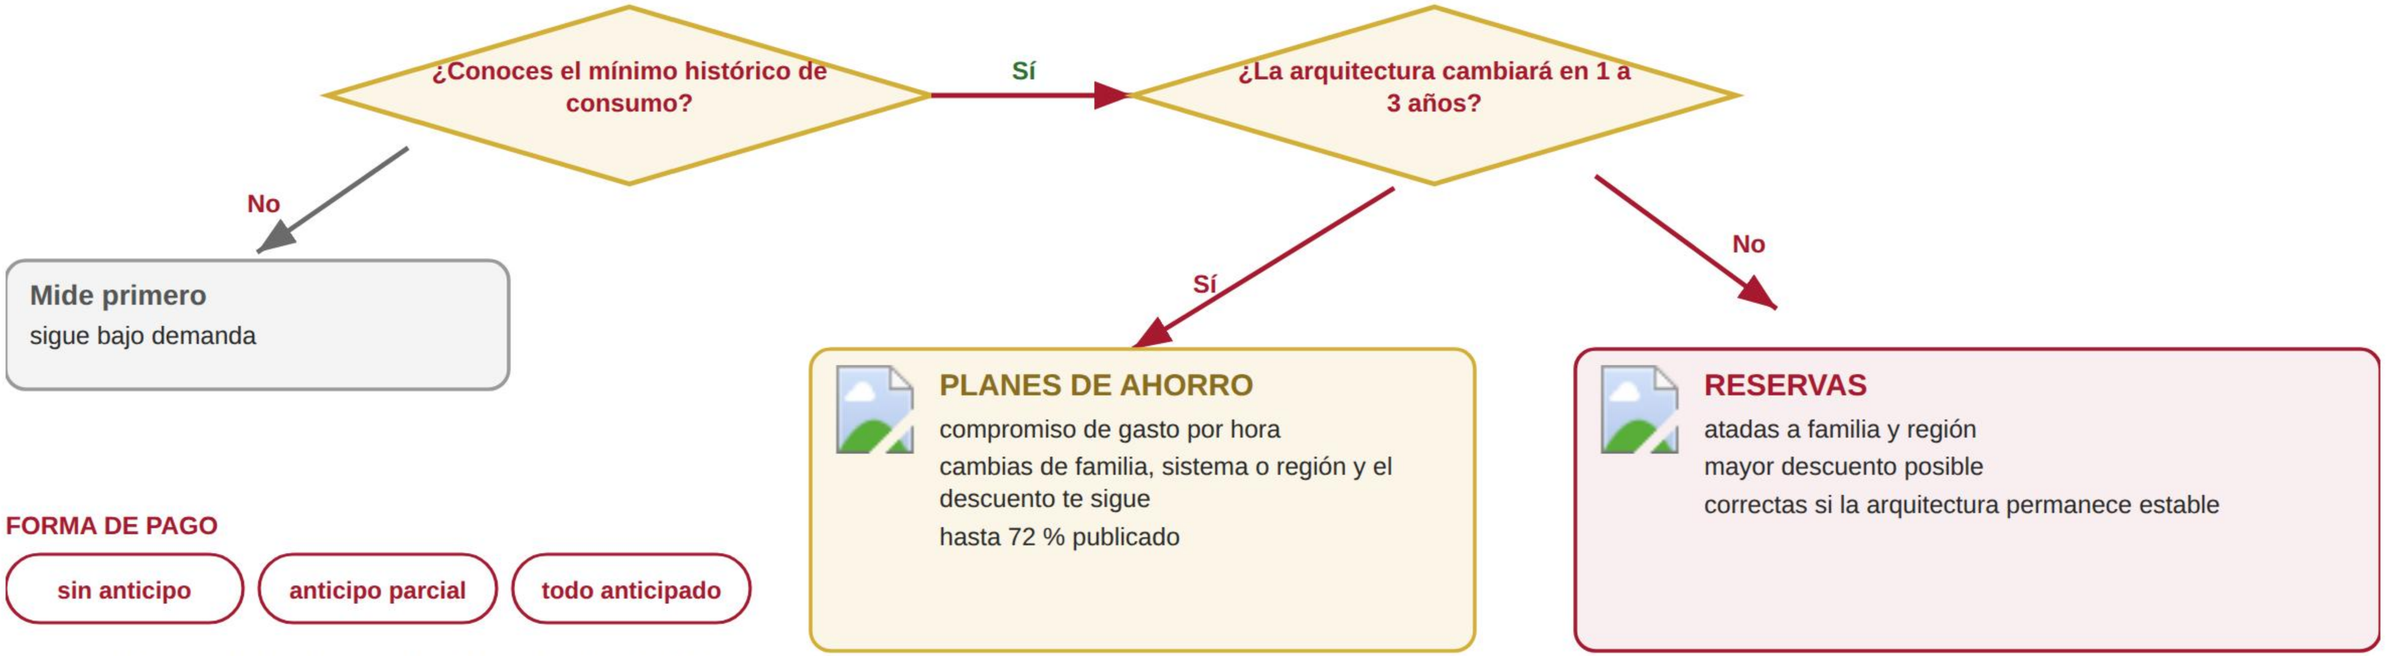
Control: en producción, el presupuesto se administra con alertas y etiquetas; sin etiquetas no hay dueño de la factura.

AWS — AWS Budgets, Cost Explorer y estrategias de etiquetado de costos (docs.aws.amazon.com)

DECISIÓN

Reservas o planes de ahorro: cómo elegir

Flexibilidad contra descuento: la decisión depende de cuánto puede cambiar la arquitectura durante el compromiso.



FORMA DE PAGO

sin anticipo | **anticipo parcial** | **todo anticipado**

a mayor anticipo y plazo, mayor descuento y menor flexibilidad

Regla común: se compromete el mínimo histórico de consumo, nunca el promedio. Lo comprometido se paga aunque no se use.

Criterio: flexibilidad contra descuento: la decisión depende de cuánto puede cambiar la arquitectura durante el compromiso.

SÍNTESIS

Lo que queda de la Parte 3

Tres modelos, una cartera y un principio: el diseño de la aplicación decide qué precio se puede pagar.

100 %

bajo demanda

flexibilidad total, sin compromiso ni riesgo

precio relativo

hasta 72 %

compromiso

descuento publicado sobre la demanda base estable

precio relativo

hasta 90 %

spot

descuento publicado para cargas tolerantes a interrupción

precio relativo

2 min

aviso spot

tiempo para reaccionar por diseño

2:00 → 0:00

PRINCIPIO DE LA PARTE

Sin tolerancia a fallos no hay spot; sin demanda medida no hay compromiso seguro.

El diseño de la aplicación decide qué precio se puede pagar.

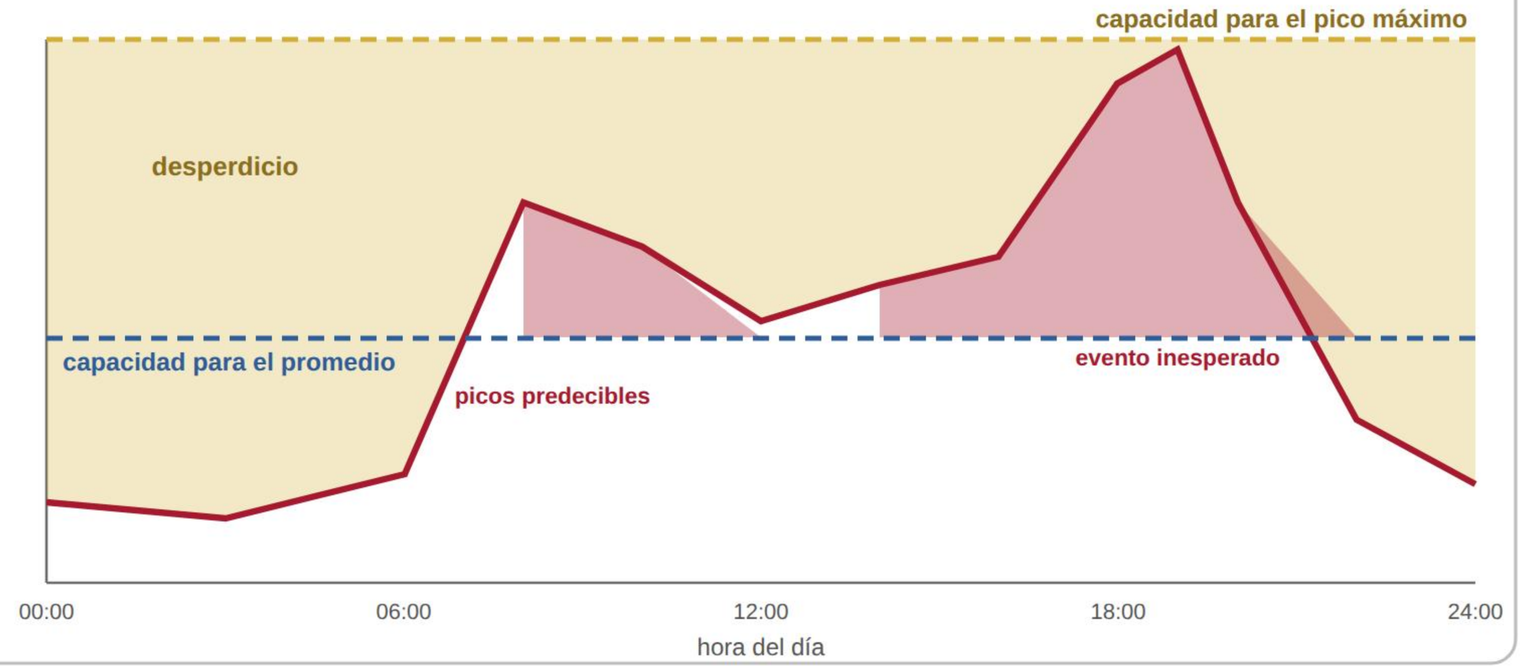
Sigue: Parte 3: cómo crece un sistema cuando la demanda sube, y el laboratorio de la semana.

EL PROBLEMA

La demanda no es constante

Dimensionar para el pico desperdicia; dimensionar para el promedio colapsa en el pico — la tensión que resuelve el escalado.

DEMANDA REAL DE UN SISTEMA A LO LARGO DEL DÍA



Dimensionar para el pico

Siempre alcanza, pero la mayor parte del día la capacidad está ociosa: se paga por lo que no se usa.

Dimensionar para el promedio

Es barato, pero colapsa en los picos: lentitud, errores y ventas perdidas justo cuando más importan.

La capacidad fija obliga a elegir entre desperdicio y colapso; el escalado rompe esa disyuntiva.

Problema: la tensión que resuelve el escalado: adaptar la capacidad a la demanda, no la demanda a la capacidad.

Hacia arriba: la misma máquina, más grande

Más vCPU, más memoria, más disco en la instancia existente — simple, con límite físico y con interrupción.

ANTES

m5.xlarge

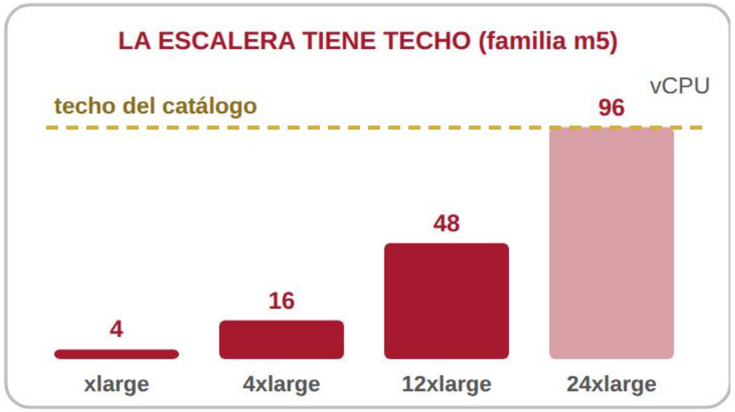
4 vCPU · 16 GiB

detener,
cambiar tipo,
arrancar

DESPUÉS

m5.4xlarge

16 vCPU · 64 GiB



LÍMITES DEL ESCALADO VERTICAL

Techo físico

la talla más grande del catálogo marca el límite

Interrupción

hay que detener y arrancar para cambiar de talla

Punto único de fallo

un solo servidor: si cae, cae todo

Útil como ajuste

y para bases monolíticas

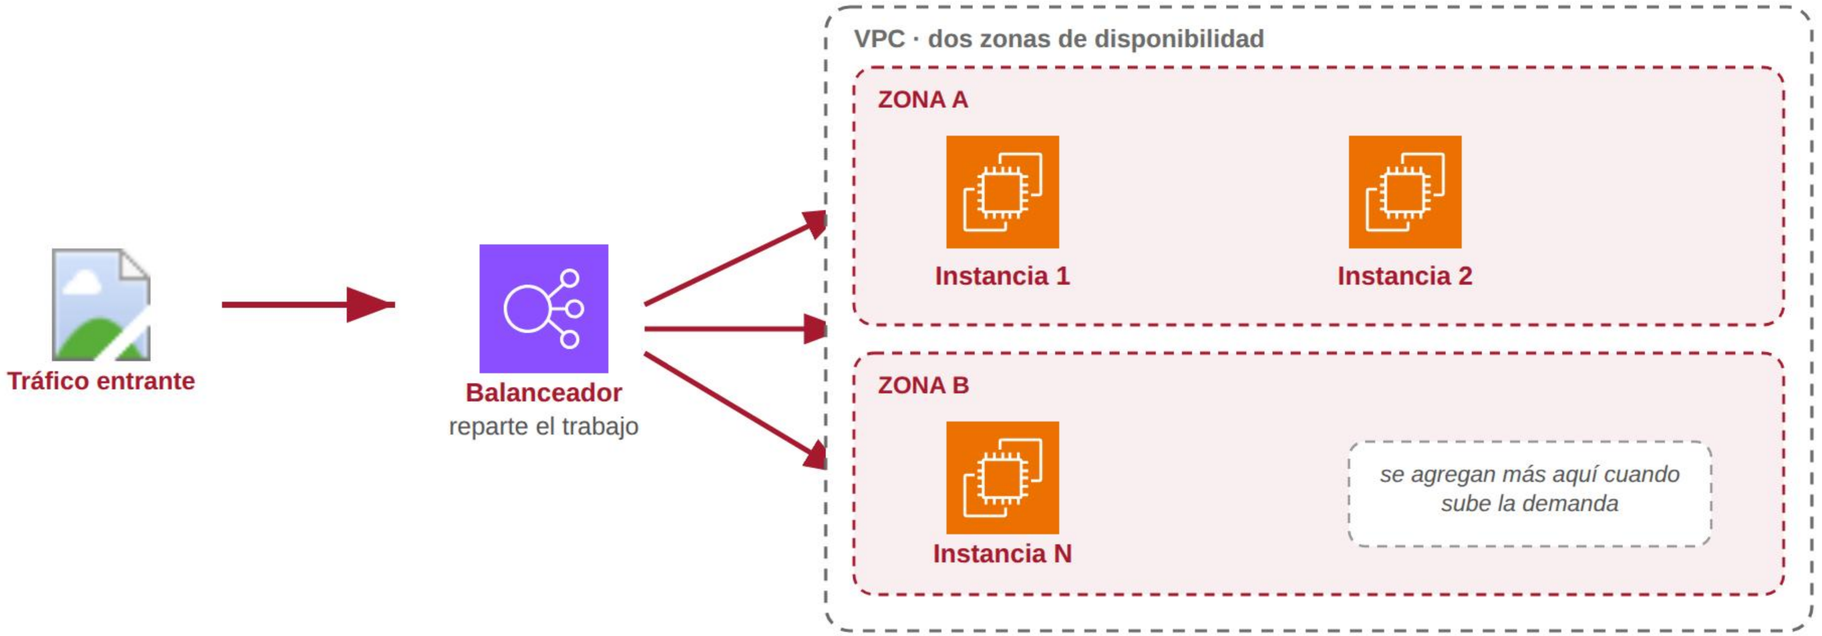
Vertical: simple para la aplicación, limitado para el sistema.

AWS — Change the instance type y tamaños de m5 (docs.aws.amazon.com/ec2) · valores de referencia

ESCALADO HORIZONTAL

Hacia afuera: más máquinas iguales

Agregar instancias idénticas y repartir el trabajo — sin límite práctico, con dos condiciones de diseño.



CONDICIONES DE DISEÑO

1. **Un balanceador que distribuya el tráfico**
2. **Instancias intercambiables, sin datos locales imprescindibles**

habilita redundancia y elasticidad

Sin techo práctico y sin punto único de fallo

agregar instancias idénticas y repartir el trabajo

Horizontal: si una instancia cae, el balanceador sigue repartiendo entre las demás.

AWS — Elastic Load Balancing y Amazon EC2 Auto Scaling · arquitectura Multi-AZ (docs.aws.amazon.com)

COMPARACIÓN

Vertical contra horizontal

Dos direcciones, criterios distintos: la decisión se toma por límite, disponibilidad y costo.

VERTICAL (scale up)	CRITERIO	HORIZONTAL (scale out)
el catálogo de tallas	Límite de capacidad	sin techo práctico
punto único de fallo	Tolerancia a fallos	tolera la caída de una instancia
requiere detener y arrancar	Al crecer	crece sin interrupción de servicio
ninguno: simple	Cambio en la aplicación	exige balanceador y sin estado

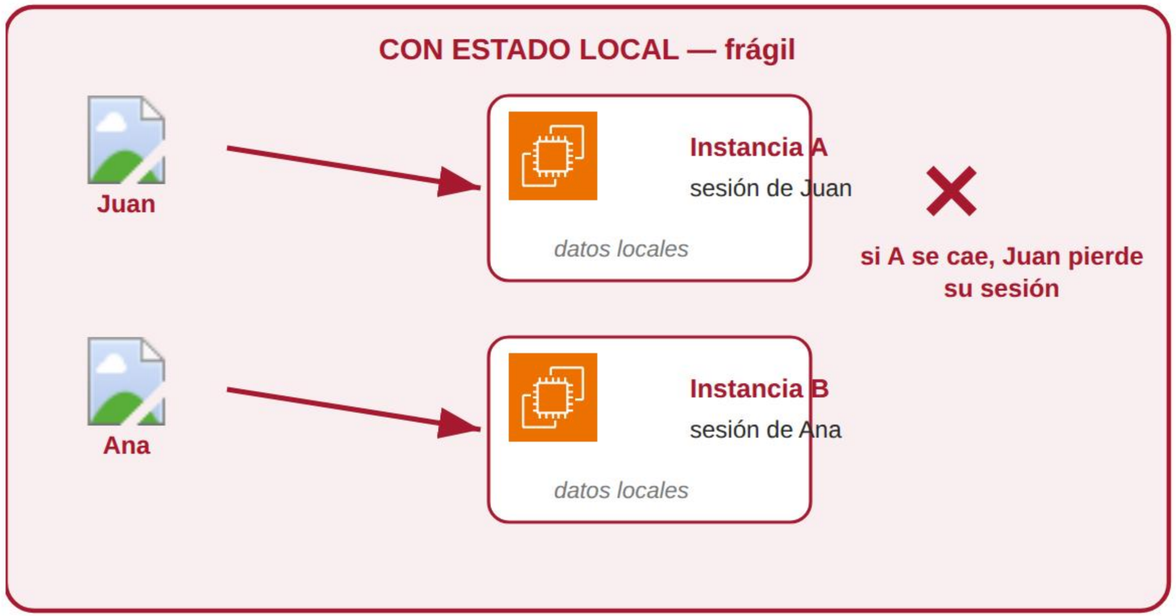
En la práctica, los sistemas maduros combinan las dos: ajuste vertical dentro de un rango y escalado horizontal para la variación.

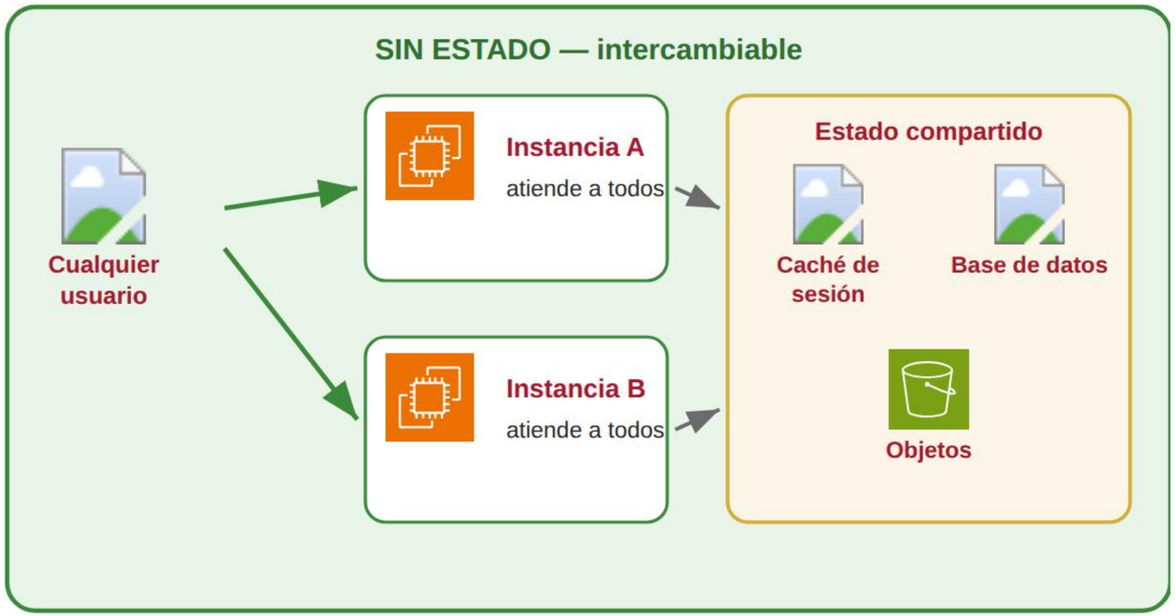
Criterio: la decisión se toma por límite, disponibilidad y costo; no hay una dirección universalmente superior.

CONDICIÓN DE DISEÑO

Sin estado: la propiedad que habilita todo

Si cada instancia puede atender cualquier solicitud, el grupo puede crecer, encogerse y reemplazarse sin que nadie lo note.





El estado vive en servicios compartidos (caché, base de datos, objetos). Es la misma propiedad que exige spot: la máquina puede desaparecer sin perder el trabajo.

Propiedad: si cada instancia puede atender cualquier solicitud, el grupo puede crecer, encogerse y reemplazarse sin que nadie lo note.

FUNDAMENTO

Por qué la nube empuja al horizontal

Unidades estándar creadas por API en minutos: la economía de la nube está construida sobre máquinas intercambiables.

MASCOTA: una máquina con nombre propio



servidor-pedidos-01

Se cuida a mano, se parcha a mano y, si se enferma, se cura. Nadie se atreve a apagarla.

GANADO: unidades estándar e intercambiables



web-01 · web-02 · web-03 · web-04 …

Se crean desde la misma imagen, se numeran y, si una falla, se reemplaza. Eso lo hace trivial la nube.

```
RunInstances imagen=web-v1.4 tipo=m5.large cantidad=10
```



La unidad es estándar

crear una instancia es una operación de API; crear diez es la misma operación repetida



La factura es por uso

pagar por unidad y tiempo hace racional agregar capacidad temporal



La operación se simplifica

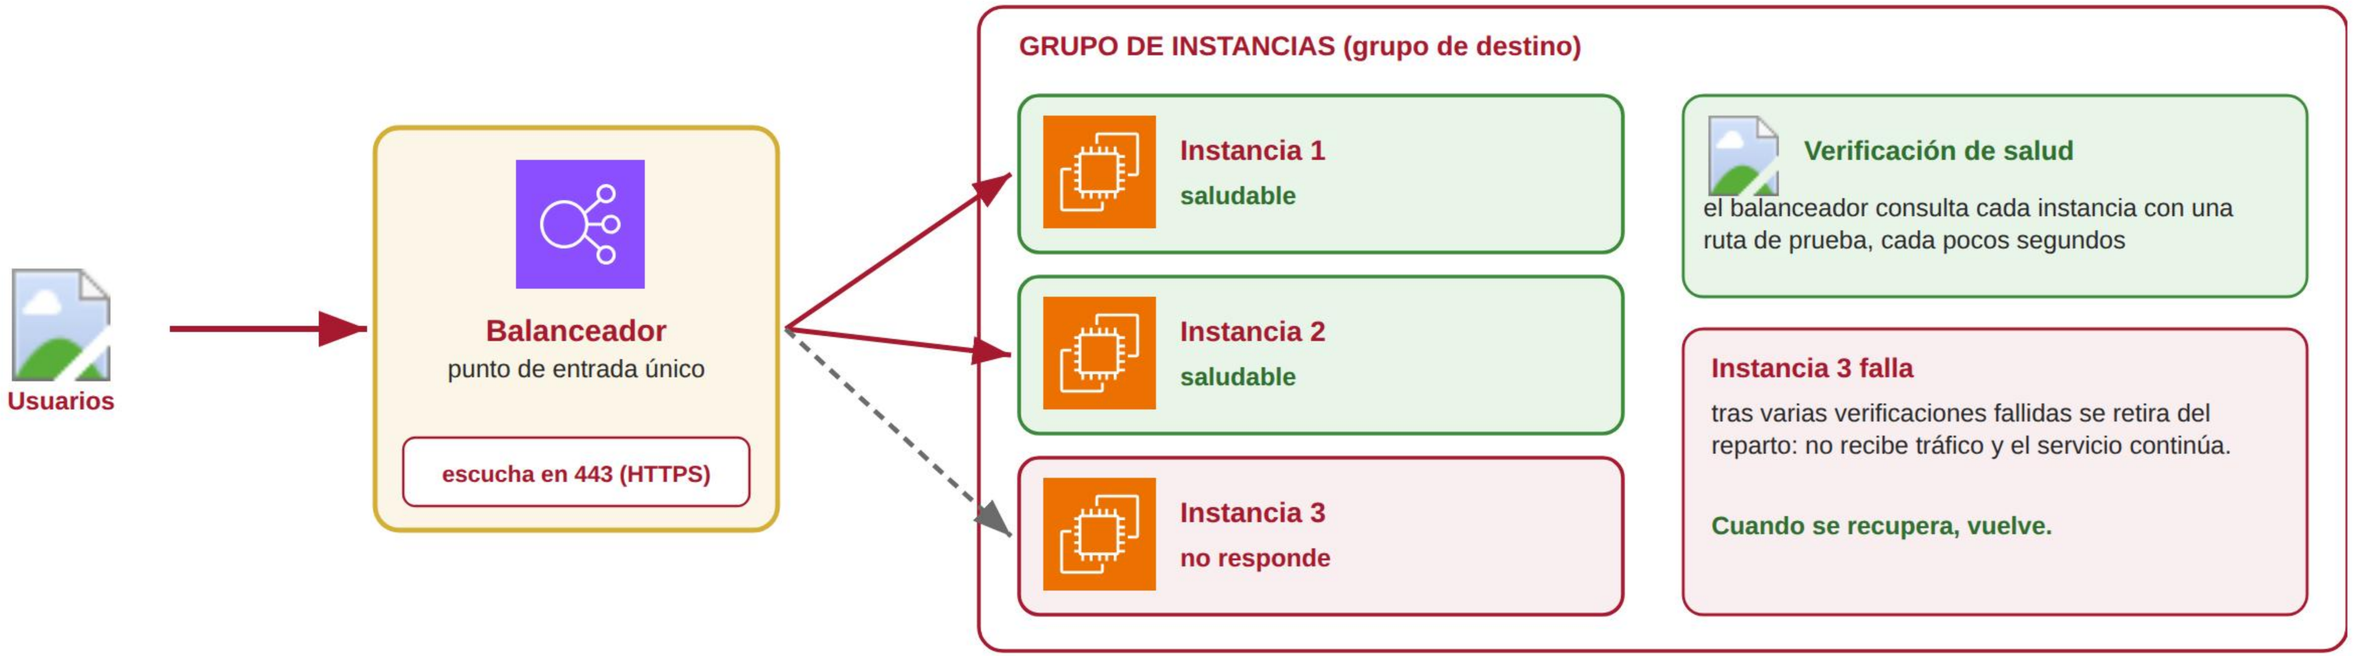
reemplazar, rotar versiones, distribuir entre zonas y recuperarse de fallos

Cambio de mentalidad: no se persigue la máquina más grande: se diseña un sistema donde agregar máquinas normales sea trivial.

PIEZA CLAVE

El balanceador de carga

El punto de entrada que reparte tráfico, verifica salud y permite crecer sin que el usuario lo note.



Reparte tráfico · verifica salud · permite reemplazos sin que el usuario lo note

es la pieza que hace posible el escalado horizontal

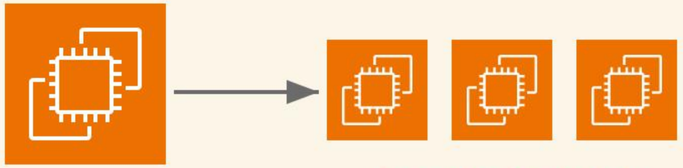
Resultado: la verificación de salud retira la instancia que no responde y el servicio continúa.

ESTRATEGIA

Híbrido y excepciones: dónde el vertical sigue mandando

La combinación razonable y el caso legítimo que la nube no resuelve por ti: las bases monolíticas.

ESTRATEGIA COMBINADA



Base ajustada verticalmente

instancias horizontales para la variación

La instancia base se dimensiona con métricas; las instancias horizontales absorben los picos.

EXCEPCIÓN: BASE MONOLÍTICA



Un solo escritor

La coherencia transaccional impide repartir el motor entre máquinas: se escala hacia arriba.

PUENTE A LA SEMANA 8



Base administrada

asume réplica, failover y respaldo: el escalado deja de ser tuyo.

Dos errores que evita: escalar horizontalmente una carga que exige coherencia total, y creer que el horizontal siempre es superior.

El criterio es estructural, no ideológico.

Criterio: lo estructural decide: lo que no se puede repartir, se hace más grande o se delega a un servicio administrado.

AWS — Amazon RDS: Multi-AZ y réplicas de lectura (docs.aws.amazon.com) · estrategia de elaboración propia

PLANIFICACIÓN

Cuántas instancias: pruebas de carga y capacidad

El tamaño del grupo no se adivina: se calcula con métricas por instancia y una prueba que simule la demanda real.

PRUEBA DE CARGA EN UNA SOLA INSTANCIA



CÁLCULO DEL TAMAÑO DEL GRUPO (ejemplo ilustrativo)

Capacidad	Pico de demanda	Margen
200 solicitudes/s por instancia	1.800 solicitudes/s	una instancia extra por si cae una

1.800 ÷ 200 = 9 + 1 de margen

10 instancias en el pico

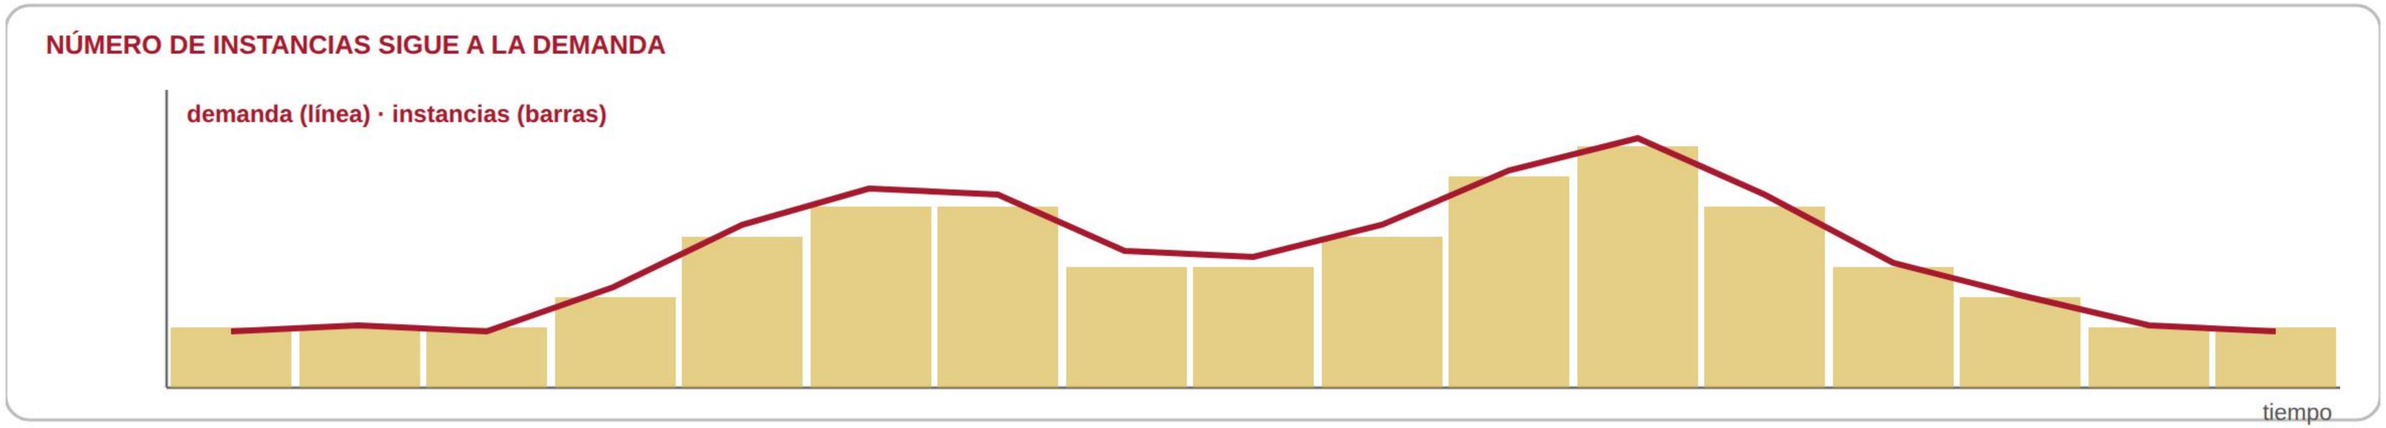
1. **Capacidad por instancia** — prueba de carga
2. **Demanda real** — pico típico y evento extremo
3. **Tamaño del grupo** — pico + margen por caída

Ojo: la prueba de carga revela el recurso escaso: CPU saturada pide más unidades o familia distinta; memoria saturada pide otra decisión.

Elasticidad: la pieza que falta

Decidir automáticamente cuándo agregar o quitar instancias según métricas — tema de la semana 10.





Diferencia: escalabilidad = poder crecer · elasticidad = crecer y encogerse solo, pagando lo usado.

AWS — Amazon EC2 Auto Scaling y Amazon CloudWatch (docs.aws.amazon.com) · curva ilustrativa

LABORATORIO

El laboratorio de esta semana: sitio dinámico sobre EC2

Actividad calificada del 10 % — módulo 5 de AWS Academy, escenario de cafetería.

Lab de desafíos AWS · Módulo 5 · 10 % de la nota

Escenario de cafetería: un sitio web dinámico ejecutándose sobre una instancia de cómputo. Se evalúa automáticamente revisando los recursos reales creados en la cuenta.



1. **Crear la instancia** — plantilla y talla: Partes 1 y 2
2. **Configurar la red** — subred, dirección y grupo de seguridad: semana 4
3. **Cuidar el ciclo de vida** — conservar o limpiar recursos: Parte 3

Se califica contra los recursos reales de la cuenta, no contra los pasos marcados en pantalla.

Nota: lo que se revisa es lo que existe en tu cuenta cuando entregas.

LABORATORIO

Checklist antes de enviar el laboratorio

Seis verificaciones que evitan perder el 10 % por un detalle de configuración o un recurso olvidado.

1



Instancia

existe, en ejecución, talla correcta

2



Aplicación

responde en la dirección pública

3



Red

subred correcta, solo puertos necesarios

4



Identidad

rol con acceso a lo requerido

5



Ciclo de vida

conservar o limpiar, sin huérfanos

6



Presupuesto

consumo dentro del límite

Un laboratorio con la instancia apagada o la aplicación caída se califica como no completado, aunque el trabajo previo haya sido correcto.

Antes de enviar: seis verificaciones evitan perder el 10 % por un detalle de configuración o un recurso olvidado.

CIERRE

Semana 7 en cuatro ideas

Instancia, ciclo de vida, precio y escalado: el criterio completo para decidir cómputo.

1



Instancia

máquina aislada por el hipervisor, creada desde una imagen

2



Ciclo de vida y talla

detener pausa · terminar destruye · la talla es reversible

3



Precio

cartera de modelos según compromiso y tolerancia a fallos

4



Crecer

horizontal sin estado + balanceador; vertical como excepción



Laboratorio de la semana 7 · 10 %

Sitio dinámico sobre EC2, escenario de cafetería: se califica contra los recursos reales de la cuenta.



Próxima semana, semana 8

Bases de datos administradas y backup. Laboratorio de migración a RDS (10 %).

Cierre: instancia, ciclo de vida, precio y escalado: el criterio completo para decidir cómputo en cualquier nube.