

La instancia virtual

Parte 1 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

La instancia virtual: del hardware compartido al servidor por API

El tercer pilar de la arquitectura

Almacenamiento y red ya están contruidos; hoy entra en escena el recurso que ejecuta la aplicación.




los tres pilares se necesitan entre sí: el laboratorio de esta semana toca los tres




Cuatro partes, cuatro preguntas de ingeniería

Cada parte responde una pregunta concreta; juntas forman el criterio para decidir cómputo en cualquier nube pública.




Hilo conductor: cada decisión de cómputo se evalúa con tres criterios



Meta: Al final de la hora sabrás elegir, comprar y hacer crecer un servidor virtual sin adivinar.

Anatomía de una instancia virtual

Una máquina de software con los mismos componentes de un servidor: procesador, memoria, disco y red.




El hipervisor: la capa que multiplica el hardware

Software que particiona un servidor físico en muchas máquinas aisladas, cada una con su propio sistema operativo.

TIPO 1 — nativo (centros de datos)



TIPO 2 — hospedado (escritorio)



¿QUÉ USA CADA NUBE?



AWS: Nitro

hipervisor ligero basado en KVM



Azure: Hyper-V

el hipervisor de Microsoft



Google Cloud: KVM

kernel Linux como hipervisor



OpenStack: Nova

orquesta KVM u otros

Todos son tipo 1: la capa que multiplica el hardware vive en el servidor del proveedor

El laboratorio del curso corre sobre ese hipervisor: tú pides la instancia, la frontera no la administras.

La nube pública usa tipo 1; el tipo 2 es para tu portátil (VirtualBox, VMware Workstation).

Multi-nube: misma idea en todas las nubes; solo cambia el nombre del hipervisor.

Aislamiento: dos clientes, un mismo servidor

La frontera que impide que una instancia vea la memoria, los discos o el tráfico de otra.



FRONTERA ENTRE INQUILINOS — la garantiza el proveedor

hipervisor, memoria, discos y red virtual aislados.
Parte de la responsabilidad "de" la nube.



FRONTERAS DENTRO DE TU CUENTA — las diseñas tú



grupos de seguridad, subredes y roles de acceso.
Parte de la responsabilidad "en" la nube (semana 5).

Regla: el aislamiento entre clientes es del proveedor; el aislamiento entre tus propias cargas es tuyo.

Del servidor físico a la instancia

Lo que cambia no es la potencia: es el tiempo de provisión, el modelo de costo y la capacidad de crecer.

TIEMPO HASTA TENER EL PRIMER SERVIDOR ÚTIL (escala ilustrativa)




 CAPITAL Y COSTO	 CAPACIDAD	 CORREGIR UN ERROR
Servidor físico Inversión inicial y depreciación a varios años	Servidor físico Fija hasta la siguiente compra; el repuesto queda ocioso	Servidor físico Se corrige con dinero y tiempo
Instancia virtual Gasto operativo por uso: se paga por segundo	Instancia virtual Cambia de talla en minutos; la redundancia es asequible	Instancia virtual Se corrige en minutos: se termina y se crea otra

Consecuencia: el dimensionamiento deja de ser una apuesta a varios años y se vuelve una decisión reversible.

La imagen de máquina: la plantilla inmutable

Una plantilla versionada con sistema operativo, aplicaciones y configuración con la que se crean instancias idénticas.



user data: lo único que cambia en el primer arranque

```
#!/bin/bash
echo "Planta Barranquilla" > /var/www/html/index.html
systemctl start httpd
```

Imagen dorada: la plantilla que se cuida

construida una vez, probada y versionada (v1.4);
las instancias se reemplazan, no se parchan a mano;
los secretos nunca van dentro de la imagen.

Inmutable: para cambiar algo no se edita una instancia, se crea una imagen nueva y se reemplazan las instancias

Igual que Docker en contenedores y las imágenes de máquina de Azure y Google Cloud: la plantilla es la fuente de verdad.


Analogía: la imagen es la receta; la instancia, el plato servido. Cien instancias salen iguales.

Del clic al servicio: el arranque de una instancia

Cinco pasos que ocurren en minutos y que conviene saber leer cuando algo no funciona.




SI LA INSTANCIA NO RESPONDE, SE DIAGNOSTICA EN ORDEN INVERSO



Diagnóstico: revisa de afuera hacia adentro: lo último que se configuró es lo primero que falla.

Los discos de la instancia: raíz y datos

El volumen raíz define el arranque; los volúmenes de datos guardan lo que debe sobrevivir a la instancia.



¿QUÉ PASA CON LOS DATOS?


DETENER	se conserva	se conserva	se pierde	se conserva
TERMINAR	se elimina*	se conserva*	se pierde	se conserva

* por defecto: el volumen raíz se elimina al terminar y los de datos se conservan; ambos son configurables al crear la instancia.

Regla: lo que debe persistir nunca vive solo en el almacén local del host.

La red de la instancia: direcciones y firewall

Dirección privada estable, dirección pública reasignable y reglas de seguridad que siguen a la instancia.



Clave: el firewall sigue a la instancia; la dirección pública no, salvo que se reserve.

La identidad de la instancia: el rol, no las claves

La máquina obtiene credenciales temporales de un rol adjunto; nunca se guardan llaves dentro del servidor.



Regla: nunca se guardan claves de acceso dentro de la instancia: el rol entrega credenciales temporales.

Elegir la imagen correcta

No todas las plantillas sirven: sistema operativo, arquitectura, licencias y mantenimiento son criterios de selección.



Sistema y versión

Una versión sin soporte hereda vulnerabilidades en cada instancia creada de esa imagen.



Arquitectura

La imagen fija el procesador (x86 o ARM): no arranca en otra arquitectura.



Licenciamiento

Sistemas y software incluidos o facturados aparte: se ve en la factura.



Origen y mantenimiento

Imágenes propias versionadas y parchadas frente a imágenes de la comunidad sin control.


CICLO DE VIDA DE UNA IMAGEN DORADA PROPIA



Buena práctica: una imagen dorada propia, actualizada con un proceso definido: nada de imágenes anónimas.

Lo que queda de la Parte 1

Cuatro ideas para llevarse antes de hablar de ciclo de vida y dimensionamiento.



4

recursos que se dimensionan

vCPU, RAM, disco y red

idea 1



1

plantilla versionada

la imagen crea instancias idénticas

idea 2



0

claves guardadas en el servidor

la identidad es un rol

idea 3



3

capas de red que la protegen

tabla de rutas, NACL y grupo de seguridad

idea 4

SIGUIENTE PREGUNTA

¿Cómo se administra la instancia en el tiempo, deteniendo, redimensionando o terminando, y cómo se elige su talla?

pendiente

en ejecución

detenida

terminada

Sigue: Parte 2: ciclo de vida y tallas.

Ciclo de vida y tallas

Parte 2 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

Ciclo de vida y dimensionamiento: tallas, familias y factura

El ciclo de vida de una instancia


Seis estados y transiciones con nombre propio — saber leerlos evita el error de laboratorio más común.



Idea: cuatro estados estables y dos de paso: aprender los nombres evita el error de laboratorio más común.

Detener no es terminar

La confusión más costosa del laboratorio: una instancia detenida sigue existiendo y sigue generando cargos.



DETENER — la pausa

el cómputo deja de facturar

SE CONSERVA

disco raíz, volúmenes, IP privada e identidad

SE CONSERVA

se puede arrancar de nuevo en el mismo punto

SIGUE FACTURANDO

volúmenes e IP elástica reservada


SE PIERDE

el almacén local del host

SE PIERDE

la IP pública automática (cambia al arrancar)

Usa DETENER para pausar



TERMINAR — el borrado

la instancia deja de existir

SE DESTRUYE

la instancia: no hay vuelta atrás

SE DESTRUYE

el disco raíz, por defecto

SIGUE FACTURANDO

la IP elástica queda sin asociar: hay que liberarla

SE CONSERVA

los volúmenes de datos, por defecto

SE PIERDE

el almacén local del host

Usa TERMINAR para limpiar

Disciplina de laboratorio: detener lo que está en pausa y terminar lo que ya terminó. Activa la protección contra terminación en lo importante.

La factura cambia con cada estado

El cómputo factura solo en ejecución; el almacenamiento y las direcciones reservadas facturan casi siempre.

	pendiente	en ejecución	detenida	terminada
 Cómputo de la instancia	sin cargo	por segundo (mín. 1 min)	sin cargo	sin cargo
 Volumen raíz (EBS)	factura	factura	factura	se elimina por defecto
 Volúmenes de datos	factura	factura	factura	siguen: facturan
 IPv4 pública o elástica	por hora	por hora	por hora (elástica)	elástica sin asociar: factura
 Instantáneas (snapshots)	siempre	siempre	siempre	siempre


verde = no genera cargo en ese estado · rojo = sigue facturando

 Los cargos que nadie recuerda haber creado son los recursos huérfanos: volúmenes sueltos, direcciones sin asociar e instantáneas viejas.

Recuerda: el cómputo factura solo en ejecución; almacenamiento y direcciones facturan casi siempre.

Hibernar: congelar la memoria en disco

Cuando detener y arrancar desde cero tarda demasiado: el estado de la memoria se guarda y se restaura.



Arranque normal

sistema operativo + servicios + aplicación + carga de cachés

Desde hibernación

restaura la memoria y sigue




ideal para aplicaciones que tardan mucho en calentarse.

Requisitos: condiciones: familia compatible, hibernación habilitada al lanzar y espacio en el volumen raíz para la memoria.

Redimensionar: cómo crecer sin recrear la instancia

El tipo de instancia no es una decisión permanente: se cambia deteniendo, modificando y arrancando.




Lo que no arregla: una consulta ineficiente o una fuga de memoria. Subir de talla compra tiempo, no corrige el diseño.

Regla: el tipo de instancia no es una decisión permanente: se cambia deteniendo, modificando y arrancando.

Elegir talla: primero el recurso escaso

No se elige la instancia más grande: se identifica qué recurso limita la carga y se busca el perfil que lo maximiza.

SÍNTOMA EN LAS MÉTRICAS



Método: la talla final se ajusta con métricas reales, no con intuición, y es reversible.

Propósito general: el punto de partida

Equilibrio entre procesador y memoria — el perfil correcto para la mayoría de cargas de negocio.




Propósito general

Referencia: M y T

Equilibrio entre procesador y memoria: 4 GiB por vCPU en la familia M (m5.large: 2 vCPU, 8 GiB). La familia T añade ráfaga para picos cortos.

Ejemplo: la aplicación de pedidos de la Corporación Industrial del Caribe.




CUÁNDO USARLA

-  Servidores web y de aplicaciones
-  Desarrollo, pruebas y servicios internos
-  Primera talla cuando aún no hay métricas
-  Cuidado: una T con CPU alta constante agota créditos

SEÑAL EN LAS MÉTRICAS



Ninguno de los dos recursos domina: CPU y memoria se mueven en rangos medios y con holgura.




umbral 80 %

CPU
Memoria

Criterio: si no hay una razón medida para otra familia, esta es la elección por defecto y se corrige con métricas.

Optimizadas a cómputo: procesador de alta frecuencia

Cuando el cuello de botella es el cálculo: más CPU por cada gigabyte de memoria.




Optimizadas a cómputo

Referencia: C

Procesadores de alta frecuencia: 2 GiB por vCPU, la mitad de memoria que propósito general (c5.large: 2 vCPU, 4 GiB). Más cálculo por dólar.

Úsala cuando la métrica lo muestre, no cuando se suponga.

GiB de memoria por vCPU (referencia)



CUÁNDO USARLA



Lotes y análisis paralelo



Codificación y renderizado



Simulación y cálculo científico




Alta concurrencia por segundo

SEÑAL EN LAS MÉTRICAS



CPU sostenida sobre 80 % con memoria holgada: la carga pide cómputo, no más RAM.



Error simétrico: elegir cómputo para una carga con cachés grandes deja procesadores ociosos y presión de memoria.

Optimizadas a memoria: muchos gigabytes por vCPU

Bases de datos en memoria, cachés y analítica que mantienen grandes volúmenes de datos activos.




Optimizadas a memoria

Referencia: R y X

Muchos gigabytes por vCPU: 8 GiB por vCPU en la familia R (r5.large: 2 vCPU, 16 GiB). La familia X llega a proporciones aún mayores.

Una base o caché que no cabe en RAM se vuelve lenta.

GiB de memoria por vCPU (referencia)



CUÁNDO USARLA



Bases en memoria y cachés



Índices de búsqueda



Analítica con datos activos




Bases relacionales grandes

SEÑAL EN LAS MÉTRICAS



Memoria sostenida sobre 80 % con CPU holgada y consultas que se degradan al no caber en RAM.




Puente: este perfil reaparece en la semana 8 (bases administradas) y en la semana 12 (caché).

Almacenamiento y aceleradas: perfiles especializados

Rendimiento de disco sostenido o procesadores gráficos — dos nichos que no se cubren con tallas generales.

OPTIMIZADAS A ALMACENAMIENTO · I, D, H



Instancia
discos NVMe locales
en el mismo servidor

Discos locales de alto rendimiento y baja latencia.

- bases transaccionales de alto tráfico
- sistemas de archivos distribuidos
- búsqueda y almacenes de datos

Recuerda: el almacén local es efímero. Lo que debe persistir se replica o va a EBS y S3.

Señal: la carga espera al disco, no al procesador.

ACELERADAS · GPU Y CHIPS DE IA



GPU
entrenamiento e inferencia de modelos



Chips de IA
propios del proveedor

- renderizado profesional y simulación
- procesamiento gráfico intensivo
- video y visualización

Las más costosas por hora del catálogo: en el laboratorio consumen el presupuesto rápidamente.

COSTO RELATIVO POR HORA (ilustrativo)

General	Cómputo	Memoria	Almacenamiento	Acelerada
● ● ● ●	● ● ● ●	● ● ● ●	● ● ● ●	● ● ● ●

Para las cuatro familias: método único: identificar el recurso escaso, elegir el perfil y ajustar con métricas.

Arquitectura en la Nube · Semana 7 · Parte 2 de 4

AWS — Amazon EC2 instance types: Storage optimized y Accelerated computing (docs.aws.amazon.com)

11 / 14

Cómo leer el nombre de una instancia

Familia, generación, procesador y talla: cuatro datos en una cadena de texto.

m6g.2xlarge

familia

m general · c cómputo · r memoria · t
ráfaga

generación

más nueva, mejor precio y desempeño

procesador

g Graviton (ARM) · i Intel · a AMD · n
red

talla

large · xlarge · 2xlarge · 4xlarge...

LA TALLA SE DUPLICA CON CADA ESCALÓN (m5) 32 vCPU

2 vCPU
large

4 vCPU
xlarge

8 vCPU
2xlarge

16 vCPU
4xlarge

32 vCPU
8xlarge

MÁS EJEMPLOS

c7i.xlarge cómputo · gen. 7 · Intel · 4 vCPU

r6a.large memoria · gen. 6 · AMD · 2 vCPU

t3.micro ráfaga · gen. 3 · 2 vCPU y 1 GiB


i4i.large almacenamiento · gen. 4 · Intel

Ojo: no se memoriza el catálogo: se lee el patrón. La letra del procesador condiciona la compatibilidad de la imagen.


Créditos de ráfaga: cómo funcionan las familias T

La familia económica de propósito general no regala procesador: lo acumula y lo gasta en picos.

USO DE CPU A LO LARGO DEL DÍA



SALDO DE CRÉDITOS



Familia T (ráfaga)

Gana créditos cuando la carga está bajo la base y los gasta en los picos.

MODO ESTÁNDAR

al agotar los créditos se limita a la línea base.

MODO ILIMITADO

sigue acelerando y paga un extra por el exceso de créditos.

Ojo: una T con CPU alta constante deja de ser barata: para eso existen las familias M y C.

Lo que queda de la Parte 2

Ciclo de vida y dimensionamiento: dos decisiones reversibles si se administran con disciplina.



≠

detener ≠ terminar

pausar conserva y factura el almacenamiento; terminar destruye sin vuelta

idea 1



↕

la talla es reversible

se cambia deteniendo, modificando y arrancando

idea 2



1

recurso escaso

se identifica el límite antes de elegir la familia

idea 3



4

datos en el nombre

familia, generación, procesador y talla

idea 4

PUENTE CON LA PARTE 3: el mismo cómputo, tres precios



valores de referencia publicados

Puente: el mismo cómputo puede costar el 100 % o una fracción según cómo se compre.

Modelos de precio

Parte 3 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas


Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

Modelos de precio: pagar por lo que el diseño tolera

Por qué el cómputo domina la factura

Se factura por segundo de uso, con mínimo de un minuto por arranque — y por eso las decisiones de arquitectura se ven en el costo.

COMPOSICIÓN TÍPICA DE UNA FACTURA DE CÓMPUTO (proporciones ilustrativas)



FACTURACIÓN POR SEGUNDO (Linux, con mínimo de 1 minuto por arranque)




rayado dorado: segundos redondeados al mínimo

Primera regla: el cómputo se paga por tiempo encendido: apagar lo que no se usa es la primera optimización.

Bajo demanda: flexibilidad sin compromiso

Se paga la tarifa completa por segundo de uso, sin contrato ni anticipo — el modelo de la incertidumbre.

LO QUE SE PAGA SIGUE A LO QUE SE USA



Bajo demanda

Tarifa publicada por segundo, sin contrato ni anticipo: el precio de referencia contra el que se miden los demás.

CUÁNDO · cargas nuevas sin historial

CUÁNDO · picos impredecibles

CUÁNDO · desarrollo por jornada

CUÁNDO · laboratorio académico

Error 1: dejar todo bajo demanda por comodidad cuando la demanda base ya es conocida.


Error 2: comprometerse antes de conocer la demanda. Primero medir.

En el laboratorio: AWS Academy trabaja en este modelo: el objetivo es crear y destruir recursos, no optimizar contratos.

Compromiso: pagar menos por lo predecible

Reservas y planes de ahorro: a cambio de comprometer consumo por uno a tres años, el proveedor descuenta hasta 72 %.

SE COMPROMETE LA BASE; LO DEMÁS SE PAGA BAJO DEMANDA



RESERVAS

compromiso atado a familia y región
mayor descuento, menor flexibilidad
pago: todo anticipado, parcial o sin anticipo
ideal para la carga base muy estable



PLANES DE AHORRO

compromiso de gasto por hora (USD/h)
aplica a familias, sistemas y regiones
más flexibles, descuento algo menor
hasta 72 % de ahorro publicado

Regla: se compromete el mínimo histórico, no el promedio: la demanda que no se usa también se paga.

Spot: capacidad ociosa a precio de remate

El proveedor vende la capacidad que no está usando con descuentos publicados de hasta 90 % — a cambio, puede recuperarla.

LA CAPACIDAD DE UNA ZONA NO SIEMPRE SE USA COMPLETA

capacidad total de servidores en la zona

ocupada: bajo demanda y compromisos

ociosa

se vende como spot



Instancia spot

PRECIO RELATIVO

Bajo demanda 100 %

Spot desde ≈ 10 %

hasta 90 %

de descuento publicado
frente al precio bajo demanda

interrumpible

el proveedor puede reclamarla
el diseño debe tolerarlo

no acumulable

el consumo spot no está cubierto
por los planes de ahorro


Contrato implícito: "yo te cobro una fracción, tú aceptas que la máquina puede desaparecer"

Si la aplicación no puede cumplirlo, el ahorro es un riesgo.

Idea: spot es capacidad ociosa a precio de remate: el riesgo se paga con ingeniería.

Cómo se interrumpe una instancia spot

Aviso de dos minutos, tres formas de terminar y una señal preventiva que permite reaccionar antes.



QUÉ HACE UN DISEÑO PREPARADO



Migrar la carga

pedir capacidad en otra reserva y vaciar la instancia



Guardar estado

punto de control, cola o almacenamiento externo



Retirar del balanceador

drenar conexiones antes de que desaparezca



Reintentar

otra instancia retoma la tarea pendiente



El aviso se puede leer desde el servicio de metadatos de la instancia y también llega como evento al bus de eventos, donde puede disparar una función o una alarma.

Reacción por diseño: escuchar el aviso, guardar el trabajo y reintentar en otra instancia: eso convierte spot en ingeniería, no en lotería.

Qué cargas pueden usar spot

Sin estado, con reintentos y con puntos de control: el patrón que convierte la interrupción en un evento trivial.



SÍ: tolerantes a interrupción

requisito: unidades independientes y reintentables



trabajos por lotes y análisis de datos



contenedores y pipelines de integración continua



cómputo de alto rendimiento por unidades



entornos de prueba y desarrollo



NO: sin tolerancia a interrupción

el trabajo no se puede repetir sin efectos



bases de datos monolíticas con transacciones



sesiones guardadas localmente



controladores únicos del sistema



procesos no repetibles con efectos secundarios

PRUEBA: ¿el sistema continúa solo si la máquina desaparece?



Puntos de control

guardar avance cada cierto tiempo



Colas de tareas

las unidades esperan en la cola




Arquitecturas sin estado

cualquier máquina atiende

Patrón: tres técnicas convierten la interrupción en un evento trivial: puntos de control, colas y servicios sin estado.

La mezcla: cada carga al modelo que le corresponde

Base comprometida, picos spot, incertidumbre bajo demanda — una cartera, no un único modelo.




Compromiso

el mínimo histórico, no el promedio



Spot

picos predecibles tolerantes a fallos




Bajo demanda

cargas nuevas, experimentos y picos impredecibles

Condición: la arquitectura habilita la cartera: sin cargas sin estado no hay spot posible.

Lo que no aparece en el precio por hora

Transferencia de salida, almacenamiento, instantáneas y licencias: el costo real de una arquitectura.



Lo que aparece en la cotización: instancia × horas

precio por hora (ilustrativo)

línea de flotación



Transferencia de salida

se cobra por GB al salir a Internet o entre regiones; la entrada normalmente no



Volúmenes

facturan mientras existan, incluso con la instancia detenida



Instantáneas

respaldos incrementales por almacenamiento; se acumulan si nadie los limpia



Licencias

sistemas y software comercial: incluidos o facturados aparte según la imagen

Cada flecha es una decisión de arquitectura: regiones, replicación, respaldos y tráfico.

Consecuencia: el costo se estima por arquitectura, no por una instancia aislada.

Comparar tres estrategias con números

Ejercicio con supuestos didácticos explícitos: la mecánica del cálculo, no una tarifa real.

SUPUESTOS DIDÁCTICOS

ilustrativo, no es una cotización

10 instancias · mes de 720 horas · 0,10 USD por hora bajo demanda · 6 de base todo el mes · 4 variables, 360 h cada una

A · todo bajo demanda

base $6 \times 720 \times 0,10$

variable $4 \times 360 \times 0,10$

$\approx 576 \text{ USD}$

B · base comprometida (72 %) + variable bajo demanda

base con descuento

variable bajo demanda

$\approx 265 \text{ USD}$

ahorro frente a A: 54 %

C · base comprometida + variable en spot (90 %)

base con descuento

$\approx 135 \text{ USD}$

ahorro frente a A: 77 %

A: $(6 \times 720 + 4 \times 360) \times 0,10 = 576$ · B: $6 \times 720 \times 0,10 \times 0,28 + 4 \times 360 \times 0,10 \approx 265$ · C: $121 + 4 \times 360 \times 0,10 \times 0,10 \approx 135$

Supuestos didácticos: descuentos máximos publicados; en la práctica varían según plazo, familia y región. No usar como cotización.

Ahorrar por diseño antes que por contrato

Apagar, ajustar la talla y limpiar recursos huérfanos rinde más que cualquier descuento sobre una carga mal dimensionada.

1



Apagar lo que no se usa
desarrollo fuera de horario y pruebas olvidadas

2



Ajustar la talla
bajar de talla con métricas reales

3




Limpiar huérfanos
volúmenes, IP sin asociar, instantáneas viejas

4




Elegir almacenamiento
no todo necesita el disco más rápido

EJEMPLO: UNA INSTANCIA DE DESARROLLO DURANTE UNA SEMANA




50 h frente a 168 h por semana: ≈ 70 % menos cómputo sin comprar ningún contrato



Orden: secuencia profesional: los tres primeros pasos son reversibles; el compromiso no lo es.

Presupuesto y alertas: el freno antes de la sorpresa

En el laboratorio el presupuesto es limitado y visible; en producción se administra con alertas y etiquetas.



Presupuesto
monto y umbrales



Notificación
correo o mensaje



Análisis por servicio
cómputo, almacenamiento,
red



Etiquetas
proyecto · dueño · ambiente


Etiqueta ejemplo: proyecto = pedidos-planta · dueño = barranquilla · ambiente = prueba

En el laboratorio, AWS Academy tiene un presupuesto acotado y visible; la disciplina de apagar y terminar es la misma que se aplica en producción.

Control: en producción, el presupuesto se administra con alertas y etiquetas; sin etiquetas no hay dueño de la factura.

Reservas o planes de ahorro: cómo elegir

Flexibilidad contra descuento: la decisión depende de cuánto puede cambiar la arquitectura durante el compromiso.



FORMA DE PAGO

- sin anticipo
- anticipo parcial
- todo anticipado

a mayor anticipo y plazo, mayor descuento y menor flexibilidad

Regla común: se compromete el mínimo histórico de consumo, nunca el promedio. Lo comprometido se paga aunque no se use.

Criterio: flexibilidad contra descuento: la decisión depende de cuánto puede cambiar la arquitectura durante el compromiso.

Lo que queda de la Parte 3

Tres modelos, una cartera y un principio: el diseño de la aplicación decide qué precio se puede pagar.



100 %

bajo demanda
flexibilidad total, sin compromiso ni riesgo

precio relativo



hasta 72 %

compromiso
descuento publicado sobre la demanda base estable

precio relativo



hasta 90 %

spot
descuento publicado para cargas tolerantes a interrupción

precio relativo



2 min

aviso spot
tiempo para reaccionar por diseño

2:00 → 0:00

PRINCIPIO DE LA PARTE

Sin tolerancia a fallos no hay spot; sin demanda medida no hay compromiso seguro.
El diseño de la aplicación decide qué precio se puede pagar.

Sigue: Parte 4: cómo crece un sistema cuando la demanda sube, y el laboratorio de la semana.

Arquitectura en la Nube · Semana 7 · Parte 3 de 4

Síntesis de la Parte 3 · descuentos publicados por AWS (Savings Plans y EC2 Spot), consultados 2026-09

14 / 14

Escalado y laboratorio

Parte 4 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 7 · Periodo 2026-2 · Barranquilla, Colombia

Escalado y laboratorio: de una instancia a un sitio dinámico

La demanda no es constante

Dimensionar para el pico desperdicia; dimensionar para el promedio colapsa en el pico — la tensión que resuelve el escalado.



Dimensionar para el pico

Siempre alcanza, pero la mayor parte del día la capacidad está ociosa: se paga por lo que no se usa.



Dimensionar para el promedio


Es barato, pero colapsa en los picos: lentitud, errores y ventas perdidas justo cuando más importan.

La capacidad fija obliga a elegir entre desperdicio y colapso; el escalado rompe esa disyuntiva.

Problema: la tensión que resuelve el escalado: adaptar la capacidad a la demanda, no la demanda a la capacidad.

Hacia arriba: la misma máquina, más grande

Más vCPU, más memoria, más disco en la instancia existente — simple, con límite físico y con interrupción.



LÍMITES DEL ESCALADO VERTICAL



Techo físico

la talla más grande del catálogo marca el límite



Interrupción

hay que detener y arrancar para cambiar de talla



Punto único de fallo

un solo servidor: si cae, cae todo



Útil como ajuste

y para bases monolíticas

Vertical: simple para la aplicación, limitado para el sistema.

Hacia afuera: más máquinas iguales

Agregar instancias idénticas y repartir el trabajo — sin límite práctico, con dos condiciones de diseño.



Sin techo práctico y sin punto único de fallo

agregar instancias idénticas y repartir el trabajo

Horizontal: si una instancia cae, el balanceador sigue repartiendo entre las demás.

Vertical contra horizontal

Dos direcciones, criterios distintos: la decisión se toma por límite, disponibilidad y costo.


VERTICAL (scale up)	CRITERIO	HORIZONTAL (scale out)
el catálogo de tallas	Límite de capacidad	sin techo práctico
punto único de fallo	Tolerancia a fallos	tolera la caída de una instancia
requiere detener y arrancar	Al crecer	crece sin interrupción de servicio
ninguno: simple	Cambio en la aplicación	exige balanceador y sin estado

En la práctica, los sistemas maduros combinan las dos: ajuste vertical dentro de un rango y escalado horizontal para la variación.

Criterio: la decisión se toma por límite, disponibilidad y costo; no hay una dirección universalmente superior.

Sin estado: la propiedad que habilita todo

Si cada instancia puede atender cualquier solicitud, el grupo puede crecer, encogerse y reemplazarse sin que nadie lo note.




El estado vive en servicios compartidos (caché, base de datos, objetos). Es la misma propiedad que exige spot: la máquina puede desaparecer sin perder el trabajo.

Propiedad: si cada instancia puede atender cualquier solicitud, el grupo puede crecer, encogerse y reemplazarse sin que nadie lo note.

Por qué la nube empuja al horizontal

Unidades estándar creadas por API en minutos: la economía de la nube está construida sobre máquinas intercambiables.

MASCOTA: una máquina con nombre propio



servidor-pedidos-01

Se cuida a mano, se parcha a mano y, si se enferma, se cura. Nadie se atreve a apagarla.

GANADO: unidades estándar e intercambiables



web-01 · web-02 · web-03 · web-04 ...

Se crean desde la misma imagen, se numeran y, si una falla, se reemplaza. Eso lo hace trivial la nube.

```
RunInstances imagen=web-v1.4 tipo=m5.large cantidad=10
```



La unidad es estándar

crear una instancia es una operación de API; crear diez es la misma operación repetida



La factura es por uso

pagar por unidad y tiempo hace racional agregar capacidad temporal




La operación se simplifica

reemplazar, rotar versiones, distribuir entre zonas y recuperarse de fallos

Cambio de mentalidad: no se persigue la máquina más grande: se diseña un sistema donde agregar máquinas normales sea trivial.

El balanceador de carga

El punto de entrada que reparte tráfico, verifica salud y permite crecer sin que el usuario lo note.



Reparte tráfico · verifica salud · permite reemplazos sin que el usuario lo note


es la pieza que hace posible el escalado horizontal

Resultado: la verificación de salud retira la instancia que no responde y el servicio continúa.

Híbrido y excepciones: dónde el vertical sigue mandando

La combinación razonable y el caso legítimo que la nube no resuelve por ti: las bases monolíticas.

ESTRATEGIA COMBINADA




Base ajustada verticalmente

instancias horizontales para la variación

La instancia base se dimensiona con métricas; las instancias horizontales absorben los picos.

EXCEPCIÓN: BASE MONOLÍTICA



Un solo escritor

La coherencia transaccional impide repartir el motor entre máquinas: se escala hacia arriba.

PUENTE A LA SEMANA 8



Base administrada

asume réplica, failover y respaldo: el escalado deja de ser tuyo.

Dos errores que evita: escalar horizontalmente una carga que exige coherencia total, y creer que el horizontal siempre es superior.


El criterio es estructural, no ideológico.

Criterio: lo estructural decide: lo que no se puede repartir, se hace más grande o se delega a un servicio administrado.

Cuántas instancias: pruebas de carga y capacidad

El tamaño del grupo no se adivina: se calcula con métricas por instancia y una prueba que simule la demanda real.

PRUEBA DE CARGA EN UNA SOLA INSTANCIA



CÁLCULO DEL TAMAÑO DEL GRUPO (ejemplo ilustrativo)

Capacidad

200 solicitudes/s por
instancia

Pico de demanda

1.800 solicitudes/s

Margen

una instancia extra por si
cae una

$$1.800 \div 200 = 9 + 1 \text{ de margen}$$

10 instancias en el pico

1

Capacidad por instancia
prueba de carga

2

Demanda real
pico típico y evento extremo



3

Tamaño del grupo
pico + margen por caída

Ojo: la prueba de carga revela el recurso escaso: CPU saturada pide más unidades o familia distinta; memoria saturada pide otra decisión.

Elasticidad: la pieza que falta

Decidir automáticamente cuándo agregar o quitar instancias según métricas — tema de la semana 10.




Diferencia: escalabilidad = poder crecer · elasticidad = crecer y encogerse solo, pagando lo usado.

El laboratorio de esta semana: sitio dinámico sobre EC2

Actividad calificada del 10 % — módulo 5 de AWS Academy, escenario de cafetería.

Lab de desafíos AWS · Módulo 5 · 10 % de la nota

Escenario de cafetería: un sitio web dinámico ejecutándose sobre una instancia de cómputo. Se evalúa automáticamente revisando los recursos reales creados en la cuenta.




Se califica contra los recursos reales de la cuenta, no contra los pasos marcados en pantalla.

Nota: lo que se revisa es lo que existe en tu cuenta cuando entregas.

Checklist antes de enviar el laboratorio

Seis verificaciones que evitan perder el 10 % por un detalle de configuración o un recurso olvidado.

1

**Instancia**

existe, en ejecución, talla correcta

2

**Aplicación**

responde en la dirección pública

3

**Red**

subred correcta, solo puertos necesarios

4

**Identidad**

rol con acceso a lo requerido

5

**Ciclo de vida**

conservar o limpiar, sin huérfanos

6

**Presupuesto**

consumo dentro del límite


Un laboratorio con la instancia apagada o la aplicación caída se califica como no completado, aunque el trabajo previo haya sido correcto.

Antes de enviar: seis verificaciones evitan perder el 10 % por un detalle de configuración o un recurso olvidado.

Semana 7 en cuatro ideas

Instancia, ciclo de vida, precio y escalado: el criterio completo para decidir cómputo.

1



Instancia

máquina aislada por el hipervisor,
creada desde una imagen

2



Ciclo de vida y talla

detener pausa · terminar destruye · la
talla es reversible


3



Precio

cartera de modelos según compromiso
y tolerancia a fallos

4



Crecer

horizontal sin estado + balanceador;
vertical como excepción



Laboratorio de la semana 7 · 10 %

Sitio dinámico sobre EC2, escenario de cafetería: se califica contra los
recursos reales de la cuenta.



Próxima semana, semana 8

Bases de datos administradas y backup. Laboratorio de migración a RDS (10
%).

Cierre: instancia, ciclo de vida, precio y escalado: el criterio completo para decidir cómputo en cualquier nube.