

Alta disponibilidad: que el servicio no se caiga

Parte 1 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Medir, calcular y diseñar para que una falla no se note

Un solo servidor: la caída anunciada

El portal de pedidos de la Corporación Industrial del Caribe vive en una instancia y una base de datos, en una sola zona.



Punto único 1: la instancia

Si el servidor se reinicia o falla el hardware, el portal queda mudo hasta que alguien lo repare.

Punto único 2: la base de datos

Un solo nodo guarda todos los pedidos: sin copia en caliente no hay a dónde cambiar.

Punto único 3: la zona

Un corte de energía o red en esa zona apaga las dos piezas a la vez.

Costo de la caída (ilustrativo)

Lunes 2:15 p. m. cae el portal; se recupera a mano a las 3:45. Fueron 90 minutos de pedidos sin registrar y de despachos sin programar.


Tres palabras que no son sinónimas

Alta disponibilidad acorta la caída, tolerancia a fallos la elimina y la recuperación ante desastres restaura en otro sitio.




Alta disponibilidad (HA)

Se recupera sola en segundos o minutos. Hay una breve interrupción durante el failover.



Tolerancia a fallos (FT)

Cero interrupción: un componente gemelo ya está trabajando en paralelo y absorbe la falla.



Recuperación ante desastres (DR)

Se restaura el servicio en otra región. Tarda horas, pero sobrevive a la pérdida de todo un sitio.




Tiempo →

Medir la disponibilidad: MTBF y MTTR

Disponibilidad es el tiempo en servicio sobre el tiempo total; se mejora fallando menos o recuperando más rápido.

Cada falla abre un hueco; el tamaño del hueco es el tiempo de recuperación



$$\text{Disponibilidad} = \text{MTBF} \div (\text{MTBF} + \text{MTTR})$$

Mismo MTBF: la recuperación rápida mueve los nuevos

Ejemplo con MTBF de 720 horas (30 días)

Fallar menos

Componentes fiables, parches, redundancia que evita que una falla llegue al usuario.

Recuperar más rápido

Detección automática, failover y reemplazo de instancias sin intervención humana.

Mismo sistema, dos formas de recuperarse

MTTR de 4 horas (a mano)

$$720 \div 724 = 99,45 \%$$

MTTR de 5 minutos (automático)

$$720 \div 720,08 = 99,99 \%$$

Unas 48 horas de caída al año contra cerca de una hora.


(≈ 12 fallas al año de cada tipo; cifras ilustrativas)

Los nuevos: cuánta caída permite cada nivel

Pasar de 99 % a 99,99 % reduce la caída anual de más de tres días a menos de una hora.

Disponibilidad

Caída permitida por año por mes




Cada nueve adicional divide la caída permitida entre diez, y el costo de lograrlo sube más rápido.

Escala logarítmica en las barras. Año de 365 días; mes de 30,4 días. Los valores salen de $(1 - \text{disponibilidad}) \times \text{tiempo total}$.

En serie se resta, en paralelo se suma

Una cadena de dependencias es más débil que su pieza más débil; las réplicas independientes multiplican los nueves.

EN SERIE: todo debe funcionar a la vez, así que los porcentajes se multiplican




$$0,9999 \times 0,999 \times 0,9995$$

$$= 99,84 \%$$

≈ 14 horas de caída al año

Peor que cualquiera de las piezas por separado

EN PARALELO: basta con que una réplica viva, así que lo que falla se multiplica



Falla de ambos a la vez:

$$0,01 \times 0,01 = 0,0001$$

$$= 99,99 \%$$

Dos “dos nueves” hacen cuatro


Cuidado con el supuesto

Solo funciona si las fallas son independientes. Dos servidores en el mismo rack comparten la causa; por eso se reparten en zonas distintas.

Cazar los puntos únicos de falla (SPOF)


Un SPOF es cualquier pieza sin respaldo: si falla, cae todo el servicio. Se detecta preguntando qué pasa si esto desaparece.

Recorre la arquitectura de izquierda a derecha y marca todo lo que existe una sola vez



Regiones y zonas: la materia prima de la HA

Una región agrupa varias zonas de disponibilidad aisladas pero conectadas; de ahí sale la redundancia.




Región: área geográfica con varias zonas (tres o más) · **Zona:** sitio con falla independiente · **Borde:** puntos de presencia

Regla práctica: la alta disponibilidad se resuelve entre zonas de una región; el desastre regional, entre regiones.

Diseño multi-AZ: la VPC en dos zonas

Balanceador, servidores y base de datos se duplican por zona; una zona entera puede caer y el servicio sigue.




Redundancia en cada capa, no solo en una

Una cadena es tan fuerte como su eslabón más débil: cada capa necesita su propia respuesta a una falla.

Capa	Cómo se duplica		Mecanismo
 DNS y borde	Zona A Zona B	Servicio global con muchos puntos de presencia	Anycast
 Balanceo	Zona A Zona B	Un nodo del balanceador en cada zona	Nodos por zona
 Cómputo	Zona A Zona B	Auto Scaling reemplaza instancias dañadas	ASG multi-AZ
 Salida a Internet	Zona A Zona B	Una NAT por zona, tablas de rutas por zona	NAT por AZ
 Caché	Zona A Zona B	Réplica en otra zona y failover automático	Réplica + failover
 Base de datos	Zona A Zona B	Replicación síncrona a un standby	Multi-AZ
 Archivos y objetos	Zona A Zona B	S3 y EFS regional guardan en varias zonas	Regional

Cuando cae una zona completa

Chequeos, balanceador, Auto Scaling y failover de base de datos trabajan en cadena sin que nadie intervenga.



Qué ocurre, en orden


- 1 La zona A pierde energía o red
- 2 Fallan los chequeos de salud de los destinos de A
- 3 El balanceador deja de enviarles tráfico: todo va a B
- 4 Auto Scaling lanza instancias nuevas en B para recuperar la capacidad deseada
- 5 RDS promueve el standby de B a principal y actualiza el nombre DNS del endpoint

Sin intervención humana

Se pierden segundos o minutos; no horas.

Failover de la base de datos Multi-AZ

El endpoint DNS no cambia: la aplicación sigue usando el mismo nombre mientras el motor promueve al standby.



Regionales por diseño y zonales por defecto

Algunos servicios ya son multi zona; otros dependen de que tú distribuyas los recursos.

Ya vienen repartidos por la región

AWS opera la redundancia: tú solo eliges bien



S3

copias en 3 zonas o más



DynamoDB

replicada en 3 zonas



Balanceador

nodos por zona



SQS

colas redundantes



Lambda

ejecuta en varias zonas




Route 53

servicio global

Tú decides en qué zona viven

Si no los distribuyes, quedan en una sola zona



EC2

una instancia = una zona



Disco EBS

atado a su zona



RDS

una zona salvo Multi-AZ



ElastiCache

nodos por zona



NAT Gateway

una por zona



Subredes


cada una vive en una zona

Responsabilidad compartida

AWS ofrece las zonas; el diseño que las usa es tuyo.

Caso CIC: de una zona a dos zonas

Duplicar con criterio reduce la caída esperada diez veces; el costo adicional es menor que el de una caída larga.



10×

menos caída anual
(ilustrativo)

~2×

costo de infraestructura
(ilustrativo)

Minutos

recuperación sin
intervención humana

2 zonas

mínimo para la
producción de CIC

Lo que queda de la Parte 1

Cuatro ideas para llevarse antes de hablar del balanceador de carga.

1



Los nueves se calculan

$\text{Disponibilidad} = \text{MTBF} \div (\text{MTBF} + \text{MTTR})$. Cada nueve divide la caída entre diez.

2



Serie resta, paralelo suma

Las dependencias en cadena bajan el total; las réplicas independientes lo suben.

3



Cada capa necesita respaldo

Balanceo, cómputo, caché y datos se duplican entre zonas.

4



Caza el punto único

Pregunta qué pasa si la pieza desaparece y responde con automatización.



Siguiente: Parte 2 · Balanceo de carga

Tenemos servidores en dos zonas. Falta la pieza que reparte el tráfico y vigila cuál de ellos está sano.



Balanceo de carga: repartir y vigilar

Parte 2 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Capa 4 y capa 7, listeners, grupos de destino, health checks y DNS con failover

Un punto de entrada, muchos destinos

El balanceador publica un solo nombre y reparte cada solicitud entre servidores sanos de varias zonas.



Capa 4 contra capa 7: qué ve cada balanceador

El NLB decide con datos de transporte; el ALB entiende HTTP y por eso puede enrutar por contenido.

7 Aplicación

HTTP, gRPC, WebSocket

6 Presentación

cifrado, formato

5 Sesión

diálogo

4 Transporte

TCP, UDP, puertos

3 Red

IP, enrutamiento

2 Enlace

tramas

1 Física

señal

CAPA 4 · Network Load Balancer



NLB

Ve: IP origen, IP destino,
puerto y protocolo TCP o UDP

No lee el contenido

Decide por el flujo; conserva la IP del cliente

Millones de solicitudes por segundo, latencia mínima

CAPA 7 · Application Load Balancer



ALB

Ve: método, ruta, host,
encabezados, cookies

Lee la solicitud HTTP

Decide por contenido: /api, /pedidos, host

Redirecciones, TLS, autenticación, WAF

Paquete que ve el NLB

TCP 443 · 190.x.x.x → 10.0.1.25

Reenvía al destino por el puerto
No distingue /api de /imagenes.

Úsalo para: bases de datos, juegos, IoT,
IP fija, protocolos que no son HTTP.

Solicitud que ve el ALB

GET /api/pedidos/123
Host: pedidos.cic.com.co
Cookie: sesion=...

Envía /api al grupo de la API y
el resto al grupo del sitio web.

Úsalo para: sitios, APIs y microservicios.

Elastic Load Balancing: tres balanceadores, tres usos

ALB para HTTP, NLB para TCP y UDP de alto rendimiento, y GWLB para insertar appliances de seguridad.



Application Load Balancer

Capa 7

- ✓ HTTP, HTTPS y gRPC
- ✓ Rutas, hosts y encabezados
- ✓ Destinos: instancias, IP, Lambda
- ✓ WebSocket, WAF y autenticación

Úsalo para
Sitios web, APIs y microservicios



Network Load Balancer

Capa 4

- ✓ TCP, UDP y TLS
- ✓ Latencia ultrabaja y alto rendimiento
- ✓ IP estática por zona (Elastic IP)
- ✓ Conserva la IP del cliente

Úsalo para
Bases de datos, juegos, IoT, PrivateLink



Gateway Load Balancer

Capa 3


- ✓ Reparte hacia appliances virtuales
- ✓ Encapsula con GENEVE, puerto 6081
- ✓ Un solo punto para varios appliances
- ✓ Transparente para el tráfico

Úsalo para
Firewalls y sistemas de inspección

Heredado: Classic Load Balancer (capas 4 y 7 básicas). Para cargas nuevas se usan ALB, NLB o GWLB.
Los tres comparten la idea: un punto de entrada que reparte hacia destinos sanos en varias zonas.

Anatomía del ALB: listener, reglas y grupos de destino


El listener recibe la conexión, las reglas deciden y el grupo de destinos agrupa a quienes responden.



Reglas de enrutamiento en capa 7

Ruta, host, encabezado, consulta o IP de origen deciden a qué grupo va cada solicitud.

Una misma dirección pública puede atender muchos servicios si el balanceador entiende la solicitud



También: respuesta fija, redirección y autenticación con Cognito u OIDC antes de reenviar.

Health checks: quién entra y quién sale de rotación

El balanceador consulta cada destino con una ruta de prueba y retira a los que fallan varias veces seguidas.

CÓMO SE CONFIGURA (valores por defecto del ALB)

Ruta de prueba

/salud

Intervalo

30 s

Tiempo de espera

5 s

Umbral no sano

2 fallos

Umbral sano

5 aciertos

Código esperado


200

Un destino que falla y se recupera



sale de rotación

vuelve a rotación




Buenas prácticas

Una ruta propia como /salud que revise las dependencias críticas, no solo la portada. Ni muy laxo (deja pasar errores) ni muy estricto (saca servidores por un tropiezo). Si todos los destinos fallan, el ALB envía a todos en lugar de cerrar la puerta.

Balanceo entre zonas: cuando el reparto no es parejo


Sin cross-zone cada zona recibe la misma parte aunque tenga menos destinos; encendido, el reparto es por destino.



Sesiones: afinidad o servidores sin estado

La afinidad pega al usuario a un servidor; guardar la sesión fuera del servidor permite escalar y fallar con gracia.


CON AFINIDAD (sticky sessions)



Mismo usuario, mismo servidor mientras dure la cookie.

Si el servidor cae, la sesión se pierde.

SIN ESTADO LOCAL (recomendado)




Cualquier servidor atiende al usuario.

La sesión vive en ElastiCache o DynamoDB.

Terminación TLS: el candado en el balanceador

El ALB atiende el cifrado con un certificado de ACM y reenvía al servidor, que se libera de esa tarea.



Paso a paso

- 1 El navegador inicia TLS y pide el certificado
- 2 El listener usa el certificado de ACM (renovación automática)
- 3 ALB descifra y lee la solicitud HTTP
- 4 Reenvía al destino por HTTP, o cifra de nuevo hacia el servidor


Qué ganas al terminar TLS en el balanceador

Los servidores no gastan CPU en cifrar y el certificado se administra en un solo lugar (ACM).

SNI permite varios certificados en un mismo listener. Si la norma exige cifrado hasta el servidor, se vuelve a cifrar.


El balanceador en el borde, los servidores adentro

Los grupos de seguridad encadenados dejan una sola entrada pública; WAF y Shield protegen esa entrada.




Route 53: failover entre regiones o sitios

Cuando el chequeo de salud falla, el DNS deja de responder con el principal y entrega el secundario.



El mismo patrón en Azure y en Google Cloud

Entrada global, balanceo regional de capa 7 y de capa 4 hacia máquinas en varias zonas: cambian los nombres, no la idea.




Google Cloud Load Balancing: un solo balanceador global con una IP anycast, de capa 4 o de capa 7.

El patrón es el mismo: entrada global, balanceo regional por capa y destinos en varias zonas.

Caso CIC: el portal de pedidos con ALB

Route 53, WAF y ALB reciben; dos zonas con grupos de servidores y base de datos con standby responden.



Lo que queda de la Parte 2

Cuatro ideas para llevarse antes de hablar de Auto Scaling.

1



Capa 7 entiende, capa 4 reenvía

ALB enruta por contenido; NLB por flujo, con alto rendimiento.

2



Listener, regla, grupo, destino

Esa es la cadena de configuración de un balanceador.

3



Salud y reparto parejo


Health checks sacan a los caídos; cross-zone evita zonas saturadas.

4



Servidores sin estado

Sesiones fuera del servidor y TLS en el balanceador.



Siguiente: Parte 3 · Elasticidad

El balanceador reparte, pero la cantidad de servidores sigue fija. Ahora veremos cómo crecer y encogerse solos con la demanda.



Elasticidad: crecer y encogerse con la demanda

Parte 3 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas


Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Auto Scaling, políticas de escalado, escalado de la base de datos y la arquitectura de tres capas elástica


La demanda sube y baja; la capacidad también debería

Con capacidad fija se desperdicia de madrugada y se pierde en el pico; la elástica sigue la curva de pedidos.

Capacidad fija: se paga lo que no se usa



Capacidad elástica: sigue a la demanda



— Demanda — Capacidad Capacidad ociosa: costo sin uso Demanda sin atender: ventas perdidas


Datos ilustrativos de un día de pedidos de CIC

Escalar hacia arriba o hacia los lados

Un servidor más grande tiene techo; más servidores iguales detrás de un balanceador casi no lo tienen.


ESCALAR VERTICALMENTE (scale up)

Una máquina más potente



Límite del hardware y reinicio al cambiar de tamaño
Sigue siendo un punto único de falla

ESCALAR HORIZONTALMENTE (scale out)



Casi sin límite y sin reinicios
Exige servidores sin estado y un balanceador

Escalabilidad

Capacidad del sistema para crecer cuando hace falta.
Puedes lograrla a mano.

Elasticidad

Crear y encogerse automáticamente con la demanda.
Exige automatización, métricas y políticas.


Anatomía de un grupo de Auto Scaling

El grupo conserva el número deseado de instancias, entre un mínimo y un máximo, repartidas por zonas.




La plantilla de lanzamiento: la receta de cada instancia

Imagen, tipo, red, permisos y arranque quedan en una plantilla versionada que el grupo usa para crear instancias.



Mínima, deseada y máxima: los tres números

La capacidad deseada se mueve con la demanda, pero siempre dentro de los límites que tú defines.



Nunca baja de 2: siempre hay dos zonas con servicio

Deseada llega al tope: el grupo no pasa de 8

Máxima = 8

Mínima = 2

Regla de oro: mínimo $\geq$ número de zonas, para que ninguna zona quede sin servidores.

Con 2 zonas y mínimo 1, una zona puede quedar vacía.

Mínima

Piso de disponibilidad: con dos instancias en dos zonas el sistema resiste la caída de una zona.

Deseada


Cuántas instancias quiere el grupo ahora mismo. Las políticas la mueven.

Máxima

Techo de costo y de seguridad: protege de una factura inesperada o un error de métrica.

Seguimiento de objetivo: el termostato de la nube

Eliges una métrica y un valor deseado; el grupo suma o resta instancias para mantenerlo.



La política agrega instancias cuando el promedio sube del objetivo y las quita, con más calma, cuando baja.



Como un termostato

Tú fijas la temperatura (50 % de CPU).

Auto Scaling crea y administra las alarmas de CloudWatch por ti.



Métricas predefinidas

- ✓ CPU promedio del grupo
- ✓ Red de entrada promedio
- ✓ Red de salida promedio
- ✓ Solicitudes por destino del ALB

También puedes usar una métrica propia

Escalado por pasos: la respuesta proporcional

Cuanto mayor es la brecha frente al umbral, más instancias se agregan de una sola vez.



Cuándo conviene

Cuando quieres controlar la respuesta: un salto grande de carga merece más instancias que uno pequeño. Tú defines las bandas y los ajustes.

Pasos o simple


Por pasos reacciona proporcional a la brecha. La política simple agrega una cantidad fija y espera un enfriamiento.

Con calentamiento

Define cuánto tarda una instancia nueva en aportar, para que no se cuente doble en la métrica.

Escalado programado: anticiparse al calendario

Si sabes cuándo llega la carga, ajusta la capacidad a una hora fija en lugar de esperar a que la métrica reaccione.



Una semana típica: las acciones programadas ajustan mínimo, máximo y deseada a horas fijas

Úsalas cuando conoces el calendario

Nómina, cierres de mes, campañas del Día sin IVA o inicio del turno de planta.

Se combinan con las dinámicas

La programada fija el piso del pico; seguimiento de objetivo absorbe lo inesperado.



Acción programada

Nombre: subir-laboral

Cron: 0 7 * * 1-5

Zona horaria: America/Bogota


Mínimo 4 · Máximo 14

Deseada 10

Otra acción a las 19:00
baja de nuevo a 4.

Escalado predictivo: aprender del patrón

Con la historia de la métrica, el servicio pronostica la carga y lanza instancias antes de que el pico llegue.



El modelo aprende el patrón diario y semanal de la métrica y lanza instancias antes de que llegue la carga.

Dos modos

Solo pronóstico: ves qué haría. Pronóstico y escalado: lo aplica.

No reemplaza a la reactiva


Cubre lo previsible; el seguimiento de objetivo cubre lo imprevisto.

Cómo funciona


- ✓ Usa hasta 14 días de historia de CloudWatch
- ✓ Necesita al menos 24 horas de datos
- ✓ Pronostica las siguientes 48 horas
- ✓ Funciona con patrones cíclicos

Ciclo de vida, drenaje y enfriamiento

Auto Scaling no apaga a ciegas: drena conexiones, respeta pausas y deja ganchos para tareas propias.




Desescalado con cuidado: lo que pasa cuando el grupo retira una instancia



Escalar la base de datos: lecturas y escrituras

Las lecturas se reparten entre réplicas; las escrituras siguen un solo escritor y crecen en vertical.



Lecturas: horizontal

Más réplicas y un endpoint de lectura que las reparte. Aurora puede agregar réplicas con Auto Scaling.

Escrituras: vertical


Cambiar la clase de instancia exige breve interrupción; en Multi-AZ el corte es mínimo.

Otras opciones

Almacenamiento con autoescalado. Aurora Serverless v2 ajusta la capacidad. DynamoDB: bajo demanda.

Arquitectura web de tres capas elástica


Cada capa tiene su balanceador y su grupo, y escala con su propia métrica; los datos se replican entre zonas.



¿Cuánto cuesta la elasticidad?

Pagar por uso reduce el costo del portal a menos de la mitad frente a capacidad fija dimensionada para el pico.

Costo mensual de cómputo del portal (dólares ilustrativos)



Supuesto: 0,10 USD por hora de instancia; 720 horas al mes. Cifras ilustrativas.

Cómo se calcula

Fijo: $10 \times 720 \text{ h} \times 0,10 = 720 \text{ USD}$

Elástico: $4,5 \times 720 \text{ h} \times 0,10 = 324 \text{ USD}$

Ahorro ilustrativo: 55 %

Base estable

El mínimo siempre encendido se compra con Savings Plans o instancias reservadas.

Picos

La capacidad extra puede usar Spot, con descuentos de hasta 90 por ciento, si tolera interrupciones.

Caso CIC


El portal pasó de 10 instancias fijas a un grupo de 4 a 12.

Máximo 12 evita facturas inesperadas; la elasticidad pone el costo al ritmo de los pedidos.

Lo que queda de la Parte 3

Cuatro ideas para llevarse antes de hablar de monitorización.

1



Elasticidad es automática

Crecer y encogerse con la demanda; escalar hacia los lados.

2



Grupo + plantilla

Mínimo, deseado y máximo; la plantilla es la receta versionada.

3



Cuatro políticas

Objetivo, pasos, programada y predictiva; combínalas.

4



Los datos escalan distinto

Réplicas para leer, clase mayor para escribir, caché delante.



Siguiente: Parte 4 · Monitorización y laboratorio

Todo lo que escala depende de métricas. Veremos cómo se miden, se alarman y se visualizan, y armaremos el entorno escalable del laboratorio.



Monitorización, alarmas y laboratorio

Parte 4 de 4 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Métricas, logs y trazas; alarmas que escalan; tableros; Azure Monitor; recomendaciones y el laboratorio

Tres señales: métricas, logs y trazas

Las métricas avisan que algo pasa, los logs explican qué y las trazas muestran dónde.



Métricas

¿Cuánto y qué tan rápido?

Números en el tiempo: CPU, solicitudes, latencia, errores.

Para: Alarmas y escalado

CloudWatch Metrics




Logs

¿Qué pasó exactamente?

Registros de eventos con texto: errores, accesos, auditoría.

Para: Diagnóstico y búsqueda

CloudWatch Logs



Trazas

¿Dónde se demora?

El recorrido de una solicitud a través de los servicios.

Para: Cuellos de botella

AWS X-Ray

De la señal a la acción



Recurso emite



Se recolecta



Alarma evalúa



Notifica



Actúa: escala

CloudWatch: cómo se organizan las métricas

Una métrica es una serie en el tiempo con espacio de nombres, nombre y dimensiones; los datos se conservan hasta 15 meses.

Cómo se organiza una métrica

Espacio de nombres

AWS/EC2, AWS/ApplicationELB

Nombre de métrica

CPUUtilization, RequestCount


Dimensión

InstanceId, AutoScalingGroupName

Puntos de datos

valor + marca de tiempo + unidad

Resolución y retención de los datos



EC2: monitoreo básico y detallado

Básico: un punto cada 5 minutos, sin costo.
Detallado: un punto por minuto, con costo. El escalado rápido necesita el detallado.

Lo que no ve el hipervisor


CPU, red y disco sí llegan sin instalar nada.
La memoria y el espacio en disco no: requieren el agente de CloudWatch.

Métricas personalizadas


Tu aplicación puede publicar las suyas: pedidos por minuto, tamaño de cola, tiempo de checkout. Es la mejor señal para escalar por negocio.

El agente, los logs y las demás fuentes

El agente de CloudWatch lleva memoria, disco y logs de la aplicación; otros servicios aportan auditoría y red.




Otras fuentes que alimentan la observabilidad




Trazas distribuidas: dónde se va el tiempo

Una traza reúne los tramos de una misma solicitud y señala cuál servicio la retrasa.

Mapa de servicios: una solicitud a /api/pedidos



Traza de la solicitud (milisegundos, ejemplo)




Lectura

La consulta SQL concentra casi toda la demora: ahí se optimiza, no en el servidor web.

Alarmas: umbral, periodos y acciones

Una alarma vigila una métrica y cambia de estado cuando el umbral se incumple durante varios periodos.



Tres estados posibles de una alarma de CloudWatch

Cómo se define

Métrica y estadística (promedio, máximo, percentil), periodo de 1 minuto, 3 periodos de evaluación y 3 puntos para alarmar.

Datos faltantes


Elige si faltan datos cuenta como incumplimiento, como bueno o se ignora.



Acciones: notificar, escalar, reiniciar o recuperar la instancia

La alarma que dispara el escalado

La métrica, la alarma y la política forman un bucle que agrega instancias hasta que la carga se normaliza.




Alta: sube capacidad cuando el promedio supera el umbral · Baja: la quita cuando cae por debajo, con más calma
 Es un bucle de retroalimentación negativa: cuanto más sube la carga, más capacidad se agrega, hasta estabilizarse.

Tableros: los cuatro indicadores de oro


Tráfico, latencia, errores y saturación cuentan la salud del servicio en una sola pantalla.

Tablero «Portal CIC»: los cuatro indicadores de oro


Tráfico: solicitudes por minuto




Latencia (p95) en milisegundos




Errores 5xx por minuto



Saturación: CPU del grupo (%)



Instancias en servicio



Estado de alarmas

- ✓ CPU alta · OK
- ✗ Errores 5xx · EN ALARMA
- ✓ Latencia p95 · OK
- ✓ Destinos sin salud · OK




Los tableros de CloudWatch se comparten entre cuentas; Grafana administrado sirve para combinar varias fuentes de datos.

Azure Monitor: recolectar, analizar y actuar


Azure Monitor recoge métricas y registros, los visualiza, genera alertas y puede disparar el escalado automático.

Azure Monitor: la misma idea en otra nube



Trusted Advisor y Advisor: revisiones automáticas

Las herramientas de recomendación revisan tu cuenta y señalan costos, seguridad, rendimiento y resiliencia por mejorar.



Los planes Business y Enterprise desbloquean todas las verificaciones.
El plan básico incluye las verificaciones centrales de seguridad y límites.



AWS Health Dashboard

Eventos de AWS que afectan tu cuenta:

fallas de un servicio en tu región, mantenimientos programados y avisos de retiro de funciones.

Puede enviar eventos a EventBridge y SNS.




Azure Advisor

Recomendaciones personalizadas en confiabilidad, seguridad, rendimiento, excelencia operativa y costos.

Azure Service Health: el equivalente del Health Dashboard.

Caso integrador: el portal de CIC completo

Alta disponibilidad, balanceo, elasticidad y monitorización conviven en una sola arquitectura.




Laboratorio: arquitectura final del entorno

El resultado es un sitio web de cafetería con balanceador, grupo de Auto Scaling en dos zonas y alarmas.

Laboratorio · entorno escalable y altamente disponible (escenario de la cafetería)


min 2 · máx 6

Valen 10 por ciento de la nota. Plataforma: AWS Academy Learner Lab.




Laboratorio paso a paso: de una instancia a un grupo

Ocho pasos: AMI, balanceador, plantilla, grupo, política, y dos pruebas de alta disponibilidad y elasticidad.



Laboratorio: la prueba de carga y las evidencias

Genera carga, mira cómo la alarma y el grupo responden, y documenta con capturas lo que observaste.



Qué observar: CPU sube, alarma pasa a ALARM, el grupo agrega instancias y la CPU vuelve cerca del objetivo.

Evidencias para entregar

- ✓ Captura del grupo de destinos con destinos sanos en dos zonas
- ✓ Captura del grupo de Auto Scaling con mínimo, deseada y máximo
- ✓ Captura de la alarma en estado ALARM durante la carga
- ✓ Captura de la actividad de escalado (instancias lanzadas)
- ✓ Captura del reemplazo tras terminar una instancia
- ✓ Respuesta breve: ¿por qué dos zonas y qué pasaría con una?

Al terminar, elimina el grupo, el ALB, la AMI y los snapshots para no gastar crédito.

Semana 10 en cuatro ideas

Alta disponibilidad, balanceo, elasticidad y monitorización forman un solo diseño; el siguiente paso es automatizarlo.

1



Se mide en nueves

Multi-AZ, sin puntos únicos y redundancia en cada capa.


2



El balanceador reparte y vigila

ALB en capa 7, NLB en capa 4, health checks y Route 53.

3



La capacidad sigue la demanda

Auto Scaling con plantilla y políticas; datos con réplicas.

4



Sin métricas no hay escalado

CloudWatch, alarmas, trazas y tableros cierran el ciclo.



Semana 11 · Infraestructura como código (IaC)

Lo que hoy armaste con clics, la próxima semana lo describiremos en plantillas repetibles con CloudFormation y Terraform. También repasaremos la Unidad 2.

