SEMANA 10 · ELASTICIDAD, ALTA DISPONIBILIDAD Y MONITORIZACIÓN

Alta disponibilidad: que el servicio no se caiga

Parte 1 de 3 · Unidad 2

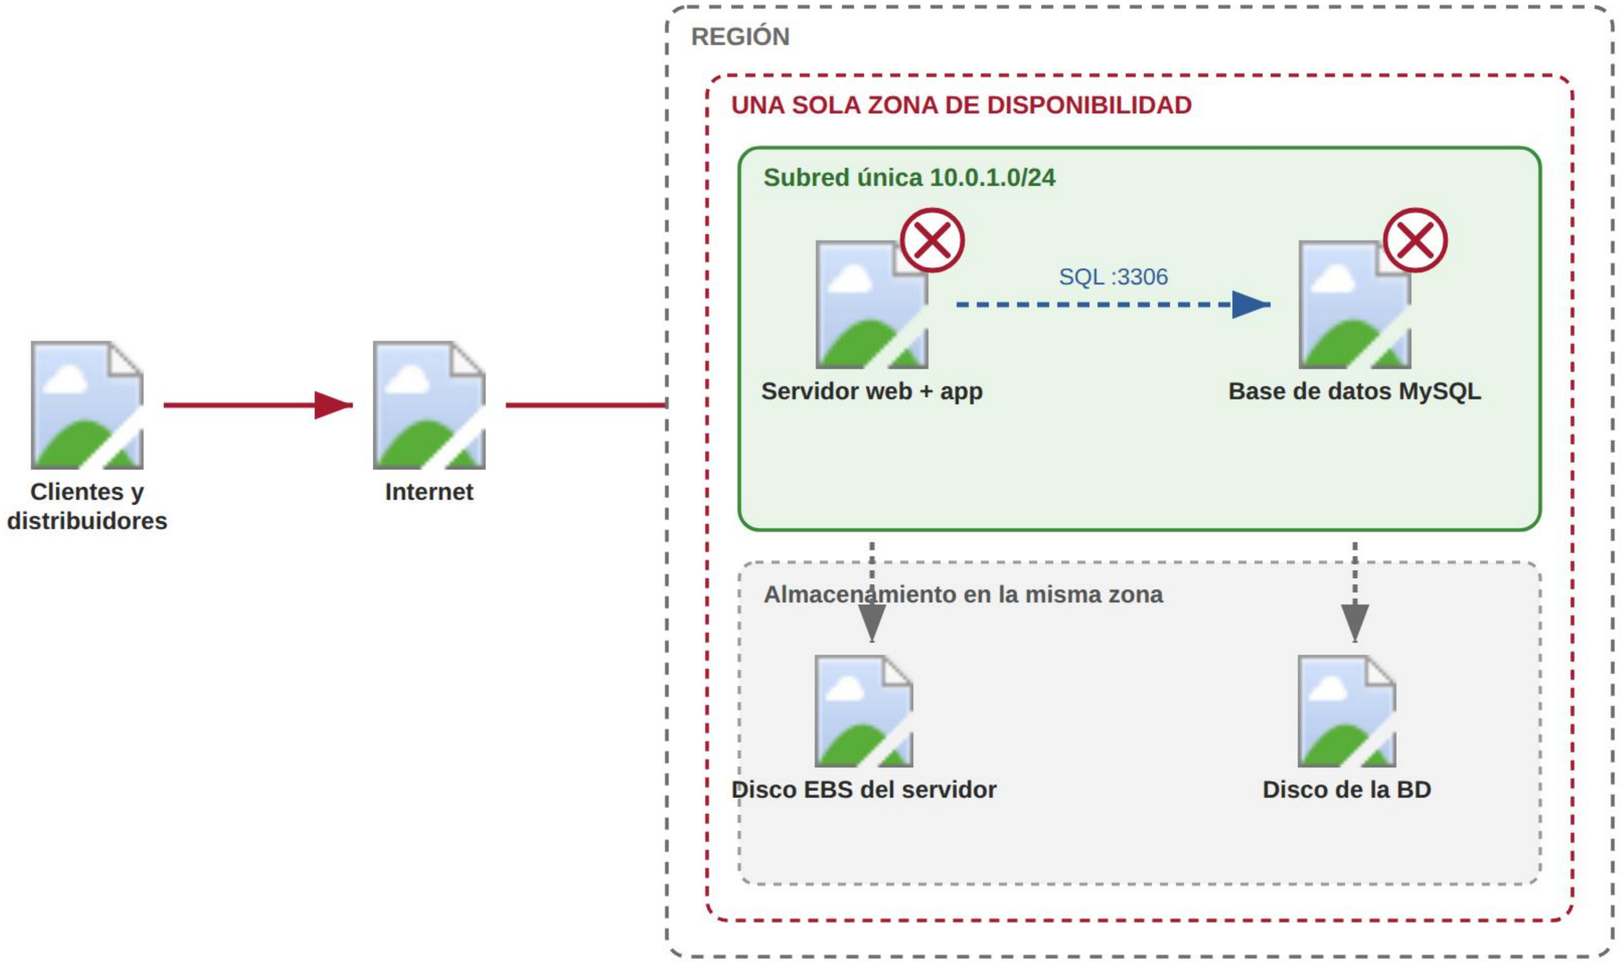
Ing. Rodolfo Cañas Cervantes
Universidad de la Costa (CUC) · Ingeniería de Sistemas
Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Medir, calcular y diseñar para que una falla no se note

ENCUADRE

Un solo servidor: la caída anunciada

El portal de pedidos de la Corporación Industrial del Caribe vive en una instancia y una base de datos, en una sola zona.



Punto único 1: la instancia

Si el servidor se reinicia o falla el hardware, el portal queda mudo hasta que alguien lo repare.

Punto único 2: la base de datos

Un solo nodo guarda todos los pedidos: sin copia en caliente no hay a dónde cambiar.

Punto único 3: la zona

Un corte de energía o red en esa zona apaga las dos piezas a la vez.

Costo de la caída (ilustrativo)

Lunes 2:15 p. m. cae el portal; se recupera a mano a las 3:45. Fueron 90 minutos de pedidos sin registrar y de despachos sin programar.

Fuente: caso docente CIC; patrón de AWS Well-Architected (Fiabilidad)

CONCEPTOS

Tres palabras que no son sinónimas

Alta disponibilidad acorta la caída, tolerancia a fallos la elimina y la recuperación ante desastres restaura en otro sitio.

Alta disponibilidad (HA)

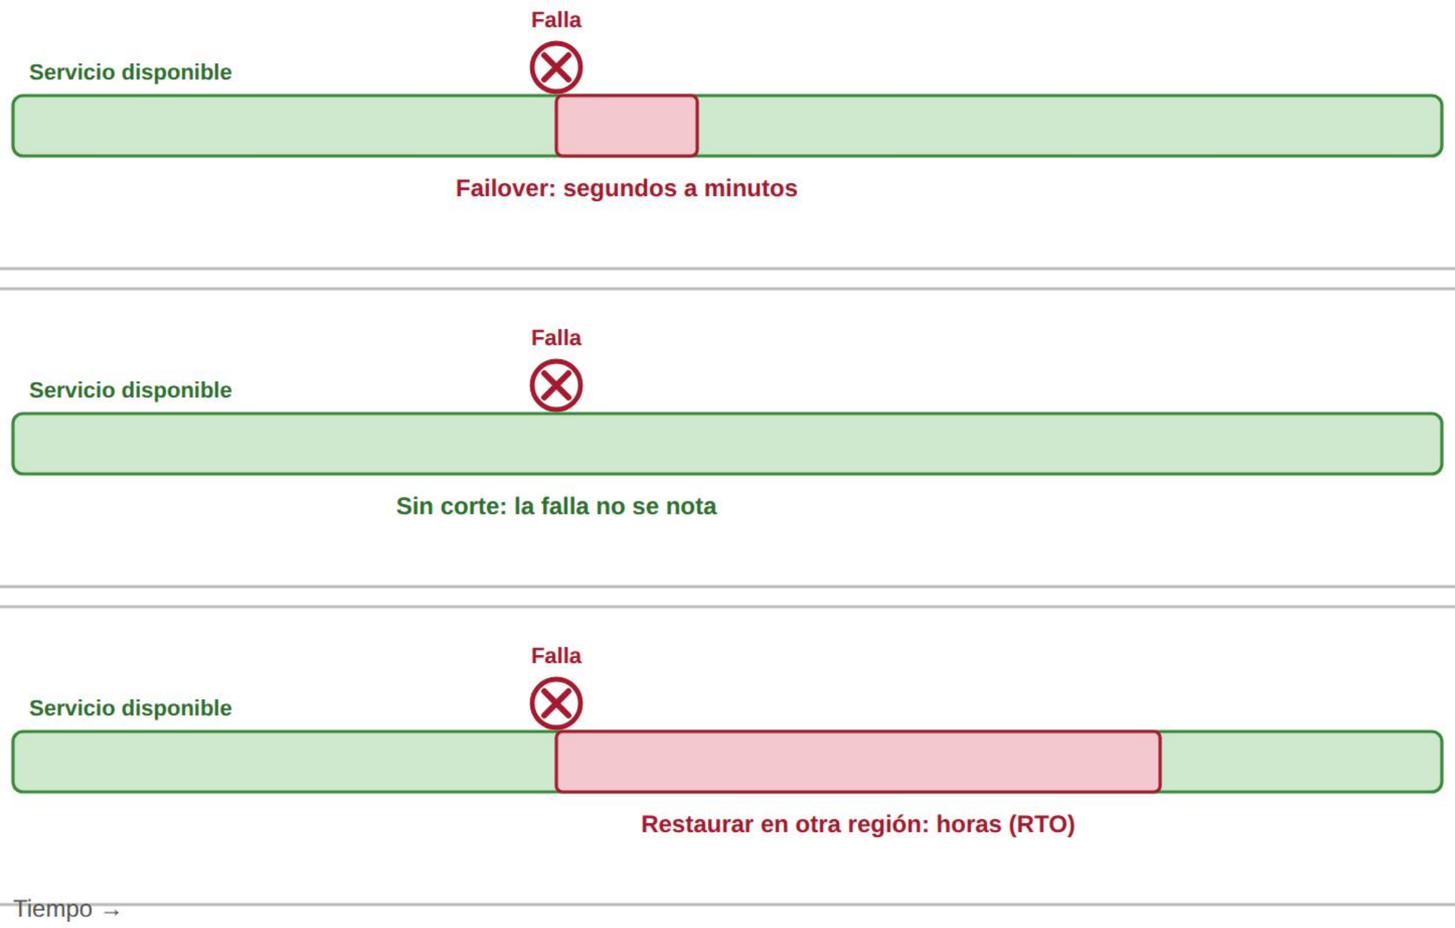
Se recupera sola en segundos o minutos. Hay una breve interrupción durante el failover.

Tolerancia a fallos (FT)

Cero interrupción: un componente gemelo ya está trabajando en paralelo y absorbe la falla.

Recuperación ante desastres (DR)

Se restaura el servicio en otra región. Tarda horas, pero sobrevive a la pérdida de todo un sitio.



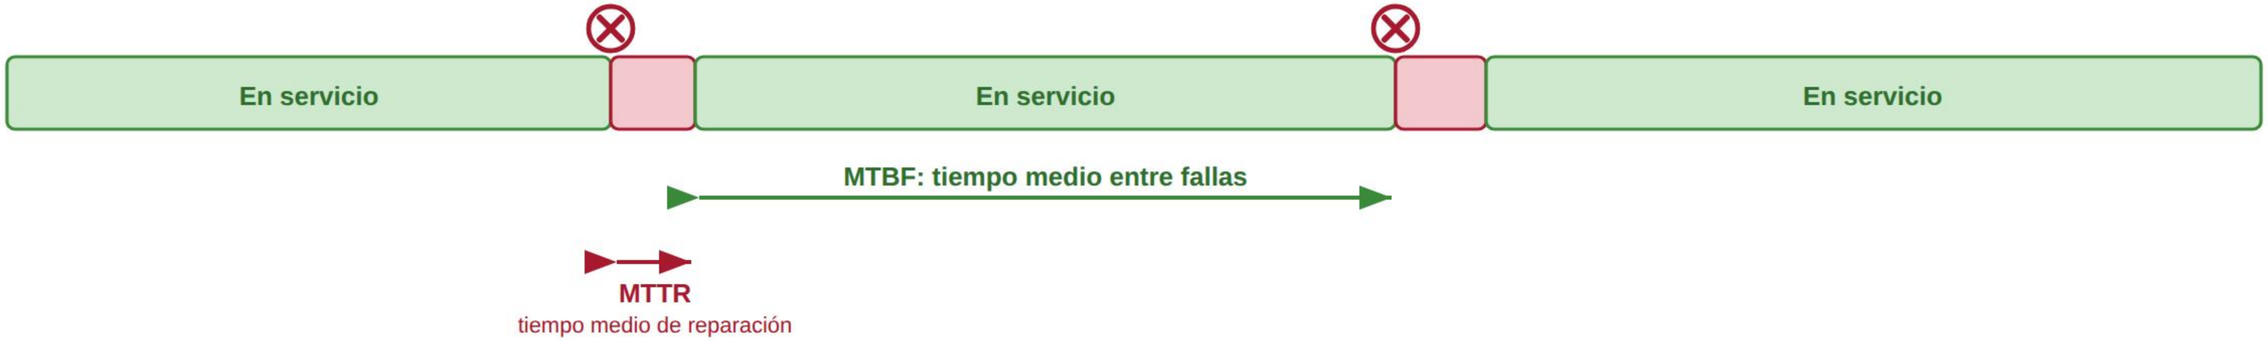
Fuente: adaptado de AWS Well-Architected — Fiabilidad y whitepaper de DR

MEDICIÓN

Medir la disponibilidad: MTBF y MTTR

MTBF (*Mean Time Between Failures*): tiempo medio entre fallas · **MTTR** (*Mean Time To Repair / Recovery*): tiempo medio de reparación o recuperación. Se mejora fallando menos o recuperando más rápido.

Cada falla abre un hueco; el tamaño del hueco es el tiempo de recuperación



Disponibilidad = MTBF ÷ (MTBF + MTTR)

Mismo MTBF: la recuperación rápida mueve los nueves

Ejemplo con MTBF de 720 horas (30 días)

Fallar menos

Componentes fiables, parches, redundancia que evita que una falla llegue al usuario.

Recuperar más rápido

Detección automática, failover y reemplazo de instancias sin intervención humana.

Mismo sistema, dos formas de recuperarse

MTTR de 4 horas (a mano)

720 ÷ 724 = 99,45 %

MTTR de 5 minutos (automático)

720 ÷ 720,08 = 99,99 %

Unas 48 horas de caída al año contra cerca de una hora.

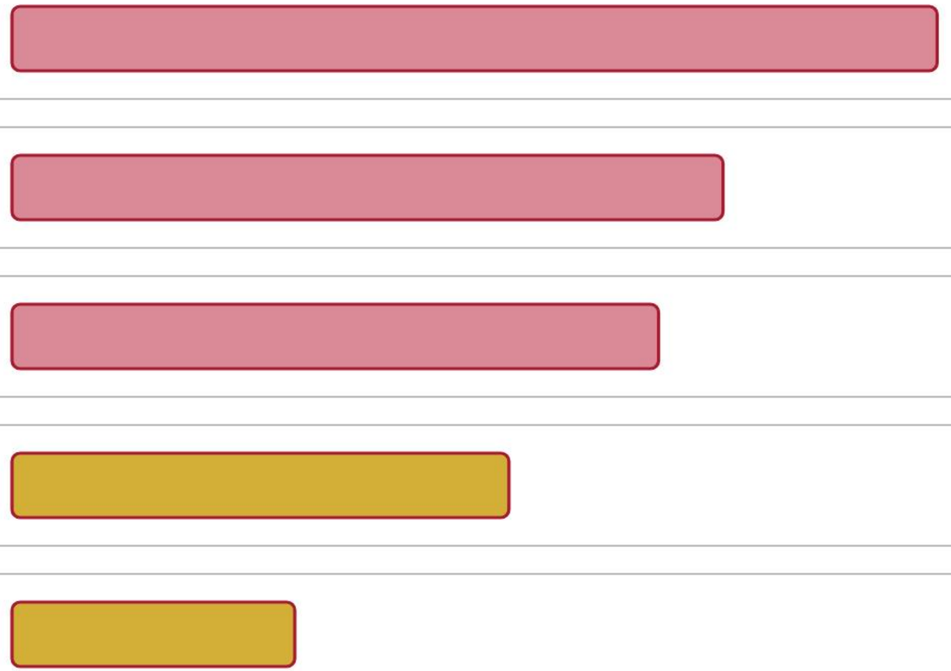
(≈ 12 fallas al año de cada tipo; cifras ilustrativas)

Fuente: adaptado de AWS Well-Architected — Fiabilidad (disponibilidad)

Los nueves: cuánta caída permite cada nivel

Pasar de 99 % a 99,99 % reduce la caída anual de más de tres días a menos de una hora.

Disponibilidad	Caída permitida por año	por mes
99 % “dos nueves”	**3,65 días**	7,3 horas
99,9 % “tres nueves”	**8,76 horas**	43,8 min
99,95 %	**4,38 horas**	21,9 min
99,99 % “cuatro nueves”	**52,6 min**	4,4 min
99,999 % “cinco nueves”	**5,26 min**	26 s



Cada nueve adicional divide la caída permitida entre diez, y el costo de lograrlo sube más rápido.

Escala logarítmica en las barras. Año de 365 días; mes de 30,4 días. Los valores salen de (1 − disponibilidad) × tiempo total.

Fuente: cálculo propio; AWS Well-Architected — Fiabilidad (tabla de disponibilidad)

CÁLCULO

En serie se resta, en paralelo se suma

Una cadena de dependencias es más débil que su pieza más débil; las réplicas independientes multiplican los nueves.

EN SERIE: todo debe funcionar a la vez, así que los porcentajes se multiplican



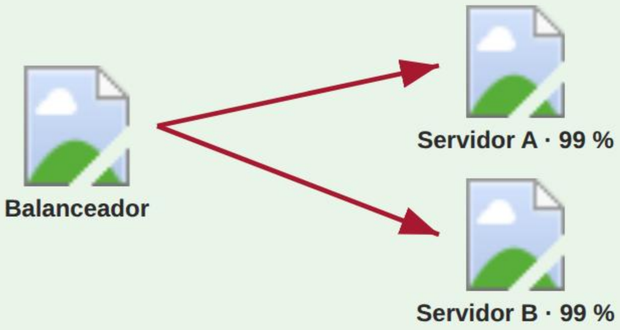
0,9999 × 0,999 × 0,9995

= 99,84 %

≈ 14 horas de caída al año

Peor que cualquiera de las piezas por separado

EN PARALELO: basta con que una réplica viva, así que lo que falla se multiplica



Falla de ambos a la vez:

0,01 × 0,01 = 0,0001

= 99,99 %

Dos “dos nueves” hacen cuatro

Cuidado con el supuesto

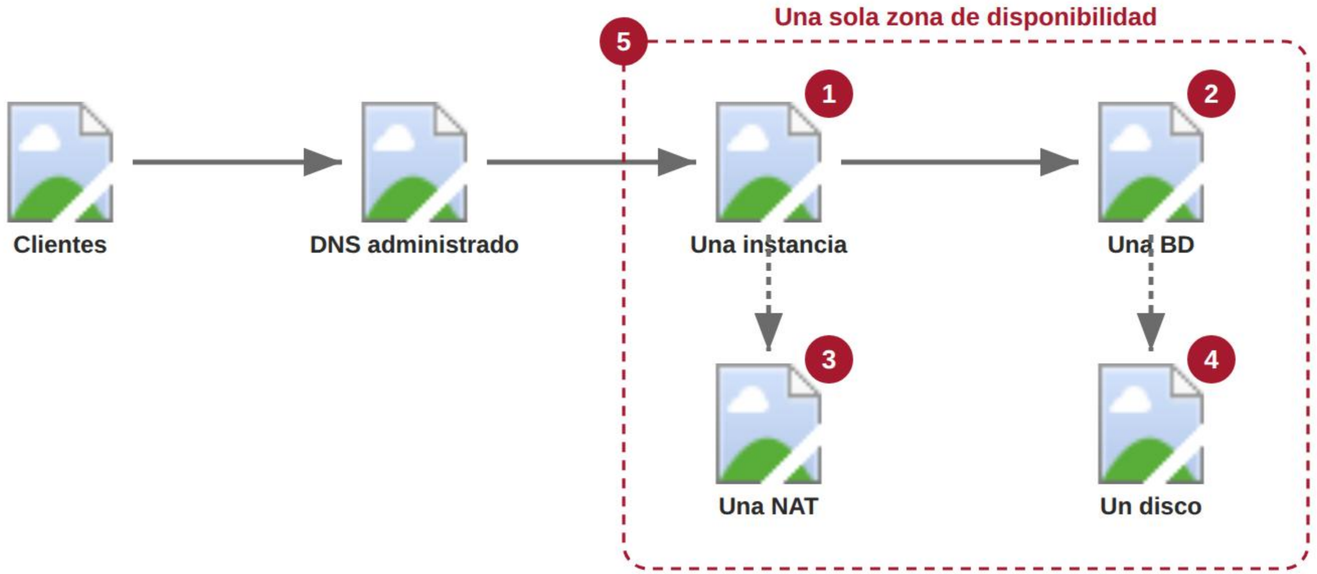
Solo funciona si las fallas son independientes. Dos servidores en el mismo rack comparten la causa; por eso se reparten en zonas distintas.

Fuente: cálculo propio; AWS Well-Architected — Fiabilidad (disponibilidad con dependencias)

Cazar los puntos únicos de falla (SPOF)

Un SPOF es cualquier pieza sin respaldo: si falla, cae todo el servicio. Se detecta preguntando qué pasa si esto desaparece.

Recorre la arquitectura de izquierda a derecha y marca todo lo que existe una sola vez



Fuera del servidor también hay puntos únicos

6. Estado en el disco local: sesiones, archivos subidos.
7. Configuración manual: solo una persona sabe instalar el servidor.
8. Una sola región: ante un desastre regional no hay a dónde ir.
9. Una sola cuenta o certificado que vence sin alerta.

1 Instancia

Antídoto

Grupo Auto Scaling en varias zonas

2 Base de datos

Antídoto

Multi-AZ con standby

3 NAT

Antídoto

Una puerta de salida por zona

4 Disco

Antídoto

Snapshots y datos en S3 o EFS

5 Zona

Antídoto

Distribuir en dos o tres zonas

Fuente: adaptado de AWS Well-Architected — Fiabilidad (eliminar SPOF)

Regiones y zonas: la materia prima de la HA

Una región agrupa varias zonas de disponibilidad aisladas pero conectadas; de ahí sale la redundancia.

REGIÓN (ej.: São Paulo, sa-east-1)

Zona de disponibilidad A



Uno o más centros de datos
energía y red propias

Fallas aisladas entre zonas
Separación física de kilómetros: una inundación o un corte eléctrico no afecta a las demás.

Zona de disponibilidad B



Uno o más centros de datos
energía y red propias

Fallas aisladas entre zonas
Separación física de kilómetros: una inundación o un corte eléctrico no afecta a las demás.

Zona de disponibilidad C



Uno o más centros de datos
energía y red propias

Fallas aisladas entre zonas
Separación física de kilómetros: una inundación o un corte eléctrico no afecta a las demás.

Enlaces dedicados de baja latencia entre zonas (milisegundos)

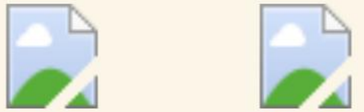
OTRA REGIÓN (ej.: N. Virginia)



Mismo diseño, otro sitio
recuperación ante desastres

Unidas por la red troncal global

UBICACIONES DE BORDE



Contenido cerca **DNS global**

Puntos de presencia cerca del usuario

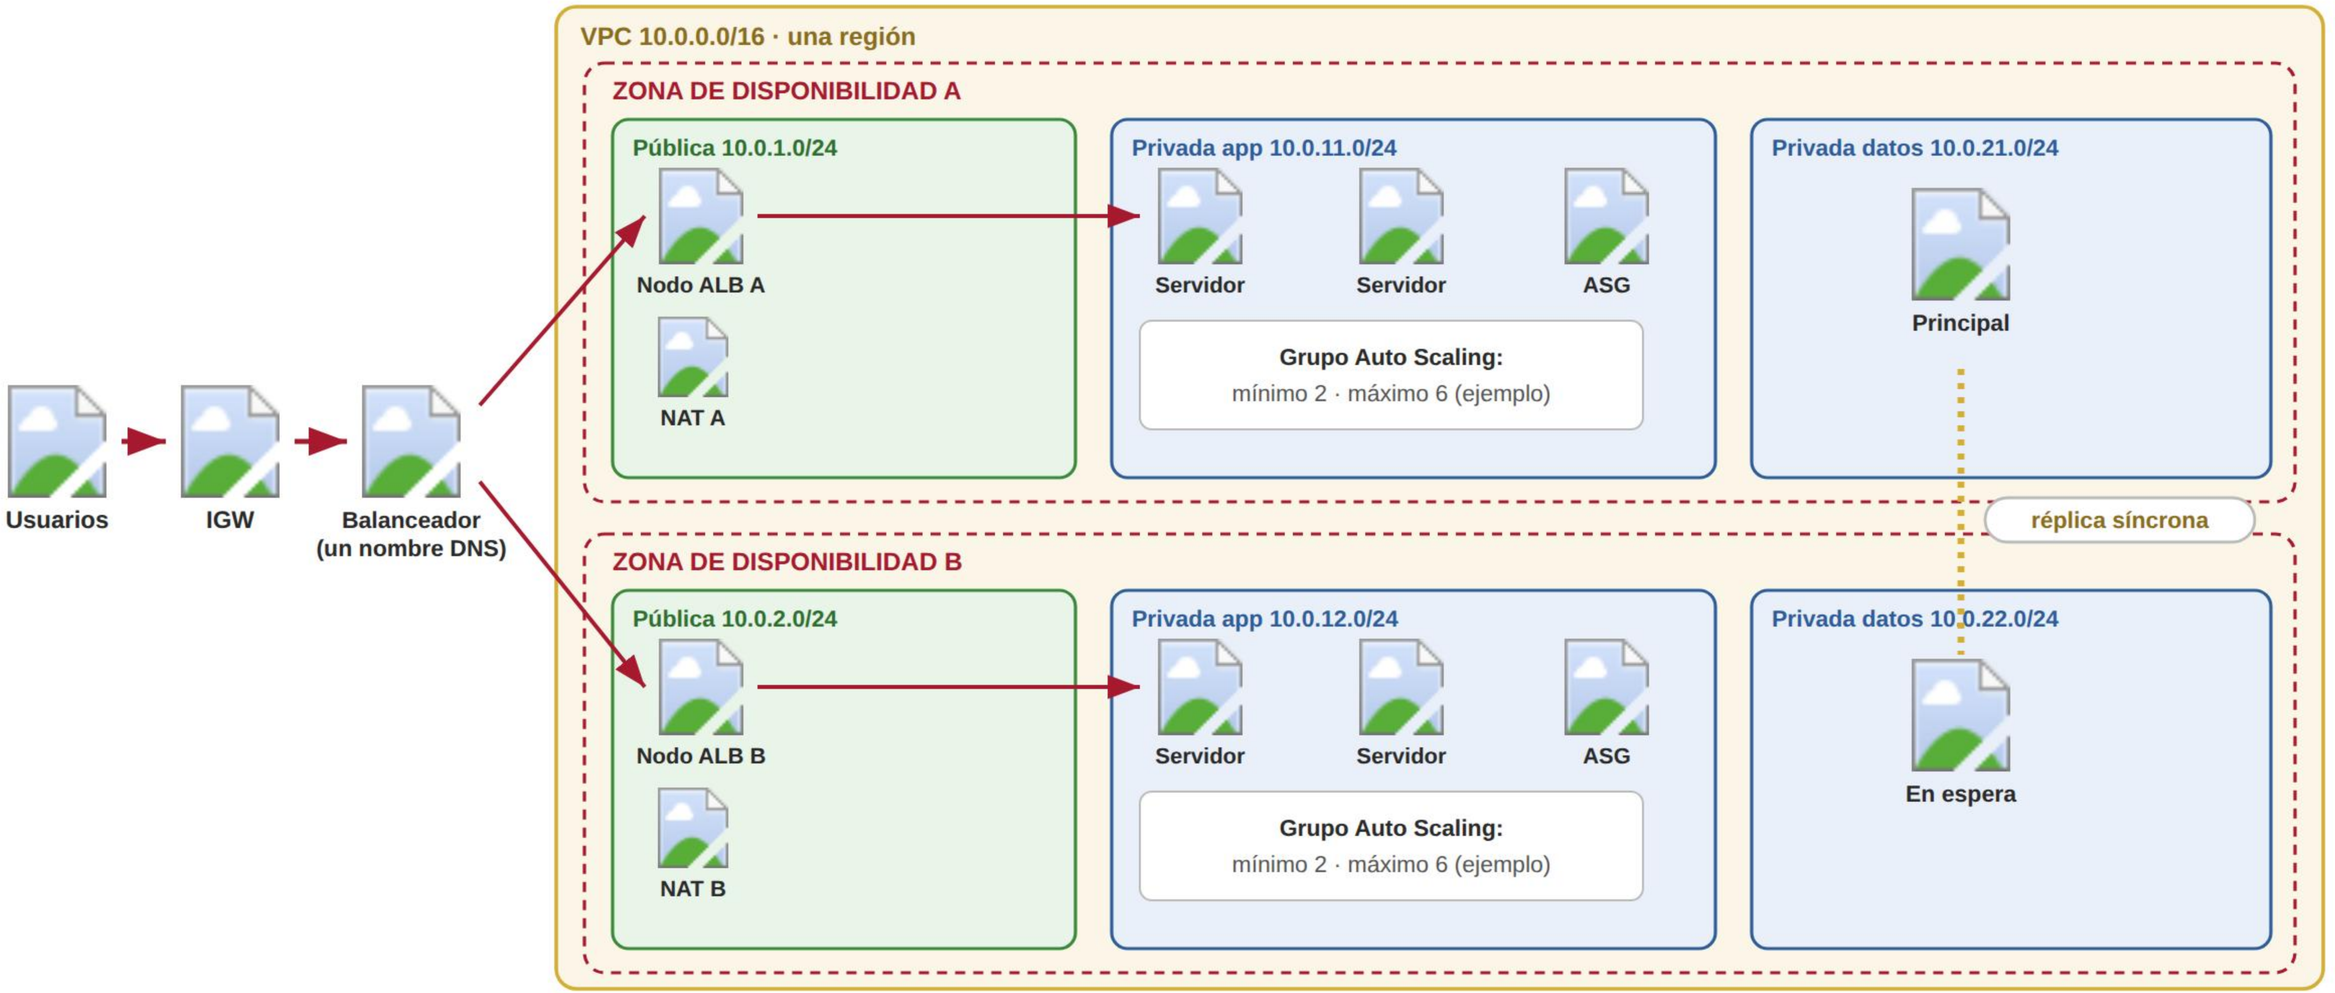
Región: área geográfica con varias zonas (tres o más) · Zona: sitio con falla independiente · Borde: puntos de presencia

Regla práctica: la alta disponibilidad se resuelve entre zonas de una región; el desastre regional, entre regiones.

Fuente: adaptado de AWS Global Infrastructure (regiones, zonas y ubicaciones de borde)

Diseño multi-AZ: la VPC en dos zonas

Balanceador, servidores y base de datos se duplican por zona; una zona entera puede caer y el servicio sigue.



Fuente: adaptado de AWS Architecture Center — referencia web de alta disponibilidad

Redundancia en cada capa, no solo en una

Una cadena es tan fuerte como su eslabón más débil: cada capa necesita su propia respuesta a una falla.

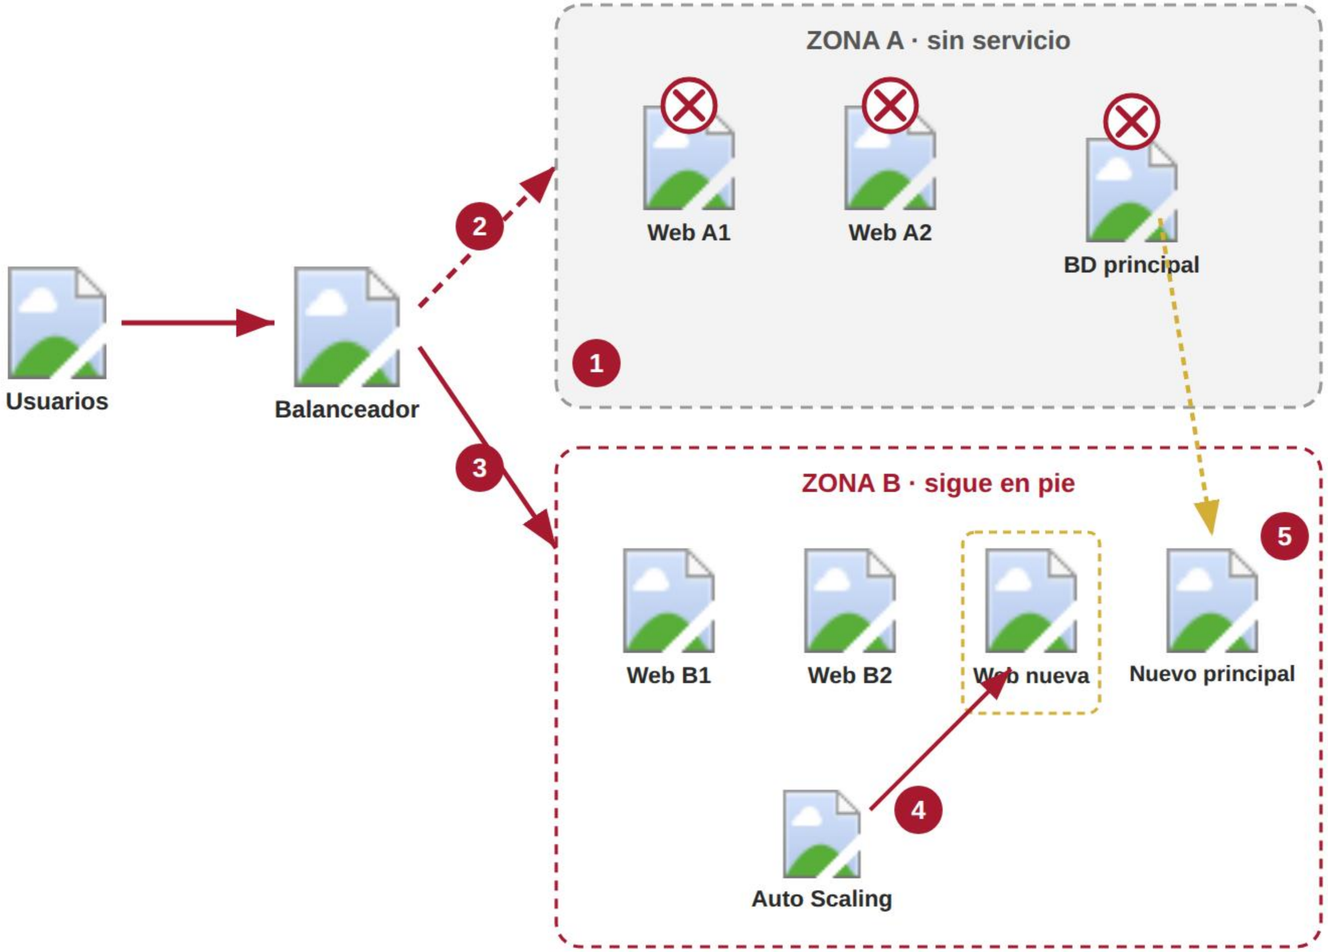
Capa		Cómo se duplica	Mecanismo
DNS y borde		Servicio global con muchos puntos de presencia	**Anycast**
Balanceo		Un nodo del balanceador en cada zona	**Nodos por zona**
Cómputo		Auto Scaling reemplaza instancias dañadas	**ASG multi-AZ**
Salida a Internet		Una NAT por zona, tablas de rutas por zona	**NAT por AZ**
Caché		Réplica en otra zona y failover automático	**Réplica + failover**
Base de datos		Replicación síncrona a un standby	**Multi-AZ**
Archivos y objetos		S3 y EFS regional guardan en varias zonas	**Regional**

Fuente: adaptado de AWS Well-Architected — Fiabilidad (diseño de arquitectura de carga de trabajo)

FALLA DE ZONA

Cuando cae una zona completa

Chequeos, balanceador, Auto Scaling y failover de base de datos trabajan en cadena sin que nadie intervenga.



Qué ocurre, en orden

1. La zona A pierde energía o red
2. Fallan los chequeos de salud de los destinos de A
3. El balanceador deja de enviarles tráfico: todo va a B
4. Auto Scaling lanza instancias nuevas en B para recuperar la capacidad deseada
5. RDS promueve el standby de B a principal y actualiza el nombre DNS del endpoint

Sin intervención humana

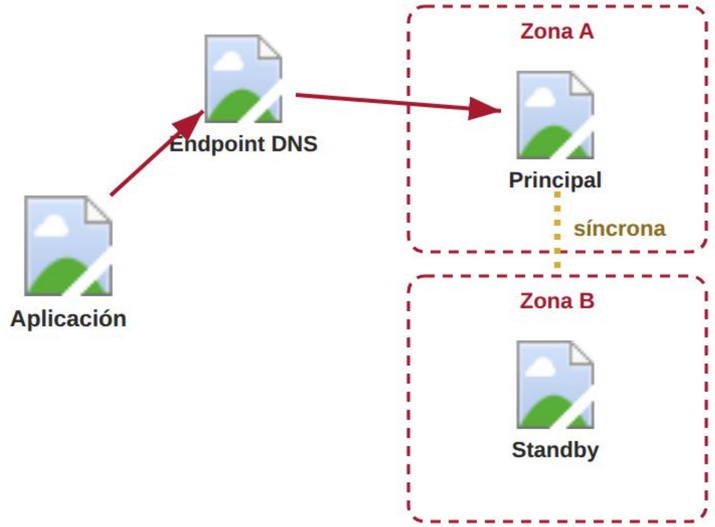
Se pierden segundos o minutos; no horas.

Fuente: adaptado de AWS Well-Architected — Fiabilidad (conmutación por error)

Failover de la base de datos Multi-AZ

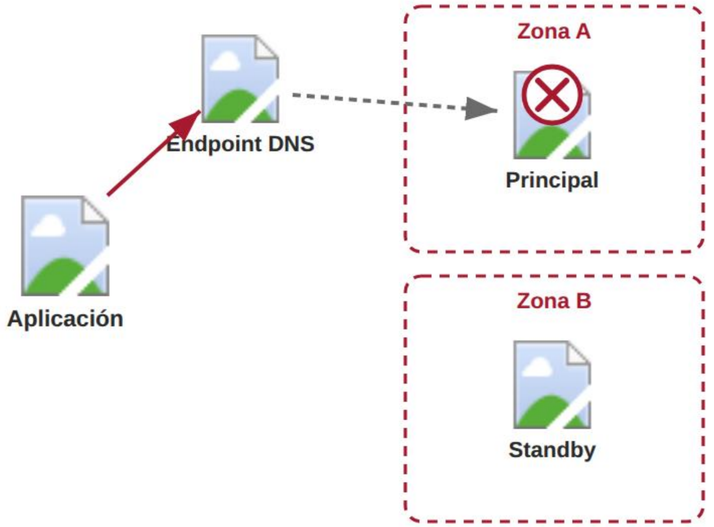
El endpoint DNS no cambia: la aplicación sigue usando el mismo nombre mientras el motor promueve al standby.

1 · Operación normal



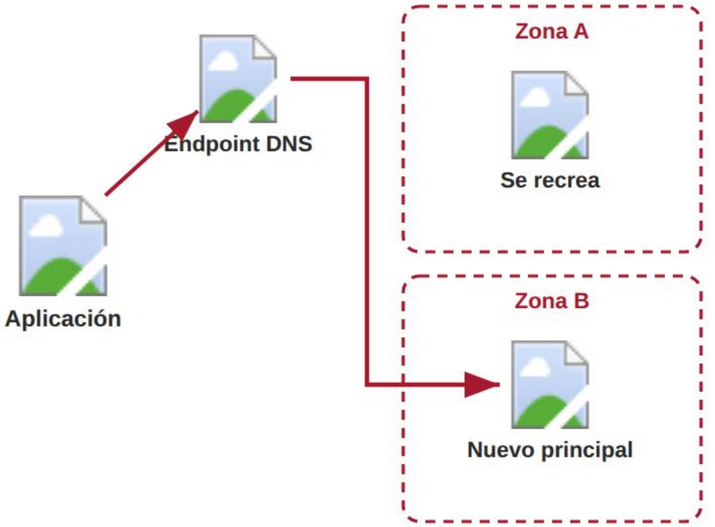
Escritura confirmada en ambas zonas

2 · Falla el principal



Detección: el principal no responde

3 · Promoción del standby



El nombre DNS apunta a la zona B

Multi-AZ, una instancia en espera

Standby síncrono que no atiende lecturas. Failover típico de uno a dos minutos. La aplicación debe reintentar la conexión.

Multi-AZ, clúster con dos standby

Dos standby legibles en otras zonas: sirven lecturas y el failover suele ser más corto.

Aurora: el almacenamiento ya está repartido

Seis copias de los datos en tres zonas; si cae el escritor, se promueve una réplica.

Fuente: adaptado de Amazon RDS User Guide — Multi-AZ y Aurora

SERVICIOS

Regionales por diseño y zonales por defecto

Algunos servicios ya son multi zona; otros dependen de que tú distribuyas los recursos.

Ya vienen repartidos por la región

AWS opera la redundancia: tú solo eliges bien



S3
copias en 3 zonas o más



DynamoDB
replicada en 3 zonas



Balanceador
nodos por zona



SQS
colas redundantes



Lambda
ejecuta en varias zonas



Route 53
servicio global

Tú decides en qué zona viven

Si no los distribuyes, quedan en una sola zona



EC2
una instancia = una zona



Disco EBS
atado a su zona



RDS
una zona salvo Multi-AZ



ElastiCache
nodos por zona



NAT Gateway
una por zona



Subredes
cada una vive en una zona

Responsabilidad compartida

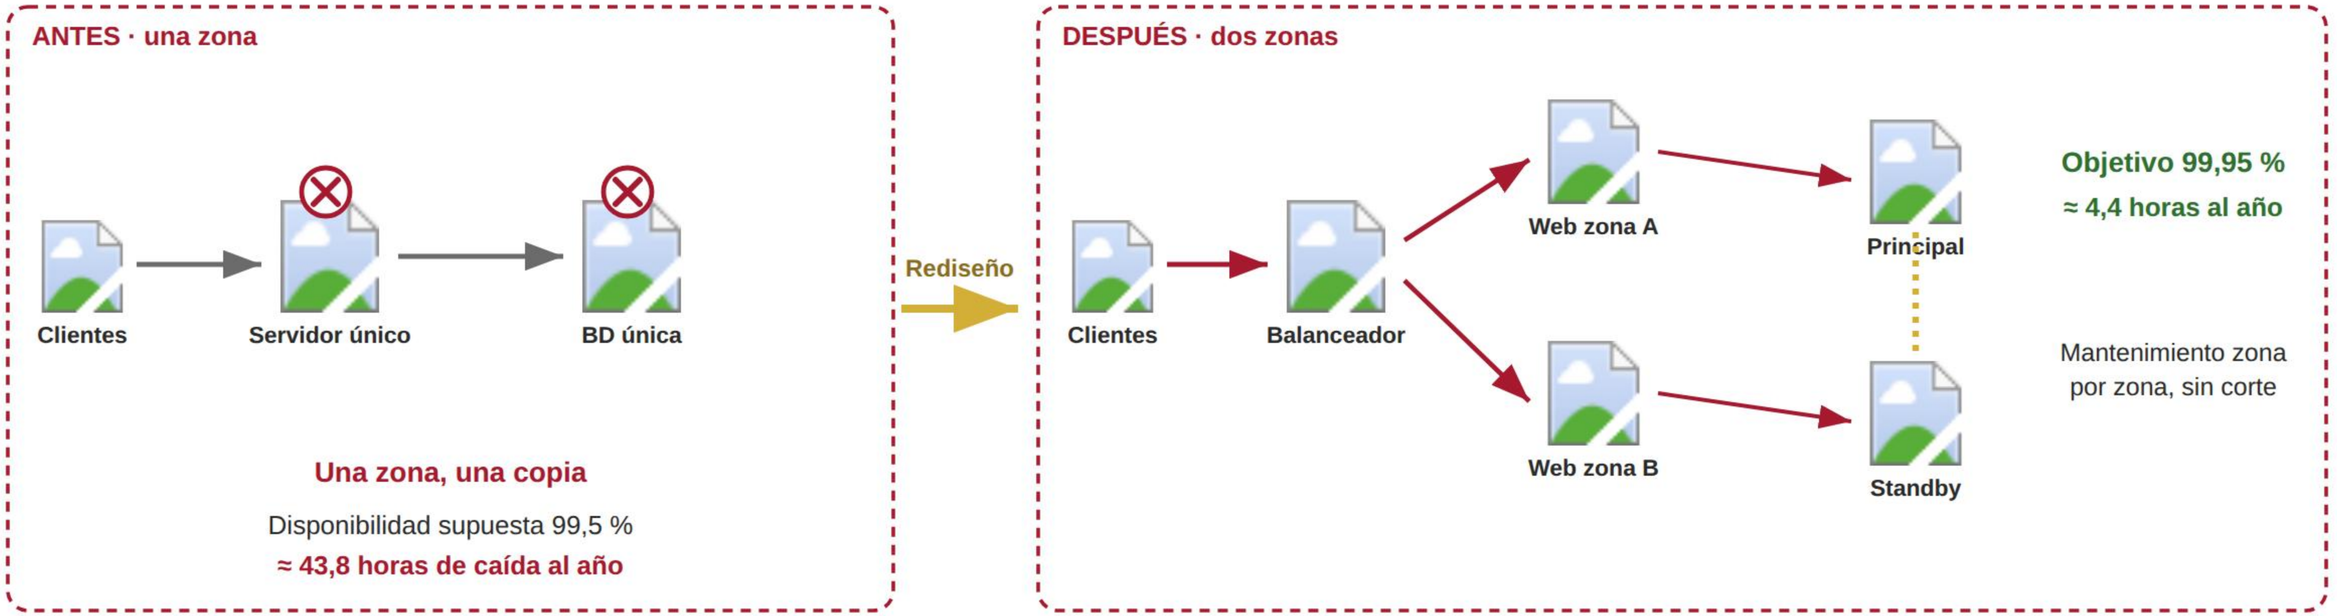
AWS ofrece las zonas; el diseño que las usa es tuyo.

Fuente: adaptado de AWS Well-Architected — Fiabilidad; documentación de cada servicio

CASO APLICADO

Caso CIC: de una zona a dos zonas

Duplicar con criterio reduce la caída esperada diez veces; el costo adicional es menor que el de una caída larga.



10×
menos caída anual (ilustrativo)

~2×
costo de infraestructura (ilustrativo)

Minutos
recuperación sin intervención humana

2 zonas
mínimo para la producción de CIC

Fuente: caso docente CIC (cifras ilustrativas); AWS Well-Architected — Fiabilidad

SÍNTESIS

Lo que queda de la Parte 1

Cuatro ideas para llevarse antes de hablar del balanceador de carga.

1



Los nueves se calculan

Disponibilidad = MTBF ÷ (MTBF + MTTR). Cada nueve divide la caída entre diez.

2



Serie resta, paralelo suma

Las dependencias en cadena bajan el total; las réplicas independientes lo suben.

3



Cada capa necesita respaldo

Balanceo, cómputo, caché y datos se duplican entre zonas.

4



Caza el punto único

Pregunta qué pasa si la pieza desaparece y responde con automatización.



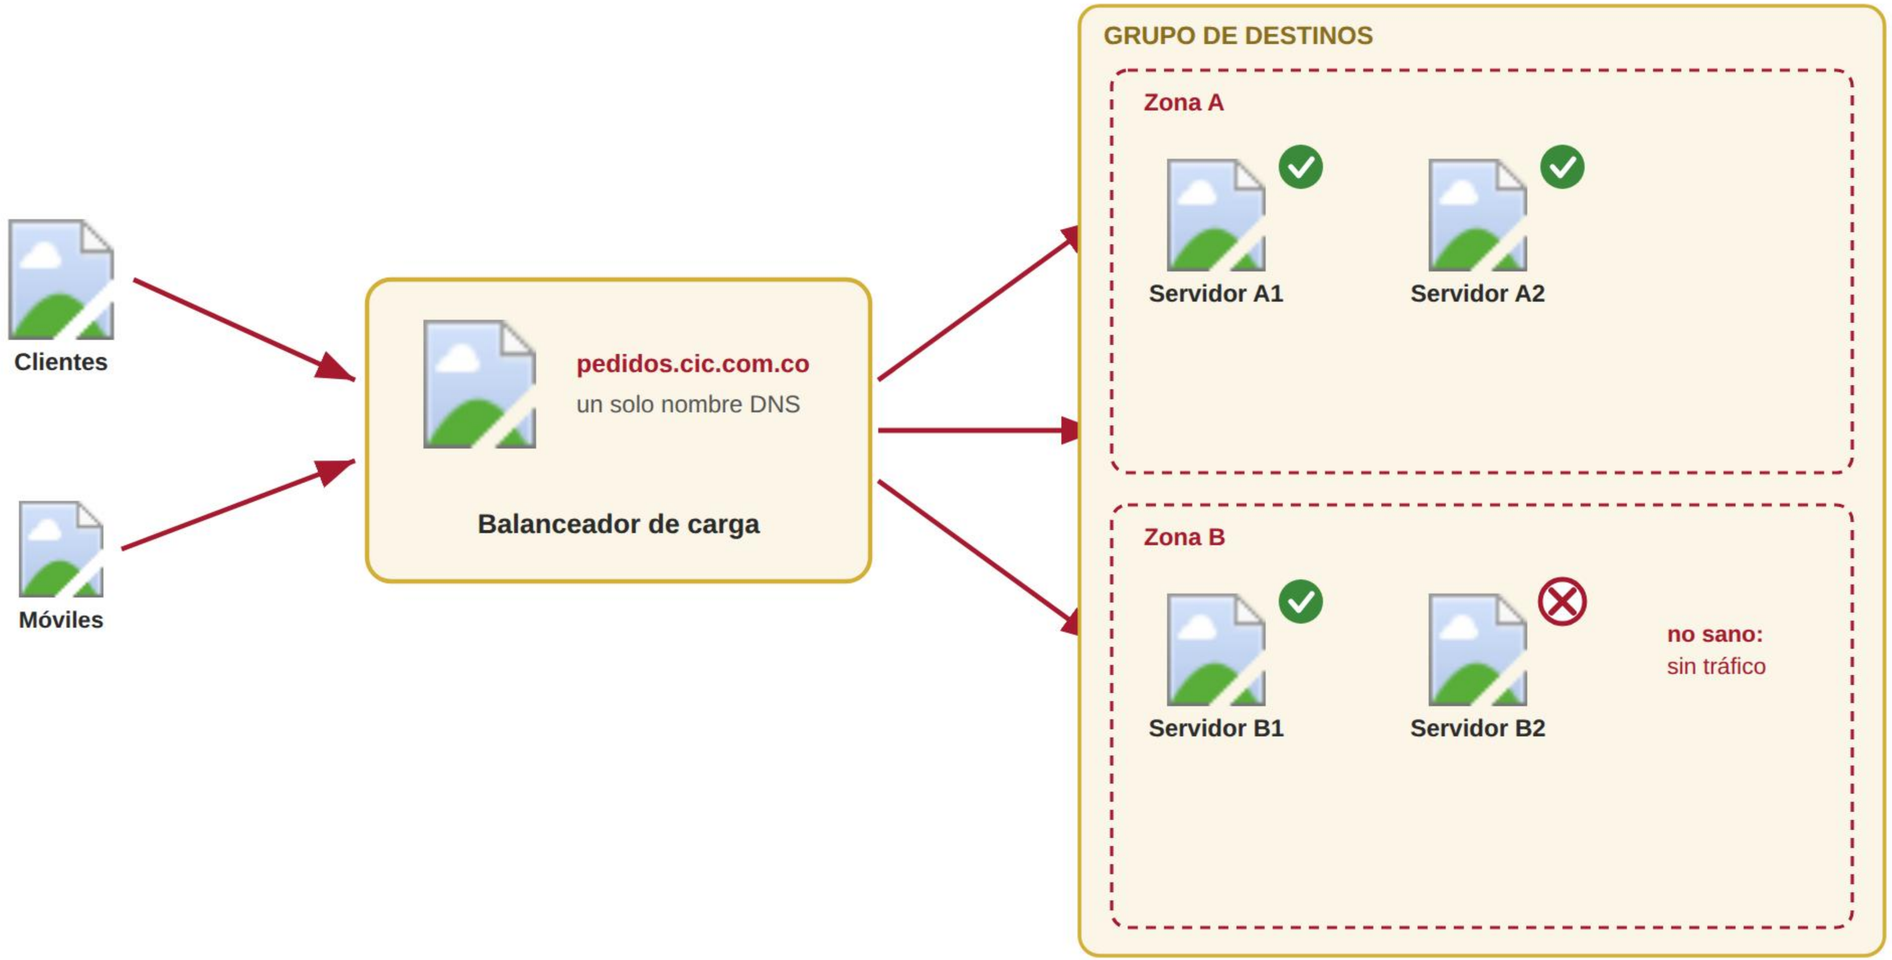
Siguiente: Parte 2 · Balanceo de carga

Tenemos servidores en dos zonas. Falta la pieza que reparte el tráfico y vigila cuál de ellos está sano.

Fuente: síntesis del curso; AWS Well-Architected — Fiabilidad

Un punto de entrada, muchos destinos

El balanceador publica un solo nombre y reparte cada solicitud entre servidores sanos de varias zonas.



Reparte

Cada solicitud va a un destino sano según un algoritmo.

Vigila

Comprueba cada destino y retira los que no responden.

Escala

Los destinos se agregan o quitan sin cambiar el nombre DNS.

Fuente: adaptado de Elastic Load Balancing User Guide (AWS)

Capa 4 contra capa 7: qué ve cada balanceador

El NLB decide con datos de transporte; el ALB entiende HTTP y por eso puede enrutar por contenido.

7 Aplicación
HTTP, gRPC, WebSocket

6 Presentación
cifrado, formato

5 Sesión
diálogo

4 Transporte
TCP, UDP, puertos

3 Red
IP, enrutamiento

2 Enlace
tramas

1 Física
señal

CAPA 4 · Network Load Balancer



NLB

Ve: IP origen, IP destino,
puerto y protocolo TCP o UDP
No lee el contenido

Decide por el flujo; conserva la IP del cliente
Millones de solicitudes por segundo, latencia mínima

CAPA 7 · Application Load Balancer



ALB

Ve: método, ruta, host,
encabezados, cookies
Lee la solicitud HTTP

Decide por contenido: /api, /pedidos, host
Redirecciones, TLS, autenticación, WAF

Paquete que ve el NLB

TCP 443 · 190.x.x.x → 10.0.1.25

Reenvía al destino por el puerto
No distingue /api de /imagenes.

Úsalo para: bases de datos, juegos, IoT,
IP fija, protocolos que no son HTTP.

Solicitud que ve el ALB

GET /api/pedidos/123
Host: pedidos.cic.com.co
Cookie: sesion=...

Envía /api al grupo de la API y
el resto al grupo del sitio web.

Úsalo para: sitios, APIs y microservicios.

Fuente: adaptado de Elastic Load Balancing User Guide y modelo OSI

FAMILIA ELB

Elastic Load Balancing: tres balanceadores, tres usos

ALB para HTTP, NLB para TCP y UDP de alto rendimiento, y GWLB para insertar appliances de seguridad.



Application Load Balancer

Capa 7

- HTTP, HTTPS y gRPC
- Rutas, hosts y encabezados
- Destinos: instancias, IP, Lambda
- WebSocket, WAF y autenticación

Úsalo para

Sitios web, APIs y microservicios



Network Load Balancer

Capa 4

- TCP, UDP y TLS
- Latencia ultrabaja y alto rendimiento
- IP estática por zona (Elastic IP)
- Conserva la IP del cliente

Úsalo para

Bases de datos, juegos, IoT, PrivateLink



Gateway Load Balancer

Capa 3

- Reparte hacia appliances virtuales
- Encapsula con GENEVE, puerto 6081
- Un solo punto para varios appliances
- Transparente para el tráfico

Úsalo para

Firewalls y sistemas de inspección

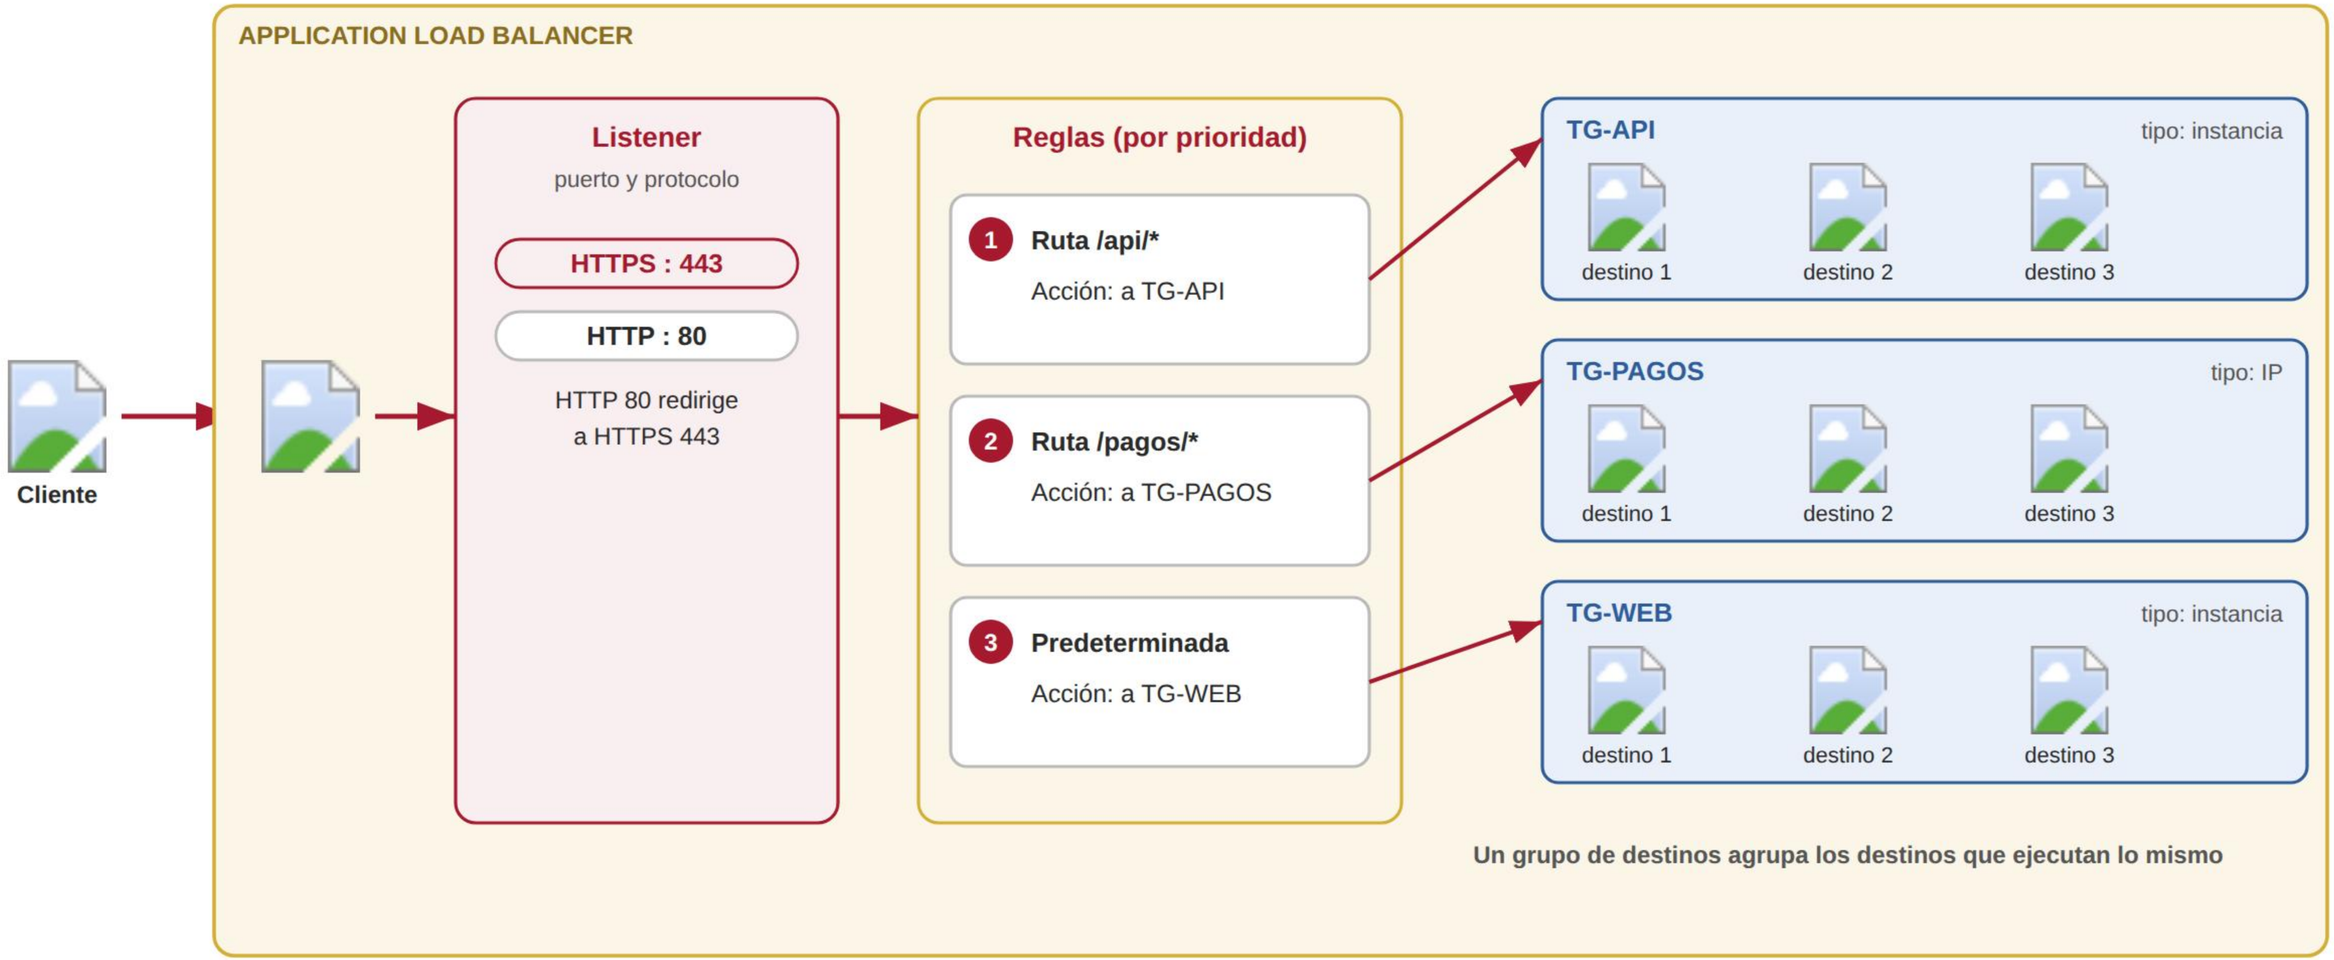
Heredado: Classic Load Balancer (capas 4 y 7 básicas). Para cargas nuevas se usan ALB, NLB o GWLB.

Los tres comparten la idea: un punto de entrada que reparte hacia destinos sanos en varias zonas.

Fuente: adaptado de AWS Elastic Load Balancing — Product details

Anatomía del ALB: listener, reglas y grupos de destino

El listener recibe la conexión, las reglas deciden y el grupo de destinos agrupa a quienes responden.



Fuente: adaptado de Elastic Load Balancing User Guide — Application Load Balancers

SEMANA 10 · ELASTICIDAD, ALTA DISPONIBILIDAD Y MONITORIZACIÓN

Balanceo de carga y elasticidad

Parte 2 de 3 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Reglas de capa 7, chequeos de salud, TLS, failover de DNS y el grupo de Auto Scaling

Reglas de enrutamiento en capa 7

Ruta, host, encabezado, consulta o IP de origen deciden a qué grupo va cada solicitud.

Una misma dirección pública puede atender muchos servicios si el balanceador entiende la solicitud

GET /api/pedidos
Condición: ruta

GET /imagenes/logo.png
Condición: ruta

tienda.cic.com.co
Condición: host

Header: X-Version=2
Condición: encabezado

?modo=movil
Condición: cadena de consulta

IP 190.85.0.0/16
Condición: IP de origen



ALB · reglas

Evalúa de menor a mayor prioridad

Gana la primera regla que coincide

Si ninguna coincide: **regla predeterminada**

Destinos ponderados
90 por ciento a v1, 10 a v2

TG-API

TG-ESTATICOS

TG-TIENDA

TG-V2

TG-MOVIL

TG-OFICINA

También: respuesta fija, redirección y autenticación con Cognito u OIDC antes de reenviar.

Fuente: adaptado de Elastic Load Balancing User Guide — Listener rules

SALUD

Health checks: quién entra y quién sale de rotación

El balanceador consulta cada destino con una ruta de prueba y retira a los que fallan varias veces seguidas.

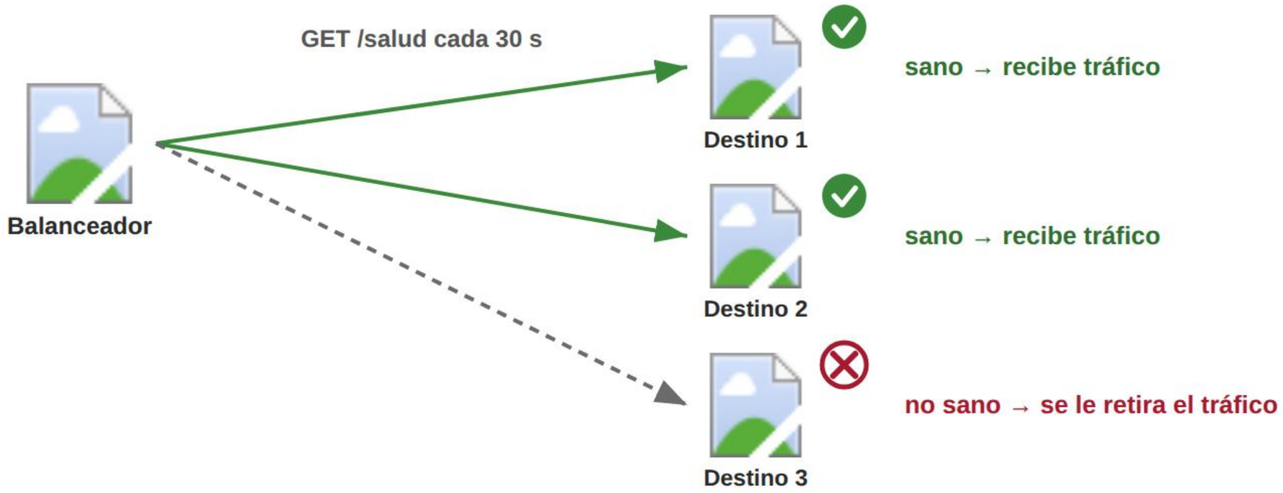
CÓMO SE CONFIGURA (valores por defecto del ALB)

Ruta de prueba	Intervalo	Tiempo de espera
/salud	30 s	5 s

Umbral no sano	Umbral sano	Código esperado
2 fallos	5 aciertos	200

Un destino que falla y se recupera





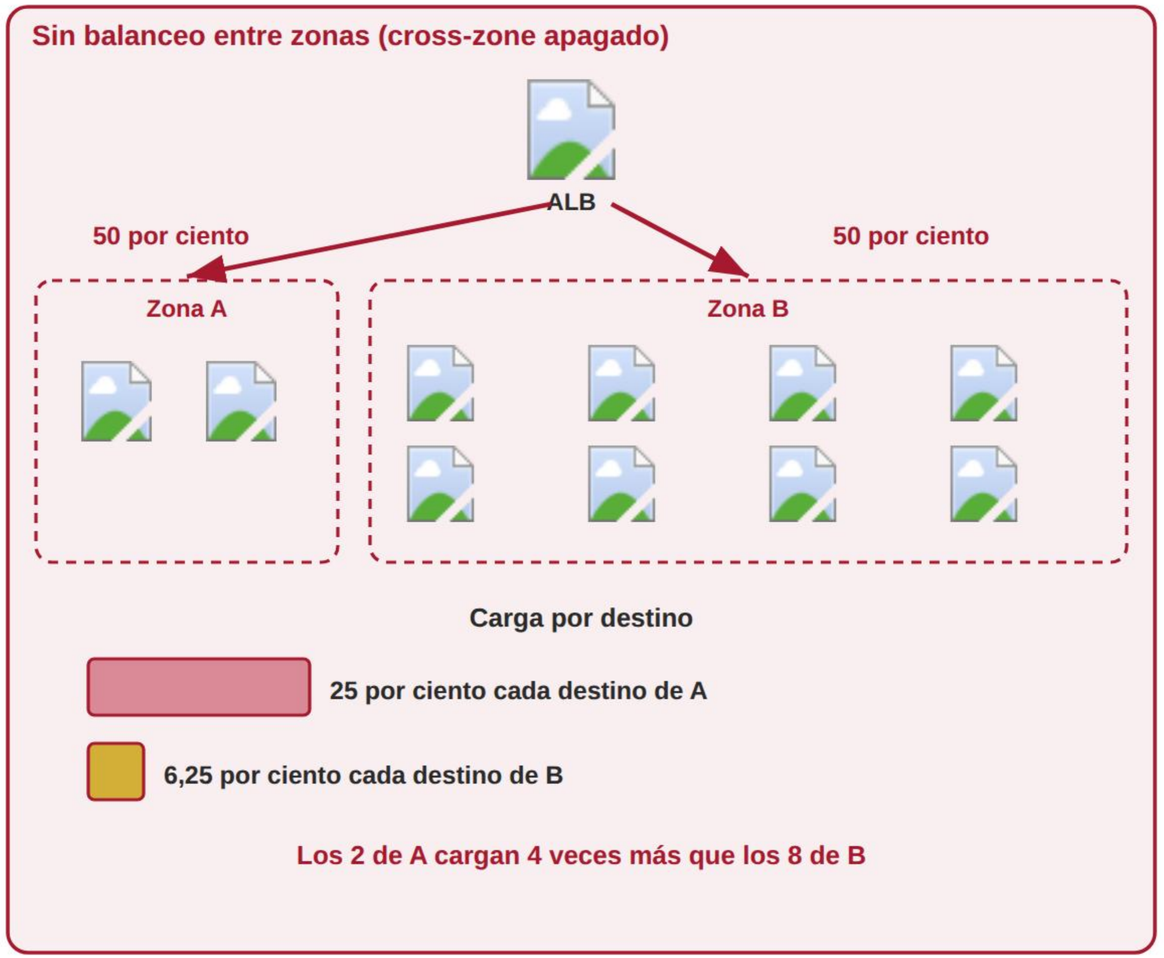
Buenas prácticas

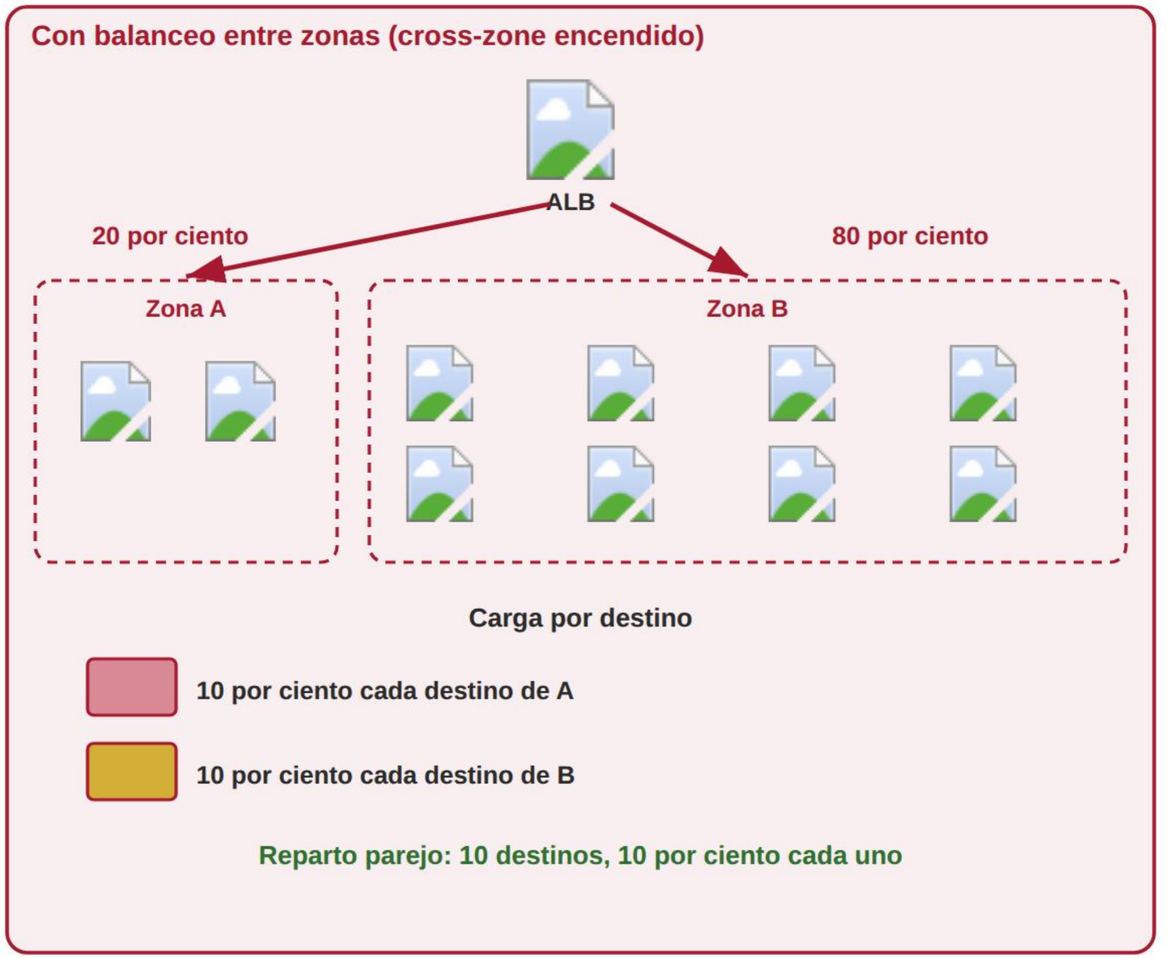
Una ruta propia como /salud que revise las dependencias críticas, no solo la portada. Ni muy laxo (deja pasar errores) ni muy estricto (saca servidores por un tropiezo). Si todos los destinos fallan, el ALB envía a todos en lugar de cerrar la puerta.

Fuente: adaptado de Elastic Load Balancing User Guide — Health checks for target groups

Balanceo entre zonas: cuando el reparto no es parejo

Sin cross-zone cada zona recibe la misma parte aunque tenga menos destinos; encendido, el reparto es por destino.

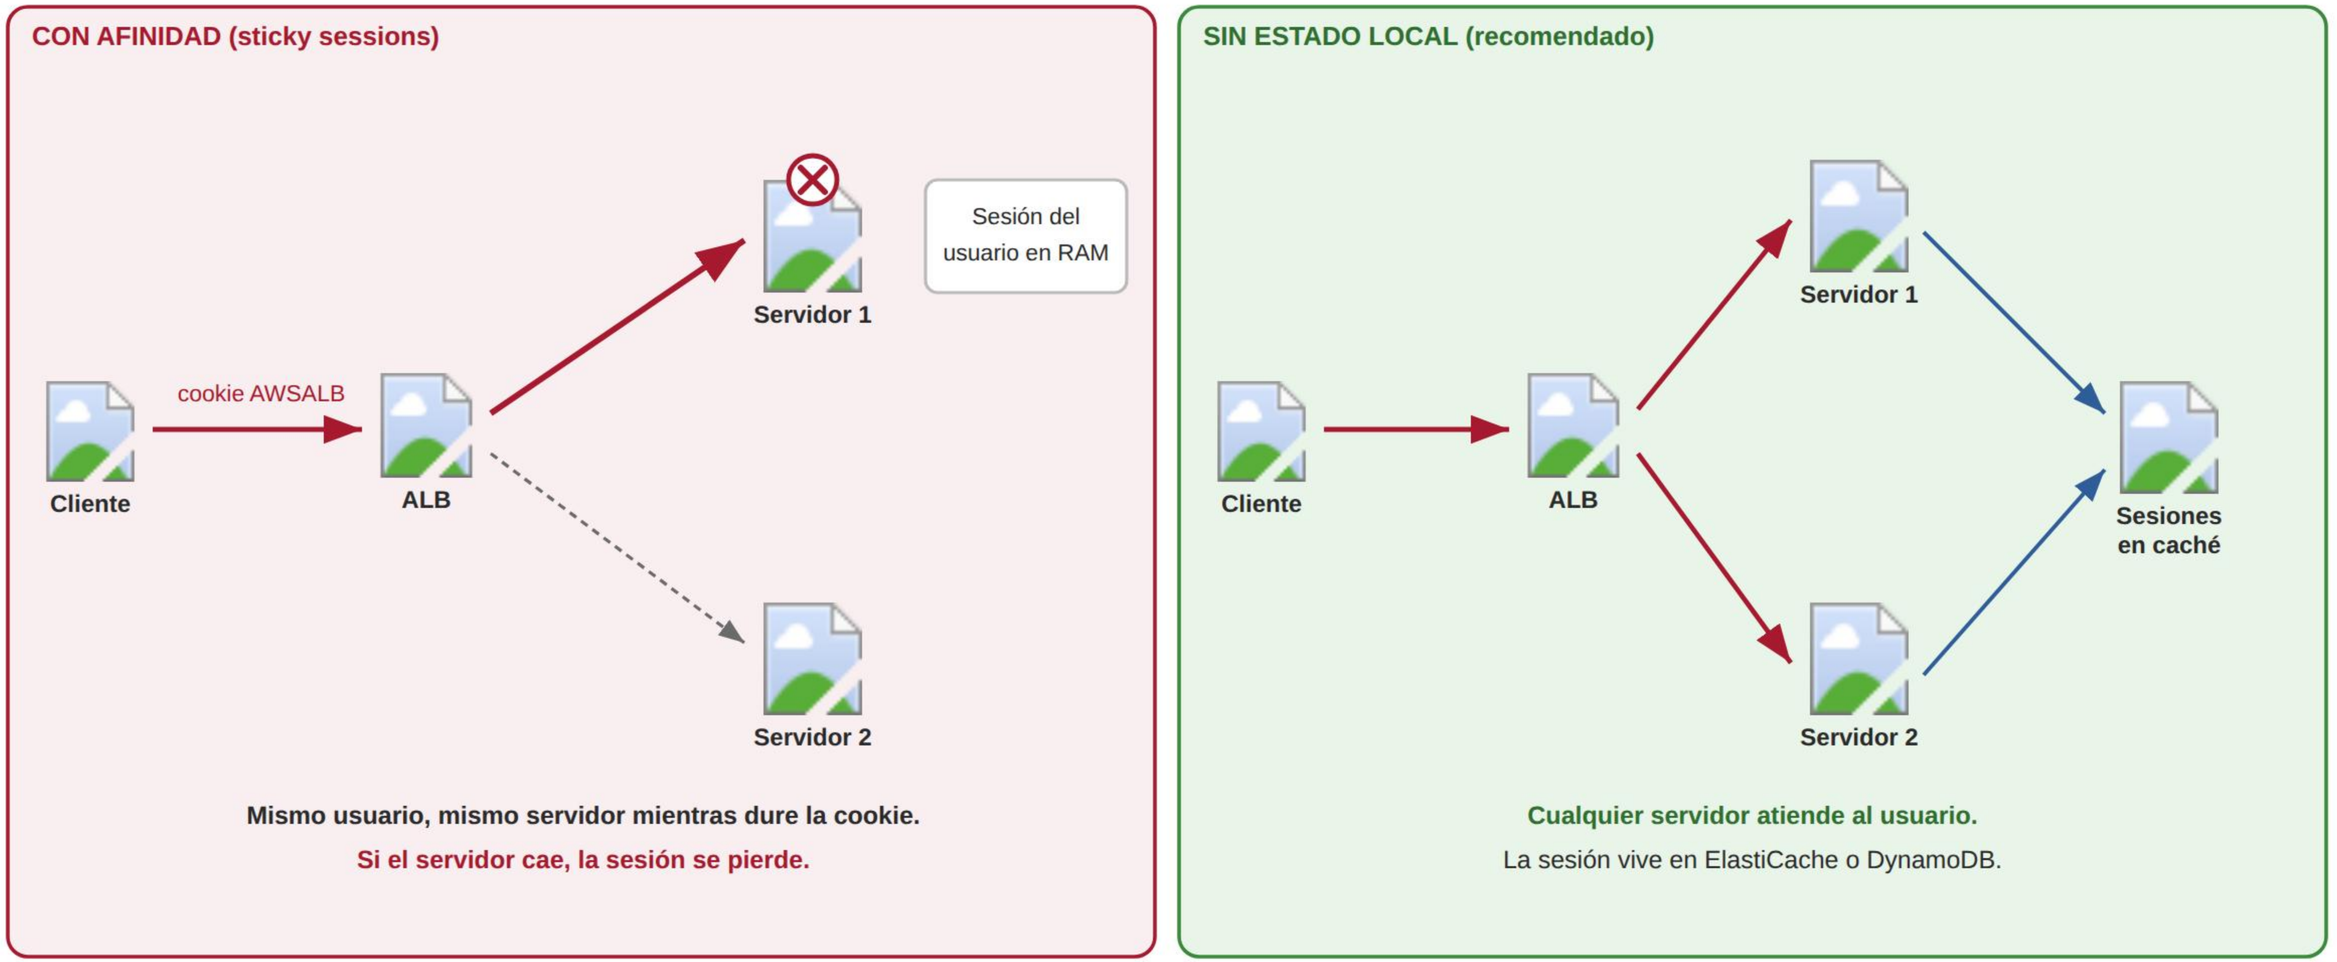




Fuente: adaptado de Elastic Load Balancing User Guide — Cross-zone load balancing

Sesiones: afinidad o servidores sin estado

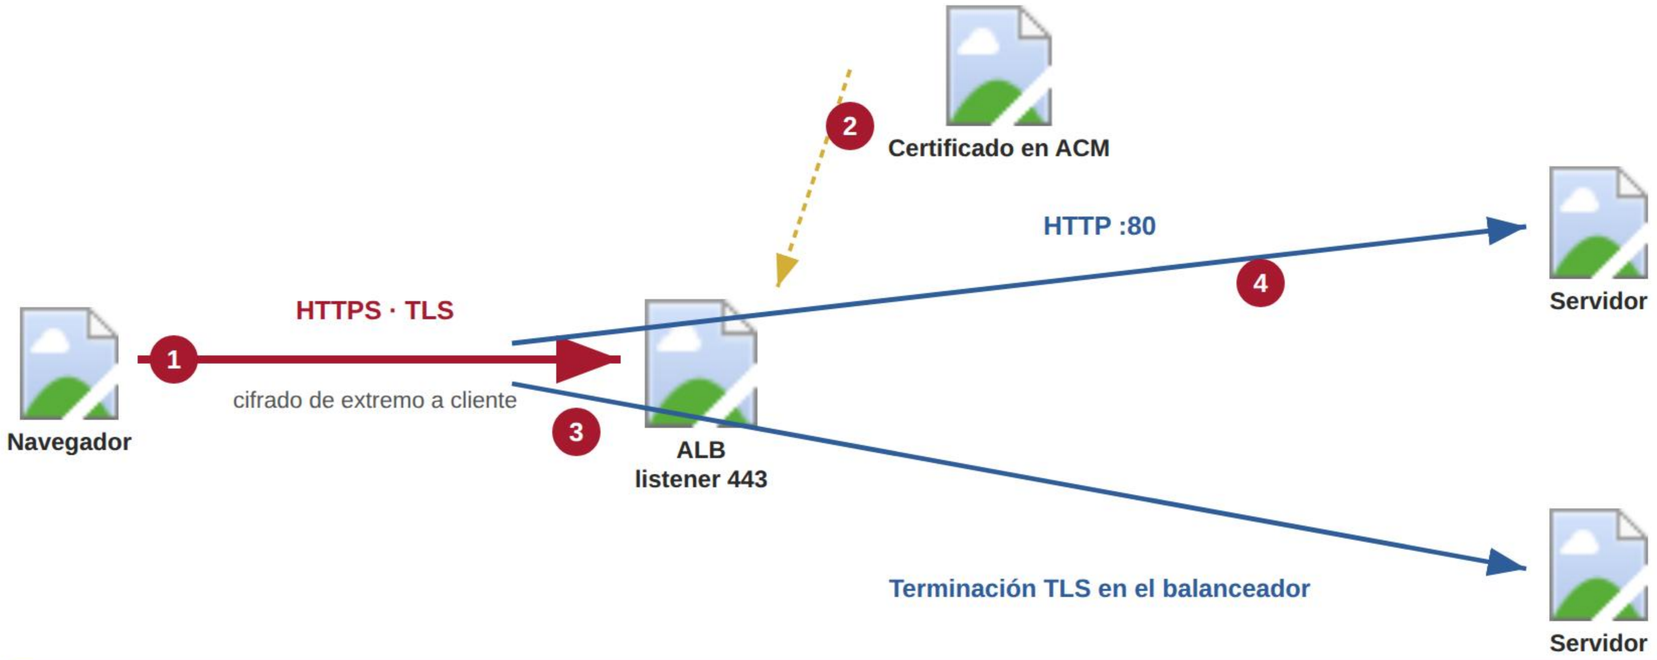
La afinidad pega al usuario a un servidor; guardar la sesión fuera del servidor permite escalar y fallar con gracia.



Fuente: adaptado de Elastic Load Balancing User Guide — Sticky sessions

Terminación TLS: el candado en el balanceador

El ALB atiende el cifrado con un certificado de ACM y reenvía al servidor, que se libera de esa tarea.



Paso a paso

1. El navegador inicia TLS y pide el certificado
2. El listener usa el certificado de ACM (renovación automática)
3. ALB descifra y lee la solicitud HTTP
4. Reenvía al destino por HTTP, o cifra de nuevo hacia el servidor

Qué ganas al terminar TLS en el balanceador

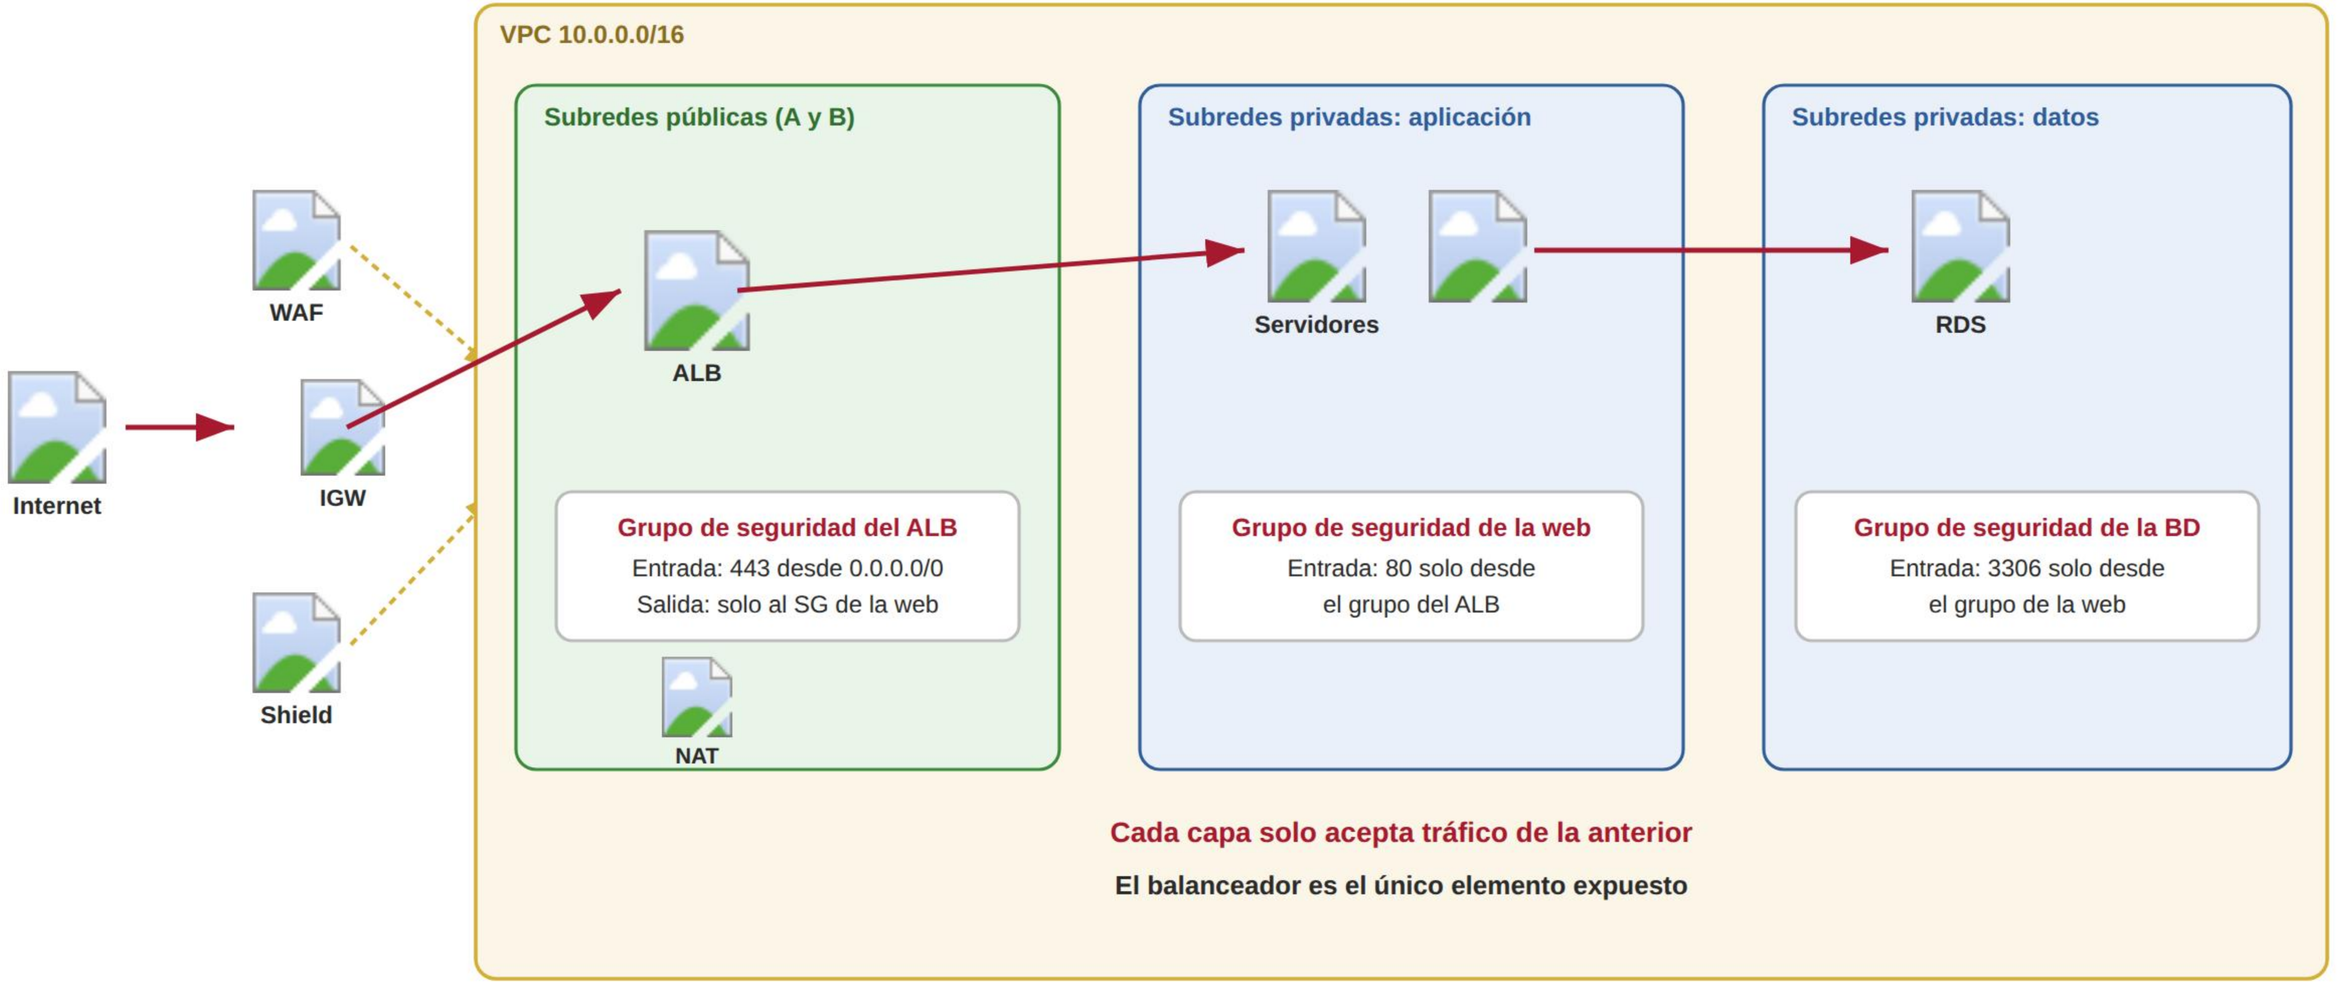
Los servidores no gastan CPU en cifrar y el certificado se administra en un solo lugar (ACM).

SNI permite varios certificados en un mismo listener. Si la norma exige cifrado hasta el servidor, se vuelve a cifrar.

Fuente: adaptado de Elastic Load Balancing User Guide — HTTPS listeners; AWS Certificate Manager

El balanceador en el borde, los servidores adentro

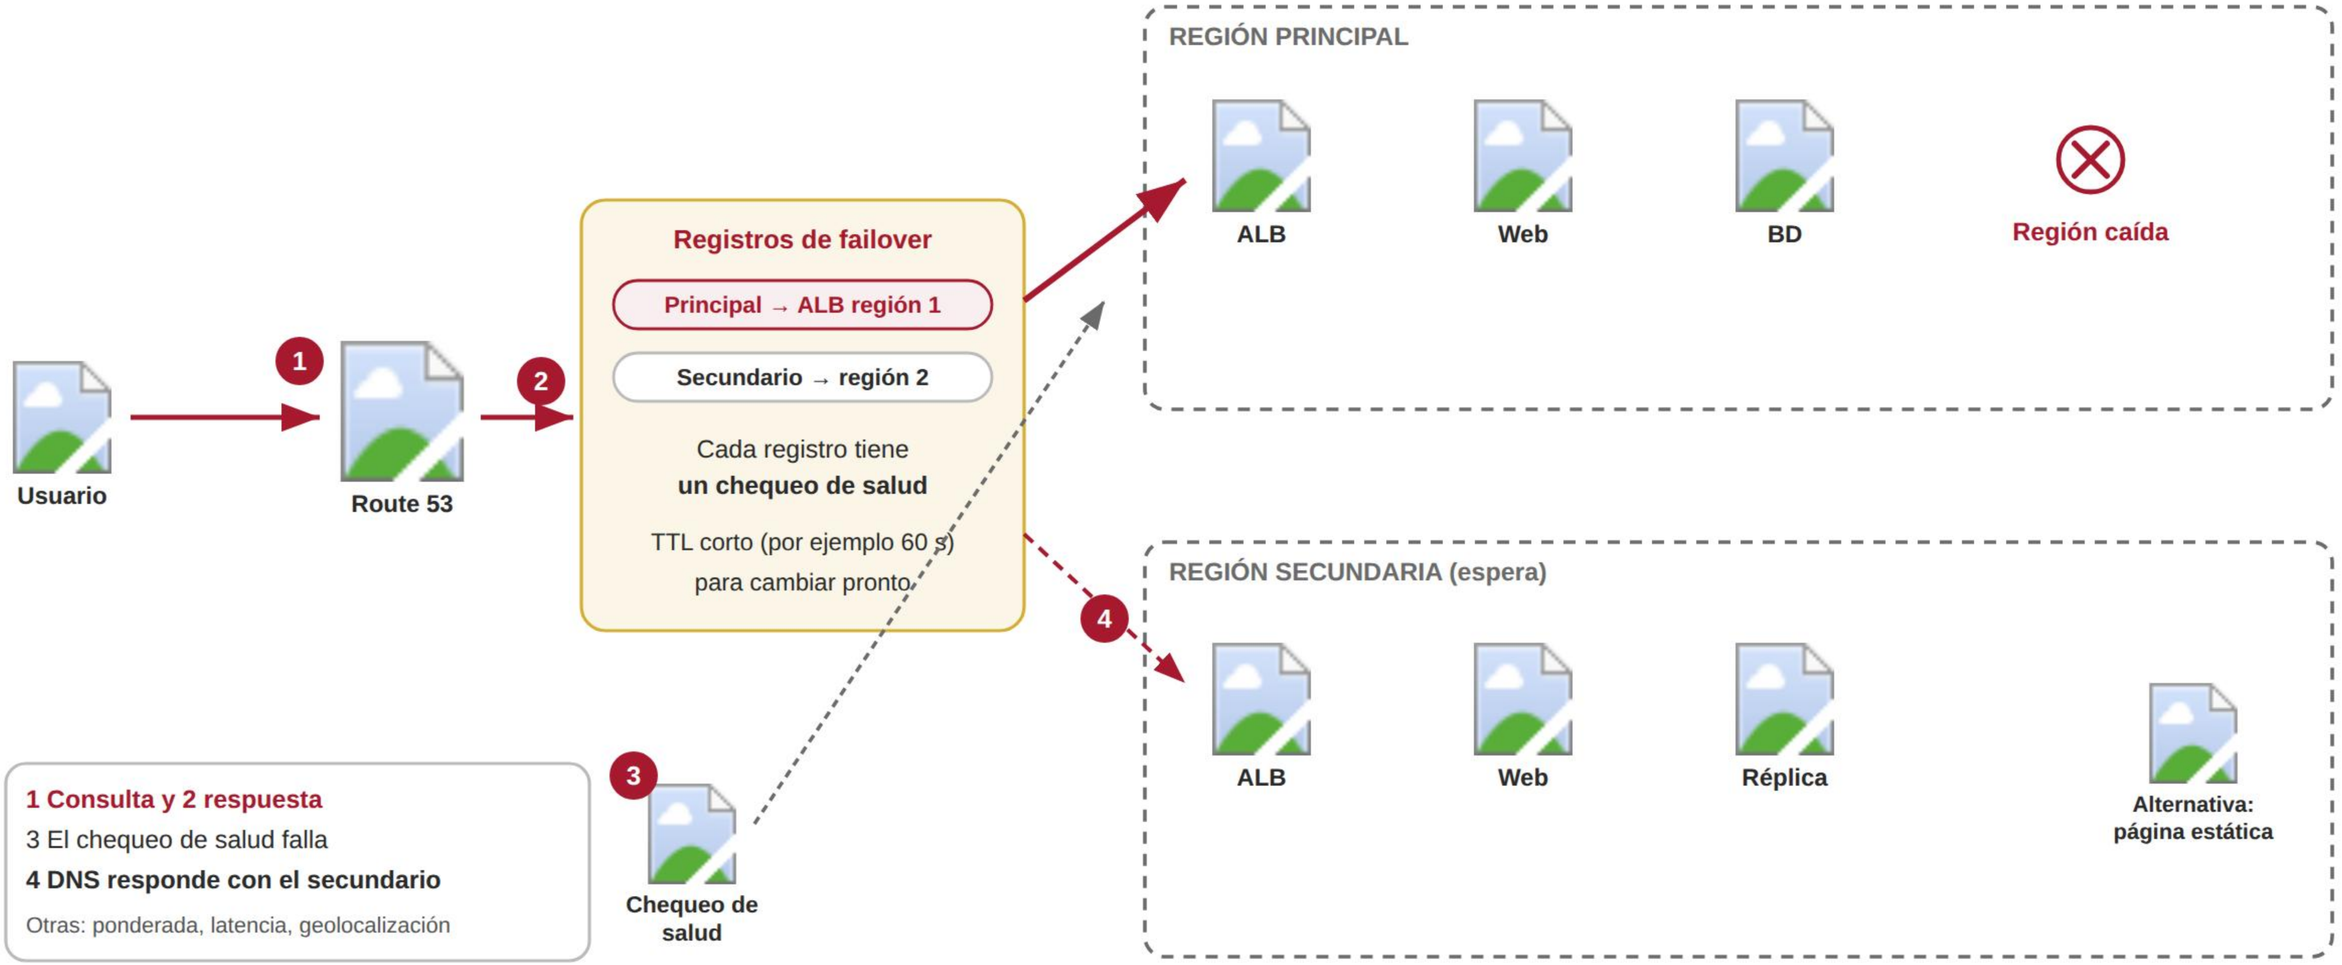
Los grupos de seguridad encadenados dejan una sola entrada pública; WAF y Shield protegen esa entrada.



Fuente: adaptado de AWS Well-Architected — Seguridad; guía de grupos de seguridad de VPC

Route 53: failover entre regiones o sitios

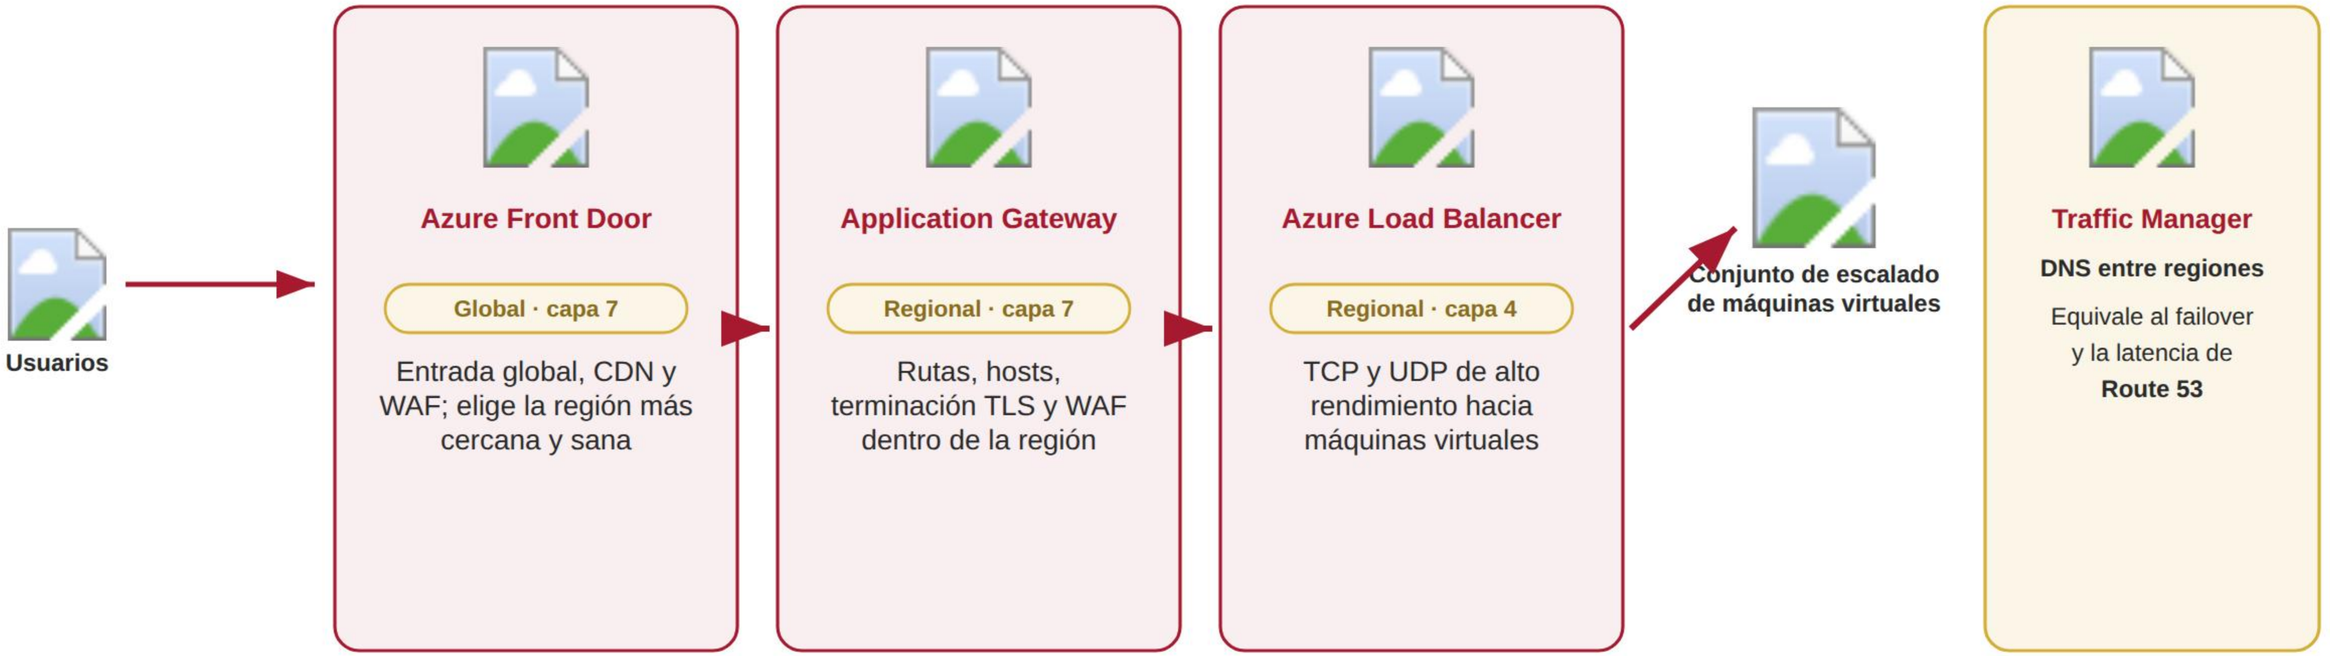
Cuando el chequeo de salud falla, el DNS deja de responder con el principal y entrega el secundario.



Fuente: adaptado de Amazon Route 53 Developer Guide — Active-passive failover

El mismo patrón en Azure y en Google Cloud

Entrada global, balanceo regional de capa 7 y de capa 4 hacia máquinas en varias zonas: cambian los nombres, no la idea.



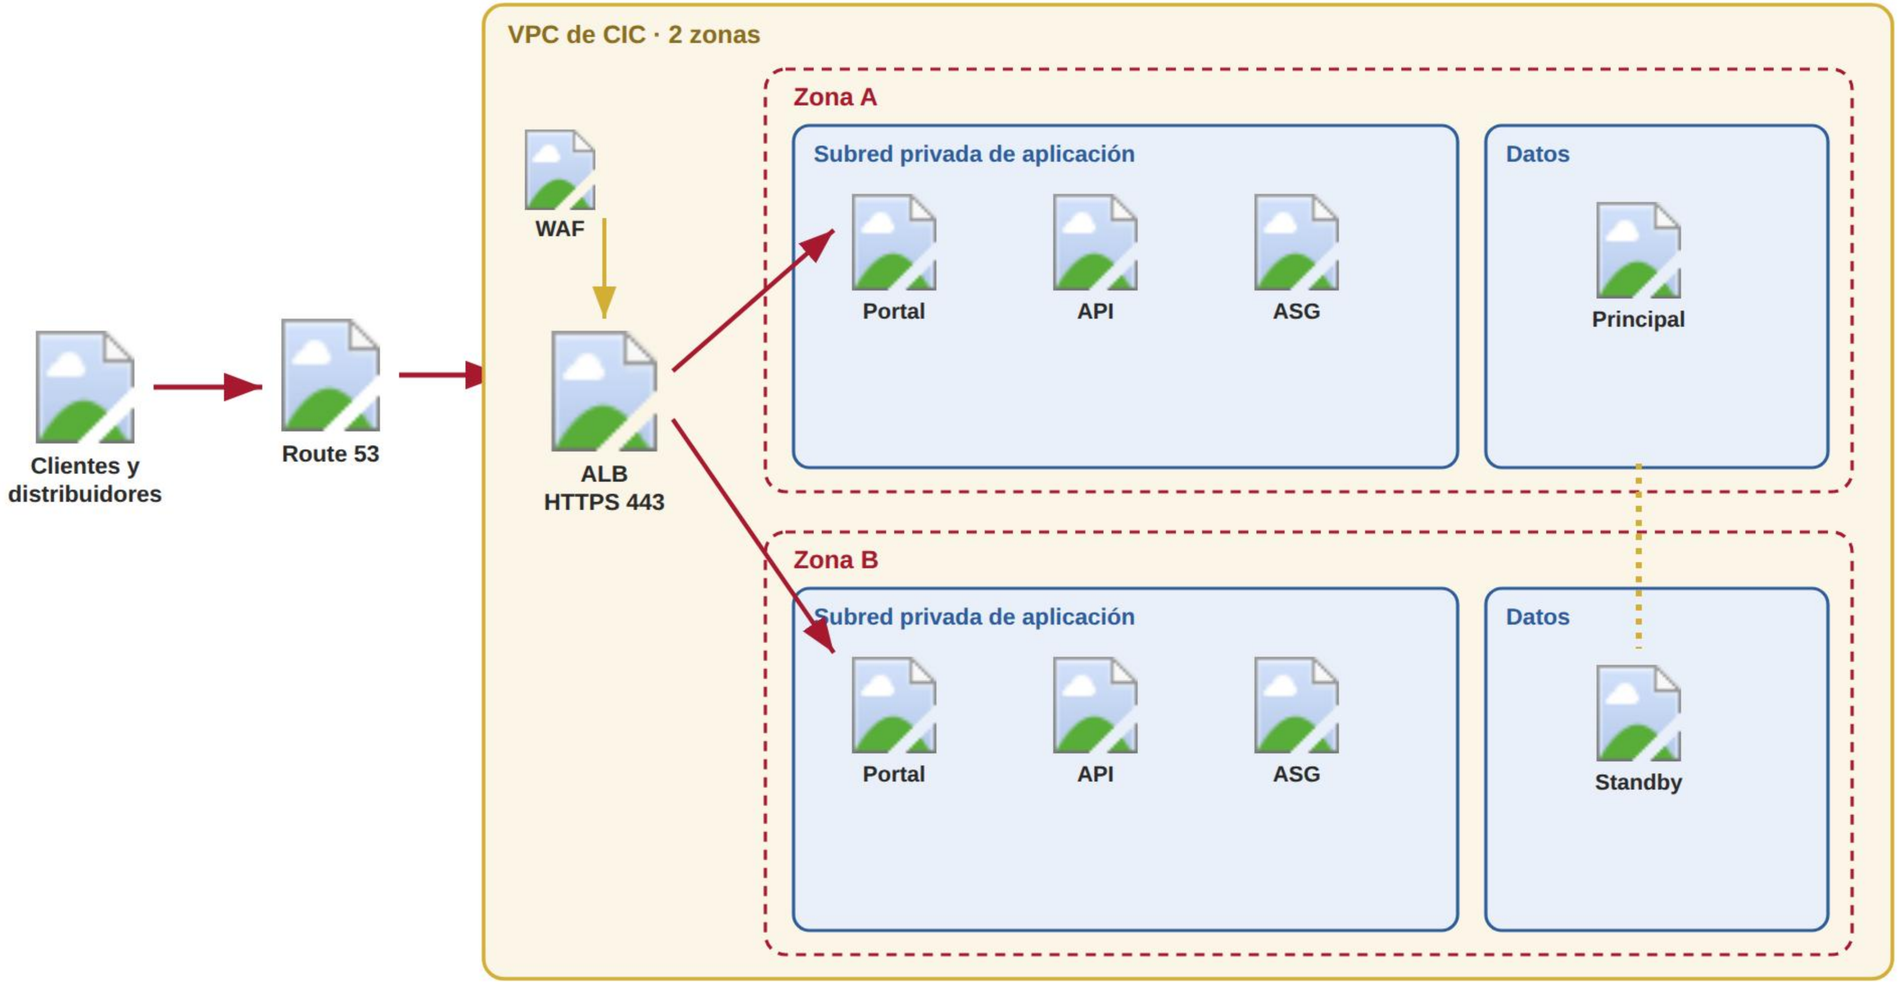
Google Cloud Load Balancing: un solo balanceador global con una IP anycast, de capa 4 o de capa 7.

El patrón es el mismo: entrada global, balanceo regional por capa y destinos en varias zonas.

Fuente: adaptado de Microsoft Learn — Load-balancing options; Google Cloud Load Balancing

Caso CIC: el portal de pedidos con ALB

Route 53, WAF y ALB reciben; dos zonas con grupos de servidores y base de datos con standby responden.



Antes

Un servidor, 90 min de caída, pedidos perdidos.

Ahora

ALB con /api y /, chequeo /salud y TLS en el balanceador.

Resultado

Un servidor puede caer o cambiarse sin que lo note el cliente.

Fuente: caso docente CIC; adaptado de AWS Architecture Center — web de alta disponibilidad

SÍNTESIS

Lo que queda de la Parte 2

Cuatro ideas para llevarse antes de hablar de Auto Scaling.

1



Capa 7 entiende, capa 4 reenvía

ALB enruta por contenido; NLB por flujo, con alto rendimiento.

2



Listener, regla, grupo, destino

Esa es la cadena de configuración de un balanceador.

3



Salud y reparto parejo

Health checks sacan a los caídos; cross-zone evita zonas saturadas.

4



Servidores sin estado

Sesiones fuera del servidor y TLS en el balanceador.



Siguiente: Parte 3 · Elasticidad

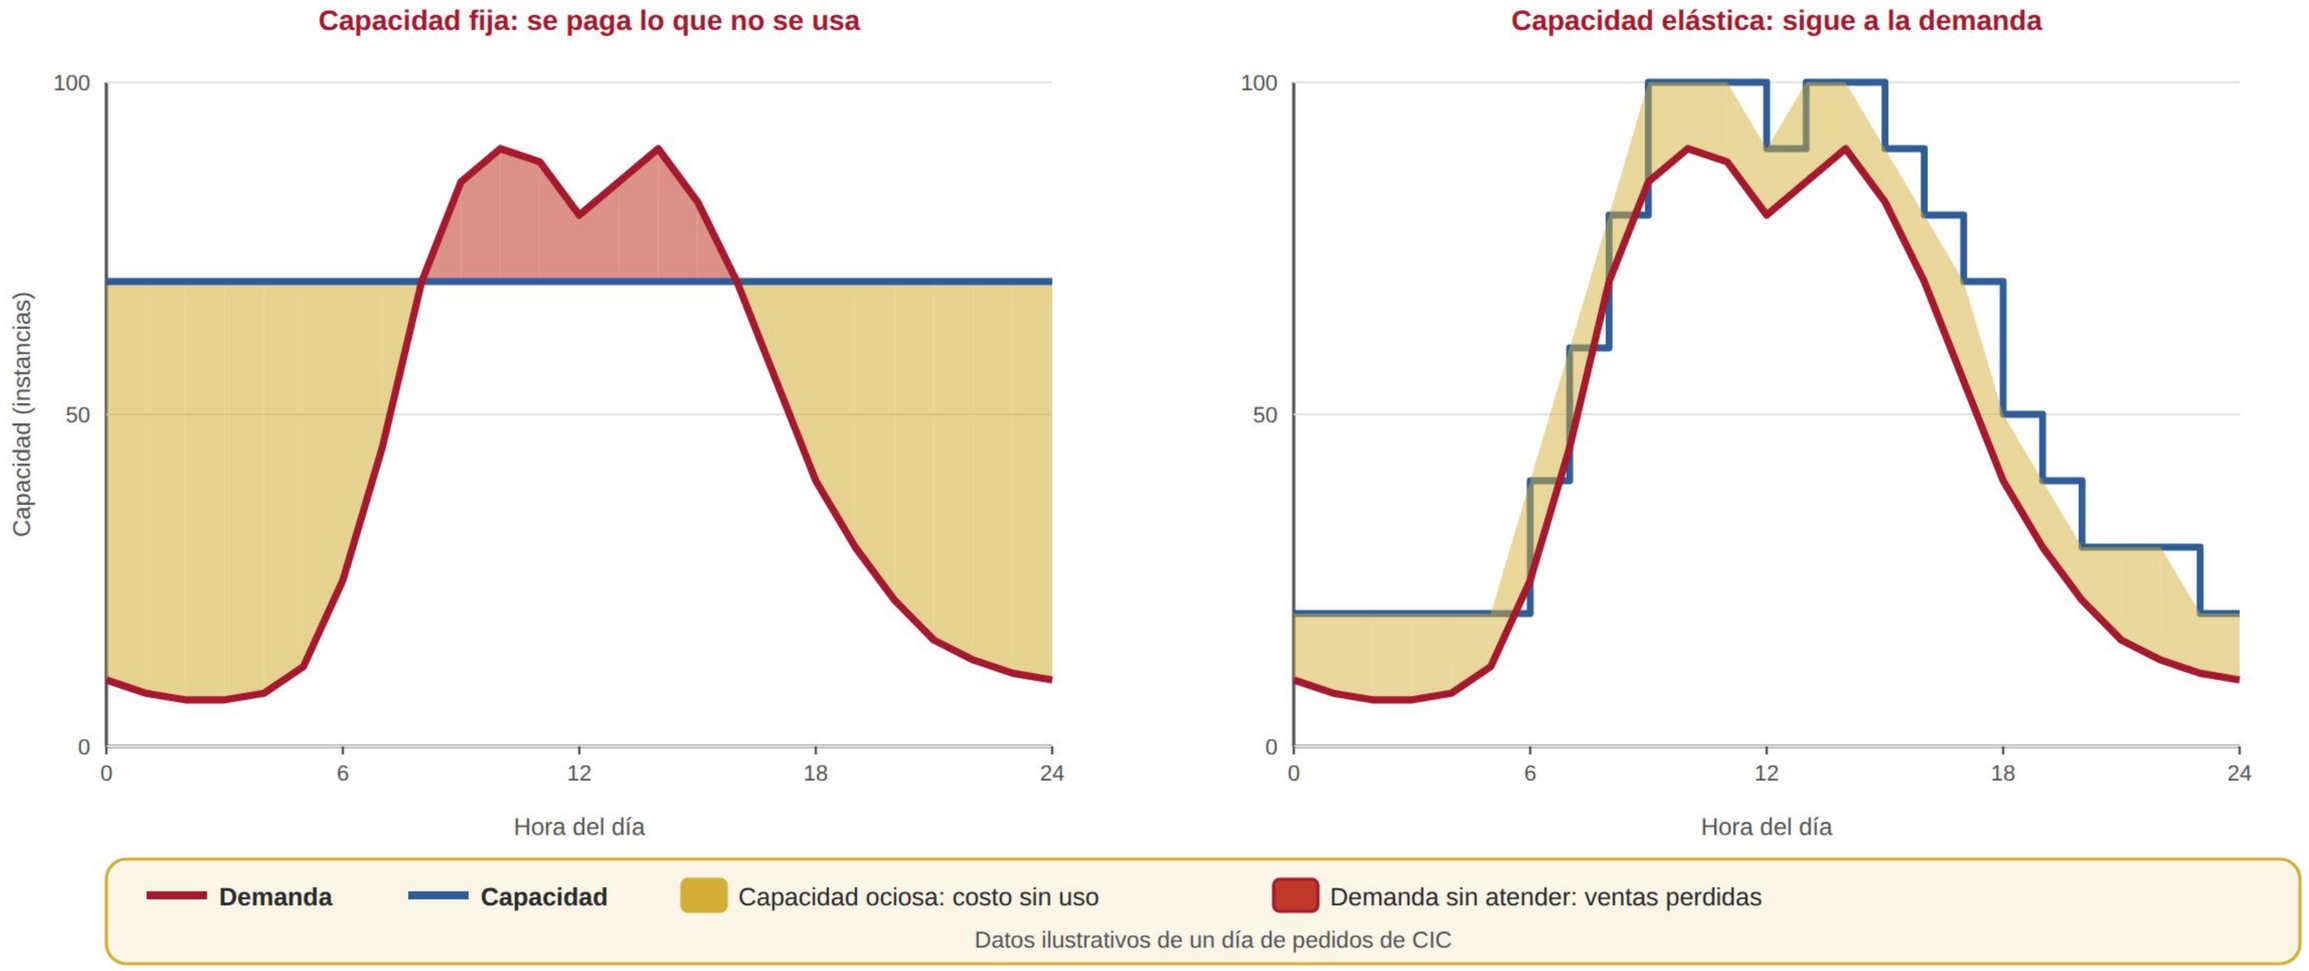
El balanceador reparte, pero la cantidad de servidores sigue fija.
Ahora veremos cómo crecer y encogerse solos con la demanda.

Fuente: síntesis del curso; Elastic Load Balancing User Guide

ENCUADRE

La demanda sube y baja; la capacidad también debería

Con capacidad fija se desperdicia de madrugada y se pierde en el pico; la elástica sigue la curva de pedidos.



Fuente: adaptado de AWS Well-Architected — Eficiencia del rendimiento; datos ilustrativos

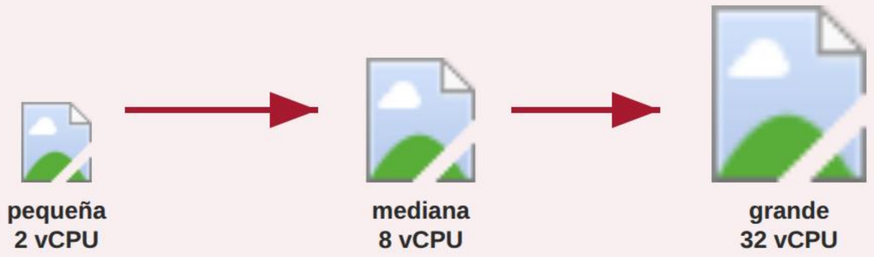
CONCEPTOS

Escalar hacia arriba o hacia los lados

Un servidor más grande tiene techo; más servidores iguales detrás de un balanceador casi no lo tienen.

ESCALAR VERTICALMENTE (scale up)

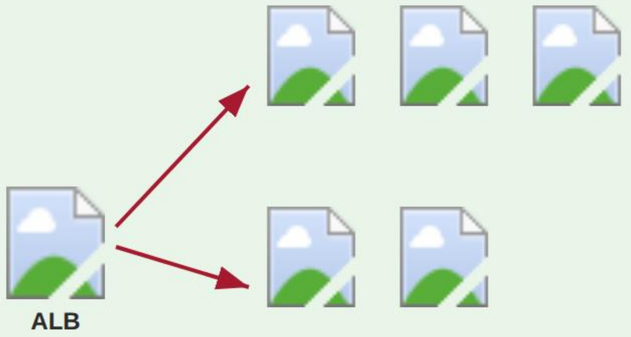
Una máquina más potente



Límite del hardware y reinicio al cambiar de tamaño

Sigue siendo un punto único de falla

ESCALAR HORIZONTALMENTE (scale out)



Más máquinas iguales

se agregan y se quitan

Casi sin límite y sin reinicios

Exige servidores sin estado y un balanceador

Escalabilidad

Capacidad del sistema para crecer cuando hace falta.

Puedes lograrla a mano.

Elasticidad

Crecer Y encogerse automáticamente con la demanda.

Exige automatización, métricas y políticas.

Fuente: adaptado de AWS Well-Architected — Eficiencia del rendimiento; NIST SP 800-145 (elasticidad rápida)

Anatomía de un grupo de Auto Scaling

El grupo conserva el número deseado de instancias, entre un mínimo y un máximo, repartidas por zonas.



Qué hace el grupo

Mantiene el número deseado de instancias vivas. Reemplaza las que fallan. Reparte entre zonas. Las registra en el grupo de destinos del ALB. Cambia el número deseado entre el mínimo y el máximo según las políticas.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide

La plantilla de lanzamiento: la receta de cada instancia

Imagen, tipo, red, permisos y arranque quedan en una plantilla versionada que el grupo usa para crear instancias.

Plantilla de lanzamiento (versionada)

Imagen (AMI)
Sistema operativo y software base

Tipo de instancia
t3.medium, m6i.large...

Perfil IAM
Rol para llamar a otros servicios

Grupos de seguridad
Reglas de red de la instancia

Volúmenes EBS
Tamaño y tipo del disco

Datos de usuario
Script de arranque (user data)

lanza

Dos formas de preparar el servidor

AMI «dorada»
Todo preinstalado: arranca rápido y es predecible.

User data
Instala al arrancar: flexible, pero más lento.

Cambiar de versión sin perder el control

- **v1** AMI de septiembre
- **v2** AMI con parche de seguridad
- **v3** Tipo m6i.large

El grupo usa «Última» o una versión fija

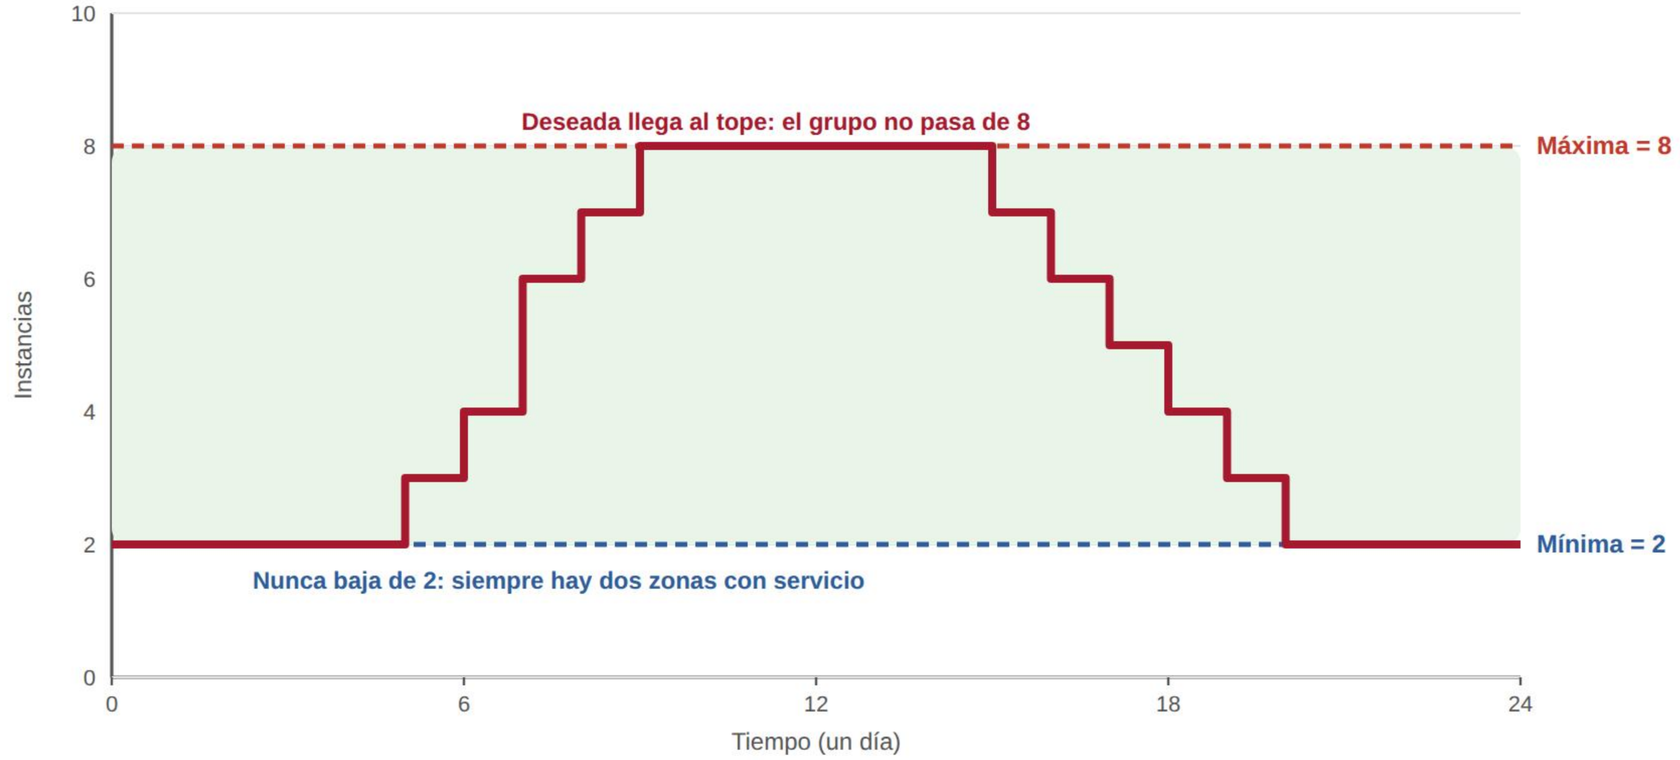
Las configuraciones de lanzamiento están descontinuadas.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Launch templates

CAPACIDAD

Mínima, deseada y máxima: los tres números

La capacidad deseada se mueve con la demanda, pero siempre dentro de los límites que tú defines.



Regla de oro: mínimo ≥ número de zonas, para que ninguna zona quede sin servidores.

Con 2 zonas y mínimo 1, una zona puede quedar vacía.

Mínima

Piso de disponibilidad: con dos instancias en dos zonas el sistema resiste la caída de una zona.

Deseada

Cuántas instancias quiere el grupo ahora mismo. Las políticas la mueven.

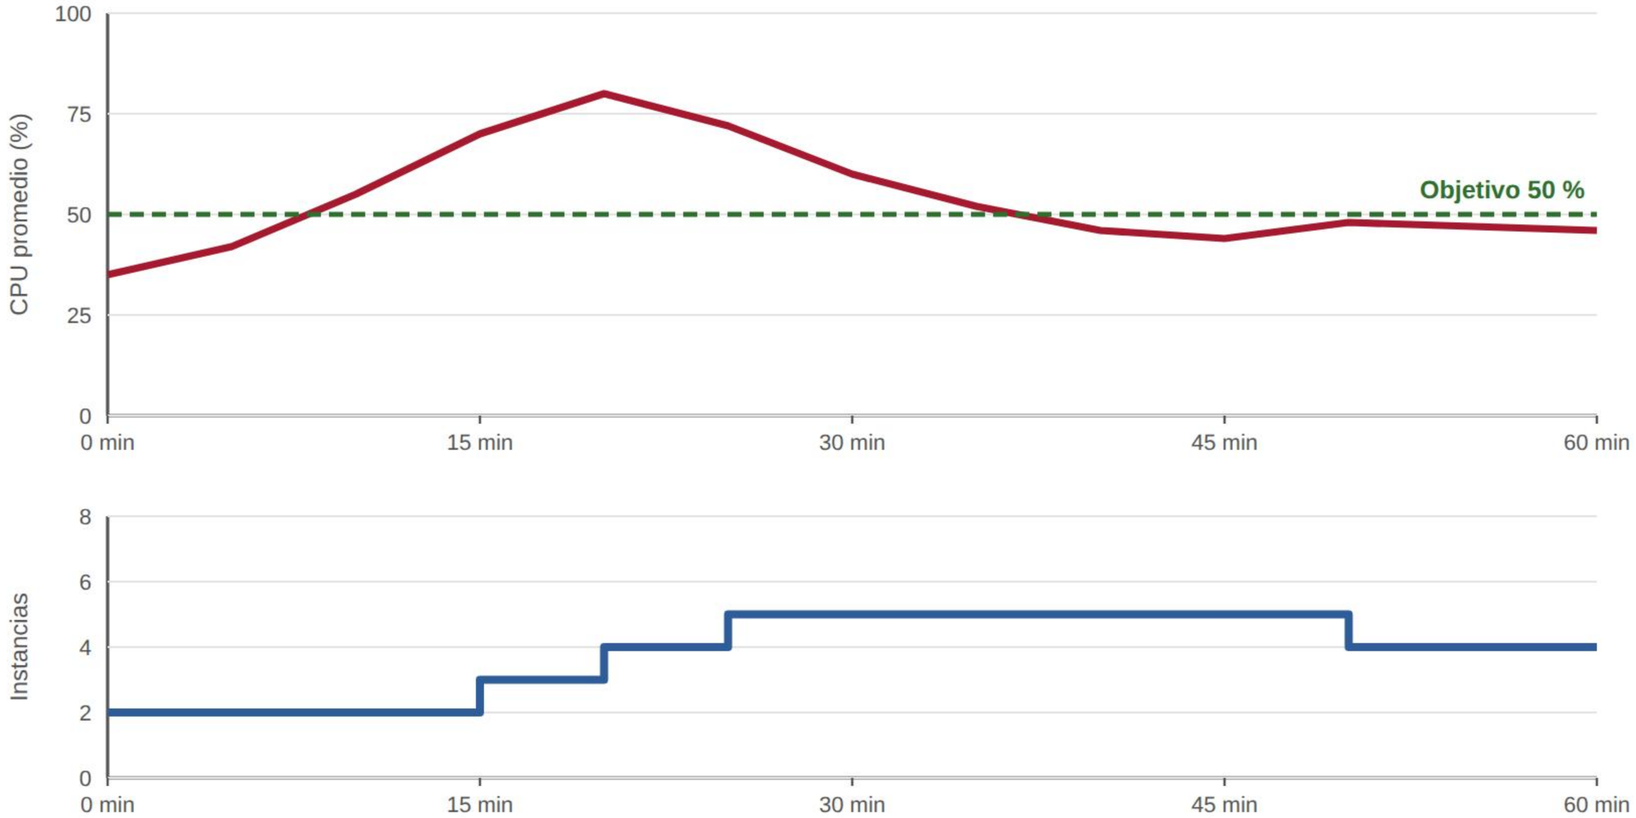
Máxima

Techo de costo y de seguridad: protege de una factura inesperada o un error de métrica.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Set scaling limits

Seguimiento de objetivo: el termostato de la nube

Eliges una métrica y un valor deseado; el grupo suma o resta instancias para mantenerlo.



La política agrega instancias cuando el promedio sube del objetivo y las quita, con más calma, cuando baja.

Como un termostato

Tú fijas la temperatura (50 % de CPU).

Auto Scaling crea y administra las alarmas de CloudWatch por ti.

Métricas predefinidas

- CPU promedio del grupo
- Red de entrada promedio
- Red de salida promedio
- Solicitudes por destino del ALB

También puedes usar una métrica propia

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Target tracking scaling policies

POR PASOS

Escalado por pasos: la respuesta proporcional

Cuanto mayor es la brecha frente al umbral, más instancias se agregan de una sola vez.

Alarma de CPU alta: tamaño de la brecha decide cuánto se agrega





Cuándo conviene

Cuando quieres controlar la respuesta: un salto grande de carga merece más instancias que uno pequeño. Tú defines las bandas y los ajustes.

Pasos o simple

Por pasos reacciona proporcional a la brecha. La política simple agrega una cantidad fija y espera un enfriamiento.

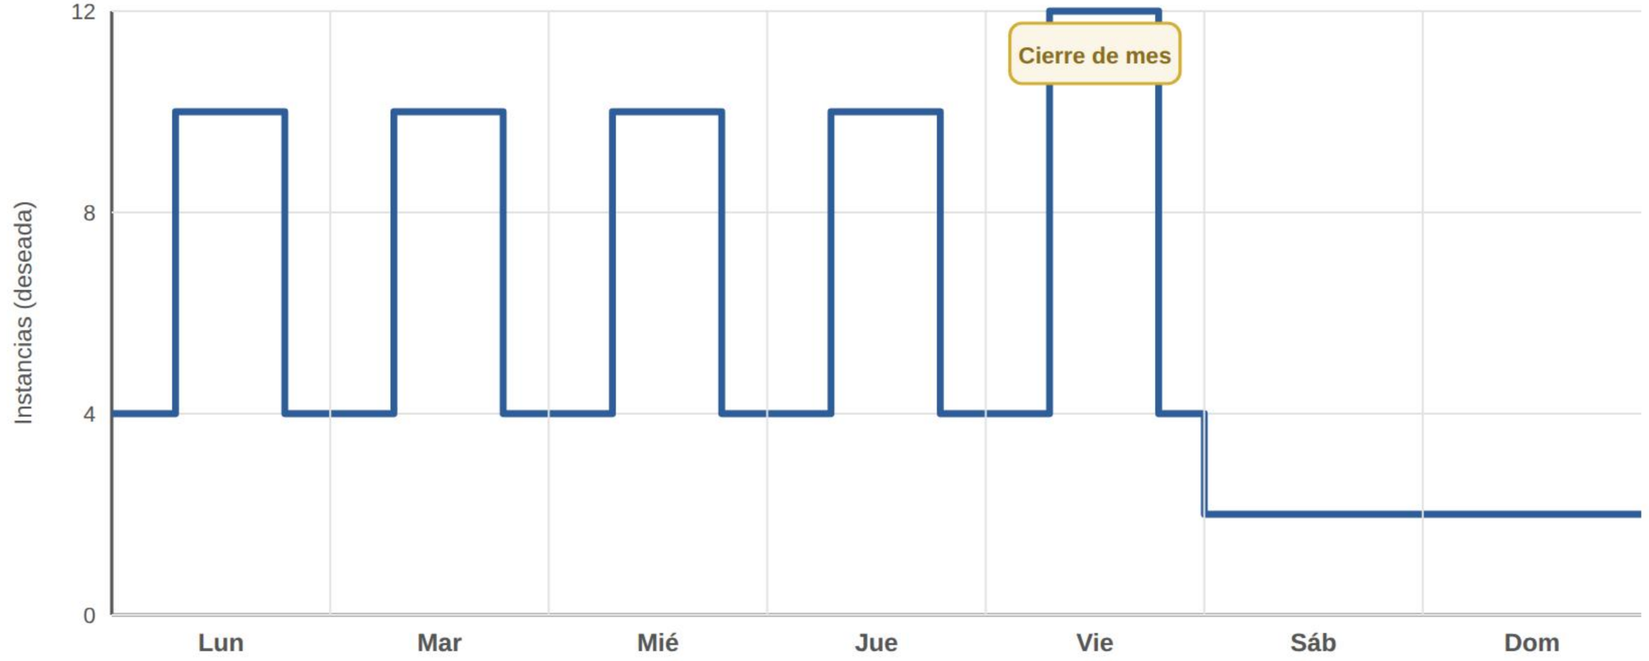
Con calentamiento

Define cuánto tarda una instancia nueva en aportar, para que no se cuente doble en la métrica.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Step and simple scaling policies

Escalado programado: anticiparse al calendario

Si sabes cuándo llega la carga, ajusta la capacidad a una hora fija en lugar de esperar a que la métrica reaccione.



Una semana típica: las acciones programadas ajustan mínimo, máximo y deseada a horas fijas

Acción programada

Nombre: subir-laboral

Cron: 0 7 * * 1-5

Zona horaria: America/Bogota

Mínimo 4 · Máximo 14

Deseada 10

Otra acción a las 19:00
baja de nuevo a 4.

Úsalas cuando conoces el calendario

Nómina, cierres de mes, campañas del Día sin IVA o inicio del turno de planta.

Se combinan con las dinámicas

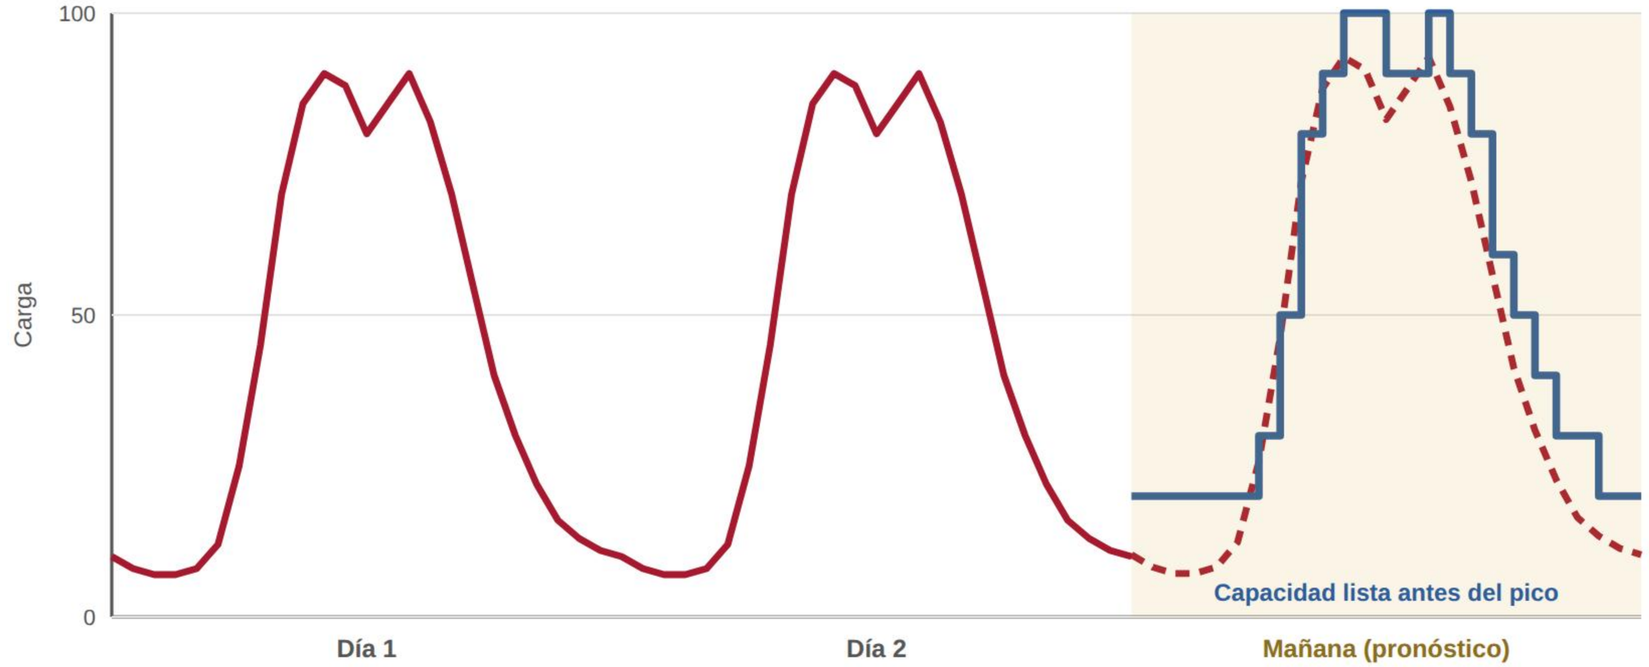
La programada fija el piso del pico; seguimiento de objetivo absorbe lo inesperado.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Scheduled scaling

PREDICTIVO

Escalado predictivo: aprender del patrón

Con la historia de la métrica, el servicio pronostica la carga y lanza instancias antes de que el pico llegue.



Cómo funciona

- Usa hasta 14 días de historia de CloudWatch
- Necesita al menos 24 horas de datos
- Pronostica las siguientes 48 horas
- Funciona con patrones cíclicos

El modelo aprende el patrón diario y semanal de la métrica y lanza instancias antes de que llegue la carga.

Dos modos

Solo pronóstico: ves qué haría. Pronóstico y escalado: lo aplica.

No reemplaza a la reactiva

Cubre lo previsible; el seguimiento de objetivo cubre lo imprevisto.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Predictive scaling

SEMANA 10 · ELASTICIDAD, ALTA DISPONIBILIDAD Y MONITORIZACIÓN

Ciclo de vida, monitorización y laboratorio

Parte 3 de 3 · Unidad 2

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 10 · Periodo 2026-2 · Barranquilla, Colombia

Ciclo de vida del grupo, réplicas de lectura, CloudWatch, alarmas y el laboratorio final

Ciclo de vida, drenaje y enfriamiento

Auto Scaling no apaga a ciegas: drena conexiones, respeta pausas y deja ganchos para tareas propias.

Pending
Lanzando y configurando

→

InService
Recibe tráfico del balanceador

→

Terminating
Se retira y se apaga

→

Terminated
Eliminada

Gancho de ciclo de vida
Pausa para instalar o registrar

Gancho de ciclo de vida
Pausa para copiar logs

Desescalado con cuidado: lo que pasa cuando el grupo retira una instancia

1 Elige la víctima



Equilibra zonas y quita la más antigua según la política de terminación.

→

2 Deja de enrutar



El balanceador no le envía solicitudes nuevas.

→

3 Drenaje de conexiones



Espera hasta 300 s (por defecto) a que terminen las solicitudes en curso.

→

4 Termina



Se apaga y se libera; la protección de desescalado puede evitarlo.

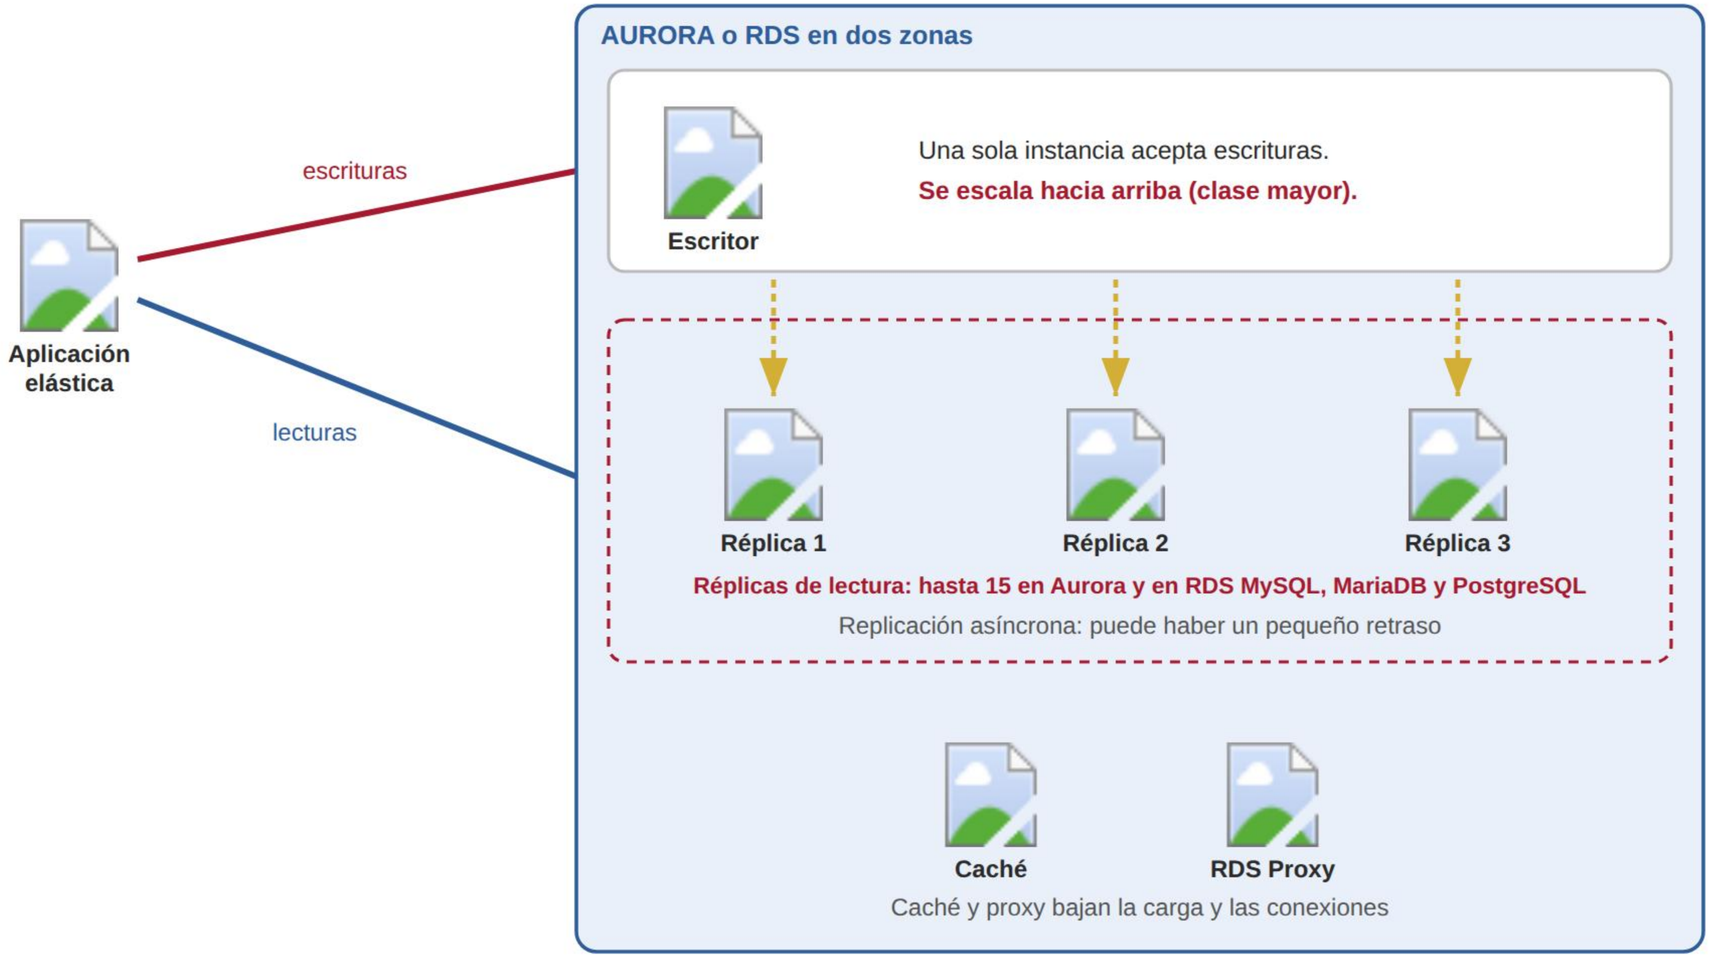
Enfriamiento (cooldown): espera 300 s entre acciones de la política simple · Calentamiento: tiempo antes de contar la instancia en la métrica

Sin estas pausas el grupo oscilaría: subir, bajar y volver a subir a cada fluctuación.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Instance lifecycle y Scale-in

Escalar la base de datos: lecturas y escrituras

Las lecturas se reparten entre réplicas; las escrituras siguen un solo escritor y crecen en vertical.



Lecturas: horizontal

Más réplicas y un endpoint de lectura que las reparte. Aurora puede agregar réplicas con Auto Scaling.

Escrituras: vertical

Cambiar la clase de instancia exige breve interrupción; en Multi-AZ el corte es mínimo.

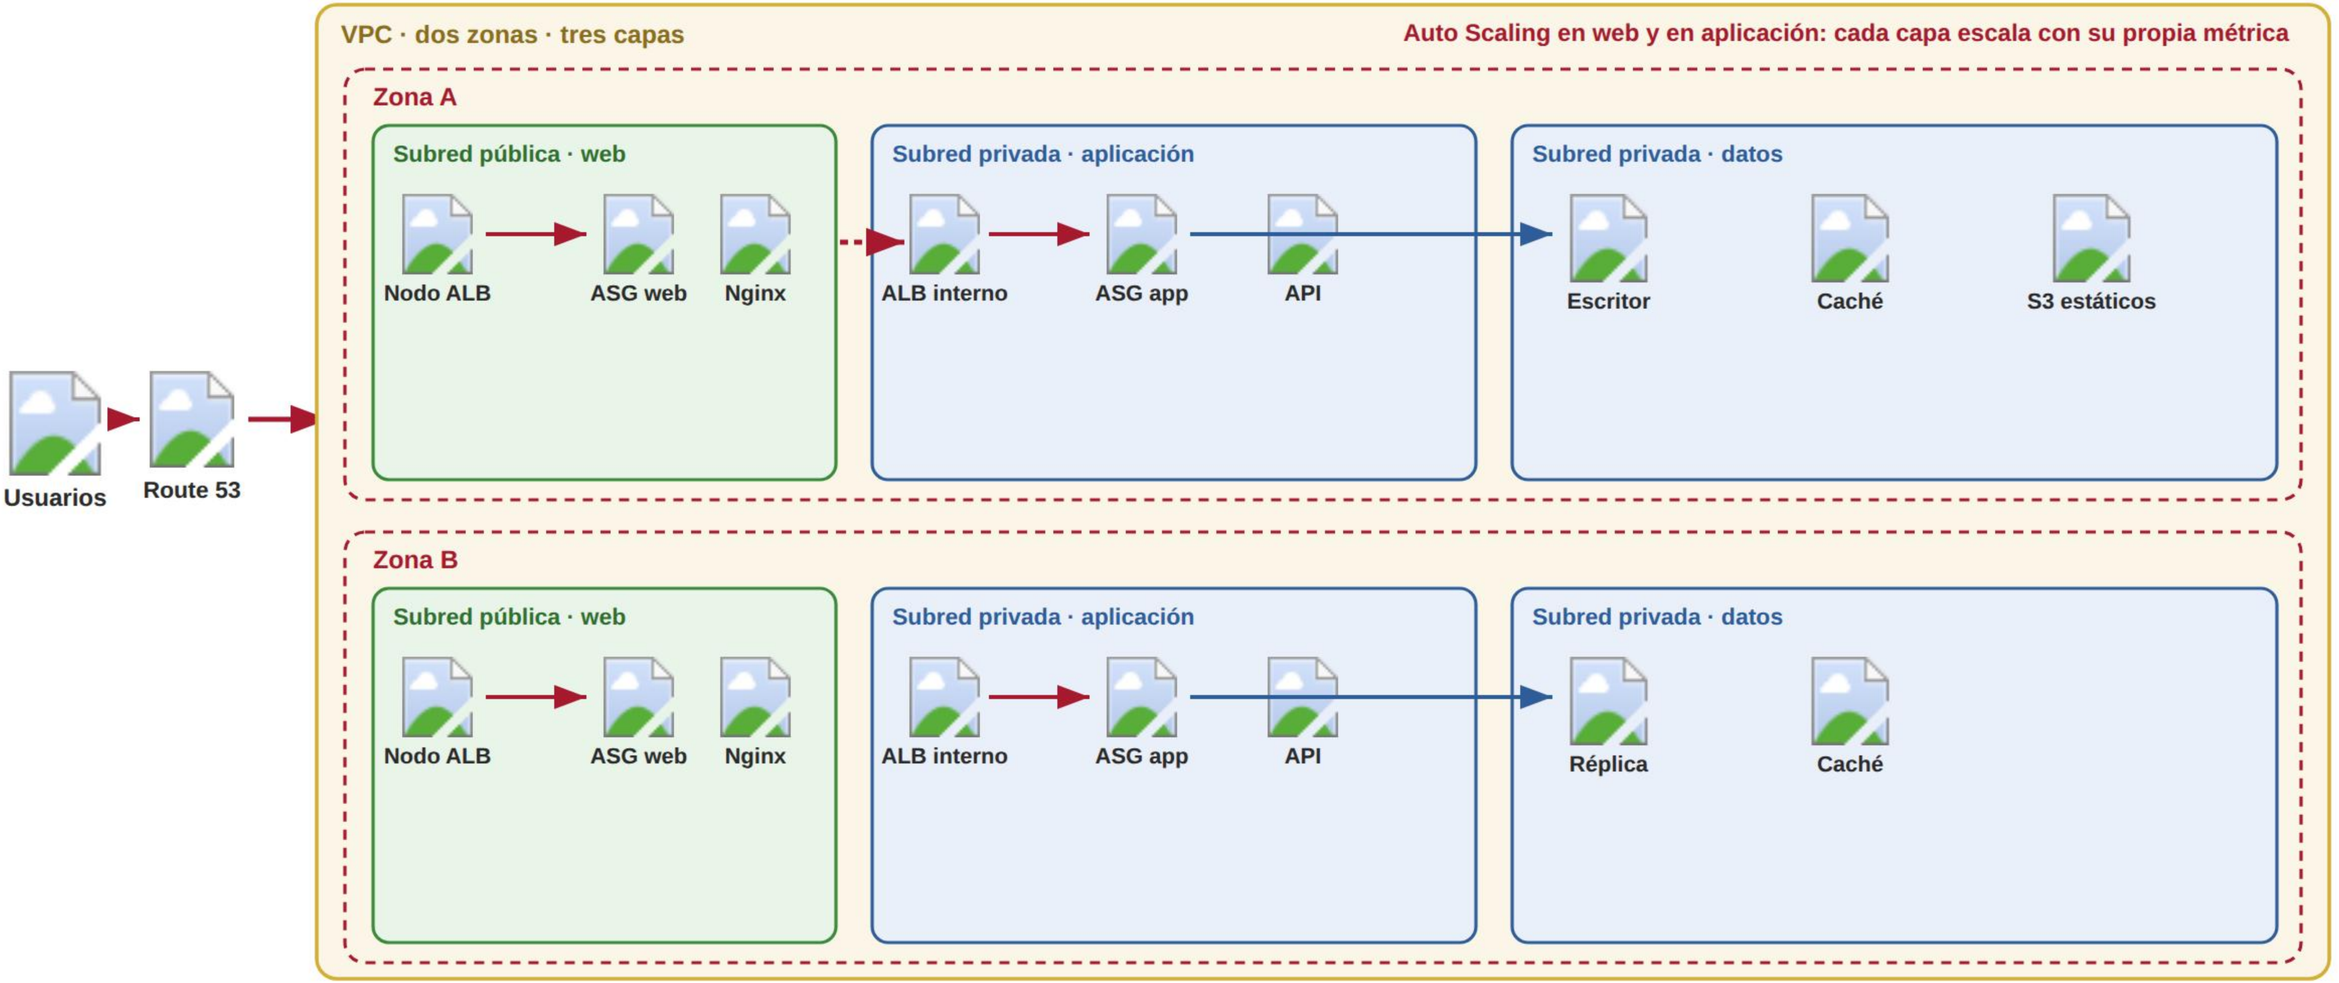
Otras opciones

Almacenamiento con autoescalado. Aurora Serverless v2 ajusta la capacidad. DynamoDB: bajo demanda.

Fuente: adaptado de Amazon RDS y Amazon Aurora User Guides — réplicas de lectura

Arquitectura web de tres capas elástica

Cada capa tiene su balanceador y su grupo, y escala con su propia métrica; los datos se replican entre zonas.

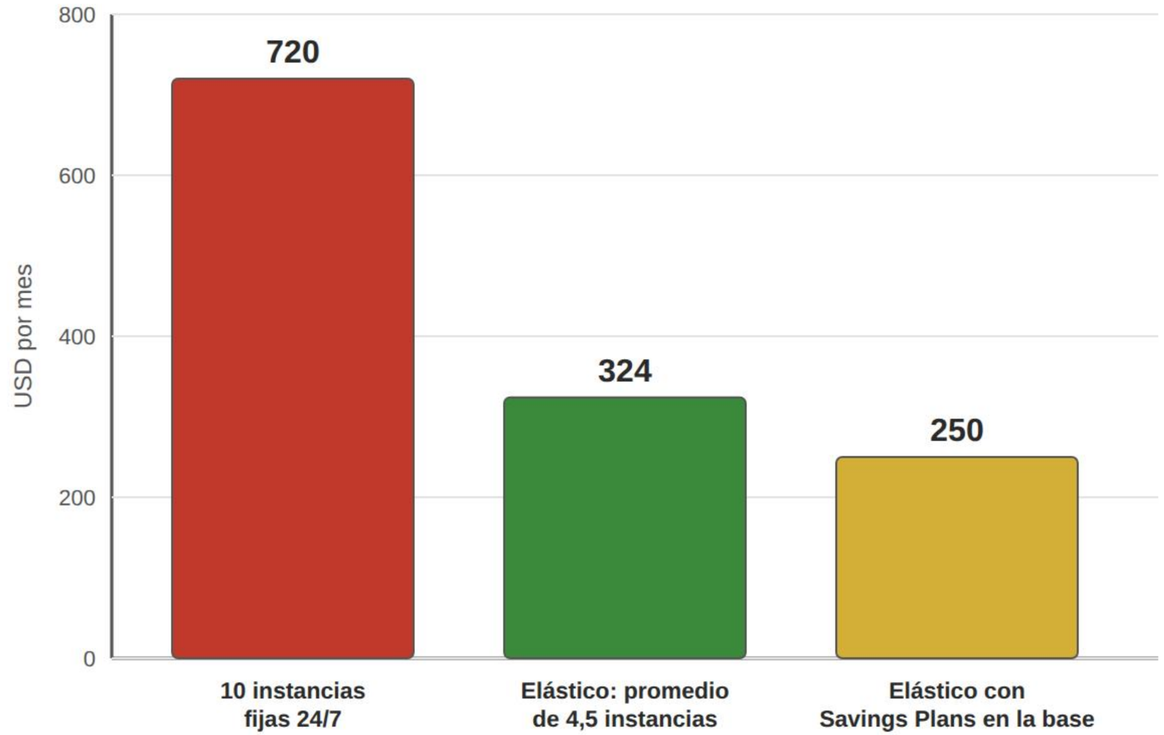


Fuente: adaptado de AWS Architecture Center — Three-tier web application; Well-Architected

¿Cuánto cuesta la elasticidad?

Pagar por uso reduce el costo del portal a menos de la mitad frente a capacidad fija dimensionada para el pico.

Costo mensual de cómputo del portal (dólares ilustrativos)



Supuesto: 0,10 USD por hora de instancia; 720 horas al mes. Cifras ilustrativas.

Cómo se calcula

Fijo: 10 × 720 h × 0,10 = 720 USD

Elástico: 4,5 × 720 h × 0,10 = 324 USD

Ahorro ilustrativo: 55 %

Base estable

El mínimo siempre encendido se compra con Savings Plans o instancias reservadas.

Picos

La capacidad extra puede usar Spot, con descuentos de hasta 90 por ciento, si tolera interrupciones.

Caso CIC

El portal pasó de 10 instancias fijas a un grupo de 4 a 12.

Máximo 12 evita facturas inesperadas; la elasticidad pone el costo al ritmo de los pedidos.

Fuente: cálculo ilustrativo; AWS Well-Architected — Optimización de costos

SÍNTESIS

Lo que queda de la Parte 3

Cuatro ideas para llevarse antes de hablar de monitorización.

1



Elasticidad es automática

Crecer y encogerse con la demanda; escalar hacia los lados.

2



Grupo + plantilla

Mínimo, deseado y máximo; la plantilla es la receta versionada.

3



Cuatro políticas

Objetivo, pasos, programada y predictiva; combínalas.

4



Los datos escalan distinto

Réplicas para leer, clase mayor para escribir, caché delante.



Siguiente: Parte 4 · Monitorización y laboratorio

Todo lo que escala depende de métricas. Veremos cómo se miden, se alarman y se visualizan, y armaremos el entorno escalable del laboratorio.

Fuente: síntesis del curso; Amazon EC2 Auto Scaling User Guide

Tres señales: métricas, logs y trazas

Las métricas avisan que algo pasa, los logs explican qué y las trazas muestran dónde.



Métricas

¿Cuánto y qué tan rápido?

Números en el tiempo: CPU, solicitudes, latencia, errores.

Para: Alarmas y escalado

CloudWatch Metrics



Logs

¿Qué pasó exactamente?

Registros de eventos con texto: errores, accesos, auditoría.

Para: Diagnóstico y búsqueda

CloudWatch Logs



Trazas

¿Dónde se demora?

El recorrido de una solicitud a través de los servicios.

Para: Cuellos de botella

AWS X-Ray

De la señal a la acción



Recurso emite



Se recolecta



Alarma evalúa



Notifica



Actúa: escala

Fuente: adaptado de AWS Well-Architected — Excelencia operativa; documentación de CloudWatch

CloudWatch: cómo se organizan las métricas

Una métrica es una serie en el tiempo con espacio de nombres, nombre y dimensiones; los datos se conservan hasta 15 meses.

Cómo se organiza una métrica

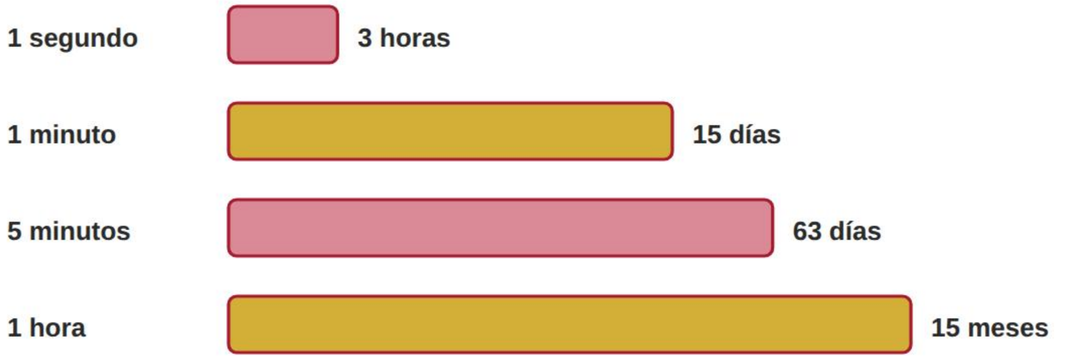
Espacio de nombres
AWS/EC2, AWS/ApplicationELB

Nombre de métrica
CPUUtilization, RequestCount

Dimensión
InstanceId, AutoScalingGroupName

Puntos de datos
valor + marca de tiempo + unidad

Resolución y retención de los datos



EC2: monitoreo básico y detallado

Básico: un punto cada 5 minutos, sin costo.
Detallado: un punto por minuto, con costo. El escalado rápido necesita el detallado.

Lo que no ve el hipervisor

CPU, red y disco sí llegan sin instalar nada.
La memoria y el espacio en disco no: requieren el agente de CloudWatch.

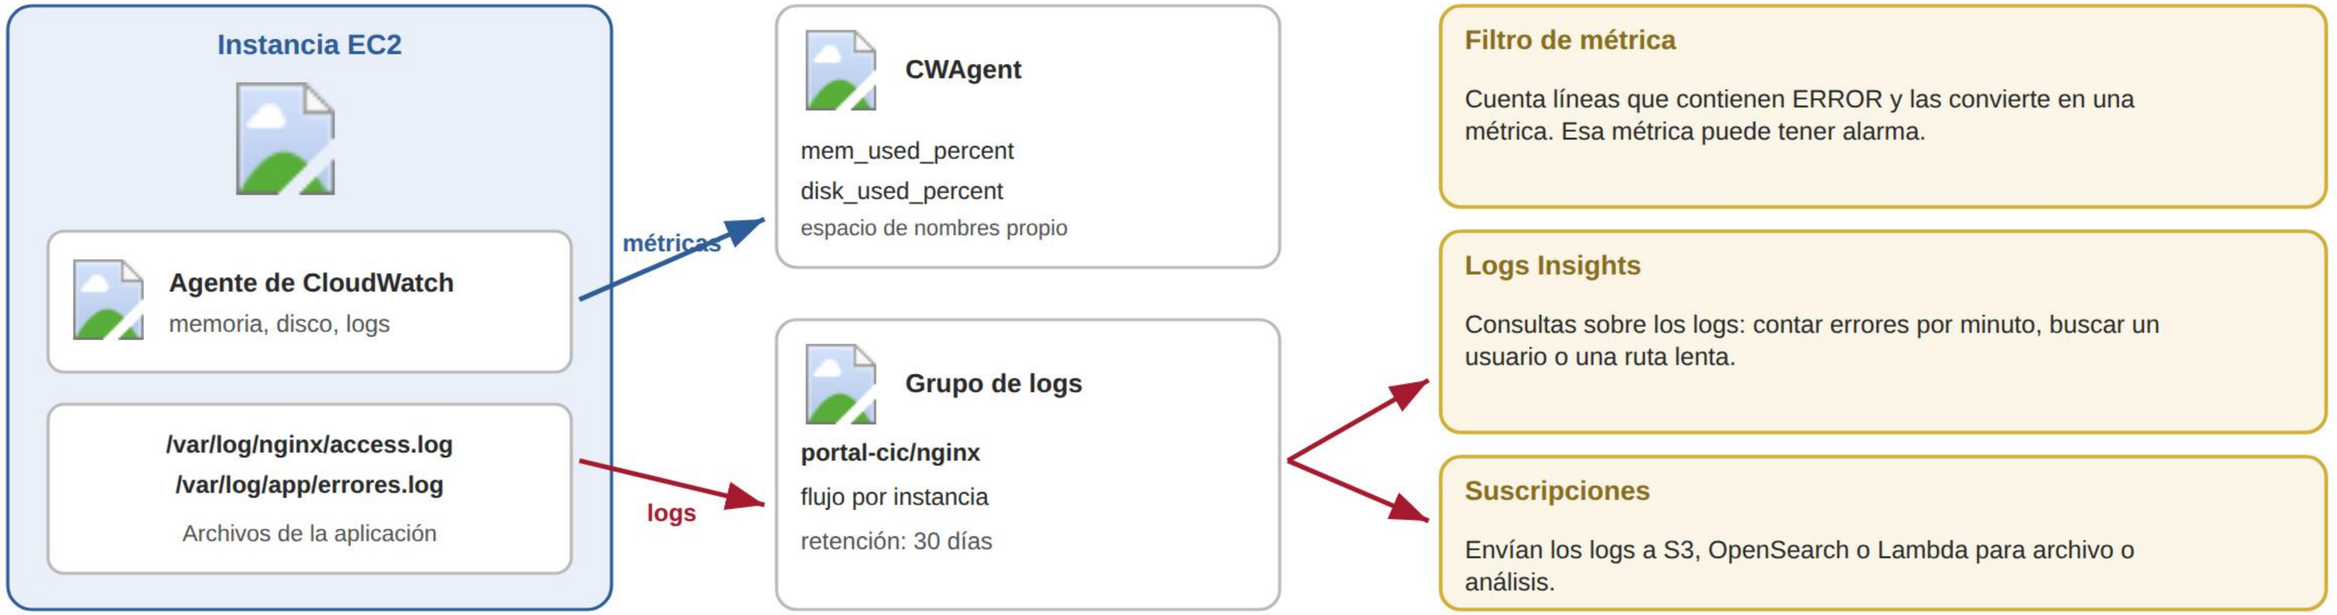
Métricas personalizadas

Tu aplicación puede publicar las suyas: pedidos por minuto, tamaño de cola, tiempo de checkout. Es la mejor señal para escalar por negocio.

Fuente: adaptado de Amazon CloudWatch User Guide — Metrics concepts

El agente, los logs y las demás fuentes

El agente de CloudWatch lleva memoria, disco y logs de la aplicación; otros servicios aportan auditoría y red.



Otras fuentes que alimentan la observabilidad

CloudTrail

Quién llamó a qué API: auditoría

VPC Flow Logs

Tráfico de red por interfaz

Logs de acceso del ALB

Cada solicitud, en S3

AWS Config

Cambios de configuración

Fuente: adaptado de Amazon CloudWatch User Guide — CloudWatch agent y Logs

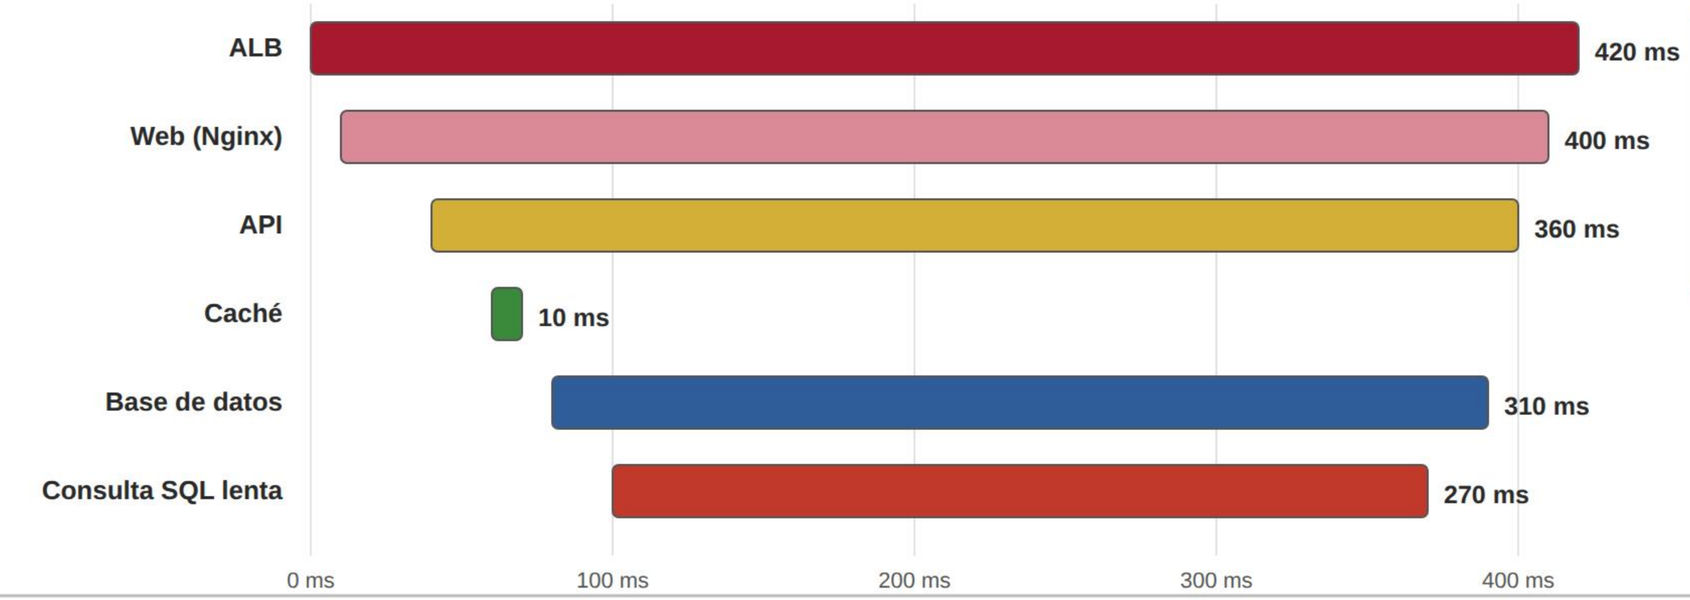
Trazas distribuidas: dónde se va el tiempo

Una traza reúne los tramos de una misma solicitud y señala cuál servicio la retrasa.

Mapa de servicios: una solicitud a /api/pedidos



Traza de la solicitud (milisegundos, ejemplo)



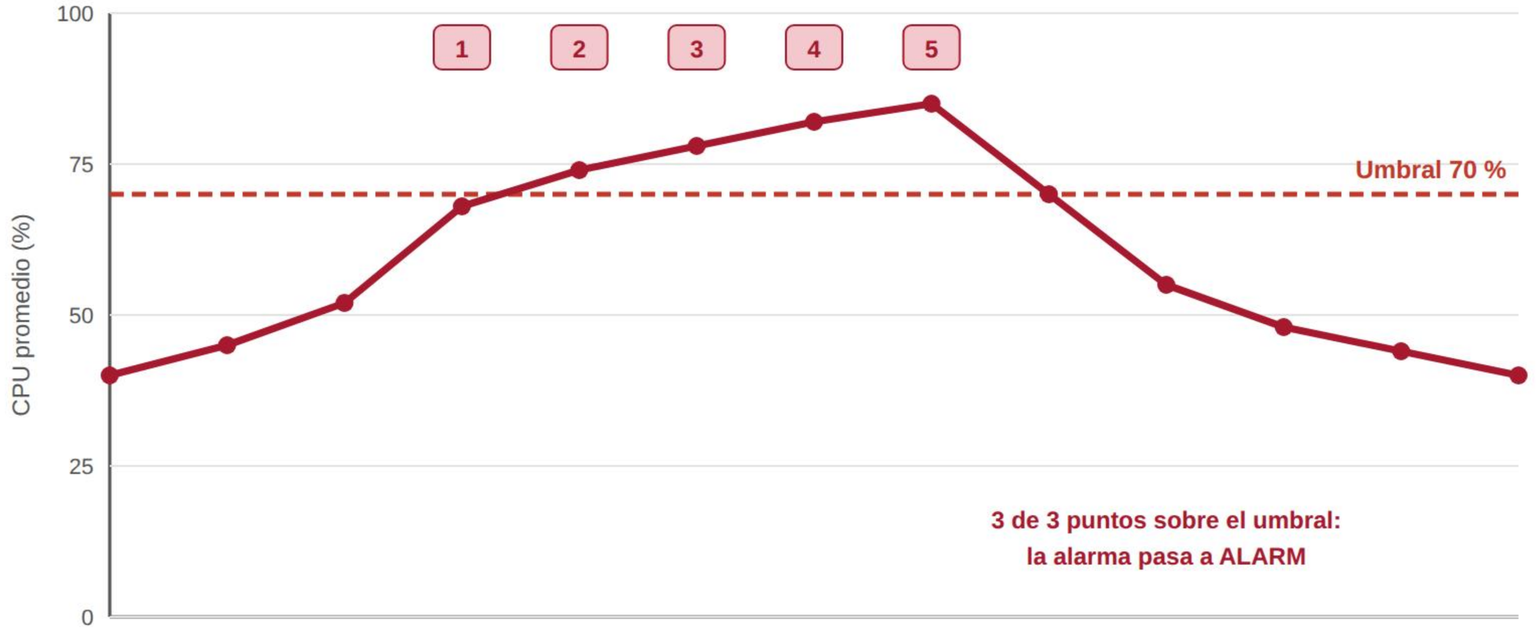
Lectura

La consulta SQL concentra casi toda la demora: ahí se optimiza, no en el servidor web.

Fuente: adaptado de AWS X-Ray Developer Guide; OpenTelemetry

Alarmas: umbral, periodos y acciones

Una alarma vigila una métrica y cambia de estado cuando el umbral se incumple durante varios periodos.



OK | ALARM | INSUFFICIENT_DATA

Tres estados posibles de una alarma de CloudWatch

Cómo se define

Métrica y estadística (promedio, máximo, percentil), periodo de 1 minuto, 3 periodos de evaluación y 3 puntos para alarmar.

Datos faltantes

Elige si faltan datos cuenta como incumplimiento, como bueno o se ignora.

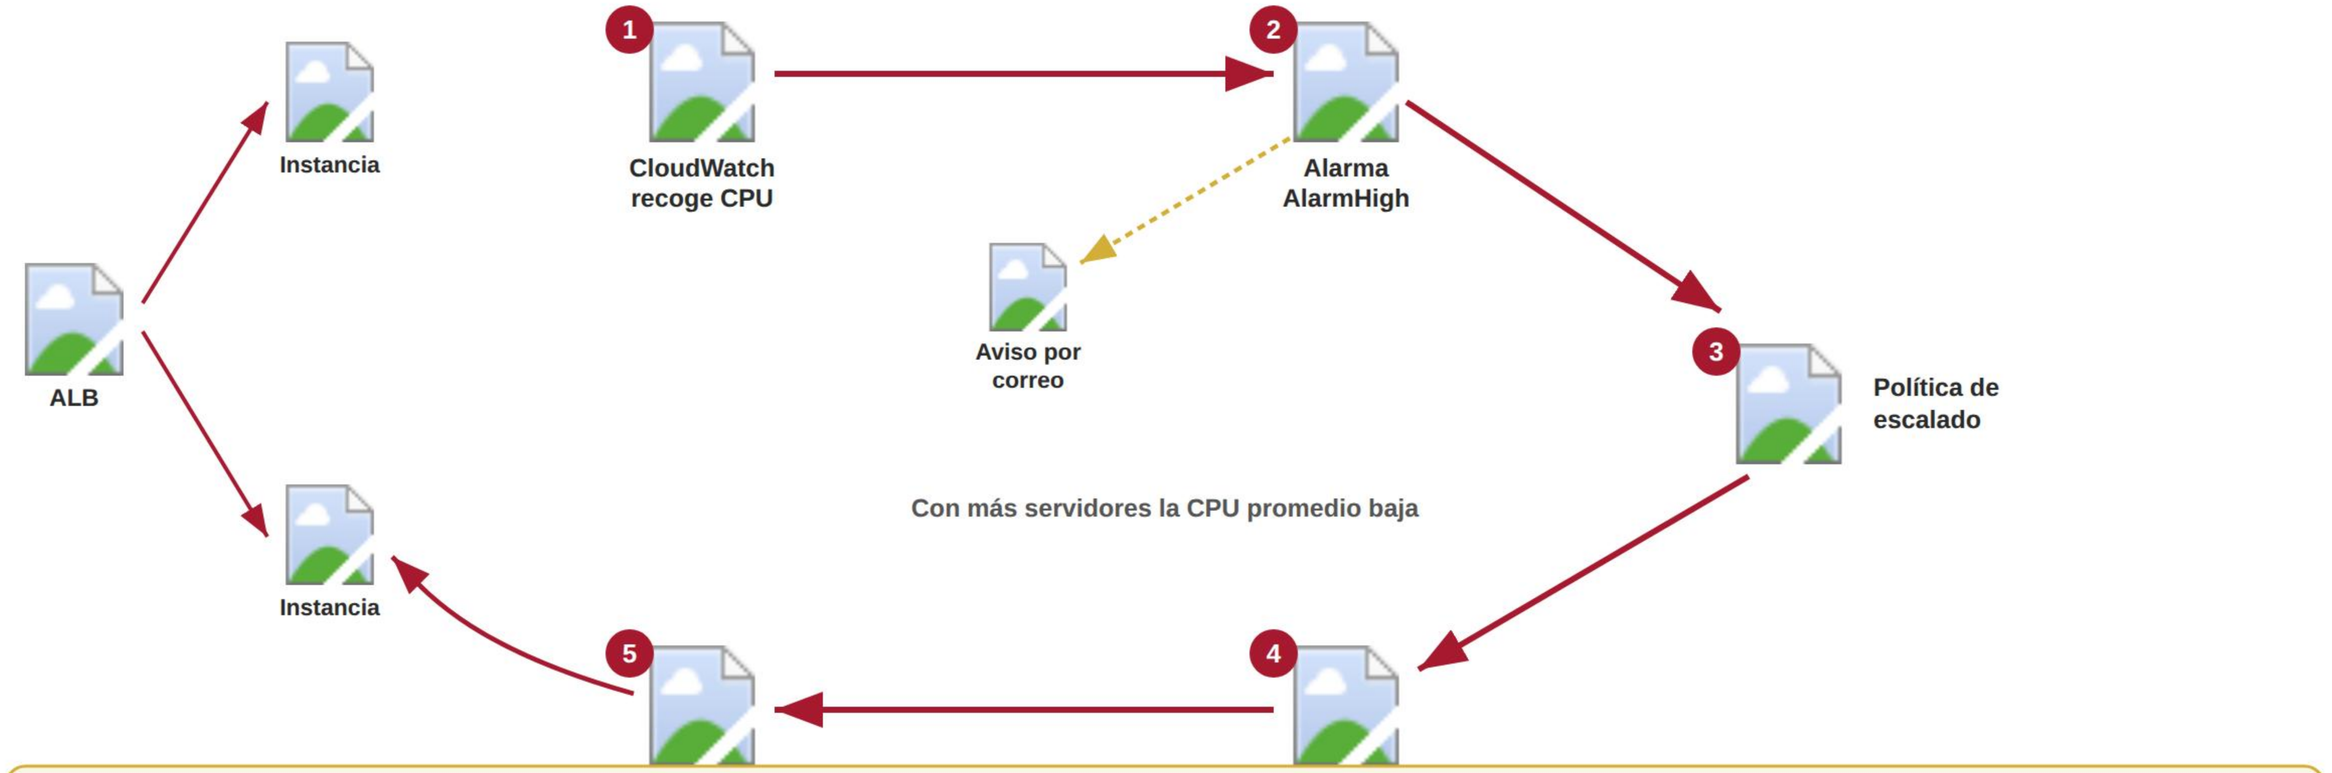


Acciones: notificar, escalar, reiniciar o recuperar la instancia

Fuente: adaptado de Amazon CloudWatch User Guide — Alarms

La alarma que dispara el escalado

La métrica, la alarma y la política forman un bucle que agrega instancias hasta que la carga se normaliza.



Alta: sube capacidad cuando el promedio supera el umbral · Baja: la quita cuando cae por debajo, con más calma

Es un bucle de retroalimentación negativa: cuanto más sube la carga, más capacidad se agrega, hasta estabilizarse.

Fuente: adaptado de Amazon EC2 Auto Scaling User Guide — Dynamic scaling

Tableros: los cuatro indicadores de oro

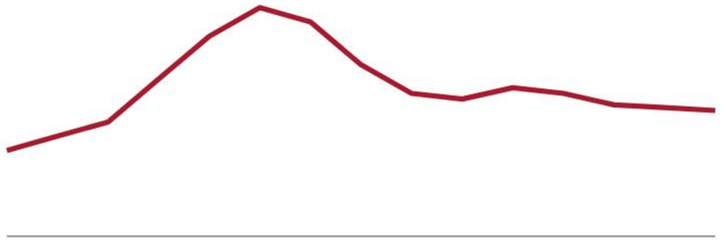
Tráfico, latencia, errores y saturación cuentan la salud del servicio en una sola pantalla.

Tablero «Portal CIC»: los cuatro indicadores de oro

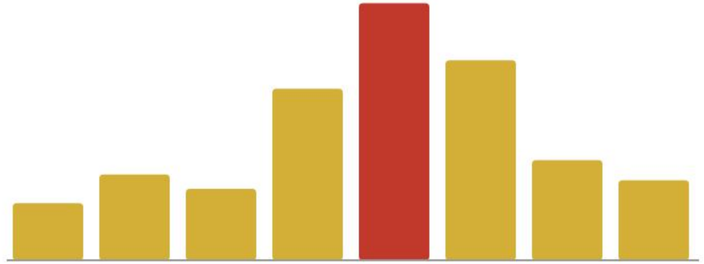
Tráfico: solicitudes por minuto



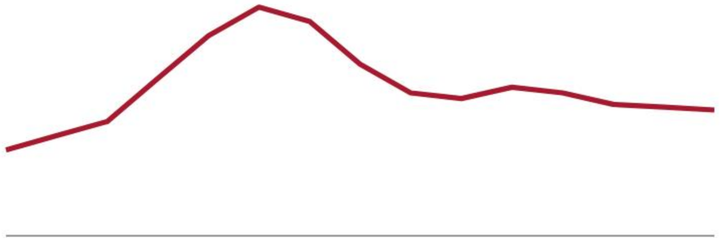
Latencia (p95) en milisegundos



Errores 5xx por minuto



Saturación: CPU del grupo (%)



Instancias en servicio



Estado de alarmas

- CPU alta · OK
- **Errores 5xx · EN ALARMA**
- Latencia p95 · OK
- Destinos sin salud · OK

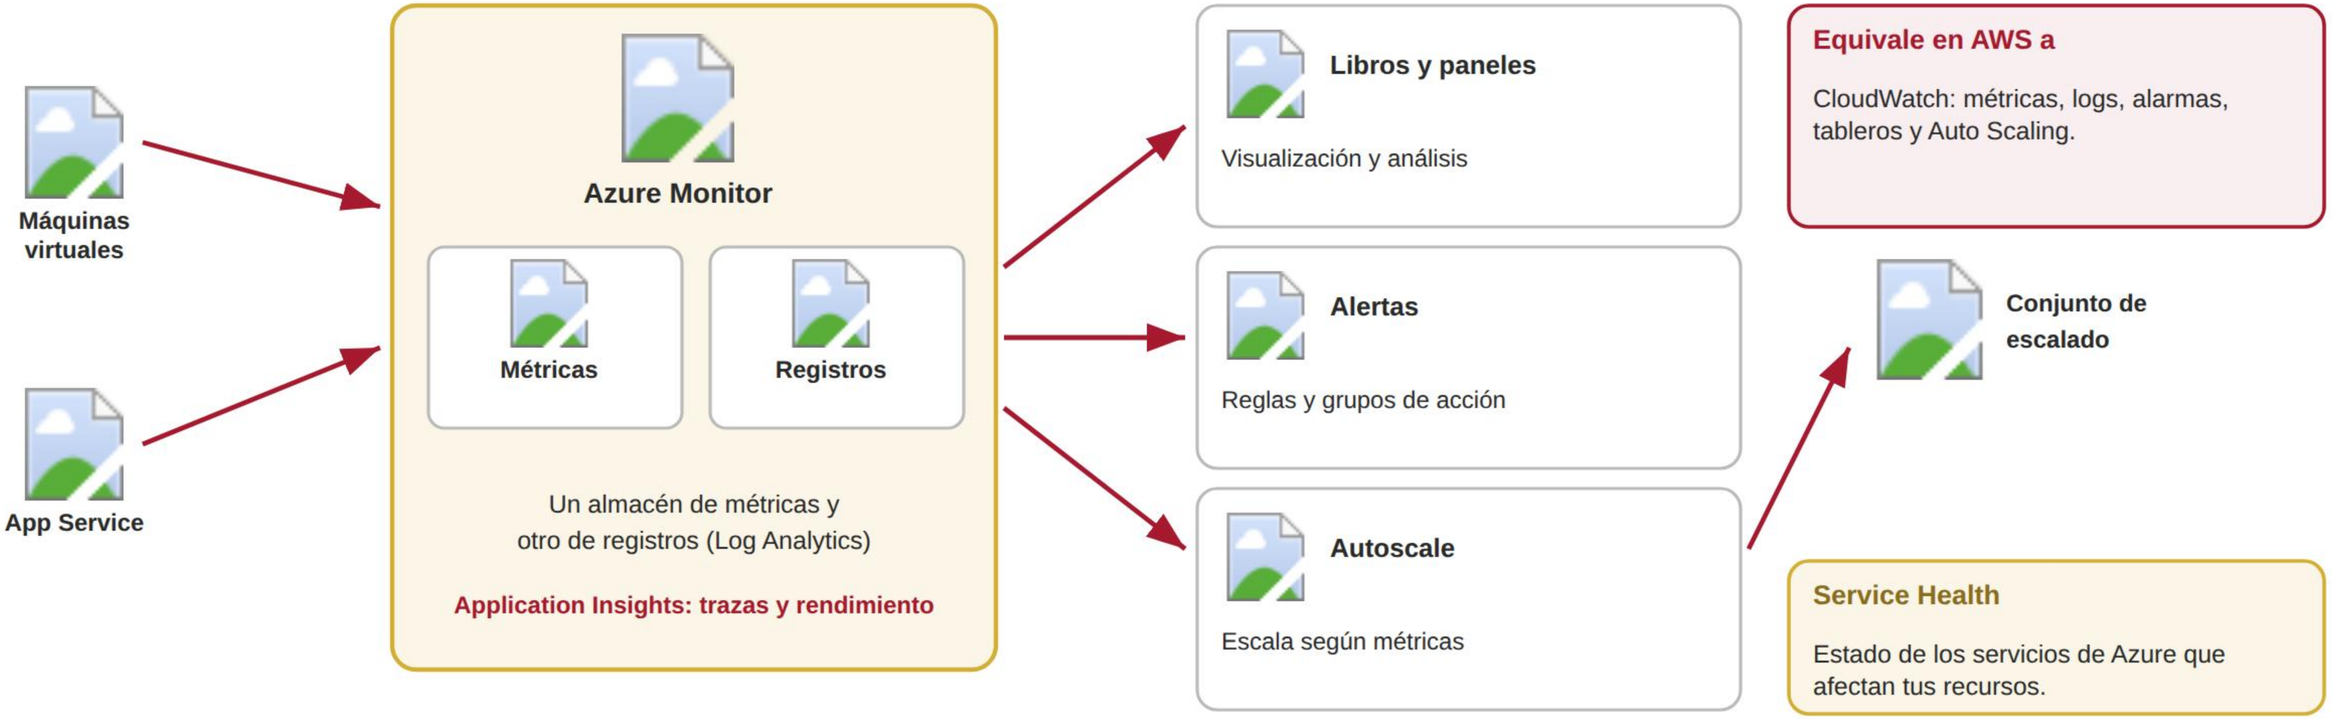
Los tableros de CloudWatch se comparten entre cuentas; Grafana administrado sirve para combinar varias fuentes de datos.

Fuente: adaptado de Amazon CloudWatch User Guide — Dashboards; Google SRE (señales de oro)

Azure Monitor: recolectar, analizar y actuar

Azure Monitor recoge métricas y registros, los visualiza, genera alertas y puede disparar el escalado automático.

Azure Monitor: la misma idea en otra nube



Diferencia útil: en Azure, registros y métricas pasan por reglas de diagnóstico; el área de trabajo de Log Analytics centraliza las consultas.

La idea no cambia: recolectar, analizar, visualizar y actuar.

Fuente: adaptado de Microsoft Learn — Azure Monitor overview; material del curso

Trusted Advisor y Advisor: revisiones automáticas

Las herramientas de recomendación revisan tu cuenta y señalan costos, seguridad, rendimiento y resiliencia por mejorar.



Trusted Advisor

Optimización de costos
Instancias ociosas, volúmenes sin usar

Rendimiento
Instancias sobrecargadas, reglas de seguridad lentas

Seguridad
Puertos abiertos, MFA del usuario raíz

Resiliencia
Instancias sin Multi-AZ, backups, ASG en una sola zona

Límites de servicio
Cuotas cerca del tope

Excelencia operativa
Buenas prácticas de operación

Los planes Business y Enterprise desbloquean todas las verificaciones.
El plan básico incluye las verificaciones centrales de seguridad y límites.



AWS Health Dashboard

Eventos de AWS que afectan tu cuenta:

fallas de un servicio en tu región, mantenimientos programados y avisos de retiro de funciones.

Puede enviar eventos a EventBridge y SNS.



Azure Advisor

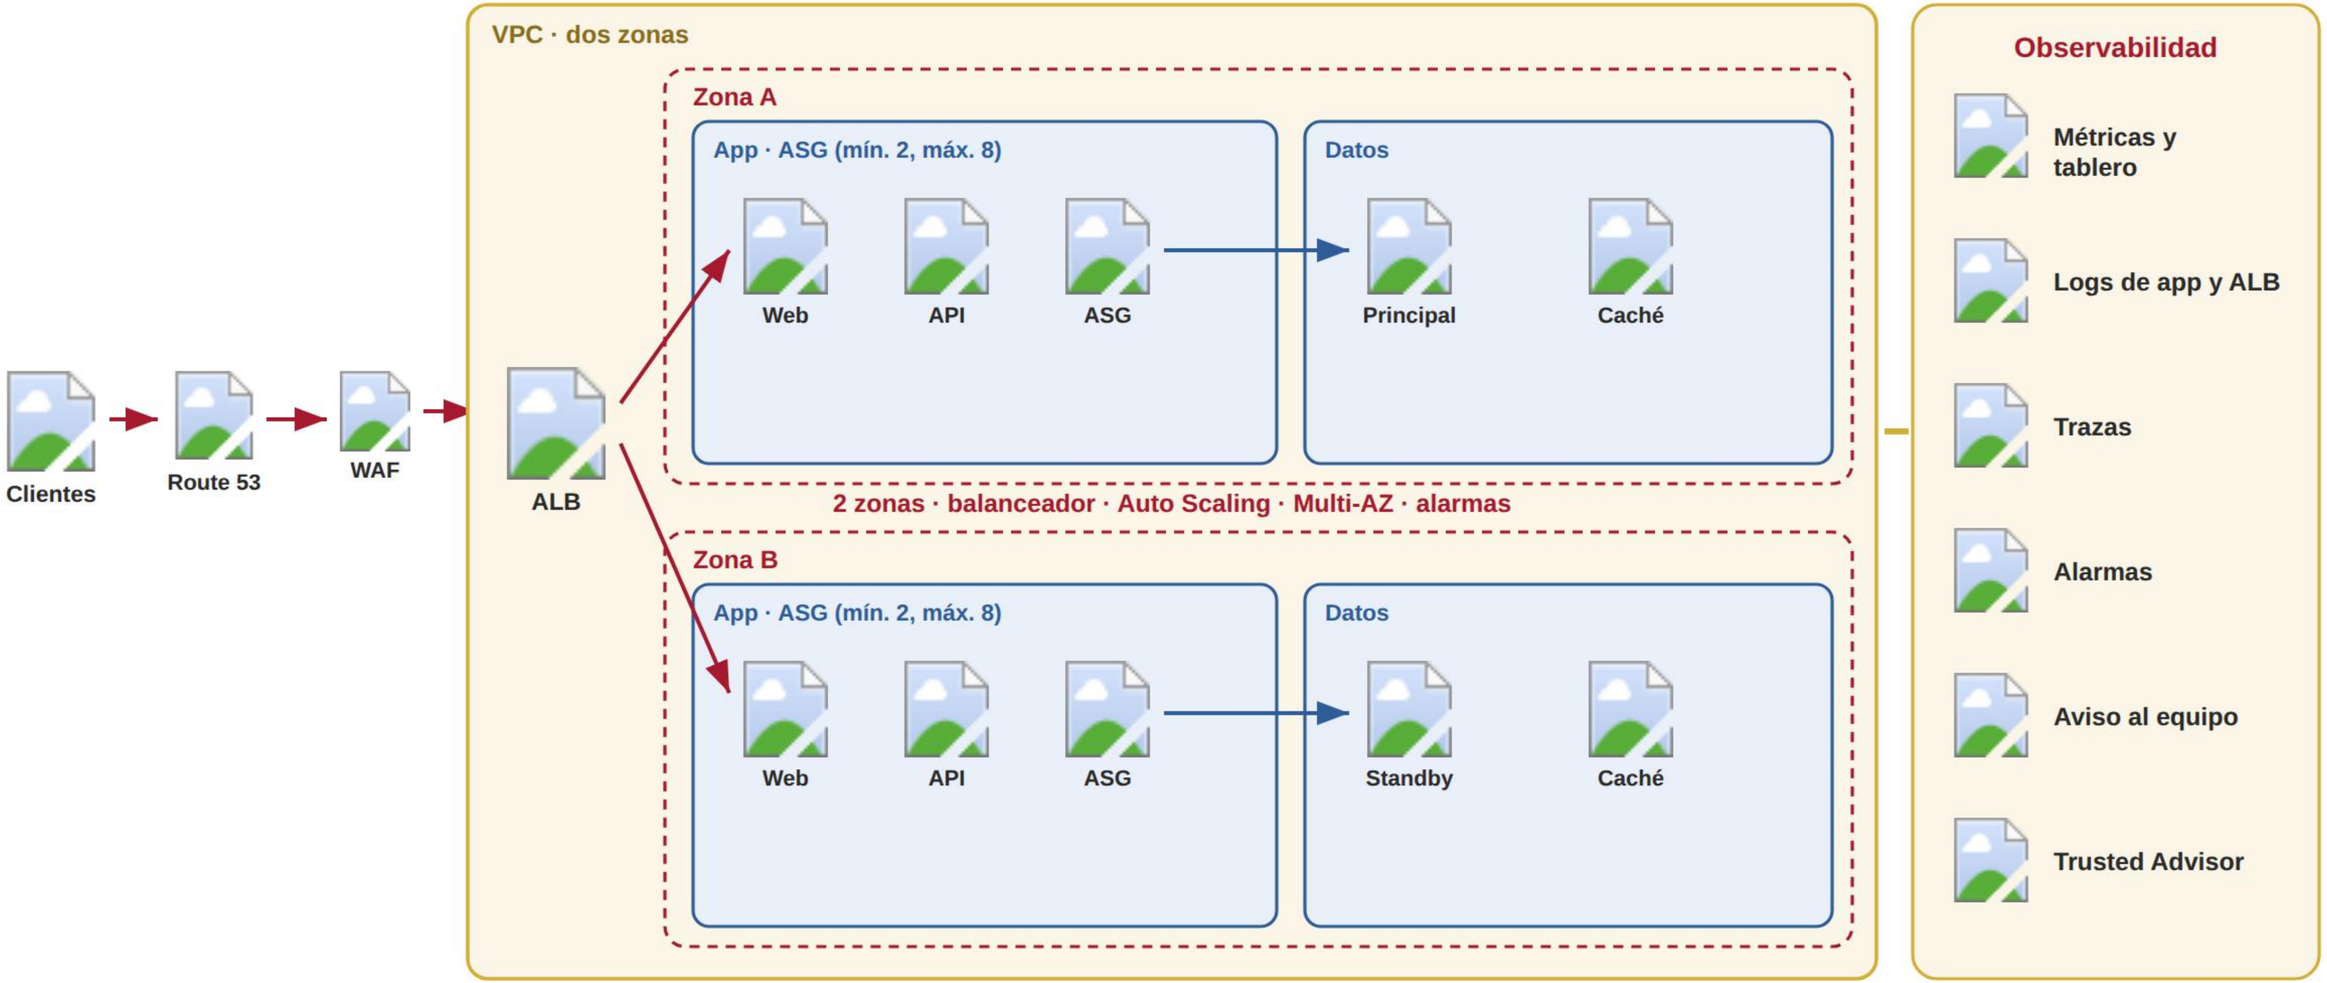
Recomendaciones personalizadas en confiabilidad, seguridad, rendimiento, excelencia operativa y costos.

Azure Service Health: el equivalente del Health Dashboard.

Fuente: adaptado de AWS Trusted Advisor y AWS Health; Microsoft Learn — Azure Advisor y Service Health

Caso integrador: el portal de CIC completo

Alta disponibilidad, balanceo, elasticidad y monitorización conviven en una sola arquitectura.



Fuente: caso docente CIC; adaptado de AWS Architecture Center y Well-Architected

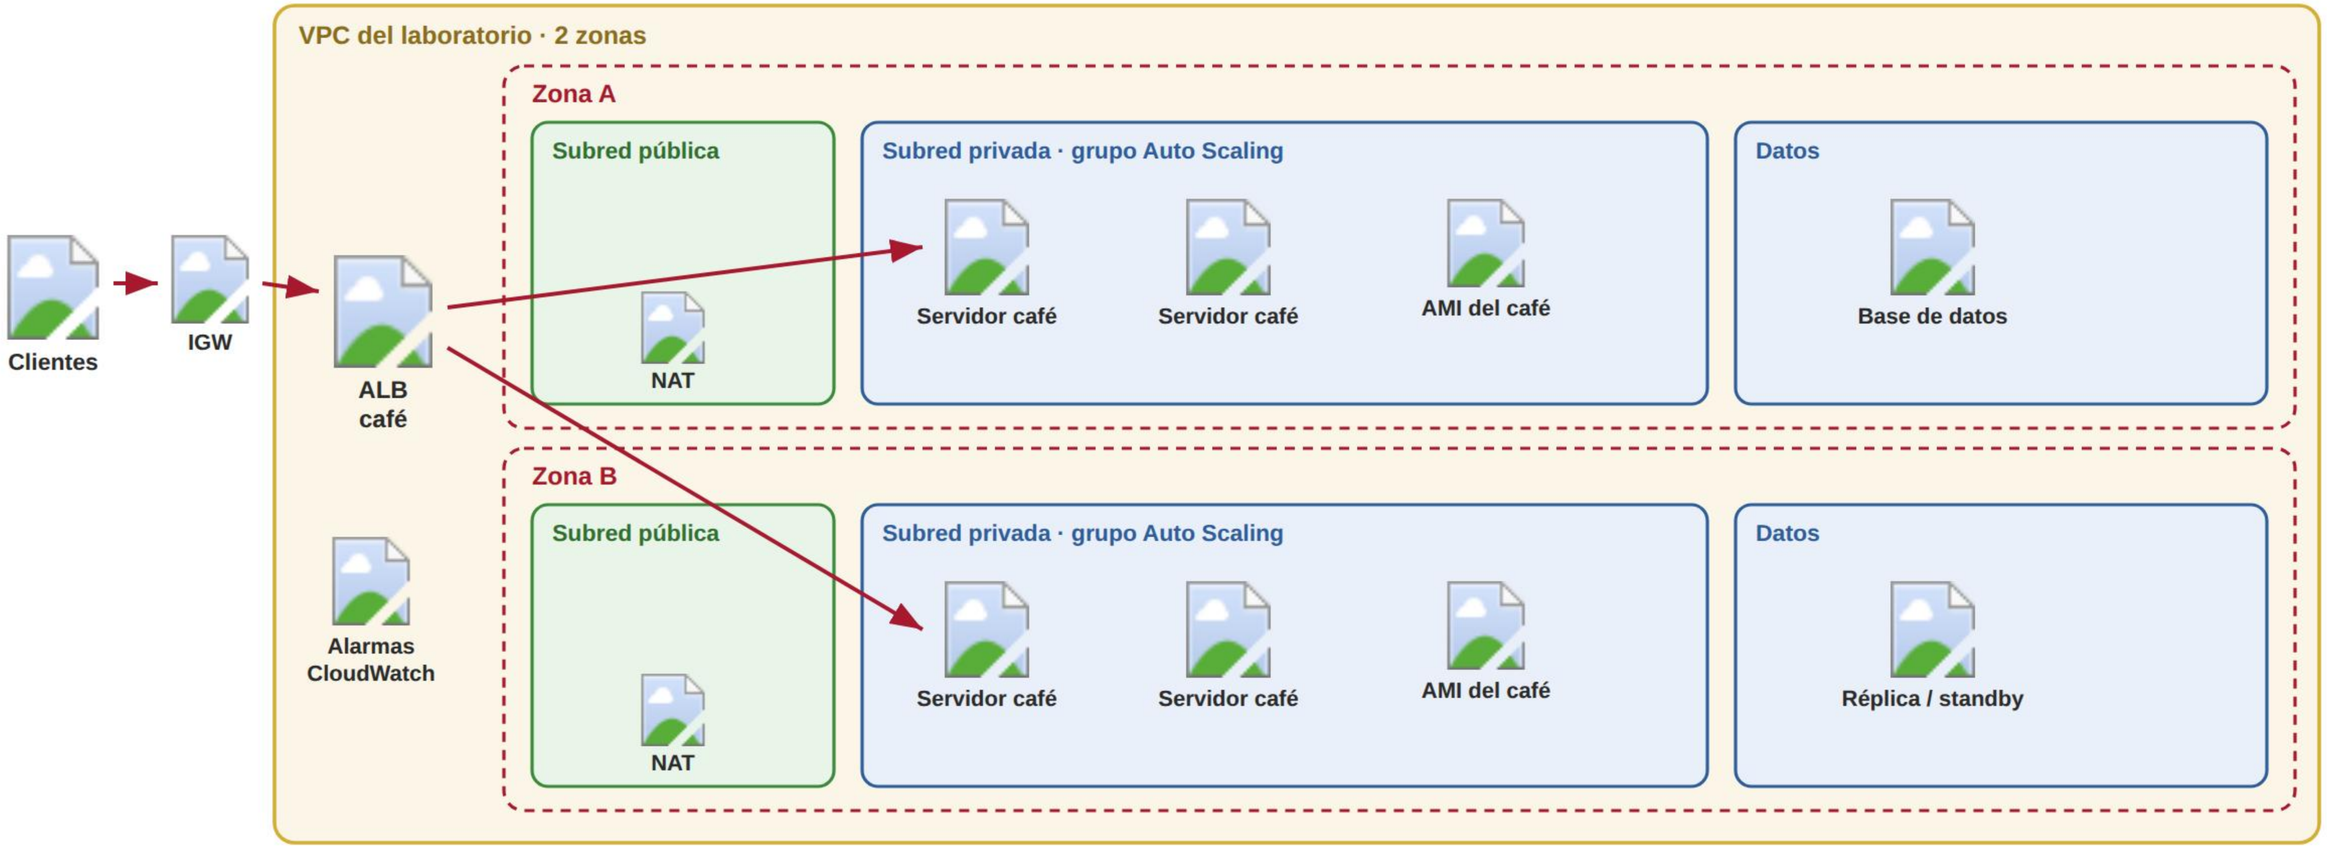
Laboratorio: arquitectura final del entorno

El resultado es un sitio web de cafetería con balanceador, grupo de Auto Scaling en dos zonas y alarmas.

Laboratorio · entorno escalable y altamente disponible (escenario de la cafetería)

min 2 · máx 6

Valen 10 por ciento de la nota. Plataforma: AWS Academy Learner Lab.



Fuente: adaptado de AWS Academy Cloud Architecting — laboratorio del módulo 10

Laboratorio paso a paso: de una instancia a un grupo

Ocho pasos: AMI, balanceador, plantilla, grupo, política, y dos pruebas de alta disponibilidad y elasticidad.

1



Revisar el punto de partida

Inspecciona la VPC, las subredes y la instancia web única del café.

2



Crear una AMI

Captura una imagen de la instancia web ya configurada.

3



Crear el balanceador

ALB en subredes públicas, listener 80 y grupo de destinos con chequeo de salud.

4



Crear la plantilla

Plantilla de lanzamiento con la AMI, tipo, grupo de seguridad y perfil IAM.

5



Crear el grupo Auto Scaling

Subredes privadas de dos zonas, mínimo 2, máximo 6, ligado al grupo de destinos.

6



Política de seguimiento

CPU promedio al 50 por ciento; Auto Scaling crea las alarmas.

7



Probar la alta disponibilidad

Abre el DNS del ALB, termina una instancia y observa cómo se reemplaza.

8



Probar la elasticidad

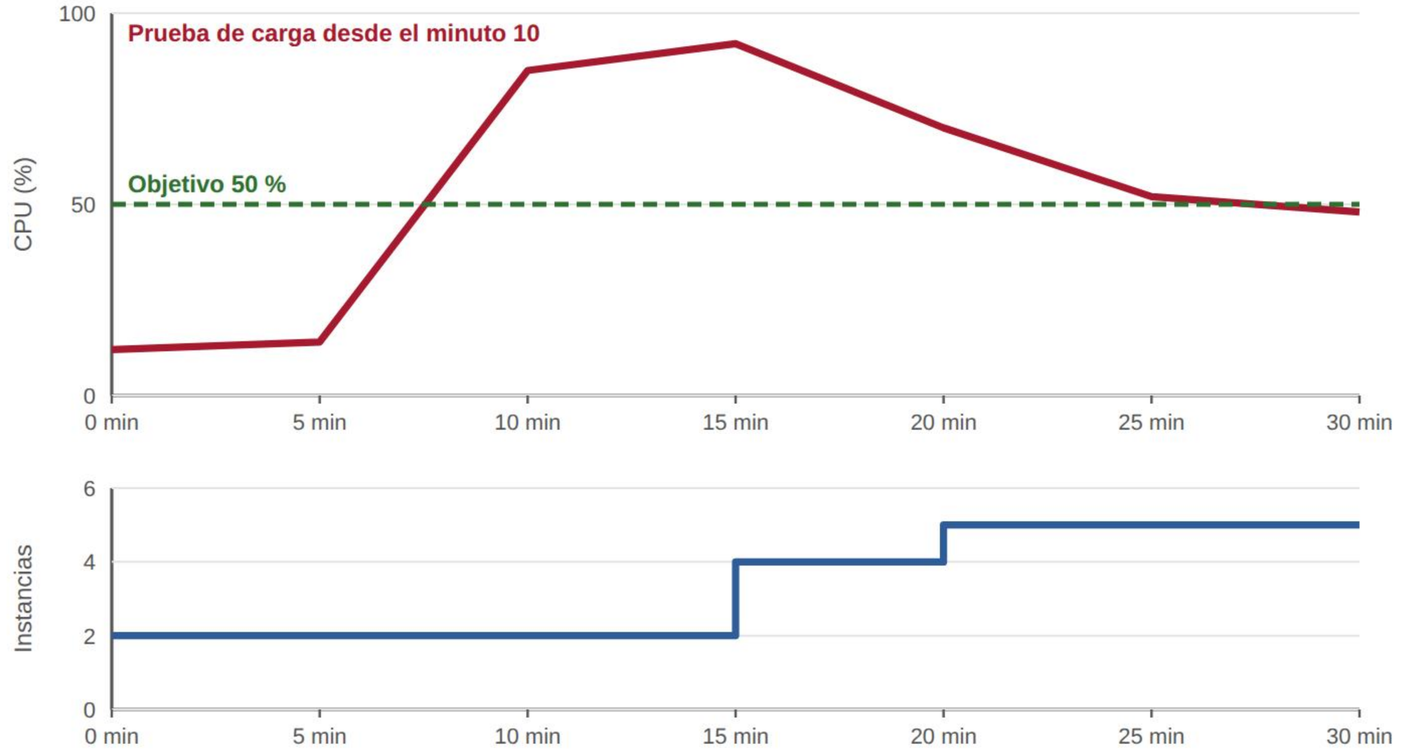
Genera carga, observa la alarma y el aumento de instancias; luego limpia.

Fuente: adaptado de AWS Academy Cloud Architecting — laboratorio del módulo 10

LABORATORIO

Laboratorio: la prueba de carga y las evidencias

Genera carga, mira cómo la alarma y el grupo responden, y documenta con capturas lo que observaste.



Qué observar: CPU sube, alarma pasa a ALARM, el grupo agrega instancias y la CPU vuelve cerca del objetivo.

Evidencias para entregar

- Captura del grupo de destinos con destinos sanos en dos zonas
- Captura del grupo de Auto Scaling con mínimo, deseada y máximo
- Captura de la alarma en estado ALARM durante la carga
- Captura de la actividad de escalado (instancias lanzadas)
- Captura del reemplazo tras terminar una instancia
- Respuesta breve: ¿por qué dos zonas y qué pasaría con una?

Al terminar, elimina el grupo, el ALB, la AMI y los snapshots para no gastar crédito.

Fuente: adaptado de AWS Academy Cloud Architecting — laboratorio del módulo 10

CIERRE

Semana 10 en cuatro ideas

Alta disponibilidad, balanceo, elasticidad y monitorización forman un solo diseño; el siguiente paso es automatizarlo.

1



Se mide en nueves

Multi-AZ, sin puntos únicos y redundancia en cada capa.

2



El balanceador reparte y vigila

ALB en capa 7, NLB en capa 4, health checks y Route 53.

3



La capacidad sigue la demanda

Auto Scaling con plantilla y políticas; datos con réplicas.

4



Sin métricas no hay escalado

CloudWatch, alarmas, trazas y tableros cierran el ciclo.



Semana 11 · Infraestructura como código (IaC)

Lo que hoy armaste con clics, la próxima semana lo describiremos en plantillas repetibles con CloudFormation y Terraform. También repasaremos la Unidad 2.

Fuente: síntesis del curso; AWS Well-Architected — Fiabilidad y Eficiencia