SEMANA 13 Â· ARQUITECTURA EN LA NUBE

OpenStack II: Arquitectura Interna, Redes de ProducciÃ³n y Alta Disponibilidad

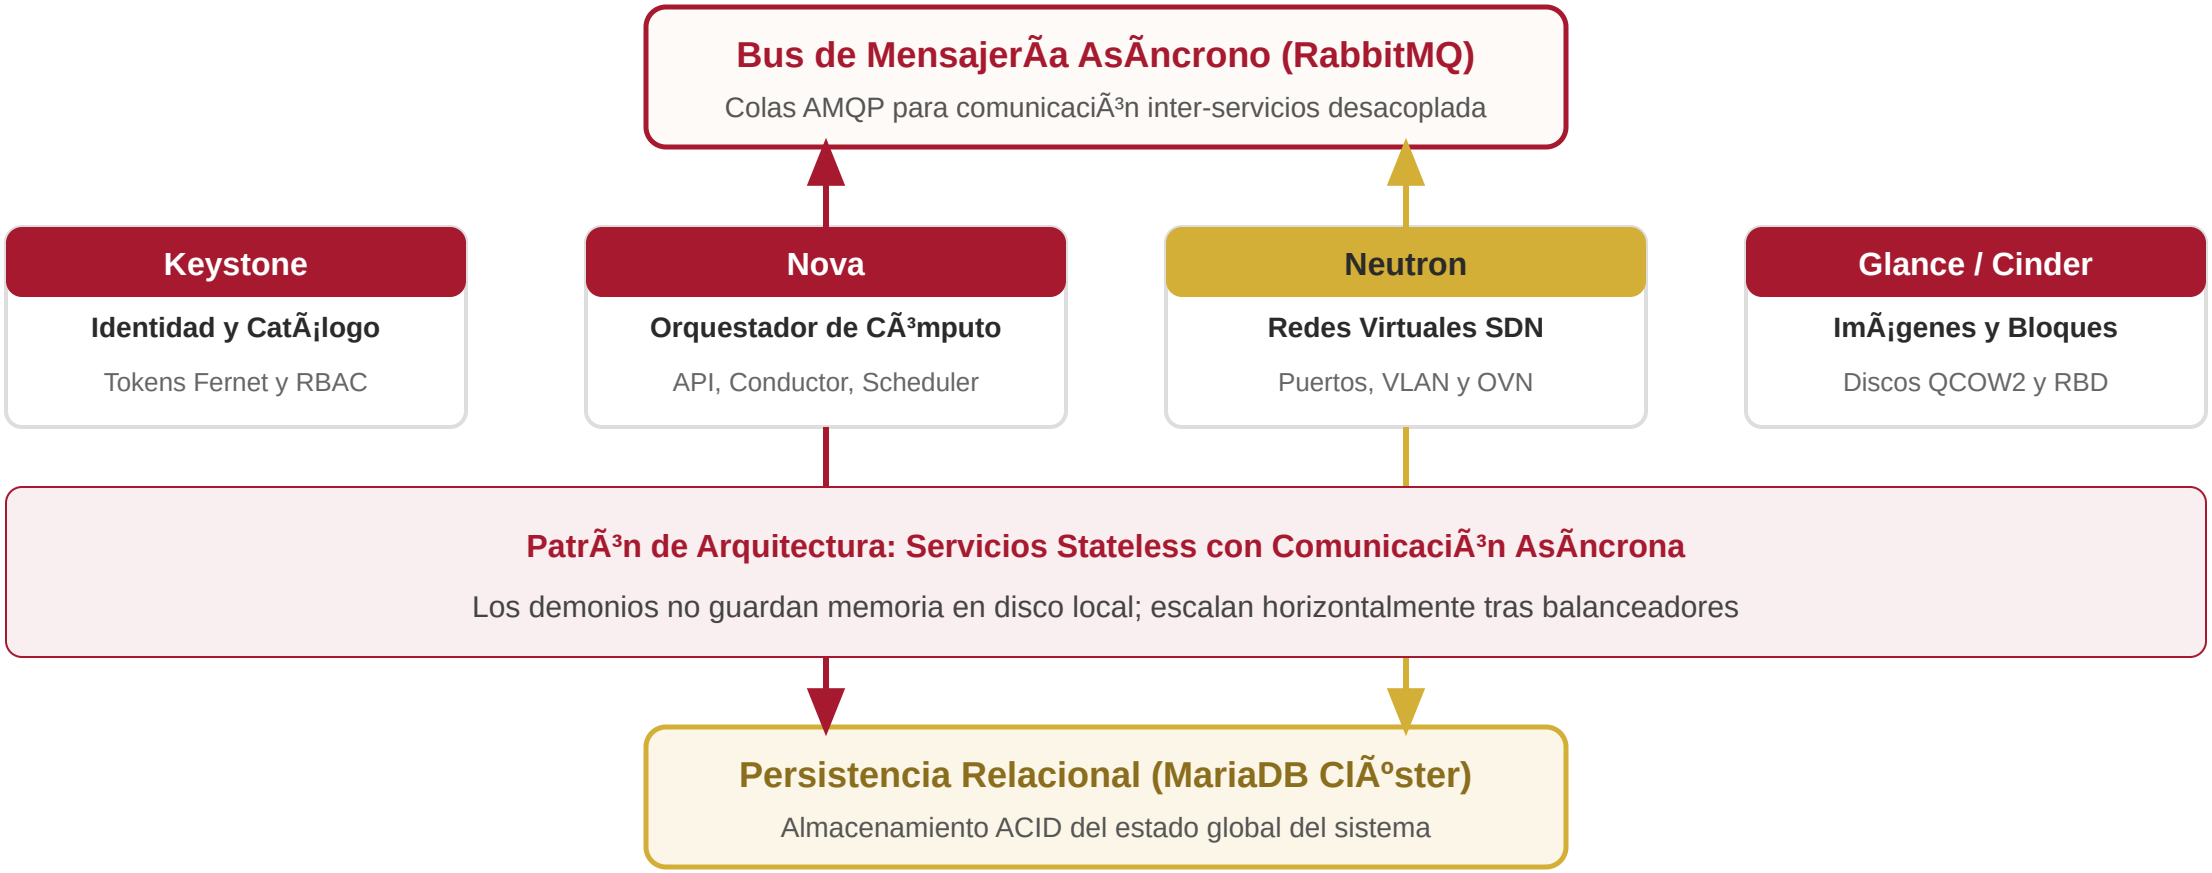
Parte 1 de 4 Â· AnatomÃa Profunda y Ciclo de Vida de una PeticiÃ³n

Ing. Rodolfo JosÃ© CaÃ±as Cervantes
Universidad de la Costa (CUC) Â· IngenierÃa de Sistemas

Arquitectura en la Nube Â· Periodo 2026-2 Â· Barranquilla, Colombia

La Nube Privada como Sistema Desacoplado

Microservicios sin estado coordinados mediante colas RPC y persistencia relacional



Fuente: OpenStack Architecture Guide (docs.openstack.org) Â· OpenInfra Foundation

Paso 1: Keystone y la ValidaciÃ³n CriptogrÃ¡fica

De credenciales a tokens Fernet firmados y resoluciÃ³n del Service Catalog

A. PeticiÃ³n POST /v3/auth/tokens

Credenciales de Usuario:

Usuario, contraseÃ±a y nombre de proyecto

Aislamiento por Proyecto:

Valida pertenencia a tenant en MariaDB

Entrada unificada CLI / Web

B. GeneraciÃ³n de Token Fernet

CriptografÃa SimÃ©trica AES-128:

Cifrado de user_id, project_id y expiraciÃ³n
Firma HMAC-SHA256 para integridad

Cero Escrituras en Base de Datos:

Token liviano (< 250 B) sin saturar disco

RotaciÃ³n periÃ³dica de llaves

C. CatÃ¡logo de Endpoints

Nova Compute:

https://openstack.cic.local:8774

Neutron Network:

https://openstack.cic.local:9696

Glance Image:

https://openstack.cic.local:9292

Fuente: OpenStack Keystone Documentation (docs.openstack.org/keystone/latest)

Paso 2: Nova API y ValidaciÃ³n de la Solicitud

ComprobaciÃ³n de cuotas de recursos, especificaciÃ³n de Flavors y persistencia inicial

POST /v2.1/servers (Carga Ãštil JSON)

ParÃ¡metros Clave de la PeticiÃ³n:

â€¢ name: "erp-db-primary" (Identificador visible)

â€¢ flavorRef: "m1.xlarge" (4 vCPU, 16 GB RAM, 80 GB disco)

â€¢ imageRef: UUID de imagen Ubuntu Server en Glance

IntercepciÃ³n WSGI Pipeline (keystonemiddleware):

Verifica el token Fernet de la cabecera X-Auth-Token

Si el token expirÃ³ o es invÃ¡lido, aborta con HTTP 401

ComprobaciÃ³n de Cuotas y Registro

VerificaciÃ³n de Cuotas del Tenant:

Â¿Quedan vCPUs y memoria libres dentro del lÃmite asignado?
Si excede cuota: Rechazo inmediato con HTTP 403 Forbidden

Persistencia en Base de Datos Nova:

Crea registro de instancia con estado inicial BUILD
Genera un UUID Ãºnico global para la mÃ¡quina virtual

Retorno SÃncrono al Cliente (HTTP 202 Accepted):

La API responde de inmediato sin esperar el arranque fÃsico

Fuente: OpenStack Nova API Guide (docs.openstack.org/nova/latest)

Paso 3: Nova Conductor y el Bus de MensajerÃa

Aislamiento de la base de datos y envÃo de RPC casts asÃncronos en RabbitMQ



Fuente: OpenStack Nova Conductor Architecture Guide Â· RabbitMQ AMQP Pattern

Paso 4: Placement y Nova Scheduler

Filtrado de hipervisores y pesaje heurÃstico para ubicar la instancia Ã³ptima

1. Consulta a Placement API

Resource Providers:

Inventario exacto de vCPU, RAM y DISK

EvaluaciÃ³n de Rasgos (Traits):

Requiere: CUSTOM_HW_AVX2, SSD_FAST

Poda masiva en milisegundos

2. Pila de Filtros (Filters)

ComputeFilter:

Elimina hipervisores inactivosto

ServerGroupAntiAffinity:

Impide ubicar dos rÃ©plicas en el mismo host

ImagePropertiesFilter:

Coteja arquitectura (x86_64, arm64, UEFI)

Genera lista de candidatos vÃ¡lidos

3. Ponderadores (Weighers)

RAMWeigher:

Favorece host con mÃ¡s memoria libre

CPUWeigher:

Equilibra la tasa de uso de procesador

Hipervisor Seleccionado:

compute-node-04.cic

Fuente: OpenStack Placement Documentation Â· Nova Filter Scheduler Spec (docs.openstack.org)

Paso 5: Neutron y la CreaciÃ³n del Puerto Virtual

AsignaciÃ³n de IP fija, direcciÃ³n MAC y configuraciÃ³n de grupos de seguridad

1. PeticiÃ³n POST /v2.0/ports

Nova Conductor solicita a Neutron:

Crear puerto en network_id del tenant

ParÃ¡metros de Interfaz:

â€¢ binding:host_id = "compute-node-04"
â€¢ device_owner = "compute:nova"

Reserva de recurso de red

2. AsignaciÃ³n L2 / L3 (IPAM)

DirecciÃ³n MAC Virtual:

fa:16:3e:4a:2b:88 (Prefijo IEEE OpenStack)

IP Fija Privada (Subnet Pool):

192.168.10.45 en subred privada
Registrada en servicio DNS / DHCP interno

Estado del Puerto: DOWN

Pasa a ACTIVE cuando el hypervisor lo enlace

3. Security Groups (Firewall L4)

Reglas de TrÃ¡fico de Entrada:

TCP 22 (SSH) y TCP 5432 (Postgres)

ImplementaciÃ³n en Hypervisor:

Open vSwitch con conntrack de Linux
Filtrado con estado a nivel de microsegundo

Aislamiento L2/L4 completo

Fuente: OpenStack Neutron API Guide Â· OVN Integration Manual (docs.openstack.org)

Paso 6: Glance, Cinder y el Almacenamiento

Diferencia crÃtica entre arranque efÃmero local y arranque persistente desde volumen

OpciÃ³n A: Boot from Image (Disco EfÃmero Nova)

Origen: CatÃ¡logo Glance

Imagen base QCOW2 descargada en /var/lib/nova/instances/_base

Mecanismo Copy-on-Write (QEMU CoW):

â€¢ La VM escribe solo los bloques diferenciales en disco local.
â€¢ MÃºltiples VMs reutilizan la misma plantilla base sin duplicar.

Riesgo ArquitectÃ³nico:

Si el nodo compute-04 sufre fallo de placa madre, el disco muere.
Apropiado solo para servidores web sin estado y workers stateless.

OpciÃ³n B: Boot from Volume (Volumen Cinder Persistente)

Origen: Cinder Volume Driver

Crea volumen de 80 GB en clÃºster Ceph RBD o cabina SAN iSCSI

ClonaciÃ³n InstantÃ¡nea CoW en Ceph:

â€¢ Glance y Cinder residen en el mismo pool de Ceph.
â€¢ ClonaciÃ³n snapshot sin transferir gigabytes por la red.

Ventaja de Alta Disponibilidad:

Si el host fÃsico falla, el volumen se re-conecta en otro nodo.
Obligatorio para bases de datos ERP y almacenamiento crÃtico.

Fuente: OpenStack Cinder Architecture Â· Glance Backend Documentation (docs.openstack.org)

Paso 7: Nova Compute y Libvirt/KVM

TraducciÃ³n de especificaciones lÃ³gicas a descriptores XML y ejecuciÃ³n de hardware virtual

1. Nova Compute Daemon

Consumo de Mensaje RPC:

compute-node-04 extrae la tarea

RecopilaciÃ³n de Insumos:

â€¢ Descriptor de red de Neutron
â€¢ ConexiÃ³n iSCSI/RBD de Cinder

OrquestaciÃ³n local

2. GeneraciÃ³n Domain XML

ConfiguraciÃ³n KVM:

<domain type='kvm'> ... <vcpu>4</vcpu>

Dispositivos Emulados VirtIO:

â€¢ virtio-net para alta tasa de red
â€¢ virtio-blk para disco de baja latencia

InyecciÃ³n de Metadatos:

cloud-init con llaves SSH y scripts

3. Kernel Linux (KVM)

AceleraciÃ³n por Hardware:

Extensiones Intel VT-x / AMD-V activas

Proceso QEMU en Host:

PID aislado en su propio cgroup
LÃmites estrictos de memoria y CPU

Instancia en estado ACTIVE

Fuente: Libvirt Domain XML Documentation Â· KVM Kernel-based Virtual Machine Guide

Manejo de Errores: Reintentos y Rollback AutomÃ¡tico

QuÃ© sucede cuando un hipervisor falla durante el arranque y cÃ³mo opera el Scheduler Retry

DetecciÃ³n de Fallo en Hypervisor

Causas Frecuentes en ProducciÃ³n:

Agotamiento sÃºbito de VRAM/RAM, fallo de red o kernel panic

EmisiÃ³n de ExcepciÃ³n RPC:

â€¢ Nova Compute captura la excepciÃ³n y notifica a Conductor.
â€¢ compute-node-04 se agrega temporalmente a la lista negra.

ParÃ¡metro scheduler_max_attempts = 3

Intenta automÃ¡ticamente reubicar en otro nodo candidato

Mecanismo de Rollback y Limpieza

1. LiberaciÃ³n de Recursos en Placement:

Devuelve los vCPUs y memoria reservados al inventario del host

2. Limpieza de Red y Almacenamiento:

â€¢ Neutron desvincula o elimina el puerto virtual.
â€¢ Cinder desenlaza la conexiÃ³n de almacenamiento iSCSI.

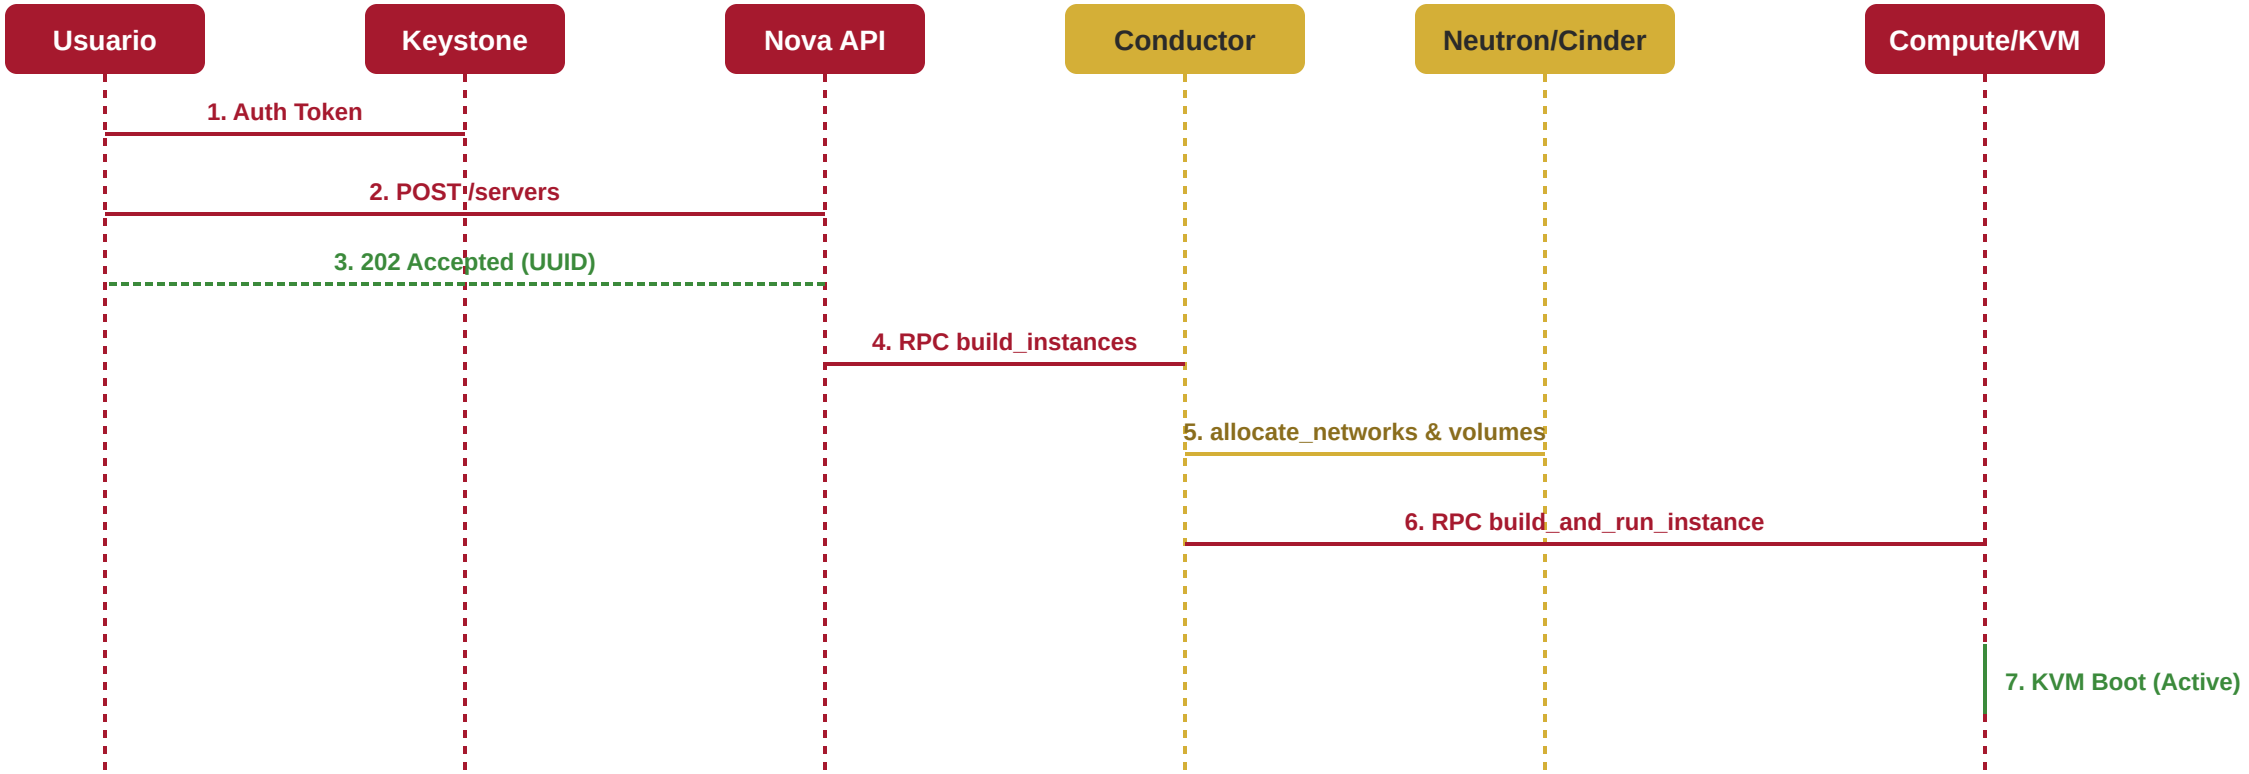
3. Estado Final si se Agotan Reintentos:

Estado ERROR con causa visible en openstack server show

Fuente: OpenStack Nova Error Handling Guide Â· Fault Management Specs

Diagrama de Secuencia Integrado del Aprovisionamiento

CronologÃa completa de interacciÃ³n entre los seis servicios nucleares de OpenStack



Fuente: OpenStack Technical Committee Workflow Sequence Diagram (wiki.openstack.org)

InspecciÃ³n y DiagnÃ³stico del Ciclo de Vida

Comandos esenciales de CLI y lectura de logs para auditar cada fase de la peticiÃ³n

Comandos CLI para Seguimiento

$ openstack server show <UUID>

Muestra status (BUILD/ACTIVE/ERROR), host y fault message
Permite verificar el ID del hipervisor donde aterrizÃ³ la VM

$ openstack server event list <UUID>

Cronograma de eventos: create, schedule, block_device_mapping, network_allocate y spawn con sus marcas de tiempo exactas

$ openstack console log show <UUID>

Salida de la consola serie virtual del kernel Linux
Audita la ejecuciÃ³n de cloud-init y el montaje de particiones

Archivos de Log por Componente

/var/log/nova/nova-api.log

InspecciÃ³n de tokens de Keystone, cuotas y payloads JSON
Revela rechazos HTTP 400 Bad Request o 403 Forbidden

/var/log/nova/nova-scheduler.log

Detalle del filtrado de Placement y pesaje de hosts
Muestra por quÃ© se descartÃ³ cada hipervisor candidato

/var/log/nova/nova-compute.log

Registro en el nodo compute-04: llamadas a Libvirt y QEMU
Identifica fallos de montaje de disco o enlaces vSwitch

Fuente: OpenStack Operations Guide Â· Troubleshooting Instance Launch (docs.openstack.org)

Caso CorporaciÃ³n Industrial del Caribe: Despliegue de ERP

Aprovisionamiento orquestado de la base de datos empresarial en la nube privada local

Centro de Datos CorporaciÃ³n Industrial del Caribe â€” Planta Barranquilla

Plano de Control (3 Nodos HA)

Keystone + Nova API

VIP 10.10.0.10 tras HAProxy

MariaDB Galera + RabbitMQ

QuÃ³rum de 3 nodos sin split-brain

GarantÃa de alta disponibilidad

Nodos de CÃ³mputo (compute-01 a 08)

Instancia ERP Aprovisionada:

• VM: erp-db (16 vCPU, 64 GB RAM)

â€¢ Hipervisor: compute-04 (KVM VirtIO)

Aislamiento por Tenant:

Proyecto "Finanzas-ERP" con cuotas estrictas

Red privada L2 sobre VLAN 120

ClÃºster Ceph Storage (6 Nodos)

Pool Cinder-Volumes:

Volumen NVMe 500 GB en RAID de red

Pool Glance-Images:

Plantillas de SO optimizadas

Red de datos 25 GbE dedicada

SÃNTESIS CONCEPTUAL

Cinco Principios del Flujo de Aprovisionamiento

Puntos de control arquitectÃ³nicos indispensables antes de estudiar las redes avanzadas

1. Stateless

Sin Estado

Microservicios

Los demonios de API no guardan memoria local; escalan tras balanceadores HA.

Escala horizontal

2. Fernet Tokens

CriptografÃa

Tokens simÃ©tricos

ValidaciÃ³n local con llaves simÃ©tricas sin sobrecargar disco en la base de datos.

Cero saturaciÃ³n BD

3. Conductor

Aislamiento

Seguridad perimetral

Los nodos compute jamÃ¡s tocan MariaDB; Conductor actÃºa como proxy blindado.

Blindaje de datos

4. Placement

Inventario

Resource Providers

Rastreo en memoria de vCPUs y memoria; filtra hosts aptos en milisegundos.

DecisiÃ³n Ã³ptima

5. Persistencia

Cinder / Ceph

AlmacÃ©n externo

Discos desacoplados del hipervisor; sobreviven caÃdas fÃsicas del host.

Resiliencia pura

Fuente: Resumen de principios de arquitectura Â· EstÃ¡ndar CUC

CIERRE DE LA PARTE 1

Lo que Viene: Redes Avanzadas en Neutron

De los puertos virtuales a las redes de proveedor, overlays VXLAN y la revoluciÃ³n de OVN

Completado en la Parte 1

El Plano de Control Desacoplado

Microservicios stateless, RabbitMQ y MariaDB Galera

Autopsia de la PeticiÃ³n de CÃ³mputo

Keystone, Nova, Placement, Neutron, Cinder y KVM

Resiliencia y Reintentos AutomÃ¡ticos

Scheduler retry, rollback limpio y auditorÃa con CLI

Lo que Descubriremos en la Parte 2

Redes de Proveedor vs Redes de Proyecto

Conectividad L2 directa vs aislamiento overlay VXLAN

La RevoluciÃ³n de OVN (Open Virtual Network)

Enrutamiento distribuido DVR sin cuellos de botella

Floating IPs y TrÃ¡fico Norte-Sur

Mapeo estÃ¡tico 1:1 con SNAT/DNAT de alto rendimiento

SEMANA 13 Â· ARQUITECTURA EN LA NUBE

OpenStack II: Arquitectura Interna, Redes de ProducciÃ³n y Alta Disponibilidad

Parte 2 de 4 Â· Redes de ProducciÃ³n: Proveedor vs Proyecto y TopologÃa SDN

Ing. Rodolfo JosÃ© CaÃ±as Cervantes
Universidad de la Costa (CUC) Â· IngenierÃa de Sistemas

Arquitectura en la Nube Â· Periodo 2026-2 Â· Barranquilla, Colombia

Redes de Proveedor (Provider Networks)

Enlace directo de capa 2 a la infraestructura del centro de datos sin NAT ni overlays

CaracterÃsticas de Provider Network

Mapeo a VLANs FÃsicas Existentes:

Conecta las VMs directamente a troncales 802.1Q de los switches fÃsicos

Sin Enrutadores Virtuales de Software:

â€¢ El gateway por defecto es el router fÃsico perimetral (Cisco / Juniper).
• Sin encapsulación ni sobrecarga NAT. traducciÃ³n de direcciones NAT.

MÃ¡ximo Rendimiento de Red y MÃnima Latencia

Ideal para bases de datos crÃticas, VoIP y servidores de almacenamiento

Esquema FÃsico L2

VM HuÃ©sped (eth0):

IP corporativa directa: 10.200.15.50 / 24 (VLAN 150)

Puente FÃsico en Hipervisor (br-ex / br-phys):

â€¢ Interfaz fÃsica bond0 conectada a switch Top-of-Rack.
â€¢ TrÃ¡fico con etiqueta 802.1Q entregado directamente al ASIC.

GestiÃ³n Restringida al Administrador:

Los inquilinos comunes no pueden crear ni modificar estas redes

Fuente: OpenStack Neutron Provider Networks Guide (docs.openstack.org/neutron/latest)

Redes de Proyecto (Self-Service / Tenant Networks)

TopologÃa lÃ³gica privada basada en overlays virtuales y enrutamiento por software

AutonomÃa de los Inquilinos (Tenants)

CreaciÃ³n Libre por Autoservicio:

Elige cualquier direccionamiento CIDR (ej. 10.0.0.0/24)

Aislamiento Total Multitenant:

• Proyectos aislados usan igual rango CIDRamente la misma subred IP.
â€¢ El trÃ¡fico no colisiona gracias a los identificadores de tÃºnel (VNI).

Enrutador Virtual de Proyecto (Virtual Router):

Proporciona Gateway L3 privado, servidor DHCP y servicio de SNAT

Diferencia CrÃtica de DiseÃ±o

Red de Proveedor (Provider):

Compartida, administrada por red central, sin NAT, enlace L2 plano.

Red de Proyecto (Tenant Overlay):

â€¢ Privada por proyecto, creada por usuarios no administradores.
â€¢ Exige Floating IP para exponer servicios a la red corporativa.

PatrÃ³n IaaS EstÃ¡ndar:

Equivalente directo a una Amazon VPC privada en nube pÃºblica

Fuente: OpenStack Neutron Self-Service Networks Guide (docs.openstack.org)

TÃºneles VXLAN y Geneve: De L2 sobre IP

Mecanismo para superar el lÃmite de 4.094 VLANs y aislar millones de redes virtuales

Estructura del Paquete Encapsulado (Geneve / VXLAN)

- **Cabecera IP/UDP Externa**
- **Cabecera Geneve (VNI 24-bits)**
- **Cabecera Ethernet Interna**
- Carga Ãštil TCP/IP de la VM

SuperaciÃ³n del LÃmite IEEE 802.1Q

De 4.094 VLANs a 16 Millones de VNIs:

El identificador de 24 bits permite crear hasta 16.777.216 redes virtuales

Geneve frente a VXLAN Tradicional:

Geneve soporta TLVs (Type-Length-Value) para transportar metadatos de conmutaciÃ³n avanzada requeridos por el plano de control OVN

Requerimientos de Infraestructura FÃsica

Sobrecarga de MTU (Overhead de 50 Bytes):

La cabecera extra reduce el MTU interno de la VM de 1500 a 1450 bytes

ConfiguraciÃ³n de Jumbo Frames (9.000 Bytes):

En producciÃ³n es obligatorio configurar MTU 9000 en los switches fÃsicos para permitir MTU 1500 completo en las VMs sin fragmentaciÃ³n IP

Fuente: RFC 7348 (VXLAN) Â· RFC 8926 (Geneve) Â· OpenStack Networking Guide

El Cuello de Botella HistÃ³rico: ML2/OVS

Por quÃ© la arquitectura tradicional basada en nodos de red y agentes Python limitaba la escala

Arquitectura Tradicional ML2/OVS

El Problema del Network Node Central:

Todo el tráfico L3 cruza por 1 nodo de red central

ProliferaciÃ³n de Namespaces de Red:

â€¢ Miles de namespaces qrouter y qdhcp gestionados por iptables.
â€¢ CaÃda de rendimiento drÃ¡stica ante cientos de reglas de filtrado.

Punto Ãšnico de Fallo y Embudo de TrÃ¡fico

TrÃ¡fico Este-Oeste entre VMs de diferente subred colapsaba el nodo de red

Sobrecarga de Agentes Python

MÃºltiples Demonios por Host:

neutron-openvswitch-agent, neutron-l3-agent, neutron-dhcp-agent

SincronizaciÃ³n FrÃ¡gil por RPC:

â€¢ RabbitMQ saturado por millones de mensajes de estado de puertos.
• Retardos al cambiar security groups.cambios de grupos de seguridad.

LÃmite de Escalabilidad PrÃ¡ctica:

Inviable para centros de datos con mÃ¡s de 200 hipervisores

Fuente: OpenStack Neutron ML2/OVS Architecture History Â· OVN Transition Whitepaper

La RevoluciÃ³n de OVN (Open Virtual Network)

Bases de datos distribuidas y demonios compilados en C para un plano de control instantÃ¡neo

Neutron Server (API)

Traductor Declarativo:

Convierte API a esquema OVN

Cero Agentes Python:

Sin neutron-l3 ni dhcp-agent

Elimina trÃ¡fico en RabbitMQ

Bases de Datos OVSDB (C/C++)

OVN Northbound DB (NB):

Modelo lógico: Switches, Routers y ACLsLs

OVN Southbound DB (SB):

Bindings de puertos y túneles VTEP VTEP

ReplicaciÃ³n Raft de alta disponibilidad

Hipervisores Compute

ovn-controller (Nativo en C):

Monitorea Southbound vÃa OVSDB

TraducciÃ³n a OpenFlow:

Programa flujos en el kernel local

Latencia sub-milisegundo

Fuente: OpenStack Neutron OVN Architecture Guide Â· OVN Project (ovn.org)

DVR: Distributed Virtual Routing en Cada Hipervisor

Enrutamiento Este-Oeste local en el propio host sin pasar por nodos centrales

Nodo Hipervisor A (compute-01)

VM Web 1

Subred A: 10.0.1.15

MAC fa:16:3e:aa:01

VM App 1

Subred B: 10.0.2.20

MAC fa:16:3e:bb:02

Enrutador LÃ³gico OVN Local (En Kernel):

El enrutamiento entre Subred A y B ocurre dentro de la RAM de compute-01

TrÃ¡fico Este-Oeste en mismo host: 0 microsegundos de red fÃsica

Nodo Hipervisor B (compute-02)

VM Base de Datos (10.0.2.80)

Alojada en el nodo fÃsico compute-02

Puerto en Subred B

TÃºnel Geneve Directo Host-a-Host:

compute-01 enruta localmente y envÃa por tÃºnel directo a compute-02

El trÃ¡fico jamÃ¡s visita un nodo de red central

Floating IPs: Mapeo EstÃ¡tico 1:1 y SNAT/DNAT

Mecanismo para exponer mÃ¡quinas virtuales privadas a la red corporativa e Internet

Red Externa (PÃºblica / WAN)

Pool de IPs Flotantes:

Rango enrutable: 200.30.0.0/24

Cliente Externo (Internet):

EnvÃa peticiÃ³n a 200.30.0.85:443

TrÃ¡fico WAN Ingresando

TraducciÃ³n NAT EstÃ¡tica 1:1

DNAT (Entrada Norte-Sur):

Destino 200.30.0.85 se traduce a IP privada 192.168.10.45

SNAT (Salida Sur-Norte):

Origen 192.168.10.45 se traduce hacia afuera como 200.30.0.85

Mapeo bidireccional estricto

Subred Privada del Tenant

MÃ¡quina Virtual ERP:

IP Fija Privada: 192.168.10.45

La VM Desconoce la Floating IP:

â€¢ Su interfaz eth0 solo ve la IP fija.
â€¢ La traducciÃ³n ocurre en el conmutador.

Totalmente transparente a la VM

Fuente: OpenStack Neutron Floating IP Architecture (docs.openstack.org)

PolÃticas de QoS en Neutron: Control de Ancho de Banda

LÃmites de tasa de transmisiÃ³n y rÃ¡fagas para evitar saturaciÃ³n del switch fÃsico

1. Bandwidth Limit Rule

LÃmite Sostenido (Max Kbps):

Tasa mÃ¡xima de transmisiÃ³n en kbit/s

RÃ¡faga MÃ¡xima (Max Burst):

TrÃ¡fico permitido por milisegundos antes de aplicar shape o drop

Evita acaparamiento de enlace

2. Marcado DSCP (ToS)

PriorizaciÃ³n en Switches FÃsicos:

Marca paquetes IP con DSCP (ej. 46 EF)

Calidad de Servicio de Extremo a Fin:

Switches Cisco/Arista respetan colas prioritarias para VoIP y trÃ¡fico SCADA

ProtecciÃ³n de trÃ¡fico industrial

3. Ancho de Banda MÃnimo

IntegraciÃ³n con Placement:

Garantiza ancho de banda reservado

CondiciÃ³n de Aprovisionamiento:

Si el host no tiene 1 Gbps libre hacia la red externa, la VM no se crea

GarantÃa formal de SLA de red

Fuente: OpenStack Neutron Quality of Service (QoS) Guide (docs.openstack.org)

AceleraciÃ³n de Red: SR-IOV y DPDK

TÃ©cnicas de omisiÃ³n del kernel Linux para alcanzar tasas de 40 a 100 Gbps

SR-IOV (Single Root I/O Virtualization)

ParticiÃ³n de Tarjeta de Red FÃsica (PCIe):

Divide 1 puerto fÃsico (PF) en mÃºltiples funciones virtuales (VF)

Paso Directo (PCIe Passthrough):

â€¢ La VM interactÃºa directamente con los registros de la tarjeta de red.
â€¢ Omite el conmutador virtual de software (OVS) y el kernel del host.

Latencia Sub-Microsegundo y Tasa de Paquetes MÃ¡xima

LimitaciÃ³n: Incompatible con Live Migration y Security Groups de software

OVS-DPDK (Data Plane Development Kit)

Conmutador en Espacio de Usuario:

OVS corre como proceso user-space con bibliotecas DPDK optimizadas

Polling Continuo (Poll Mode Drivers - PMD):

â€¢ Elimina las interrupciones lentas de hardware de la CPU.
â€¢ Procesa millones de paquetes por segundo (Mpps) sin interrupciÃ³n.

Conserva Funcionalidades SDN:

Compatible con grupos de seguridad, Live Migration y tÃºneles Geneve

Fuente: OpenStack Neutron SR-IOV Configuration Guide Â· DPDK with OVS/OVN Spec

Herramientas de AuditorÃa SDN: ovn-trace y flujos OpenFlow

CÃ³mo simular el viaje de un paquete en la topologÃa lÃ³gica para depurar problemas de red

SimulaciÃ³n con ovn-trace

**$ ovn-trace --detailed <Logical_Switch> **

'inport == "port-vm1" && eth.dst == <MAC> && ip4.dst == 10.0.2.80'

Simula el procesamiento completo sin inyectar paquetes reales

Puntos de InspecciÃ³n LÃ³gica:

â€¢ Ingress Pipeline: EvaluaciÃ³n de Security Groups.
â€¢ Logical Router: Tabla de ruteo y reescritura de TTL.
â€¢ Egress Pipeline: PolÃticas de ACL y reenvÃo a puerto destino.

Identifica en quÃ© regla exacta se descartÃ³ el paquete

InspecciÃ³n de Flujos en Hypervisor

$ ovs-ofctl dump-flows br-int

Volcado de tablas OpenFlow en el switch de integraciÃ³n local
Audita contadores de paquetes (n_packets) y bytes transferidos

DepuraciÃ³n de Conntrack de Linux:

$ conntrack -L -p tcp --dport 5432
Verifica estado de conntrack ESTABLISHED
o si son abortadas por reglas de firewall stateful

DiagnÃ³stico determinista de capas 2 a 4

Fuente: OVN Manpages (ovn-trace) Â· Open vSwitch Troubleshooting Guide

SegmentaciÃ³n de Red en CorporaciÃ³n Industrial del Caribe

TopologÃa hÃbrida combinando Provider Network industrial y Tenant Network contable

Zona Industrial: Red de Proveedor (VLAN 150)

ConexiÃ³n Directa a Planta Barranquilla:

Controladores lÃ³gicos PLC, sensores SCADA y brazos robÃ³ticos

Atributos ArquitectÃ³nicos:

â€¢ Rango IP corporativo: 10.150.0.0/23 (Sin NAT ni tÃºneles).
â€¢ Latencia ultra-baja (< 0.5 ms) para telemetrÃa crÃtica.

Seguridad Perimetral:

Firewall fÃsico Palo Alto filtra el trÃ¡fico entre planta y servidores

Zona Financiera: Red de Proyecto (Geneve)

Entorno Privado de GestiÃ³n:

Sistemas contables, facturaciÃ³n DIAN y portal de recursos humanos

Atributos ArquitectÃ³nicos:

â€¢ Subred overlay: 192.168.100.0/24 con enrutador OVN privado.
â€¢ Aislamiento criptogrÃ¡fico estricto respecto a la planta.

Conectividad Inter-Zonas:

Solo se permite paso mediante API Gateway seguro en puerto 443

MEJORES PRÃCTICAS

Cuatro Reglas de Oro en Redes OpenStack

Pautas de diseÃ±o para evitar incidentes de rendimiento y fallos de conectividad en producciÃ³n

1. Adoptar OVN

Eliminar ML2/OVS

EstÃ¡ndar obligatorio

No desplegar agentes antiguos en Python; OVN garantiza DVR y escala masiva.

Escala moderna

2. Jumbo Frames

MTU 9000 en Red

Switches fÃsicos

Configurar MTU 9000 en la red fÃsica para evitar fragmentar paquetes Geneve.

Cero fragmentaciÃ³n

3. Redes Provider

Bases de Datos

Cargas intensivas

Conectar clÃºsteres crÃticos directamente a VLAN fÃsica para mÃnima latencia L2.

Rendimiento puro

4. PolÃticas QoS

LÃmites de Ancho

Control de abusos

Fijar lÃmites mÃ¡ximos en puertos virtuales para evitar vecinos ruidosos en el host.

Equidad de recursos

Comparativa Integral: OVN vs ML2 Tradicional

Cuadro tÃ©cnico de diferencias operativas, protocolos y rendimiento de conmutaciÃ³n

DimensiÃ³n de Arquitectura	ML2 / OVS Tradicional	OVN (EstÃ¡ndar Moderno)
Plano de Control	Agentes Python pesados + RabbitMQ	**Bases de datos OVSDB en C/C++ (Raft)**
Enrutamiento L3	Centralizado en Network Nodes	**DVR distribuido nativo en cada host**
Protocolo Overlay	VXLAN estÃ¡ndar (sin TLV)	**Geneve con metadatos TLV flexibles**
Servicio DHCP / DNS	Procesos dnsmasq en namespaces	**Resuelto por reglas OpenFlow locales**
Tiempo de Convergencia	5 a 30 segundos ante cambios	**< 50 milisegundos en clÃºsteres masivos**

Fuente: OpenInfra Foundation Technical Documentation Â· OpenStack Networking Guide

Lo que Viene: Almacenamiento Ceph y Alta Disponibilidad

De los conmutadores de red a la persistencia masiva y la resiliencia del plano de control

Completado en la Parte 2

Redes de Proveedor y de Proyecto

Conexión L2 directa vs overlay Geneveon tÃºneles Geneve

La Arquitectura OVN y DVR

Enrutamiento DVR local sin cuellos de botella

Floating IPs, QoS y AceleraciÃ³n

Mapeo 1:1, límites QoS y técnicas SR-IOV

Lo que Descubriremos en la Parte 3

IntegraciÃ³n Profunda de Ceph

RBD unificado para Glance, Cinder y discos efÃmeros Nova

Alta Disponibilidad del Plano de Control

ClÃºsteres Galera, RabbitMQ Quorum y balanceo HAProxy

Fencing y GestiÃ³n de Estados con Pacemaker

PrevenciÃ³n de split-brain con STONITH y migraciÃ³n de VIPs

SEMANA 13 Â· ARQUITECTURA EN LA NUBE

OpenStack II: Arquitectura Interna, Redes de ProducciÃ³n y Alta Disponibilidad

Parte 3 de 4 Â· Almacenamiento Ceph y Alta Disponibilidad del Plano de Control

Ing. Rodolfo JosÃ© CaÃ±as Cervantes
Universidad de la Costa (CUC) Â· IngenierÃa de Sistemas

Arquitectura en la Nube Â· Periodo 2026-2 Â· Barranquilla, Colombia

Almacenamiento EfÃmero frente a Cinder

DiferenciaciÃ³n entre disco local de hipervisor y volÃºmenes de red gestionados

Disco EfÃmero (Nova Instance Dir)

UbicaciÃ³n fÃsica: /var/lib/nova/instances
Almacenamiento local directo del Compute node

Ciclo de vida: Atado a la VM
DestrucciÃ³n automÃ¡tica al terminar o eliminar la VM

LimitaciÃ³n operativa: MigraciÃ³n pesada
Requiere copia completa por red en Live Migration

Riesgo alto: PÃ©rdida de nodo implica pÃ©rdida de datos

Volumen Persistente (OpenStack Cinder)

UbicaciÃ³n fÃsica: ClÃºster de Bloques (Ceph / SAN)
Totalmente desacoplado de los hipervisores

Ciclo de vida: Independiente y duradero
Permanece intacto al destruir o recrear la instancia

Ventaja operativa: MigraciÃ³n instantÃ¡nea
Live Migration solo transfiere RAM; punteros intactos

Alta fiabilidad: RÃ©plica distribuida y snapshots online

Fuente: Cinder Storage Administration Guide (docs.openstack.org) Â· OpenInfra Foundation

Arquitectura Distribuida de Ceph RBD

EliminaciÃ³n de puntos Ãºnicos de falla mediante algoritmo pseudoaleatorio CRUSH

CAPA DE CONSUMIDORES OPENSTACK (librbd nativo en librerÃas KVM/QEMU)

- Nova: VMs con QEMU RBD driver
- Glance: Pool 'images' en Ceph
- Cinder: Pools 'volumes' y 'backups'

Monitores Ceph (MON) & Managers (MGR)

Mantiene el mapa del clÃºster (Cluster Map) con quÃ³rum Paxos

No interviene en el flujo de datos I/O: no es cuello de botella

MÃnimo 3 MONs para tolerar fallo de 1 nodo sin degradaciÃ³n

Algoritmo Determinista CRUSH

CÃ¡lculo matemÃ¡tico directo: hash(object_id) -> PG -> OSDs

El cliente calcula la ubicaciÃ³n exacta sin consultar metadatos

Escala linealmente a petabytes sin servidor centralizado

CAPA DE ALMACENAMIENTO (Ceph OSDs - BlueStore en NVMe / SSD)

Nodo Storage 01

OSD.0, OSD.1, OSD.2

BlueStore nativo NVMe

Nodo Storage 02

OSD.3, OSD.4, OSD.5

BlueStore nativo NVMe

Nodo Storage 03

OSD.6, OSD.7, OSD.8

BlueStore nativo NVMe

ReplicaciÃ³n 3x

DistribuciÃ³n entre racks independientes

Fuente: Ceph Architecture Guide (docs.ceph.com) Â· Ceph Foundation

Clonado InstantÃ¡neo Copy-on-Write (CoW)

InteracciÃ³n nativa entre Glance y Cinder en Ceph para arranque en submilisegundos

1. Imagen Base RAW (Glance)

Pool: images en Ceph RBD
Formato raw (sin qcow2 emulado)

Snapshot de ProtecciÃ³n
Marcado read-only: rbd snap protect

Bloques Compartidos
â€¢ Sistema Operativo base: 4 GB
â€¢ Cero bytes transferidos por red
â€¢ Lectura compartida entre 100+ VMs

2. Clon Cinder (rbd clone)

Pool: volumes en Ceph RBD
Hereda bloques padre por punteros

Tiempo de CreaciÃ³n
< 100 milisegundos (metadatos)

Mecanismo Copy-on-Write
â€¢ Lecturas van a la imagen base
â€¢ Solo escrituras nuevas se graban
â€¢ Ahorro masivo de almacenamiento

3. Impacto en ProducciÃ³n

Sin CoW (Tradicional)
Descarga 20 GB vÃa HTTP Glance
Demora: 30 a 90 segundos por VM

Con Ceph CoW Nativo
OperaciÃ³n interna de punteros RBD
Demora: Menos de 1 segundo

Flattener Background:
OpciÃ³n de aplanar si se migra de pool

Fuente: OpenStack Cinder Ceph Driver Guide Â· OpenInfra Foundation

ConexiÃ³n de VolÃºmenes: De Cinder a KVM

Flujo de control os-brick para exponer bloques de red a los procesos QEMU

1. Cinder API & Volume

cinder initialize_connection

Valida permisos de tenant

Genera credenciales de acceso

Devuelve diccionario de conexiÃ³n:

```
driver_volume_type: rbd
name: volumes/vol-uuid
hosts: [10.0.1.11, ...]
auth_key: AQB7...==
keyring: client.cinder
```

2. Nova Compute

InvocaciÃ³n de os-brick

LibrerÃa cliente agnÃ³stica

Traduce el target de bloques:

â€¢ iSCSI: login iscsiadm y multipath

â€¢ FC: zoning y rescan SCSI bus

â€¢ NVMe-oF: nvme connect-subsys

â€¢ Ceph RBD: inyecciÃ³n directa XML

Sin mapeo de bloques en kernel

con Ceph: no requiere /dev/rbd0

3. Libvirt & QEMU

InyecciÃ³n de XML de Disco

Genera fragmento de configuraciÃ³n

```
<disk type='network'>
<driver type='raw'/>
<source protocol='rbd'
name='volumes/vol-id'>
<target dev='vdb'/>
</disk>
```

Hot-plug dinÃ¡mico sin reinicio

4. MÃ¡quina Virtual

Dispositivo VirtIO (/dev/vdb)

El kernel invitado detecta el disco

I/O directo QEMU a Ceph OSDs

Cero intermediaciÃ³n en host

Rendimiento nativo con cachÃ©

Multi-attach disponible para HA

DesconexiÃ³n limpia (detach)

Fuente: OpenStack os-brick Documentation Â· OpenInfra Foundation

Resiliencia: RÃ©plica Tripartita vs Erasure Coding

Compromiso entre consumo de almacenamiento bruto, latencia y tolerancia a fallos

RÃ©plica 3x (Replicated Pool - Recomendado)

Mecanismo: 3 copias idÃ©nticas en OSDs distintos
Un objeto de 4 MB se almacena idÃ©ntico en 3 discos

Eficiencia de espacio: 33.3 % (Factor 3x)
Para guardar 10 TB Ãºtiles se requieren 30 TB brutos

Rendimiento I/O: MÃ¡xima velocidad y baja latencia
Sin sobrecarga de cÃ¡lculo de paridad matemÃ¡tica

Caso de uso ideal: Cinder Volumes y Glance Images

Erasure Coding (EC k=4, m=2)

Mecanismo: FragmentaciÃ³n + Paridad Reed-Solomon
Objeto se divide en k trozos de datos y m de paridad

Eficiencia de espacio: 66.6 % (Factor 1.5x)
Para guardar 10 TB Ãºtiles se requieren solo 15 TB brutos

Rendimiento I/O: PenalizaciÃ³n en escritura aleatoria
Requiere cÃ¡lculo de paridad y lectura previa en escrituras

Caso de uso ideal: Cinder Backups y Swift Object Store

Fuente: Ceph CRUSH Architecture and Erasure Code Guidelines Â· Red Hat / OpenInfra

Arquitectura de 3 Nodos de Control

DiseÃ±o en clÃºster activo-activo para eliminar cualquier punto Ãºnico de fallo (SPOF)

DIRECCIÃ“N IP VIRTUAL COMPARTIDA (VIP 200.30.0.100)

Gestionada por Keepalived VRRP en interfaz de gestiÃ³n

Controlador 01 (Master VRRP)	Controlador 02 (Backup VRRP)	Controlador 03 (Backup VRRP)
HAProxy + Keepalived (Activo)	HAProxy + Keepalived (Standby)	HAProxy + Keepalived (Standby)
Galera MariaDB Nodo 1 (Sync)	Galera MariaDB Nodo 2 (Sync)	Galera MariaDB Nodo 3 (Sync)
RabbitMQ ClÃºster Nodo 1 (Raft)	RabbitMQ ClÃºster Nodo 2 (Raft)	RabbitMQ ClÃºster Nodo 3 (Raft)
APIs Nova, Neutron, Cinder, Glance	APIs Nova, Neutron, Cinder, Glance	APIs Nova, Neutron, Cinder, Glance
Estado: Operativo / QuÃ³rum 3/3	**Estado: Operativo / QuÃ³rum 3/3**	**Estado: Operativo / QuÃ³rum 3/3**

Fuente: OpenStack High Availability Guide Â· OpenInfra Foundation

ClÃºster Galera MariaDB: ReplicaciÃ³n Multi-Master

SincronizaciÃ³n mediante wsrep, control de concurrencia y certificaciÃ³n de transacciones

MariaDB Galera 01 (Writer)

Canal wsrep puerto 4567

â€¢ Recibe escrituras del HAProxy

â€¢ Genera conjunto de escritura (writeset)

â€¢ CertificaciÃ³n antes de COMMIT

Estado: Primary Component
Secuencia: seqno sincronizado

MariaDB Galera 02 (Sync)

ReplicaciÃ³n sÃncrona virtual

â€¢ Aplica writesets en cola interna

â€¢ Certifica transacciones simultÃ¡neas

â€¢ Sin demora de rÃ©plica esclava

Estado: Primary Component
Secuencia: seqno idÃ©ntico

MariaDB Galera 03 (Sync)

Votante de quÃ³rum activo

â€¢ Valida quÃ³rum de mayorÃa (>50%)

â€¢ Previene inconsistencia de red

â€¢ Listo para asumir como escritor

Estado: Primary Component
Secuencia: seqno idÃ©ntico

Regla CrÃtica de ConfiguraciÃ³n: Escritor Ãšnico en HAProxy (Single-Writer Pattern)

Aunque Galera soporta multi-master, en OpenStack todos los servicios deben escribir a un solo nodo primario.

Escribir concurrentemente a varios nodos genera bloqueos de certificaciÃ³n (deadlocks - wsrep_cert_fail).

Fuente: MariaDB Galera Cluster Documentation & OpenStack Design Guide

RabbitMQ: Quorum Queues con Algoritmo Raft

SuperaciÃ³n de las colas reflejadas (Mirrored Queues) clÃ¡sicas ante particiones de red

Mirrored Queues ClÃ¡sicas (Legacy / Obsoleto)

Protocolo: RÃ©plica ad-hoc no formal
Un nodo lÃder sincroniza rÃ©plicas sin verificaciÃ³n de consenso

Comportamiento ante ParticiÃ³n de Red
Vulnerable a split-brain; riesgo de pÃ©rdida de mensajes RPC

SincronizaciÃ³n de Nodos Nuevos: Bloqueante
Detiene el procesamiento del clÃºster mientras resincroniza

Estado: Declarado deprecated en RabbitMQ 3.8+

Quorum Queues (EstÃ¡ndar OpenStack 2024+)

Protocolo: Algoritmo Formal Raft Consensus
ElecciÃ³n determinista de lÃder y confirmaciÃ³n por quÃ³rum

Comportamiento ante ParticiÃ³n de Red
A prueba de split-brain; solo la particiÃ³n mayoritaria procesa

SincronizaciÃ³n No Bloqueante
RecuperaciÃ³n continua de logs sin congelar el flujo de RPC

Parámetro: oslo.messaging quorum_queues=true

Fuente: RabbitMQ Quorum Queues Guide Â· VMware Tanzu / OpenStack

HAProxy y Keepalived: El Front-End de Nube

Enrutamiento de endpoints con comprobaciÃ³n de salud activa y failover VRRP instantÃ¡neo

KEEPALIVED VRRP (Virtual Router Redundancy Protocol - RFC 3768)

Heartbeat cada 1s en vlan-mgmt Â· Si MASTER falla 3 heartbeats -> BACKUP asume VIP en 3s

HAProxy: DistribuciÃ³n Inteligente por Capa y Servicio

Capa 7 HTTP/TLS (APIs)

â€¢ Keystone :5000 (Round Robin)
â€¢ Nova API :8774 (Round Robin)
â€¢ Neutron :9696 (Round Robin)
Health check: GET /healthcheck

Capa 4 TCP (Bases de Datos)

â€¢ MariaDB Galera :3306
â€¢ 1 Primario Activo
â€¢ 2 Secundarios Backup
Health check: clustercheck script

Capa 4 TCP (MensajerÃa)

â€¢ RabbitMQ AMQP :5672
â€¢ Round Robin con stickiness
â€¢ MÃ¡xima concurrencia TCP
Health check: tcp-check connect

TerminaciÃ³n TLS y Cifrado Corporativo

HAProxy descarga los certificados TLS/SSL liberando a los workers Python de la carga criptogrÃ¡fica

Fuente: HAProxy Architecture Guide & OpenStack Security Guide

Aislamiento de Nodos Falla: STONITH y Fencing

Pacemaker y Corosync para apagar fÃsicamente servidores anÃ³malos antes de que corrompan datos

El Riesgo: Nodo Zombi (Split-Brain)

PÃ©rdida de enlace de red (Heartbeat roto)

El nodo sigue vivo pero desconectado del quÃ³rum

Peligro: Doble escritura simultÃ¡nea

Ambos lados intentan montar el mismo volumen o IP

Resultado CatastrÃ³fico: CorrupciÃ³n de Datos

â€¢ DestrucciÃ³n irreversible de sistemas de archivos

â€¢ Inconsistencias masivas en la base de datos

La SoluciÃ³n: STONITH (Fencing Hardware)

Significado: Shoot The Other Node In The Head

Mecanismo implacable de aislamiento fÃsico por hardware

AcciÃ³n: Disparo a controladora IPMI / iLO / iDRAC

Corte inmediato del suministro elÃ©ctrico de la placa base

GarantÃa Absoluta: Seguridad de Datos

â€¢ El clÃºster sabe con certeza que el nodo no puede escribir

â€¢ ReasignaciÃ³n de recursos segura y sin split-brain

Fuente: Pacemaker Cluster from Scratch Â· ClusterLabs & OpenStack HA

Snapshots Consistentes: Del Host al Storage

SincronizaciÃ³n con qemu-guest-agent y fsfreeze para congelar I/O antes del snapshot

1. PeticiÃ³n de Snapshot

openstack volume snapshot create

Cinder verifica metadatos

Si el volumen estÃ¡ en uso (in-use):

â€¢ Requiere quiesce de filesystem

Delega la coordinaciÃ³n a Nova

para hablar con el hipervisor

2. QEMU Guest Agent

Llamada fsfreeze vÃa socket

Nova instruye a libvirt:

â€¢ guest-fsfreeze-freeze

El kernel invitado descarga

bÃºferes sucios a disco (flush)

Pausa transitoria de I/O

3. Snapshot en AlmacÃ©n

rbd snap create instantÃ¡neo

Ceph congela Ã¡rbol de punteros

DuraciÃ³n de la captura: < 50 ms

Consistencia a nivel de aplicaciÃ³n

Retorno de Ã©xito inmediato

al controlador Cinder

4. DescongelaciÃ³n (Thaw)

guest-fsfreeze-thaw

El kernel invitado reanuda I/O

Cero tiempo de inactividad

Bases de datos no corruptas

Punto de restauraciÃ³n vÃ¡lido

Listo para backup o clone

Fuente: OpenStack Cinder & QEMU Guest Agent Documentation

MÃ©tricas Clave: Del Hipervisor a Ceph

TelemetrÃa Prometheus y umbrales crÃticos para evitar degradaciÃ³n del plano de control

1. Salud de Ceph Storage

MÃ©trica: ceph_health_status
HEALTH_OK vs HEALTH_WARN
Alerta ante OSDs down o out

MÃ©trica: Degraded Placement Groups
pgs_degraded > 0
Indica pÃ©rdida temporal de rÃ©plica

MÃ©trica: UtilizaciÃ³n OSD Nearfull
Umbral de advertencia al 85 %
Bloqueo total de escrituras al 95 %

Herramienta: Ceph Manager Exporter
Puerto nativo 9283 scrapeado por Prometheus

2. Salud de Base de Datos Galera

MÃ©trica: wsrep_cluster_size
Valor esperado: 3 nodos activos
Alerta inmediata si cae a 2

MÃ©trica: wsrep_cluster_status
Primary Component (Normal)
Non-Primary indica split-brain

MÃ©trica: wsrep_flow_control_paused
Tiempo pausado por nodo lento
Debe tender a 0.00 en rÃ©gimen normal

Herramienta: mysqld_exporter
Puerto 9104 con scrape de wsrep_* variables

3. Salud de Colas RabbitMQ

MÃ©trica: rabbitmq_queue_messages
Mensajes encolados pendientes
Crecimiento constante = workers muertos

MÃ©trica: rabbitmq_alarms
Bloqueo de memoria o disco
Alarma bloquea a productores Nova

MÃ©trica: Particiones de Red
rabbitmq_node_partitions
Debe ser siempre 0 en clÃºster Raft

Herramienta: rabbitmq_prometheus
Plugin nativo en puerto 15692

Fuente: Ceph Monitoring Guidelines & OpenStack Telemetry Architecture

Falla de Controlador en la CorporaciÃ³n

SimulaciÃ³n de corte de enlace en Nodo 1 y respuesta autÃ³noma de la infraestructura

Fase 1: T0 (Falla Repentina)

Corte de Switch Core Top-of-Rack

Controlador 01 pierde enlace de red
La VIP 200.30.0.100 deja de responder

Impacto Inmediato en CÃ³mputo

Â¡CERO impacto en VMs activas!
Las VMs en KVM siguen ejecutando

TrÃ¡fico de ProducciÃ³n

Neutron DVR enruta localmente
Ceph I/O viaja directo a OSDs

Fase 2: T + 3s (ConmutaciÃ³n)

ConmutaciÃ³n VRRP Keepalived

Controlador 02 detecta 3 pÃ©rdidas
Emite Gratuitous ARP y asume la VIP

Ajuste de Galera MariaDB

HAProxy conmuta escrituras al Nodo 2
QuÃ³rum Galera preservado (2 de 3)

ReelecciÃ³n en RabbitMQ

LÃderes Raft reelegidos en Nodo 2
RPC se restablece sin pÃ©rdidas

Fase 3: T + 10m (ReintegraciÃ³n)

RestauraciÃ³n de Enlace FÃsico

Controlador 01 reanuda servicios
Permanece como BACKUP VRRP

ResincronizaciÃ³n Galera

State Snapshot Transfer (IST)
Solo recupera transacciones delta

Estado Final del ClÃºster

QuÃ³rum pleno 3 de 3 restaurado
Cero caÃda de servicio al negocio

DecÃ¡logo de Resiliencia en Nube Privada

Directrices arquitectÃ³nicas obligatorias para la estabilidad de sistemas de misiÃ³n crÃtica

Reglas 1 a 5: Plano de Datos y Storage

1. Almacenamiento Centralizado Desacoplado
Utilizar Ceph RBD para boot-from-volume y desacoplar hipervisores.

2. Formato RAW en Glance para CoW
Evitar qcow2 en Glance cuando se use Ceph para permitir clonado instantÃ¡neo.

3. Aislamiento FÃsico de Red de Almacenamiento
Separar el trÃ¡fico de rÃ©plica Ceph en VLAN de 25/100 GbE dedicada.

4. RÃ©plica Tripartita para Discos Transaccionales
Reservar Erasure Coding solo para backups y buckets S3 frÃos.

5. Agente QEMU Obligatorio en Plantillas de SO
Garantizar qemu-guest-agent para instantÃ¡neas consistentes sin caÃda.

Reglas 6 a 10: Plano de Control y Gobernanza

6. MÃnimo 3 Nodos de Control FÃsicos
NÃºmero impar para resolver quÃ³rum de Paxos y Raft sin split-brain.

7. Escritor Ãšnico en ClÃºster Galera
Balancear en modo primary/backup en HAProxy para prevenir deadlocks.

8. Quorum Queues en RabbitMQ
Abandonar colas reflejadas obsoletas y migrar al protocolo Raft.

9. Fencing STONITH Obligatorio
Integrar tarjetas IPMI para corte elÃ©ctrico ante particiones de red.

10. Umbral de OcupaciÃ³n Estricto al 80 %
Mantener 20 % libre en Ceph para rebalanceo automÃ¡tico ante falla.

Fuente: OpenStack Operations & Resiliency Guide Â· OpenInfra Foundation

SEMANA 13 Â· ARQUITECTURA EN LA NUBE

OpenStack II: Arquitectura Interna, Redes de ProducciÃ³n y Alta Disponibilidad

Parte 4 de 4 Â· OperaciÃ³n en ProducciÃ³n, Despliegue y Viabilidad EconÃ³mica

Ing. Rodolfo JosÃ© CaÃ±as Cervantes
Universidad de la Costa (CUC) Â· IngenierÃa de Sistemas

Arquitectura en la Nube Â· Periodo 2026-2 Â· Barranquilla, Colombia

DevStack frente a ProducciÃ³n

Diferencias radicales entre un entorno efÃmero de desarrollo y un despliegue empresarial

DevStack (Solo Pruebas y Desarrollo)

TopologÃa: Todo en un solo nodo (All-in-One)
Controlador, base de datos y cÃ³mputo en la misma mÃ¡quina

Aislamiento: Procesos Systemd directos
CÃ³digo clonado directamente de ramas Git en /opt/stack

Resiliencia: Cero tolerancia a fallos
Un reinicio o caÃda corrompe el entorno completo

Prohibido en producciÃ³n: DiseÃ±ado solo para developers

Kolla-Ansible (EstÃ¡ndar de ProducciÃ³n)

TopologÃa: Distribuida y Altamente Disponible
3 controladores, N cÃ³mputos y clÃºster Ceph separado

Aislamiento: Contenedores Docker inmutables
ImÃ¡genes versionadas probadas por la comunidad OpenInfra

Operatividad: Actualizaciones y Rollbacks
Rolling upgrades sin caÃda y configuraciÃ³n declarativa

Arquitectura de referencia: Telecomunicaciones y banca

Fuente: DevStack vs Production Deployment Docs (docs.openstack.org) Â· OpenInfra Foundation

Arquitectura de Kolla-Ansible

Microservicios en contenedores Docker gobernados por inventarios y playbooks Ansible

1. Nodo Operador (Deployer)

Inventario YAML /multinode

[control] 3 servidores
[compute] N servidores

ConfiguraciÃ³n: globals.yml

kolla_base_distro: ubuntu
neutron_plugin_agent: ovn

Playbooks Idempotentes

kolla-ansible -i multinode prechecks
kolla-ansible -i multinode deploy

2. Nodos FÃsicos Destino

Docker Daemon Nativo

Host OS limpio (solo Docker y kernel KVM)
Cero librerÃas Python de OpenStack en host

Montajes y ConfiguraciÃ³n

Directorios mapeados: /etc/kolla/servicio
Logs centralizados y sockets UNIX locales

Redes de Host (host_network: true)

Rendimiento sin NAT ni capas Docker bridge

3. Contenedores Desplegados

nova_api, nova_conductor, nova_scheduler

neutron_server, ovn_controller, ovn_northd

glance_api, cinder_api, cinder_volume

mariadb, rabbitmq, keepalived, haproxy

Ventaja Operativa Insuperable:

Reiniciar o sustituir un servicio toma 2 segundos sin contaminar el sistema operativo del host

Fuente: Kolla-Ansible Deployment Guide (docs.openstack.org/kolla-ansible)

Aprovisionamiento FÃsico con Ironic

De servidores apagados en rack a nodos de cÃ³mputo activos mediante PXE, IPMI e inspecciÃ³n de hardware

1. Descubrimiento e IPMI

Enrollment del Servidor

Ironic registra MAC y BMC

EnvÃa orden de encendido

vÃa Redfish o IPMI por red OOB

ParÃ¡metros de Control:

â€¢ ipmi_address: 10.0.99.15
â€¢ boot_interface: ipxe
â€¢ power_interface: redfish

2. InspecciÃ³n de Hardware

Arranque Ramdisk iPXE

El servidor arranca IPA

(Ironic Python Agent) en RAM

Escanea arquitectura real:

Inventario AutomÃ¡tico:

â€¢ Recuento CPU / Cores
â€¢ Memoria RAM exacta
â€¢ Discos NVMe / SSD y NICs

3. InyecciÃ³n de Imagen

Escritura en Disco Local

IPA descarga la imagen RAW

desde Glance vÃa iSCSI o HTTP

Escribe directo en el disco fÃsico

Configdrive & Cloud-init:

â€¢ Inyecta llaves SSH
â€¢ Configura IPs estÃ¡ticas
â€¢ Configura Docker / KVM

4. Nodo Operativo

Reinicio a Disco Local

Ironic reinicia el servidor

Arranca desde el almacenamiento

interno con el SO de producciÃ³n

IntegraciÃ³n Inmediata:

â€¢ Se une al clÃºster Kolla
â€¢ Nova registra recursos
â€¢ Listo para recibir VMs

Fuente: OpenStack Ironic Project Documentation Â· OpenInfra Foundation

MigraciÃ³n en Vivo (Live Migration)

Traslado de instancias activas entre hipervisores KVM con pausas imperceptibles menores a 100 ms

Fase 1: Pre-Copy Iterativo

Transferencia de Memoria RAM

Copia inicial de memoria RAM por redr red

Rastreo de PÃ¡ginas Sucias (Dirty Pages)

La VM sigue ejecutando y modificando memoria
QEMU retransmite solo las pÃ¡ginas alteradas

Almacenamiento Compartido (Ceph RBD):

Â¡Cero bytes de disco! Ambos hipervisores leen y escriben directamente al clÃºster Ceph.

Fase 2: Stop-and-Copy (Downtime)

Convergencia de Memoria

Cuando el residuo de pÃ¡ginas sucias es mÃnimo

Pausa MÃnima de la CPU

DuraciÃ³n tÃpica: 30 a 80 milisegundos
Transfiere registros CPU y memoria delta delta

Auto-Convergence / Post-Copy:

Si la VM escribe mÃ¡s rÃ¡pido que la red, QEMU frena levemente la vCPU para forzar la convergencia.

Fase 3: Switchover y ReanudaciÃ³n

ConmutaciÃ³n de Red InstantÃ¡nea

OVN emite RARP para actualizar switchesÃsica

Sesiones TCP Preservadas

Clientes conectados no perciben caÃda ni corte
La VM continúa en la misma instrucciónucciÃ³n

Comando del Operador:

```
server migrate --live-migration
```

El host origen queda libre para mantenimiento fÃsico.

Fuente: Nova Live Migration Architecture & QEMU Documentation Â· QEMU.org

Rolling Upgrades y Compatibilidad N-1

Mantenimiento de compatibilidad en RPC y bases de datos para actualizar versiones sin detener la nube

1. VerificaciÃ³n Previa

ComprobaciÃ³n de Salud

EjecuciÃ³n de validadores:

```
nova-status upgrade check
```

Result: Success (OK)

Valida versiones de celdas, placement API y compatibilidad

Backup total de Galera MariaDB

2. Esquema de BD

MigraciÃ³n No Destructiva

Aplica expansiÃ³n de tablas:

```
nova-manage db sync
```

Solo agrega columnas nuevas

Los nodos en versiÃ³n N-1 siguen operando sin notar las nuevas columnas de BD

3. Controladores

Paso Rolling de Nodos

Actualiza Nodo 1 de control:

RPC Pinning Activo:

upgrade_levels: auto

Los microservicios nuevos emiten mensajes RPC en dialecto antiguo hasta que todos migren

4. CÃ³mputos y Cierre

Vaciado y Upgrade

1. Live migrate de VMs fuera
2. Actualizar nova-compute
3. Reincorporar nodo al clÃºster

```
db online_data_migrations
```

TransformaciÃ³n final de datos

Nube actualizada al 100 %
sin un solo minuto de caÃda

Fuente: OpenStack Upgrades Guide & Fast-Forward Upgrade Documentation

Modelo Financiero: CapEx frente a OpEx

AnÃ¡lisis comparativo de estructuras de costos entre adquisiciÃ³n de hardware y consumo elÃ¡stico

Nube Privada (Modelo CapEx Dominante)

InversiÃ³n Inicial Elevada (Capital Expenditure)
Compra de servidores bare-metal, switches 25/100G y racks

Costos Operativos Fijos y Predecibles
EnergÃa elÃ©ctrica (PUE), enfriamiento, espacio en datacenter

Costo Marginal por CÃ³mputo: Cercano a Cero
Ejecutar la VM al 100 % 24/7 no incrementa la factura mensual

Sin tarifas sorpresa de transferencia de datos (Egress: $0)

Nube PÃºblica (Modelo OpEx Puro)

Cero InversiÃ³n Inicial (Zero Upfront CapEx)
Aprovisionamiento elÃ¡stico instantÃ¡neo en segundos

FacturaciÃ³n por Consumo Continuo (On-Demand)
Cobro por hora/segundo de vCPU, memoria RAM y almacenamiento

Costo Acumulativo en Cargas Sostenidas
Una instancia encendida continuamente resulta costosa al aÃ±o

Tarifas de salida: $0.05 a $0.09 por GB egress

Fuente: OpenStack Foundation Enterprise TCO Model & The Cost of Cloud Trinity

CRITERIOS DE SELECCIÃ“N

Â¿CuÃ¡ndo Conviene una Nube Privada?

Ãrbol de decisiÃ³n tÃ©cnica y de negocio para justificar la adopciÃ³n de OpenStack

1. Cargas Sostenidas 24/7

UtilizaciÃ³n Estable > 70 %

Bases de datos transaccionales, ERPs centrales y microservicios fijos

EconomÃa de Escala Local

El costo por vCPU mensual cae hasta un 60 % frente a nube pÃºblica

Veredicto EconÃ³mico:

Si no se apagan los fines de semana, la nube privada es mÃ¡s rentable.

2. Latencia y TrÃ¡fico Masivo

Latencia Sub-milisegundo

Control industrial SCADA, IoT planta, robÃ³tica y procesamiento en el borde

Petabytes de Transferencia

Exportar 100 TB mensuales en AWS cuesta cerca de 9,000 USD de egress

Veredicto Operativo:

Nube privada elimina por completo las tarifas de red WAN y egress.

3. Cumplimiento y SoberanÃa

RegulaciÃ³n Colombiana y Local

Leyes de protecciÃ³n de datos (Habeas Data), sector financiero y defensa nacional

Custodia FÃsica Total

Gobernanza sobre discos fÃsicos, llaves criptogrÃ¡ficas y auditorÃa fÃsica

Veredicto Legal:

Requisito innegociable cuando la ley exige residencia local de datos.

Fuente: Gartner Research on Private Cloud Economics & 451 Research Cloud Pulse

ANÃLISIS DE COSTO TOTAL

Caso de TCO: Nube Privada vs AWS (3 AÃ±os)

SimulaciÃ³n comparativa para 100 instancias de cÃ³mputo equivalentes a m6i.large

OpenStack On-Premise (3 Cómputo + 3 Ceph) 3 Ceph)

Servidores Dell PowerEdge (CapEx):
6 servidores con doble Xeon + 512GB RAM + NVMe ~ $65,000 USD

Redes y ConmutaciÃ³n (Switches 25G ToR):
2 switches redundantes Top-of-Rack + cableado DAC ~ $12,000 USD

EnergÃa y ClimatizaciÃ³n Datacenter (3 AÃ±os):
Consumo estimado 4 kW continuos con PUE 1.3 ~ $16,800 USD

Soporte y Repuestos Hardware (3 AÃ±os):
GarantÃa Dell ProSupport 24/7 en sitio ~ $14,000 USD

TCO Total Nube Privada (36 Meses):

Aprox. $107,800 USD ($2,994 USD / mes)

AWS us-east-1 (100 Instancias m6i.large)

CÃ³mputo EC2 On-Demand (100 VMs 24/7):
$0.096 por hora x 730 horas x 100 VMs = $7,008 USD / mes

Almacenamiento EBS gp3 (100 x 50GB = 5TB):
5,000 GB x $0.08 por GB = $400 USD / mes

TrÃ¡fico de Red Egress (Estimado 10 TB / mes):
10,000 GB x $0.09 por GB = $900 USD / mes

Soporte AWS Business (10 % de factura):
Soporte empresarial mÃnimo ~ $830 USD / mes

TCO Total AWS (36 Meses):

Aprox. $328,968 USD ($9,138 USD / mes)

Fuente: AWS Pricing Calculator (us-east-1) vs Dell PowerEdge BOM Â· Caso ilustrativo empresarial

SobresuscripciÃ³n Segura de Recursos

Multiplicadores de sobreasignaciÃ³n para maximizar densidad sin provocar disputas de rendimiento

vCPU Allocation Ratio

Ratio TÃpico: 3.0:1 a 6.0:1

ParÃ¡metro: cpu_allocation_ratio
En 64 hilos fÃsicos asigna hasta 256 vCPUs

Comportamiento del Scheduler

KVM multiplexa hilos por tiempo (CFS)
Ã“ptimo para servidores web y dev/test

ExcepciÃ³n de ProducciÃ³n:

Bases de datos pesadas exigen ratio 1.0:1 con CPU Pinning dedicado para evitar jitter

RAM Allocation Ratio

Ratio Seguro: 1.0:1 (Estricto)

ParÃ¡metro: ram_allocation_ratio
No comprometer mÃ¡s memoria de la fÃsica

El Peligro del Swap / OOM Killer

Si el host satura RAM, el kernel Linux mata procesos QEMU matando VMs en vivo

OptimizaciÃ³n KSM:

Kernel Samepage Merging permite fusionar pÃ¡ginas idÃ©nticas de SO ahorrando 15-20 %

Storage Overcommit

Ratio Ceph: Thin Provisioning

Solo se reserva espacio cuando se escribe
Permite asignar 50 TB en 20 TB reales

MonitorizaciÃ³n Obligatoria

Supervisar crecimiento de thin pools
Alarmas automÃ¡ticas al alcanzar 80 %

Regla de Capacidad:

Nunca permitir que el aprovisionamiento fÃsico supere el umbral de nearfull Ceph

Multitenancy y Cuotas en Keystone

Aislamiento lÃ³gico y presupuestario por departamento mediante dominios, proyectos y roles RBAC

DOMINIO CORPORATIVO KEYSTONE (CorporacionIndustrialDelCaribe)

Contenedor de alto nivel para usuarios, grupos y polÃticas organizacionales integradas vÃa LDAP / Active Directory

Proyecto: Planta Barranquilla

Cuotas de CÃ³mputo y Red:

â€¢ vCPUs: 128 nÃºcleos mÃ¡ximos
â€¢ RAM: 512 GB garantizados
â€¢ Floating IPs: 10 IPs pÃºblicas

Seguridad y Aislamiento:

VLAN 100 de Proyecto aislada en OVN
Cero visibilidad hacia otros proyectos

Proyecto: AnalÃtica y Big Data

Cuotas de CÃ³mputo y Red:

â€¢ vCPUs: 256 nÃºcleos mÃ¡ximos
â€¢ RAM: 1024 GB asignados
â€¢ Almacenamiento Cinder: 40 TB Ceph

Seguridad y Aislamiento:

Red Geneve cifrada con IPsec
Flavor dedicado con passthrough GPU

Proyecto: Desarrollo e InnovaciÃ³n

Cuotas de CÃ³mputo y Red:

â€¢ vCPUs: 64 nÃºcleos mÃ¡ximos
â€¢ RAM: 128 GB asignados
â€¢ Discos efÃmeros rÃ¡pidos

Seguridad y Aislamiento:

LÃmites estrictos de consumo mensual
Permite auto-servicio a desarrolladores

Fuente: OpenStack Identity Service Guide Â· OpenInfra Foundation

Hardening y Cumplimiento de la Nube

Aislamiento criptogrÃ¡fico dm-crypt en Ceph, polÃticas SELinux en KVM y auditorÃa centralizada

1. Aislamiento Hipervisor

sVirt y SELinux / AppArmor

Cada proceso QEMU corre con etiqueta MCS Ãºnica:

```
svirt_t:s0:c123,c456
```

ProtecciÃ³n escape de VM

Si un atacante escapa de la VM, el kernel bloquea el acceso **a otros procesos o archivos**

2. Cifrado en Reposo

dm-crypt / LUKS en OSDs

Todos los discos NVMe/SSD se cifran a nivel de bloques:

```
AES-XTS-256 por hardware
```

Llaves en Barbican KMS

El robo fÃsico de un disco del datacenter resulta inÃºtil: **Datos totalmente ilegibles**

3. Cifrado en TrÃ¡nsito

TLS Interno & IPsec OVN

APIs pÃºblicas y privadas con certificados TLS 1.3:

TÃºneles Geneve Cifrados:
Cifrado IPsec entre hosts KVM

InspecciÃ³n de trÃ¡fico pasivo en los switches de red **no revela ningÃºn dato Ãºtil**

4. Trazabilidad Total

OpenStack CADF & SIEM

Eventos en formato estÃ¡ndar Cloud Audit (DMTF CADF):

Registro Inmutable:
QuiÃ©n, cuÃ¡ndo, quÃ© y desde dÃ³nde

ExportaciÃ³n continua a SIEM para auditorÃas ISO 27001, **SOC 2 y cumplimiento legal**

Fuente: OpenStack Security Guide & CIS Benchmark for OpenStack

TopologÃa Desplegada en la CIC

Arquitectura fÃsica final de 13 nodos para la planta industrial en la zona franca de Barranquilla

Plano de Control (3 Nodos HA)

Servidores Dell R650 (1U)

â€¢ 2x Intel Xeon Gold (32 cores)
â€¢ 128 GB RAM ECC DDR4
â€¢ Doble fuente redundante 800W

Servicios en Contenedores Kolla:

â€¢ MariaDB Galera (QuÃ³rum 3)
â€¢ RabbitMQ Quorum Queues (Raft)
â€¢ HAProxy + Keepalived VRRP

Conectividad de Red:

2x 25 GbE LACP bonding hacia switches Core Top-of-Rack redundantes

Plano de CÃ³mputo (6 Nodos KVM)

Servidores Dell R750 (2U)

â€¢ 2x Intel Xeon Gold (64 cores)
â€¢ 512 GB RAM ECC DDR4 por nodo
â€¢ Total cÃ³mputo: 384 cores, 3 TB RAM

Capacidades de EjecuciÃ³n:

â€¢ QEMU/KVM con mÃ³dulo OVN nativo
â€¢ DVR local para enrutamiento L3
â€¢ Live Migration sin corte de red

Cargas Soportadas:

MÃ¡s de 200 VMs empresariales (ERP, MES planta, SCADA y microservicios)

Almacenamiento (4 Nodos Ceph)

Servidores Dell R750xd (24 BahÃas)

â€¢ 8x 3.84 TB NVMe SSD por servidor
â€¢ Total discos: 32 OSDs BlueStore
â€¢ Capacidad bruta: 122 TB NVMe

ConfiguraciÃ³n Ceph RBD:

â€¢ RÃ©plica 3x para Cinder y Glance
â€¢ Capacidad neta Ãºtil: 40 TB NVMe
â€¢ Copy-on-Write instantÃ¡neo (<1s)

Red Ceph Dedicada:

VLAN exclusiva de 100 GbE para evitar congestiÃ³n en replicaciÃ³n OSD

ESTRATEGIA ARQUITECTÃ“NICA

La Nube HÃbrida Inteligente

Sinergia entre OpenStack para cargas predecibles locales y nubes pÃºblicas para elasticidad global

Nube Privada OpenStack (NÃºcleo Estable)

Cargas Base del Negocio (Steady State)
Bases de datos principales, SAP, SCADA, telemetrÃa

Ventaja Principal: Costo Marginal Cero
MÃ¡xima economÃa en cargas que operan 24/7/365

SoberanÃa de Datos Absoluta
InformaciÃ³n confidencial dentro del datacenter propio

Gobernanza completa sobre hardware y firmware

Nube PÃºblica AWS / Azure (ExpansiÃ³n ElÃ¡stica)

Picos Estacionales (Cloud Bursting)
CampaÃ±as comerciales de fin de aÃ±o y dÃas sin IVA

Servicios Gestionados Avanzados de IA
Acceso a clusters masivos de GPUs H100 y modelos base

Presencia Global en MÃºltiples Regiones
DistribuciÃ³n CDN y front-ends de cara a clientes externos

Interconexión VPN IPsec y Direct Connect y Direct Connect

Fuente: Multi-Cloud and Hybrid Architecture Framework Â· Cloud Native Computing Foundation

TransiciÃ³n al Laboratorio OpenStack

ExperimentaciÃ³n guiada con el plano de control, consola Horizon y comandos CLI en entorno real

CONTINUIDAD PRÃCTICA: GUÃA DEL LABORATORIO OPENSTACK

1. ExploraciÃ³n en Horizon

Consola Web de AdministraciÃ³n

â€¢ InspecciÃ³n de topologÃas virtuales

â€¢ VisualizaciÃ³n grÃ¡fica de redes OVN

â€¢ GestiÃ³n de cuotas de proyecto

Acceso vÃa portal de laboratorios

2. Control vÃa CLI OpenStack

AutomatizaciÃ³n por Terminal

â€¢ Carga de credenciales openrc.sh

â€¢ CreaciÃ³n de puertos y routers

â€¢ AsociaciÃ³n de IPs flotantes

Sintaxis declarativa openstack client

3. VerificaciÃ³n de CÃ³mputo

Ciclo Completo de la Instancia

â€¢ CreaciÃ³n de primera mÃ¡quina virtual

â€¢ Acceso por llave SSH privada

â€¢ ValidaciÃ³n de metadatos cloud-init

Prueba de conectividad exterior

Siguiente Paso: DirÃjase a la GuÃa del Lab OpenStack (laboratorios/lab-openstack) para iniciar la prÃ¡ctica.