

Datos como activo: de la fuente a la decisión

Parte 1 de 4 · Unidad 3

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 15 · Periodo 2026-2 · Barranquilla, Colombia

Las cinco V, los tipos de datos y el pipeline que convierte datos en decisiones.

Una empresa con datos, pero sin visión de conjunto

La Corporación Industrial del Caribe genera datos en seis lugares distintos y ninguno conversa con el otro.



Del dato crudo a la decisión


Un dato sin contexto no sirve; el valor aparece cuando se convierte en una acción.

cada paso agrega valor y reduce el volumen



Las cinco V: cinco preguntas sobre cualquier dato

Volumen, velocidad, variedad, veracidad y valor describen el reto de datos de una empresa.



Volumen: de megas a petabytes en la misma empresa

Cada fuente crece a un ritmo distinto, y el almacenamiento tiene que crecer sin rediseñarse.



Hojas de cálculo de ventas

un año completo

≈ 50 MB



ERP: transacciones

cinco años de historia

≈ 200 GB



Sensores de planta

un año, lectura por segundo

≈ 20 TB



Cámaras de calidad

un año de video e imágenes

≈ 2 PB

1 MB

1 GB

1 TB

1 PB

Escala logarítmica: cada marca vale 1.000 veces la anterior · cifras ilustrativas

Velocidad: qué tan frescos deben estar los datos

Cuanto más rápida la decisión, más cerca del tiempo real debe estar el procesamiento.

¿qué tan frescos necesitamos los datos?



Variedad: tres formas de guardar la misma realidad

La mayoría de los datos nuevos de una empresa no caben en una tabla.



Estructurados

filas y columnas fijas

Pedido	Cliente	Fecha	Total
1021	Cartón SA	03/09	1.2 M
1022	Caribe Pack	03/09	860 K
1023	Agro Sur	04/09	2.4 M
1024	Cartón SA	05/09	530 K
1025	Plas Norte	05/09	970 K

Tablas del ERP

Amazon RDS · Aurora · Redshift

esquema antes de guardar



Semiestructurados

forma flexible, con etiquetas

```
{
  "sensor": "H3-T01",
  "ts": "2026-09-03T14:02",
  "temp": 87.4,
  "alarma": false,
  "etiquetas": ["horno", "planta1"]
}
```

Eventos JSON de sensores

DynamoDB · DocumentDB · S3

esquema flexible, se lee al consultar



No estructurados

sin esquema definido

foto

PDF

video

defecto_linea2_0903.jpg

factura_proveedor_88421.pdf

el contenido no cabe en columnas

Fotos, PDF y video

Amazon S3

sin esquema; hay que extraer significado

Veracidad: un dato dudoso es peor que no tener dato

Los errores de calidad se detectan con reglas automáticas, no con la intuición del analista.

Lecturas crudas que llegan del historiador

sensor	fecha	temp	unidad
H3-T01	03/09 14:02	87,4	°C
H3-T01	03/09 14:02	87,4	°C
H3-T02	03/09 14:03	(vacío)	°C
H3-T01	31/02/2026	88,1	°C
H3-T04	03/09 14:05	188,6	°F
H3-T05	03/09 14:06	4000	°C
H3-T06	03/09 14:07	86,9	°C

- duplicado
- valor nulo
- fecha imposible
- unidad distinta
- valor atípico

**Reglas de calidad (AWS Glue Data Quality)**

Compleitud

sin vacíos obligatorios

Validez

formatos y rangos correctos

Unicidad

sin registros repetidos

Consistencia

una sola unidad

Oportunidad

llegan a tiempo

**Cuarentena**


lo que falla se aparta y se avisa
nunca se borra en silencio

**Zona curada**

solo datos validados llegan al análisis
y a los tableros de gerencia



Valor: cuatro niveles de analítica, cada uno más valioso

Se empieza describiendo lo que pasó y se avanza hacia automatizar lo que se debe hacer.




El pipeline de datos: cinco etapas, un mismo camino

Ingstar, almacenar, procesar, analizar y visualizar es el mapa de toda la semana.



El pipeline en la Corporación Industrial del Caribe

Tres fuentes distintas convergen en un solo lago y alimentan los tableros de gerencia.




1 las fuentes entran 2 aterrizan crudas 3 Glue limpia y cataloga 4 se consulta con SQL 5 se visualiza

Sensores con IoT Core, ERP con DMS y archivos con DataSync: tres fuentes, un solo lago.


OLTP y OLAP: operar no es lo mismo que analizar

Una base transaccional y una analítica se diseñan distinto; por eso el pipeline las separa.



Un solo almacén, muchos motores de análisis

Separar almacenamiento y cómputo permite usar la herramienta adecuada sobre la misma copia de los datos.



Seguridad y gobierno desde el primer día

El dato es un activo sensible: se protege por capas y no se agrega al final.



Cumplimiento

Ley 1581 de 2012 de protección de datos personales (habeas data) y políticas de la empresa



Auditoría

Quién consultó qué dato y cuándo: AWS CloudTrail y registros de acceso



Descubrimiento de datos sensibles

Amazon Macie encuentra cédulas, correos y teléfonos dentro de S3



Permisos por tabla, columna y fila

IAM y AWS Lake Formation: cada rol ve solo lo que necesita



Cifrado

En reposo con AWS KMS y en tránsito con TLS; las llaves las controla la empresa

Lo que queda de la Parte 1

Los datos son un activo; el pipeline es el camino que lo convierte en decisiones.

1 Cinco V

volumen, velocidad, variedad, veracidad
y valor describen el reto

2 Tres formas

estructurados, semiestructurados
y no estructurados

3 Cinco etapas

ingestar, almacenar, procesar,
analizar y visualizar



Ingestar

Parte 2




Almacenar

Parte 3




Procesar

Partes 3 y 4



Analizar

Parte 3



Visualizar

Parte 4

Lo que sigue: la Parte 2 abre la puerta de entrada

¿Cómo llegan los datos a la nube: por lotes, en flujo, desde bases de datos y desde la planta?

Ingesta: Llevar los datos a la nube

Parte 2 de 4 · Unidad 3

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 15 · Periodo 2026-2 · Barranquilla, Colombia

Lotes y flujo, Kinesis, Kafka gestionado, replicación de bases de datos y sensores de planta.

La ingesta: la puerta de entrada del pipeline

Cada tipo de origen tiene su propio mecanismo, y casi todos terminan en el mismo lago.



Por lotes o en flujo: dos ritmos de ingesta


El lote acumula y descarga de una vez; el flujo mueve cada evento apenas ocurre.

POR LOTES (batch)

camión que descarga cada noche




Origen



se acumulan durante horas

una carga



Procesa de una vez



Lago

Latencia

horas a días

Costo y complejidad
bajos: herramientas simples

Ideal para
cierres, informes, cargas históricas

EN FLUJO (streaming)

banda transportadora continua



Origen



cada evento viaja apenas se produce



Procesa cada evento



Lago


Latencia
milisegundos a segundos

Costo y complejidad
mayores: siempre encendido

Ideal para
alertas, tableros vivos, IoT


Elegir el ritmo: qué retraso tolera la decisión

La pregunta correcta no es cuántos datos hay, sino cuánto puede esperar quien los necesita.




Mover archivos a la nube de forma confiable

DataSync copia desde la planta y Transfer Family recibe archivos de aliados externos.



Kinesis Data Streams: anatomía de un flujo





Los datos se reparten en shards, se conservan un tiempo y varios consumidores los leen por separado.




Claves de partición: cómo se reparte la carga

La clave decide el shard: una clave bien repartida usa toda la capacidad del stream.

REGISTROS (con su clave)



ESPACIO DE HASH DIVIDIDO EN SHARDS



Un shard admite 1 MB/s de entrada. Si una clave domina, ese shard se satura y los demás sobran.

Lo que sí garantiza Kinesis


Orden de llegada dentro de cada shard.
Todos los registros de un mismo horno quedan juntos, en secuencia, para calcular tendencias correctamente.

El problema del shard caliente

Elegir una clave con poca variedad concentra el tráfico.
Solución: claves más repartidas, por ejemplo
horno-3 más el número del sensor.


Amazon Data Firehose: entrega gestionada al lago

Firehose junta, transforma y entrega los datos sin que administres servidores ni shards.



Streams frente a Firehose: control o comodidad

Data Streams da control fino sobre la lectura; Firehose entrega al destino sin administrar nada.



¿Cuál escojo?

¿Necesitas varios consumidores o re leer datos?

Data Streams


¿Solo quieres llevar el flujo al lago o a Redshift?

Firehose

¿Necesitas ambos?
Streams en el centro y Firehose como un consumidor más


Kafka gestionado: Amazon MSK

Es Apache Kafka estándar, con los brokers repartidos en tres zonas y operados por AWS.




Árbol de decisión: Kinesis, Firehose o MSK

Dos preguntas bastan para escoger el servicio de ingesta en flujo.




DMS: replicar la base del ERP sin detenerla

Primero se copia el estado inicial y luego se aplican los cambios hasta decidir el corte.




Línea de tiempo de la migración: el ERP no se detiene




Sensores en la planta: del horno a la nube

El gateway de borde traduce, filtra y protege la conexión de la planta con AWS IoT Core.




IoT Core: temas MQTT y reglas que reparten los datos

Cada sensor publica en un tema y las reglas SQL deciden a quién le llega cada mensaje.



Lo que queda de la Parte 2

Cuatro tipos de origen, dos ritmos y un mismo destino: la zona raw del lago.



Almacenar y catalogar: el lago de datos y el almacén

Parte 3 de 4 · Unidad 3

Ing. Rodolfo Cañas Cervantes


Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 15 · Periodo 2026-2 · Barranquilla, Colombia

Zonas del lago en S3, Parquet, catálogo y ETL con Glue, gobierno con Lake Formation, Athena y Redshift.

Del silo al lago: una sola fuente de verdad

Cuando cada área guarda su copia, las cifras no cuadran; el lago concentra y gobierna los datos.



Amazon S3: la base del lago de datos

Es durable, elástico, acepta cualquier formato y se puede abaratar con reglas de ciclo de vida.



Durable

11 nueves de durabilidad
99,999999999 %



Elástico

crece sin planificar
capacidad ni comprar discos



Cualquier formato

CSV, JSON, Parquet,
imágenes, video



Desacoplado

muchos motores leen
la misma copia

Clases de almacenamiento: el dato envejece y se enfría, la factura baja

Standard
datos activos

0 a 30 días

Standard-IA
consulta ocasional

30 a 90 días

Glacier Instant Retrieval
archivo con acceso en ms

90 a 365 días


Glacier Deep Archive
retención legal

más de 1 año

Reglas de ciclo de vida: S3 mueve los objetos solos · plazos ilustrativos, se ajustan por política

Zonas del lago: raw, curated y consumo

Cada zona sube la calidad: se conserva el original, se limpia y finalmente se publica para el negocio.



Convención de nombres de zonas: también se llaman bronce, plata y oro (arquitectura medallón)
el principio es el mismo: cada zona sube la calidad y baja el volumen

Filas contra columnas: por qué Parquet ahorra

Una consulta analítica casi nunca necesita todas las columnas, y el formato columnar lo aprovecha.

SELECT AVG(temp)

solo necesita una columna




Tabla lógica: 5 lecturas × 6 columnas

sensor	fecha	temp	presión	humedad	turno
H3-T01	03/09	87,4	1,2	61	A
...	...	...	...	...	...
...	...	...	...	...	...
...	...	...	...	...	...

Formato por filas (CSV, JSON)

cada fila se guarda completa



lee todo

para leer la columna temp hay que recorrer toda la fila: lee el 100 % de los bytes

Formato por columnas (Parquet)

cada columna se guarda junta




lee solo temp

solo se lee el bloque de temp: ≈ 1/6 de los bytes, y comprime mejor porque los valores se parecen


Parquet por dentro: bloques con estadísticas

Cada bloque guarda su mínimo y su máximo, así el motor descarta lo que no necesita.



AWS Glue: el catálogo que convierte archivos en tablas


Un crawler descubre el esquema de los archivos y lo registra para que todos los motores lo usen.



Un solo catálogo para todos los motores: el esquema se define una vez y todos lo reutilizan
sin catálogo, los archivos son solo bytes; con catálogo, son tablas

ETL con AWS Glue: de raw a curated

Un trabajo de Glue limpia, convierte y guarda en Parquet sin que administres un clúster.



```
df = spark.read.csv("s3://cic-lago/raw/sensores/", header=True)
df = df.dropDuplicates(["sensor", "ts"]).filter("temp IS NOT NULL")
df = df.withColumn("temp", (df.temp - 32) * 5 / 9) # solo filas en °F
(df.write.partitionBy("fecha")
    .parquet("s3://cic-lago/curated/sensores/"))
```

Esquema simplificado en PySpark: la lógica es el ejemplo, no un script de producción

Cómo se dispara



Programado: cada noche



Evento: llegó un archivo nuevo



Flujo de trabajo encadenado

Lake Formation: quién ve qué columna

Los permisos se definen una vez, por columna y por fila, y todos los motores los respetan.

Tabla clientes del lago: ¿qué columnas ve cada rol?

- 

Analista de ventas
solo ciudad y ventas
- 

Científico de datos
cédula con hash irreversible
- 

Auditor interno
todo, con registro de acceso

nombre	cédula	ciudad	ventas
sin acceso bloqueada	sin acceso bloqueada	visible permitida	visible permitida
sin acceso bloqueada	enmascarada hash	visible permitida	visible permitida
visible permitida	visible permitida	visible permitida	visible permitida



AWS Lake Formation

Permisos centrales por base, tabla, columna y fila, con etiquetas (LF-tags)


Se otorga una vez y lo respetan Athena, Redshift Spectrum, EMR y Glue

Cómo se aplica la regla



Athena: SQL directo sobre los archivos de S3

No hay servidor que administrar: se escribe SQL, Athena lee S3 y cobra por lo escaneado.




Optimizar consultas: formato, partición y tamaño

Los mismos datos pueden costar mil veces menos de consultar si se organizan bien.

Particiones: se lee solo la carpeta necesaria

Datos escaneados por la misma consulta (ilustrativo, 1 TB de CSV)



WHERE fecha = '2026-09-03'

1 carpeta de 5 (o de 365)

Cinco hábitos que bajan la factura

- 1 Parquet en vez de CSV
- 2 comprimir (Snappy o ZSTD)
- 3 particionar por la columna de filtro
- 4 archivos de 128 MB o más, no miles de pequeños

CSV sin comprimir

≈ 5,00 USD



CSV comprimido

≈ 1,50 USD



Parquet

≈ 0,30 USD



Parquet + partición


≈ 0,01 USD



precio por TB escaneado ilustrativo: 5 USD · la reducción real depende de columnas y filtros

Amazon Redshift: el almacén de datos de AWS

Un nodo líder reparte la consulta entre nodos de cómputo que leen columnas comprimidas en paralelo.



Opciones de despliegue

Aprovisionado

eliges tipo y número de nodos

Serverless

escala solo, pagas por uso (RPU)

Concurrency Scaling

capacidad extra en picos de consultas

Conexión con el lago



Redshift Spectrum

consulta tablas del lago
sin copiarlas al almacén


Lago contra almacén: esquema al leer o al escribir

El lago es flexible y barato; el almacén es veloz y predecible. Se complementan.



Arquitectura combinada: lago y almacén en la CIC

El lago guarda todo y explora con Athena; el almacén sirve rápido los tableros que gerencia consulta cada día.



1 ingresa 2 aterriza en raw 3 Glue limpia, cataloga y publica 4 Athena explora y Redshift sirve 5 se visualiza

Spectrum permite que Redshift lea el lago sin copiar · Lake Formation gobierna ambos motores

Lo que queda de la Parte 3

Con el lago, el catálogo y los motores de consulta, los datos ya están listos para analizarse.



Analizar y visualizar: la arquitectura moderna de datos

Parte 4 de 4 · Unidad 3

Ing. Rodolfo Cañas Cervantes

Universidad de la Costa (CUC) · Ingeniería de Sistemas

Semana 15 · Periodo 2026-2 · Barranquilla, Colombia

QuickSight, analítica en tiempo real, arquitectura de referencia y el caso completo de la Corporación Industrial del Caribe.


Del lago a la decisión: cada pregunta, su herramienta

Cuatro personas hacen cuatro preguntas distintas sobre los mismos datos del lago.



Motores de análisis: de sin servidores a control total

Se empieza por lo más administrado y se baja a más control solo cuando la carga lo exige.




¿Cómo se escoge?

empieza por el extremo sin servidores; baja a más control solo si la carga lo exige
cada escalón hacia la derecha agrega flexibilidad, pero también trabajo de operación


Amazon QuickSight: del conjunto de datos al tablero

Se conecta a las fuentes, modela un conjunto de datos y publica tableros para lectores.



Un tablero para la planta: tres lecturas en segundos

Indicadores arriba, tendencia con umbral y causas ordenadas: el tablero responde antes de que se pregunte.



Buenas prácticas: que el gráfico se entienda solo

Menos color, más orden: un gráfico claro se lee en cinco segundos.



1 Una pregunta por gráfico

el título es la conclusión

2 Ordenar de mayor a menor

salvo series de tiempo

3 Color con propósito

resaltar lo importante, no decorar


4 Etiquetas directas

sin obligar a mirar la leyenda

Analítica en tiempo real: del sensor a la alerta en segundos


Flink calcula sobre el flujo y dispara acciones sin esperar a que lleguen los lotes.

ANALÍTICA EN TIEMPO REAL: segundos desde el sensor hasta la alerta



Ventanas de tiempo: cómo agrupar un flujo infinito

Un flujo no termina; para calcular algo hay que cortarlo en ventanas.



Camino caliente y camino frío sobre el mismo flujo


Un camino responde en segundos con lo aproximado; el otro corrige en horas con lo exacto.



También existe la variante Kappa: todo en flujo y, si hace falta, se vuelve a procesar relejendo el stream

Arquitectura moderna de datos: el lago en el centro

Los datos se mueven hacia afuera, hacia adentro y alrededor del perímetro, siempre con un gobierno común.



Bases de propósito específico: cada carga, su motor

No se usa un martillo para todo: cada tipo de dato y consulta tiene un motor que lo resuelve mejor.



Aurora y RDS

Pedidos y facturación

¿Por qué?
transacciones consistentes con SQL



DynamoDB

Estado actual de cada equipo

¿Por qué?
lectura en milisegundos a cualquier escala



Timestream for InfluxDB

Series de tiempo de sensores


¿Por qué?
consultas por intervalos y tendencias



OpenSearch Service

Búsqueda en registros de fallas

¿Por qué?
texto libre, logs y paneles



Redshift

Tableros históricos

¿Por qué?
SQL analítico sobre años de datos



Neptune

Cadena de suministro

¿Por qué?
relaciones entre proveedores y piezas (grafo)




Y todas se conectan con el lago

cada base entrega su historia al lago (hacia adentro) y recibe del lago lo que necesita (hacia afuera)
así el lago conserva la historia completa y cada motor sirve su propia carga sin estorbar a los demás

El caso completo: la Corporación Industrial del Caribe

Un camino caliente alerta en segundos y el camino del lago decide con datos completos del día.



Costo del pipeline: dónde está y cómo bajarlo

Cada etapa tiene palancas propias; medir por etapa permite ahorrar sin perder capacidad.

¿Dónde se va el dinero de un pipeline? (reparto ilustrativo)



Pilares Optimización de costos y Eficiencia del rendimiento (Well-Architected)

etiquetas por proyecto para ver quién gasta · AWS Budgets para alertas · revisar el pipeline cada trimestre

Reto: diseña el pipeline de la banda transportadora 2

Cinco etapas, cinco decisiones: tu diseño debe justificar el ritmo, el costo y el gobierno.



Reto de diseño

Banda transportadora 2

Tiene acelerómetros que envían 1.000 lecturas por segundo cada uno.

a Alerta si la vibración sube

b Reporte semanal por turno

c Conservar 3 años por auditoría

Trabajo en grupos · 10 minutos

dibuja y justifica cada decisión

Ingestar




¿Lote o flujo?
¿Streams, Firehose o MSK? ¿Borde?

Almacenar



¿Qué zonas?
¿Qué formato?
¿Ciclo de vida?

Procesar



¿Glue o Flink?
¿Qué limpiar?
¿Qué agregar?

Analizar



¿Athena o Redshift?
¿Con qué ritmo?

Visualizar



¿Alerta o tablero?
¿Quién lo ve?
¿Qué permisos?

Criterios con los que se evalúa tu diseño

Ritmo correcto

la latencia que pide la alerta

Costo razonable

sin pagar tiempo real donde no hace falta

Gobierno

quién ve qué, cifrado y auditoría

Semana 15 en cuatro ideas

Los datos, bien ingeridos, almacenados y analizados, se convierten en decisiones.

1



Los datos valen cuando deciden

Las cinco V describen el reto y el pipeline de cinco etapas lo resuelve.

2



La ingesta se elige por ritmo

Lotes para lo que puede esperar; flujo para lo que no: Kinesis, Firehose, MSK, DMS o IoT Core.


3



Lago, catálogo y gobierno

S3 con zonas, Parquet, Glue para catalogar y transformar, y Lake Formation para los permisos.

4



Cada pregunta, su motor

Athena explora, Redshift sirve, Flink alerta y QuickSight muestra.

Semana 15 en cuatro ideas

Próxima semana · Semanas 16 y 17

Planificación de recuperación ante desastres y repaso general

qué pasa si falla una región: RPO, RTO, estrategias de DR y preparación del Parcial 3